یک

بِسْمِ اَللَّهِ اَلرَّحْمَٰنِ اَلرَّحِيمِ



دانشگاه کاشان

دانشکده مهندسی برق و کامپیوتر

گروه مهندسی کامپیوتر

تحلیل و طراحی فروشگاه حضوری هوشمند بر اساس مجموعه‌داده‌ی فروشگاه دان‌هامبی

Analysis and Design of a Smart Physical Retail Store Using the Dunnhumby Dataset

فاطمه سادات دست‌یافته — شماره دانشجویی: ۴۰۰۲۱۱۶۰۰۱۴

سمانه تابنده — شماره دانشجویی: ۴۰۰۲۱۱۶۰۰۰۹

سینا مظفری‌راد — شماره دانشجویی: ۴۰۰۲۱۱۶۰۲۱۴

گزارش پروژه پایانی دوره کارشناسی مهندسی کامپیوتر

استاد پروژه: دکتر وحیدی‌پور

شهریور ۱۴۰۵

سپاسگزاری

در پایان این مرحله از پروژه، بر خود لازم می‌دانیم از جناب آقای دکتر وحیدی‌پور صمیمانه سپاسگزاری کنیم. پرسش‌های دقیق و پیشنهادهای عملی ایشان در طول کار، نگاه ما را از یک پیاده‌سازی ساده فراتر برد و پروژه را به کاری تحلیلی و منسجم تبدیل کرد. شکل‌گیری بخش‌های اصلی سامانه، از شیوه‌ی طراحی و ارزیابی مدل‌ها تا انتخاب معیارهای رتبه‌بندی و افزودن دیدگاه هوش تجاری، مرهون همین راهنمایی‌هاست.

تقدیم به خانواده‌هایمان

که همراهی و آرامش آن‌ها پشتوانه ادامه این مسیر بود.

فهرست مطالب

فصل اول: کلیات و مقدمه ۱

۱-۱ پیشینه و زمینه موضوع ۱

۱-۲ بیان مسئله ۲

۱-۳ اهمیت و ضرورت انجام پروژه ۲

۱-۴ اهداف پروژه ۳

۱-۵ روش کلی انجام کار ۴

۱-۶ جنبه‌های فنی پروژه ۴

۱-۶-۱ معماری کلی و پشته فناوری ۴

۱-۶-۲ پایگاه داده و شیوه دسترسی به آن ۵

۱-۶-۳ ساختار ماژول‌های نرم‌افزاری ۶

۱-۶-۴ کتابخانه‌های پردازش داده و یادگیری ماشین ۶

۱-۶-۵ رابط کاربری و لایه نمایش ۷

۱-۶-۶ کنترل دسترسی و پیکربندی اجرا ۷

۱-۷ محدوده این گزارش و ساختار فصل‌های بعد ۸

فصل دوم: معرفی مجموعه‌داده، آماده‌سازی و ساختار پایگاه داده ۹

۲-۱ منشأ، دامنه و ویژگی‌های مجموعه‌داده ۹

۲-۱-۱ جامعه مورد مطالعه و گستره زمانی ۹

۲-۱-۲ واحد مشاهده و دانه داده ۱۰

۲-۱-۳ تفسیر شناسه‌ها و متغیرهای زمانی ۱۰

۲-۲ شناسنامه فایل‌های منبع و جدول‌های نهایی ۱۰

۲-۳ شرح جدول‌های اصلی ۱۱

۲-۳-۱ جدول تراکنش‌ها ۱۱

۲-۳-۲ جدول محصولات ۱۲

۲-۳-۳ جدول خانوار ۱۲

۲-۴ مراحل آماده‌سازی داده ۱۳

۲-۴-۱ استانداردسازی نام ستون‌ها و مقادیر تهی ۱۳

۲-۴-۲ کنترل تراکنش و قرارداد مبلغ ۱۴

۲-۴-۳ استانداردسازی اندازه محصول ۱۴

۲-۴-۴ یکتایی شناسه‌ها و تشخیص تکرار ۱۴

۲-۴-۵ قالب متن و بارگذاری ۱۴

۲-۵ نمایه کمی داده مورد استفاده ۱۵

۲-۶ ساختار پایگاه داده و وابستگی جدول‌ها ۱۶

۲-۶-۱ کلیدها و منطق ارتباط ۱۶

۲-۶-۲ مسیرهای اصلی پیوند داده ۱۶

۲-۶-۳ مرز داده پایه و نتایج تحلیلی ۱۷

۲-۷ کنترل کیفیت و محدودیت‌های داده ۱۷

۲-۷-۱ پوشش کلیدها و رکوردهای یتیم ۱۷

۲-۷-۲ داده‌های تهی و طبقه نامشخص ۱۷

۲-۷-۳ ماهیت ناشناس و غیرتقویمی داده ۱۷

۲-۷-۴ دامنه تعمیم نتیجه‌ها ۱۸

۲-۸ شرح ستون‌های فایل‌های منبع ۱۸

۲-۸-۱ ستون‌های فایل تراکنش ۱۸

۲-۸-۲ ستون‌های فایل محصول ۲۰

۲-۸-۳ ستون‌های فایل مشخصات خانوار ۲۰

۲-۹ نقش داده در فصل‌های بعد ۲۱

۲-۱۰ جمع‌بندی فصل ۲۲

فصل سوم: معرفی سامانه و صفحه اصلی تحلیل ۲۳
۳-۱ جایگاه صفحه اصلی در سامانه ۲۳
۳-۲ کنترل دسترسی و ورود به سامانه ۲۳
۳-۳ ساختار دیداری و اجزای صفحه ۲۴
۳-۴ شاخص‌های کلیدی صفحه اصلی ۲۵
۳-۴-۱ رکوردهای تراکنشی ۲۵
۳-۴-۲ محصولات یکتا ۲۶
۳-۴-۳ خانوارهای فعال ۲۶
۳-۴-۴ درآمد کل ۲۶
۳-۴-۵ منطق مقایسه دوره‌ای ۲۶
۳-۵ مسیرهای دسترسی به بخش‌های تحلیلی ۲۷
۳-۵-۱ تحلیل سبد خرید ۲۷
۳-۵-۲ قوانین انجمنی ۲۷
۳-۵-۳ بخش‌بندی مشتریان ۲۷
۳-۵-۴ ماندگاری مشتری ۲۸
۳-۵-۵ مدیریت داده ۲۸
۳-۵-۶ اطلاعات و جست‌وجوی مشتری ۲۸
۳-۵-۷ پیشنهاددهنده محصول ۲۸
۳-۶ نمودار روند بازار ۲۹
۳-۷ تعامل کاربر و طراحی واکنش‌گرا ۲۹
۳-۸ ملاحظات تفسیری ۲۹
۳-۹ جمع‌بندی فصل ۳۰
فصل چهارم: تحلیل توصیفی سبد خرید ۳۱
۴-۱ جایگاه صفحه تحلیل سبد خرید در سامانه ۳۱

۴-۲ واحدهای تحلیل و تعریف‌های پایه ۳۲
۴-۳ ساختار سربرگ تحلیل توصیفی ۳۳
۴-۴ بخش سبدهای پرارزش ۳۳
۴-۴-۱ منطق محاسبه و مرتب‌سازی ۳۴
۴-۴-۲ اندازه فهرست و صفحه‌بندی ۳۴
۴-۴-۳ ملاحظه تفسیری ۳۴
۴-۵ بخش محصولات پرارزش ۳۵
۴-۵-۱ دو معیار رتبه‌بندی و دلیل نمایش هم‌زمان آن‌ها ۳۵
۴-۵-۲ غنی‌سازی اطلاعات محصول ۳۶
۴-۵-۳ نمای جزئیات محصول ۳۷
۴-۶ تنظیم پارامترها و اجرای الگوریتم ۳۷
۴-۶-۱ دوره تراکنشی ۳۷
۴-۶-۲ تعداد قوانین قابل نمایش ۳۷
۴-۶-۳ حداقل پشتیبان ۳۸
۴-۶-۴ حداقل اطمینان ۳۸
۴-۷ شاخص‌های چهارگانه سربرگ ۳۹
۴-۸ معیارهای سنجش قانون انجمنی ۴۰
۴-۹ منطق استخراج قوانین در این پروژه ۴۱
۴-۹-۱ گام نخست: تعیین اقلام واجد شرایط ۴۱
۴-۹-۲ گام دوم: پویش سبدها و شمارش هم‌زمانی ۴۱
۴-۹-۳ گام سوم: ساخت قانون جهت‌دار ۴۲
۴-۹-۴ نسبت این پیاده‌سازی با الگوریتم استاندارد ۴۲
۴-۱۰ دو سطح تحلیل و نمونه نتایج ۴۲
۴-۱۱ خواندن کارت قانون و نمای جزئیات ۴۴

۴-۱۲ ذخیره قوانین در پایگاه داده ۴۵
۴-۱۳ رفتار سامانه در زمان اجرا ۴۵
۴-۱۴ ملاحظات تفسیری و محدودیت‌ها ۴۶
۴-۱۵ جمع‌بندی فصل ۴۶
فصل پنجم: تحلیل پیش‌بینانه سبد خرید ۴۸
۵-۱ جایگاه سربرگ پیش‌بینانه و تفاوت آن با تحلیل توصیفی ۴۸
۵-۲ دو مسئله پیش‌بینی مستقل در یک سربرگ ۴۸
۵-۳ اصول مشترک: اعتبارسنجی زمانی و پرهیز از نشت داده ۴۹
۵-۳-۱ چرا تقسیم تصادفی در این مسئله نادرست است ۴۹
۵-۳-۲ مفهوم روز مبدأ و پنجره برچسب ۵۰
۵-۳-۳ فاصله‌گذاری میان مجموعه آموزش و آزمون ۵۰
۵-۳-۴ معنای «اندازه آموزش» در این پروژه ۵۱
۵-۴ زیربخش نخست: دسته‌بند خرید دوباره از گروه کالایی ۵۱
۵-۴-۱ تعریف مسئله و واحد پیش‌بینی ۵۱
۵-۴-۲ ساخت نمونه‌ها روی مجموعه‌ای از روزهای مبدأ ۵۲
۵-۴-۳ ویژگی‌های ورودی مدل ۵۲
۵-۴-۴ پیش‌پردازش داده پیش از آموزش ۵۳
۵-۴-۵ چهار الگوریتم و تنظیم‌های اصلی آن‌ها ۵۴
۵-۴-۶ نمونه‌گیری و کنترل هزینه محاسبات ۵۵
۵-۴-۷ معیارهای ارزیابی ۵۶
۵-۴-۸ نتایج اعتبارسنجی ۵۷
۵-۴-۹ خروجی عملیاتی و شیوه نمایش آن ۵۸
۵-۴-۱۰ ملاحظات تفسیری این زیربخش ۶۰
۵-۵ زیربخش دوم: پیش‌بینی درآمد محصول با مدل سری زمانی ۶۰

۵-۵-۱ تعریف مسئله و دانه تحلیل ۶۰
۵-۵-۲ ساخت دوره‌های سی‌روزه و ماتریس محصول در دوره ۶۱
۵-۵-۳ پارامترهای پیکربندی ۶۱
۵-۵-۴ محدودیت تقویم و مفهوم عمق نظارت‌شده ۶۲
۵-۵-۵ مدل نخست: شبکه بازگشتی رمزگذار و رمزگشا ۶۳
۵-۵-۶ مدل دوم: مدل مستقیم مستقل ۶۴
۵-۵-۷ مبنای مقایسه: میانگین اخیر ۶۵
۵-۵-۸ ویژگی‌های ورودی و چرایی حذف مؤلفه فصلی ۶۵
۵-۵-۹ تصحیح بازگردانی از فضای لگاریتمی ۶۶
۵-۵-۱۰ هماهنگ‌سازی با پیش‌بینی مجموع کل ۶۶
۵-۵-۱۱ معیارهای ارزیابی خطا و کیفیت رتبه‌بندی ۶۷
۵-۵-۱۲ نتایج اعتبارسنجی ۶۷
۵-۵-۱۳ قاعده انتخاب مدل ۷۰
۵-۵-۱۴ بازآموزی تولیدی و تولید پیش‌بینی آینده ۷۰
۵-۶ ذخیره‌سازی مدل‌ها و مدیریت نسخه ۷۲
۵-۷ رفتار سامانه هنگام آموزش ۷۲
۵-۸ ملاحظات تفسیری و محدودیت‌ها ۷۳
۵-۹ جمع‌بندی فصل ۷۴
فصل ششم: هوش تجاری و تحلیل تفاضلی سبد خرید ۷۵
۶-۱ جایگاه سربرگ هوش تجاری در صفحه تحلیل سبد خرید ۷۵
۶-۲ معماری داده: طرح ستاره‌ای و نماهای پایه ۷۶
۶-۳ منطق پالایش هم‌بسته ۷۷
۶-۳-۱ برش‌دهنده‌های اصلی و فرعی ۷۷
۶-۳-۲ انتخاب چندگانه و نشانه‌های پالایش ۷۷

۶-۳-۳ پالایش با کلیک روی نمودار ۷۸
۶-۳-۴ ذخیره نما و ابزارهای هر کارت ۷۸
۶-۴ نوار شاخص‌های کلیدی ۷۹
۶-۵ صفحه نمای کلی ۸۰
۶-۵-۱ نمودار سلسله‌مراتب محصول ۸۰
۶-۵-۲ کارت برداشت خودکار ۸۱
۶-۵-۳ نمودار سلسله‌مراتب تقویمی ۸۲
۶-۶ صفحه محصولات ۸۳
۶-۶-۱ نوع برند و توزیع اندازه سبد ۸۳
۶-۶-۲ جدول پرفروش‌ترین محصولات ۸۵
۶-۶-۳ منحنی تمرکز درآمد ۸۷
۶-۷ صفحه زمان و الگوی خرید ۸۸
۶-۷-۱ ساعت روز و روز هفته ۸۸
۶-۷-۲ نقشه حرارتی هفته در ساعت ۹۰
۶-۷-۳ روند شدت تخفیف ۹۱
۶-۸ صفحه مشتریان ۹۲
۶-۸-۱ بخش‌های رفتاری مشتریان ۹۲
۶-۸-۲ جمعیت‌شناسی و مسئله پوشش داده ۹۳
۶-۹ صفحه فروشگاه‌ها ۹۴
۶-۱۰ صفحه رشد و وفاداری ۹۵
۶-۱۰-۱ تفاضل دو دوره کامل ۹۵
۶-۱۰-۲ خانوار تازه در برابر خانوار بازگشتی ۹۷
۶-۱۰-۳ دهک‌های ارزش خانوار ۹۸
۶-۱۱ صفحه قیمت‌گذاری و ترویج ۹۹

۶-۱۱-۱ ترکیب درآمد بر پایه عمق تخفیف ۹۹
۶-۱۱-۲ سهم برند خصوصی به تفکیک گروه کالایی ۱۰۱
۶-۱۲ صفحه آزمون‌های معنادار: هسته تحلیل تفاضلی ۱۰۲
۶-۱۲-۱ چرا مقدار احتمال به تنهایی کافی نیست ۱۰۲
۶-۱۲-۲ اندازه اثر و آستانه‌های تفسیر ۱۰۲
۶-۱۲-۳ شش آزمون روی یک جفت گروه ۱۰۴
۶-۱۲-۴ جست‌وجوی خودکار بزرگ‌ترین تفاوت‌ها ۱۰۵
۶-۱۲-۵ رتبه‌بندی شیوه‌های گروه‌بندی ۱۰۷
۶-۱۲-۶ تصحیح آزمون چندگانه ۱۰۹
۶-۱۳ نمونه‌گیری و کنترل هزینه محاسبات ۱۰۹
۶-۱۴ جمع‌بندی تحلیلی نتایج این مجموعه‌داده ۱۱۰
۶-۱۵ ملاحظات تفسیری و محدودیت‌ها ۱۱۱
۶-۱۶ جمع‌بندی فصل ۱۱۲
فصل هفتم: استخراج قوانین انجمنی در سطح محصول ۱۱۳
۷-۱ جایگاه صفحه قوانین انجمنی در سامانه ۱۱۳
۷-۲ تفاوت این صفحه با بخش قوانین صفحه تحلیل سبد خرید ۱۱۴
۷-۳ تعریف مسئله در سطح محصول ۱۱۵
۷-۴ ساختار صفحه و گام‌های کاری ۱۱۵
۷-۵ پارامترهای ورودی و معنای هر یک ۱۱۷
۷-۵-۱ دوره تراکنشی ۱۱۷
۷-۵-۲ تعداد نتایج ۱۱۸
۷-۵-۳ حداقل پشتیبان ۱۱۹
۷-۵-۴ حداقل اطمینان ۱۱۹
۷-۵-۵ اعتبارسنجی مقادیر در سرور ۱۱۹

۷-۶ منطق استخراج قوانین در سطح محصول ۱۲۰
۷-۶-۱ گام نخست: تعیین بازه زمانی و شمارش سبدها ۱۲۰
۷-۶-۲ گام دوم: تبدیل آستانه نسبی به حداقل تعداد سبد ۱۲۱
۷-۶-۳ گام سوم: شمارش هم‌زمانی با خودالحاقی جدول تراکنش‌ها ۱۲۱
۷-۶-۴ گام چهارم: انتخاب نامزدها بر اساس بهبود ۱۲۲
۷-۶-۵ گام پنجم: افزودن اطلاعات توصیفی محصول ۱۲۲
۷-۶-۶ گام ششم: ساخت قانون دوسویه و مرتب‌سازی نهایی ۱۲۳
۷-۶-۷ نسبت این پیاده‌سازی با الگوریتم Apriori ۱۲۳
۷-۷ شیوه محاسبه معیارها در این صفحه ۱۲۴
۷-۸ نمایش نتایج و خواندن کارت قانون ۱۲۵
۷-۹ نمای جزئیات قانون ۱۲۶
۷-۱۰ صفحه‌بندی سمت مرورگر ۱۲۷
۷-۱۱ ثبت قوانین در پایگاه داده ۱۲۸
۷-۱۱-۱ ساختار جدول قوانین ۱۲۸
۷-۱۱-۲ ثبت تکی و پنجره تأیید ۱۲۹
۷-۱۱-۳ ثبت گروهی ۱۳۰
۷-۱۱-۴ نمایش وضعیت ذخیره در اجراهای بعدی ۱۳۰
۷-۱۲ نمونه نتایج و شیوه خواندن آن‌ها ۱۳۰
۷-۱۳ رفتار سامانه در زمان اجرا و ملاحظات کارایی ۱۳۲
۷-۱۴ ملاحظات تفسیری و محدودیت‌ها ۱۳۲
۷-۱۵ جمع‌بندی فصل ۱۳۳
فصل هشتم: داشبورد تحلیلی، تحلیل ریزش و اولویت‌بندی ماندگاری مشتری ۱۳۵
۸-۱ جایگاه سه صفحه در فرایند تصمیم‌گیری ۱۳۵
۸-۱-۱ قاعده خوانش زنجیره تصمیم ۱۳۶

۸-۲ بخش‌بندی مشتریان و پیکربندی مدل ریزش ۱۳۶
۸-۲-۱ نمای بخش‌های RFM ۱۳۶
۸-۲-۲ تنظیم آزمایش ریزش ۱۳۹
۸-۲-۳ نمای کلی ریسک ریزش ۱۴۳
۸-۲-۴ راهنمای تفسیر نتایج ۱۴۴
۸-۳ تحلیل مدیریتی وضعیت بازار و مسیر تصمیم‌گیری ۱۴۶
۸-۳-۱ نقش صفحه اصلی ۱۴۶
۸-۳-۲ شاخص‌های کلیدی و منطق مقایسه ۱۴۶
۸-۳-۳ مسیرهای دسترسی تحلیلی ۱۴۷
۸-۳-۴ قواعد تفسیر شاخص‌های کلان ۱۴۷
۸-۳-۵ نمودار روند بازار ۱۴۷
۸-۴ ارزیابی تفصیلی ریسک ریزش در سطح مشتری ۱۴۸
۸-۴-۱ هدف و نقطه ورود ۱۴۸
۸-۴-۲ ارتباط ریسک با نمایه RFM ۱۴۹
۸-۴-۳ سابقه زمانی مشتری و قواعد آزمایش ۱۴۹
۸-۴-۴ تفسیر جدول تاریخچه ۱۵۲
۸-۴-۵ قواعد کنترل کیفیت تصمیم فردی ۱۵۲
۸-۴-۶ ملاحظات تفسیری صفحه ریزش ۱۵۲
۸-۵ اولویت‌بندی مداخله‌های ماندگاری مشتری ۱۵۳
۸-۵-۱ هدف عملیاتی صفحه ۱۵۳
۸-۵-۲ فیلترها و اولویت‌بندی ۱۵۴
۸-۵-۳ اجزای جدول ماندگاری ۱۵۵
۸-۵-۴ قاعده ثبت و بازبینی اقدام ۱۵۵
۸-۶ یکپارچگی جریان تصمیم و قواعد اجرایی ۱۵۵

۸-۷ محدودیت‌ها و نکات کاربردی ۱۵۶
۸-۸ جمع‌بندی فصل ۱۵۷
فصل نهم: سامانه‌های پیشنهاددهنده و صفحات مرتبط با مشتری ۱۵۸
۹-۱ جایگاه فصل در معماری سامانه ۱۵۸
۹-۲ جست‌وجو و پروفایل مشتری ۱۵۹
۹-۲-۱ هدف و شیوه دسترسی ۱۵۹
۹-۲-۲ ملاحظات تفسیری پروفایل ۱۶۰
۹-۳ صفحه خریدهای مشتری ۱۶۱
۹-۳-۱ هدف صفحه و سازمان‌دهی اطلاعات ۱۶۱
۹-۳-۲ کاربرد تحلیلی تاریخچه خرید ۱۶۲
۹-۴ پیشنهاد محصول به مشتری ۱۶۴
۹-۴-۱ تعریف مسئله و رویکرد ترکیبی ۱۶۴
۹-۴-۲ تولید مجموعه نامزدها ۱۶۴
۹-۴-۳ پالایش مشارکتی و شباهت خانوارها ۱۶۵
۹-۴-۴ ویژگی‌های رفتاری و مدل رتبه‌بندی ۱۶۶
۹-۴-۵ قواعد تجاری پس از امتیازدهی ۱۶۷
۹-۴-۶ حافظه میانی و نمایش خروجی ۱۶۸
۹-۵ پیشنهاد مشتری به محصول ۱۶۹
۹-۵-۱ تعریف مسئله و سطوح انتخاب ۱۶۹
۹-۵-۲ تولید نامزدهای مشتری ۱۷۰
۹-۵-۳ رتبه‌بندی و ارائه فهرست ۱۷۰
۹-۵-۴ صفحه جزئیات محصول ۱۷۲
۹-۶ مقایسه دو جهت پیشنهاددهی ۱۷۳
۹-۷ آموزش و ارزیابی مدل ۱۷۴

۹-۷-۱ ساخت داده آموزشی ۱۷۴
۹-۷-۲ معیارهای ارزیابی ۱۷۵
۹-۸ ملاحظات اجرایی، اخلاقی و محدودیت‌ها ۱۷۶
۹-۹ سناریوی استفاده پیشنهادی ۱۷۷
۹-۱۰ جمع‌بندی فصل ۱۷۷
فصل دهم: نتیجه‌گیری و پیشنهادات ۱۷۹
۱۰-۱ جمع‌بندی کلی نتایج ۱۷۹
۱۰-۱-۱ آماده‌سازی داده و شکل‌گیری سامانه ۱۷۹
۱۰-۱-۲ شناخت فروش و الگوهای خرید ۱۸۰
۱۰-۱-۳ تحلیل مشتری و پیش‌بینی رفتار ۱۸۰
۱۰-۱-۴ ارتباط تحلیل با پیشنهاد محصول ۱۸۱
۱۰-۲ ارزیابی نتایج و روش‌ها ۱۸۱
۱۰-۲-۱ اعتبار تحلیل توصیفی و قوانین انجمنی ۱۸۱
۱۰-۲-۲ ارزیابی پیش‌بینی خرید دوباره ۱۸۲
۱۰-۲-۳ ارزیابی پیش‌بینی درآمد محصول ۱۸۲
۱۰-۲-۴ ارزیابی ریزش و اولویت‌بندی ماندگاری ۱۸۳
۱۰-۲-۵ ارزیابی سامانه پیشنهاددهنده ۱۸۳
۱۰-۲-۶ جمع‌بندی مقایسه و دامنه اعتبار ۱۸۴
۱۰-۳ پیشنهادات برای ادامه کار ۱۸۶
۱۰-۳-۱ تکمیل و یکسان‌سازی ارزیابی ۱۸۶
۱۰-۳-۲ بهبود مدل‌ها بر اساس نوع خطا ۱۸۶
۱۰-۳-۳ سنجش اثر اقدام در فروشگاه ۱۸۷
۱۰-۳-۴ آماده‌سازی داده و سامانه برای استفاده عملی ۱۸۷
واژه‌ها و اختصارهای پرکاربرد ۱۸۹

منابع ۱۹۷

فهرست شکل‌ها

شکل ۳-۱ - نمای بخش بالایی صفحه اصلی سامانه تحلیل بازار ۲۴

شکل ۴-۱ - نمای بالای صفحه تحلیل سبد خرید و سربرگ تحلیل توصیفی ۳۲

شکل ۴-۲ - بخش محصولات پرارزش با نمای مرتب‌شده بر اساس تعداد تراکنش ۳۶

شکل ۴-۳ - پنل تنظیم پارامترها، دکمه اجرای الگوریتم و شاخص‌های چهارگانه پس از اجرا ۳۹

شکل ۴-۴ - فهرست قوانین انجمنی سطح گروه کالایی پس از اجرای الگوریتم ۴۳

شکل ۴-۵ - فهرست قوانین انجمنی سطح کالا و بالاترین بهبود به‌دست‌آمده ۴۴

شکل ۵-۱ - ساختار چهار الگوریتم دسته‌بندی به‌کاررفته در زیربخش نخست ۵۵

شکل ۵-۲ - پنل تنظیمات دسته‌بند خرید دوباره و نتیجه اعتبارسنجی زمانی آن ۵۸

شکل ۵-۳ - نمودار تعداد مورد انتظار بازگشت و جدول امتیاز گروه‌های کالایی ۵۹

شکل ۵-۴ - ساختار شبکه بازگشتی رمزگذار و رمزگشا و مسیر بازخورد و آموزش آن ۶۴

شکل ۵-۵ - پنل اجرای پیش‌بینی درآمد محصول و شاخص‌های کلیدی نتیجه اعتبارسنجی ۶۹

شکل ۵-۶ - بخشی از جدول نتایج پیش‌بینی درآمد محصول با نمایش هم‌زمان دو مدل ۷۲

شکل ۶-۱ - نوار صفحه‌های داخلی و نوار شاخص‌های کلیدی سربرگ هوش تجاری ۷۶

شکل ۶-۲ - نمودار سلسله‌مراتب محصول و کارت برداشت خودکار در صفحه نمای کلی ۸۱

شکل ۶-۳ - نمودار سلسله‌مراتب تقویمی در سطح سال ۸۲

شکل ۶-۴ - نمودار حلقه‌ای نوع برند و نمودار توزیع اندازه سبد ۸۴

شکل ۶-۵ - جدول پرفروش‌ترین محصولات در صفحه محصولات ۸۷

شکل ۶-۶ - منحنی تمرکز درآمد بر حسب درصد تجمعی محصولات ۸۸

شکل ۶-۷ - نمودار درآمد بر حسب ساعت روز و درآمد روزانه بر حسب روز هفته ۹۰

شکل ۶-۸ - نقشه حرارتی درآمد بر حسب روز هفته و ساعت ۹۱

شکل ۶-۹ - درآمد ماهانه و نرخ تخفیف بر روی دو محور ۹۱

شکل ۶-۱۰ - نمودار ترکیبی درآمد و تعداد خانوار به تفکیک بخش مشتری ۹۳

شکل ۶-۱۱ - نمودار درآمد بر حسب بازه سنی و یادداشت پوشش داده جمعیت‌شناختی ۹۴

شکل ۶-۱۲ - نمودار حبابی عملکرد فروشگاه‌ها بر پایه تعداد سبد، ارزش متوسط سبد و درآمد ۹۵
شکل ۶-۱۳ - نمودار دوسویه تفاضل درآمد میان دو دوره کامل متوالی ۹۶
شکل ۶-۱۴ - درآمد خانوارهای تازه و بازگشتی در بیست و سه دوره سی‌روزه ۹۷
شکل ۶-۱۵ - سهم هر دهک خانوار از درآمد و منحنی سهم تجمعی ۹۹
شکل ۶-۱۶ - ترکیب درآمد بر پایه عمق تخفیف ۱۰۰
شکل ۶-۱۷ - سهم برند خصوصی و برند ملی به تفکیک گروه کالایی ۱۰۱
شکل ۶-۱۸ - کارت‌های شش آزمون معناداری روی جفت بخش قهرمانان و مشتریان وفادار ۱۰۵
شکل ۶-۱۹ - جدول نتیجه جست‌وجوی خودکار بزرگ‌ترین تفاوت‌ها ۱۰۷
شکل ۶-۲۰ - رتبه‌بندی بُعدهای گروه‌بندی بر پایه سهم پراکندگی توضیح‌داده‌شده ۱۰۹
شکل ۷-۱ - نمای بالای صفحه قوانین انجمنی، پنل تنظیمات و دکمه اجرای الگوریتم ۱۱۳
شکل ۷-۲ - نمای کارتی نتایج و ابزار انتخاب گروهی در بالای فهرست قوانین ۱۲۵
شکل ۷-۳ - پنجره جزئیات قانون شامل معیارها و برداشت‌های تجاری پیشنهادی ۱۲۷
شکل ۷-۴ - پنجره تأیید ثبت قانون پیش از نوشتن در پایگاه داده ۱۲۹
شکل ۸-۱ - نمای بخش‌بندی جاری مشتریان بر مبنای RFM ۱۳۷
شکل ۸-۲ - تنظیم روش تولید داده و آموزش آزمایش ریزش مشتری ۱۳۹
شکل ۸-۳ - جزئیات آزمایش فعال ریزش مشتری و شاخص‌های ارزیابی ۱۴۰
شکل ۸-۴ - توزیع سطح‌های ریسک ریزش و نمونه مشتریان در مدل فعال ۱۴۳
شکل ۸-۵ - راهنمای تفسیر بخش‌های RFM و سطح‌های ریسک ریزش ۱۴۵
شکل ۸-۶ - نمای تحلیل ریزش مشتری ۱۸۳۰ و نمایه فعلی RFM ۱۴۸
شکل ۸-۷ - مسیر زمانی RFM و ریزش مشتری ۱۸۳۰ ..... ۱۵۱
شکل ۸-۸ - فهرست اولویت‌های ماندگاری مشتری بر اساس ریسک ریزش ۱۵۳
شکل ۹-۱ - نمای صفحه جست‌وجوی مشتری بر اساس شناسه خانوار ۱۵۹
شکل ۹-۲ - نمای صفحه پروفایل مشتری و مسیرهای دسترسی به خریدها و پیشنهادها ۱۶۱
شکل ۹-۳ - نمای صفحه خریدهای مشتری، فیلتر زمانی و گروه‌بندی اقلام بر اساس سبد ۱۶۳

شکل ۹-۴ - نمای جزئیات اقلام سبد خرید منتخب ۱۶۳
شکل ۹-۵ - نمای پیشنهادهای محصول برای یک مشتری و گروه‌بندی آن‌ها بر اساس گروه کالایی ۱۶۹
شکل ۹-۶ - نمونه‌های فهرست پیشنهادی و امتیازهای محصولات منتخب برای مشتری ۱۶۹
شکل ۹-۷ - صفحه انتخاب محصول، گروه کالایی یا دپارتمان برای پیشنهاد مشتری ۱۷۱
شکل ۹-۸ - فهرست رتبه‌بندی‌شده مشتریان پیشنهادی برای هدف منتخب ۱۷۲
شکل ۹-۹ - نمای جزئیات محصول، مشتریان خریدار و قوانین انجمنی مرتبط ۱۷۳

فهرست جدول‌ها

جدول ۱-۱ – اجزای پشته فناوری سامانه و نقش هر یک ۵

جدول ۲-۱ – شناسنامه داده‌های اصلی مورد استفاده در سامانه ۱۱

جدول ۲-۲ – آماده‌سازی داده‌های اصلی و کنترل‌های اعتبار آن‌ها ۱۳

جدول ۲-۳ – شاخص‌های کمی داده تراکنشی مورد استفاده ۱۵

جدول ۲-۵ – ستون‌های فایل تراکنش و شرح هر یک ۱۹

جدول ۲-۶ – ستون‌های فایل محصول و شرح هر یک ۲۰

جدول ۲-۷ – ستون‌های فایل مشخصات خانوار و شرح هر یک ۲۱

جدول ۳-۱ – تعریف و مقدار شاخص‌های اصلی صفحه نخست ۲۵

جدول ۴-۱ – اجزای سربرگ تحلیل توصیفی و هدف هر جزء ۳۳

جدول ۴-۲ – نمونه‌هایی از تفاوت رتبه‌بندی محصولات بر اساس تکرار و بر اساس ارزش فروش ۳۵

جدول ۴-۳ – پارامترهای اجرای تحلیل توصیفی و اثر آن‌ها ۳۸

جدول ۴-۴ – تعریف، مبنای محاسبه و مقدار شاخص‌های چهارگانه سربرگ توصیفی ۳۹

جدول ۴-۵ – معیارهای ارزیابی قانون انجمنی و شیوه تفسیر آن‌ها ۴۰

جدول ۴-۶ – مقایسه سطح گروه کالایی و سطح کالا در استخراج قوانین ۴۳

جدول ۵-۱ – مقایسه دو مسئله پیش‌بینی موجود در سربرگ تحلیل پیش‌بینانه ۴۹

جدول ۵-۲ – ویژگی‌های ورودی دسته‌بند خرید دوباره و سطح تعریف هر دسته ۵۳

جدول ۵-۳ – الگوریتم‌های دسته‌بندی و تنظیم‌های اصلی هر یک ۵۴

جدول ۵-۴ – نتایج اعتبارسنجی چهار الگوریتم روی دوره آزمون، افق سه‌ماهه و اندازه آموزش هشتاد درصد ۵۷

جدول ۵-۵ – نمونه‌ای از امتیاز گروه‌های کالایی در آخرین روز داده با الگوریتم تقویت گرادیانی ۵۹

جدول ۵-۶ – پارامترهای پیکربندی پیش‌بینی درآمد محصول ۶۲

جدول ۵-۷ – مقایسه دو مدل و مبنای ساده روی دوره آزمون سه‌دوره‌ای ۶۸

جدول ۵-۸ – مجموع درآمد واقعی و پیش‌بینی‌شده در سه دوره آزمون ۶۹

جدول ۵-۹ – نمونه‌ای از خروجی پیش‌بینی درآمد سه دوره آینده برای پرفروش‌ترین محصولات ۷۱

جدول ۶-۱ – شاخص‌های کلیدی سربرگ هوش تجاری، شیوه محاسبه و مقدار روی کل داده ۷۹
جدول ۶-۲ – ترکیب فروش بر پایه نوع برند و ویژگی‌های توزیع اندازه سبد ۸۴
جدول ۶-۳ – ده محصول برتر بر پایه درآمد و تعداد سبد حاضر در آن ۸۶
جدول ۶-۴ – درآمد روزانه به تفکیک روز هفته ۸۹
جدول ۶-۵ – درآمد، تعداد خانوار و درآمد سرانه هر بخش مشتری ۹۲
جدول ۶-۶ – تفاضل درآمد دوره بیست و سوم نسبت به دوره بیست و دوم به تفکیک گروه کالایی ۹۶
جدول ۶-۷ – سهم هر دهک خانوار از درآمد و سهم تجمعی ۹۸
جدول ۶-۸ – ترکیب درآمد بر پایه عمق تخفیف ۱۰۰
جدول ۶-۹ – آزمون‌های آماری این صفحه، پرسش هر آزمون و معیار اندازه اثر آن ۱۰۳
جدول ۶-۱۰ – ده تفاوت برتر یافت‌شده در جست‌وجوی خودکار ۱۰۶
جدول ۶-۱۱ – رتبه‌بندی بُعدها بر پایه سهم پراکندگی توضیح‌داده‌شده از ارزش سبد ۱۰۸
جدول ۷-۱ – مقایسه دو مسیر استخراج قانون انجمنی در سامانه ۱۱۴
جدول ۷-۲ – اجزای صفحه قوانین انجمنی و نقش هر جزء ۱۱۷
جدول ۷-۳ – تعداد سبد هر دوره و حداقل تعداد سبد لازم برای آستانه‌های پیشنهادی ۱۱۸
جدول ۷-۴ – پارامترهای صفحه، مقدار پیش‌فرض و قاعده اصلاح در سرور ۱۲۰
جدول ۷-۵ – شیوه محاسبه معیارها در سطح محصول و مخرج هر کسر ۱۲۴
جدول ۷-۶ – اجزای کارت قانون و آنچه هر جزء نشان می‌دهد ۱۲۶
جدول ۷-۷ – فیلدهای جدول قوانین انجمنی و نقش هر فیلد ۱۲۹
جدول ۷-۸ – نمونه‌ای از قوانین به‌دست‌آمده در سطح محصول با تنظیمات پیش‌فرض ۱۳۱
جدول ۸-۱ – نقش و خروجی سه صفحه اصلی در مسیر تصمیم‌گیری مشتری ۱۳۶
جدول ۸-۲ – توزیع مشتریان در بخش‌های RFM و میانگین هزینه هر بخش ۱۳۸
جدول ۸-۳ – تنظیمات و شاخص‌های ارزیابی مدل فعال ریزش ۱۴۲
جدول ۸-۴ – توزیع سطح‌های ریسک ریزش و قاعده اقدام ۱۴۴
جدول ۹-۱ – صفحات اصلی فصل و نقش هر یک ۱۵۹

جدول ۹-۲ - اطلاعات نمایش‌داده‌شده در پروفایل مشتری و کاربرد تفسیری آن‌ها ۱۶۰
جدول ۹-۳ - اجزای صفحه خریدهای مشتری و هدف هر جزء ۱۶۲
جدول ۹-۴ - منابع تولید نامزد در پیشنهاد محصول به مشتری ۱۶۵
جدول ۹-۵ - ویژگی‌های مفهومی مدل پیشنهاددهنده ۱۶۷
جدول ۹-۶ - قواعد کنترلی خروجی پیشنهاد محصول ۱۶۸
جدول ۹-۷ - مسیرهای شناسایی مشتری بالقوه برای محصول ۱۷۰
جدول ۹-۸ - مقایسه پیشنهاد محصول به مشتری و پیشنهاد مشتری به محصول ۱۷۳
جدول ۹-۹ - معیارهای مناسب برای ارزیابی پیشنهاددهنده ۱۷۵
جدول ۱۰-۱ - خلاصه نتایج کمی ارزیابی مدل‌ها ۱۸۵

فصل اول: کلیات و مقدمه

۱-۱ پیشینه و زمینه موضوع

هر خرید در یک فروشگاه زنجیره‌ای چند نوع اطلاعات ایجاد می‌کند: چه محصولی خریداری شده، خرید در چه زمانی انجام شده، محصول متعلق به کدام گروه کالایی[۱] است، مبلغ پرداختی چه مقدار بوده و آیا تخفیف یا برنامه تبلیغاتی بر خرید اثر داشته است. وقتی این اطلاعات در یک بازه طولانی و برای تعداد زیادی خانوار[۲] جمع‌آوری شود، مجموعه‌ای شکل می‌گیرد که می‌تواند رفتار واقعی مشتریان را نشان دهد. مجموعه‌داده[۳] The Complete Journey دانهامبی نمونه شناخته‌شده‌ای از چنین داده‌ای است و اطلاعات تراکنش[۴]، محصول، خانوار، کمپین[۵] و کوپن[۶] را در قالب جداول مرتبط ارائه می‌کند {۱}.

بررسی اولیه این مجموعه‌داده در مرحله آغاز پروژه انجام شد و ساختار جدول‌ها، ستون‌های اصلی و کاربردهای احتمالی آن مستند گردید. در ادامه روشن شد که ارزش اصلی داده صرفاً در معرفی ستون‌ها نیست. مسئله مهم‌تر این است که چگونه ارتباط میان رکوردهای مختلف به یک پاسخ قابل فهم برای کاربر تبدیل شود. برای مثال، یک جدول تراکنش به تنهایی فقط مجموعه‌ای بزرگ از ردیف‌هاست، اما با پیوند آن به اطلاعات محصول می‌توان ترکیب سبد خرید[۷] را شناخت و با پیوند آن به خانوار می‌توان تفاوت رفتار گروه‌های مشتری را بررسی کرد.

پروژه حاضر از همین نقطه عبور می‌کند و تلاش دارد داده را از حالت فایل و جدول خارج کند و در قالب یک سامانه قابل استفاده ارائه دهد. در این سامانه، هر بخش برای پاسخ‌دادن به یک پرسش مشخص طراحی شده است. صفحه اصلی وضعیت کلی را نشان می‌دهد. بخش سبد خرید به ساختار خریدها می‌پردازد. قوانین انجمنی[۸] همراهی کالاها را بررسی می‌کنند. بخش‌بندی مشتریان[۹] رفتار خانوارها را خلاصه می‌کند.

---

[۱] Department

[۲] Household

[۳] Dataset

[۴] Transaction

[۵] Campaign

[۶] Coupon

[۷] Market Basket

[۸] Association Rules

[۹] Customer Segmentation

تحلیل ماندگاری مشتری[۱۰] احتمال از دست رفتن مشتری را می‌سنجد. پیشنهاددهنده محصول[۱۱] مخاطبان مناسب یک کالا را پیدا می‌کند. داشبورد[۱۲] هوش تجاری[۱۳] امکان مرور و ریزشدن در گزارش‌ها را فراهم می‌سازد.

۱-۲ بیان مسئله

مسئله اصلی پروژه، زیادبودن تعداد رکوردها و چندجدولی‌بودن داده است. کاربر برای رسیدن به یک نتیجه ساده، مانند شناخت پرفروش‌ترین محصولات یک دوره یا مقایسه دو گروه مشتری، باید چند مرحله انجام دهد: جدول مناسب را انتخاب کند، ارتباط آن را با جدول‌های دیگر بشناسد، داده نامعتبر یا ناقص را کنار بگذارد، شاخص را به شکل درست محاسبه کند و در پایان نتیجه را به صورت قابل فهم نمایش دهد. تکرار این فرایند برای هر پرسش، هم زمان‌بر است و هم احتمال برداشت نادرست از داده را افزایش می‌دهد.

مشکل دوم به تفاوت میان داده عملیاتی و اطلاعات تصمیم‌ساز مربوط می‌شود. عدد خام زمانی مفید است که تعریف آن روشن باشد. برای نمونه، عنوان «تعداد تراکنش‌ها» ممکن است به تعداد سبدها، تعداد مراجعات یا تعداد ردیف‌های اقلام خرید اشاره کند. در صفحه اصلی این پروژه، مقدار نمایش‌داده‌شده برابر تعداد رکوردهای جدول تراکنش است. بنابراین هر ردیف یک قلم ثبت‌شده از خرید را نشان می‌دهد و نباید آن را بدون بررسی با تعداد سبدهای مستقل برابر دانست. همین دقت در تعریف شاخص‌ها، بخش مهمی از طراحی سامانه محسوب می‌شود.

مسئله سوم، اتصال تحلیل‌های متنوع در یک ساختار واحد است. تحلیل توصیفی، قانون انجمنی، بخش‌بندی RFM، پیش‌بینی رفتار خرید و گزارش هوش تجاری از نظر هدف و خروجی با یکدیگر تفاوت دارند. اگر این اجزا بدون یک مسیر مشخص کنار هم قرار گیرند، کاربر میان صفحه‌های متعدد سردرگم می‌شود. به همین دلیل صفحه اصلی فقط یک ظاهر اولیه نیست. این صفحه نقشه ورود به سامانه است و باید ضمن نمایش وضعیت کلی، کاربرد هر بخش را نیز به‌طور کوتاه معرفی کند.

۱-۳ اهمیت و ضرورت انجام پروژه

---

[۱۰] Customer Retention

[۱۱] Product Recommender

[۱۲] Dashboard

[۱۳] Business Intelligence

از دید آموزشی، این پروژه چند موضوع دوره کارشناسی را در یک مسئله واقعی به هم متصل می‌کند: طراحی پایگاه داده، آماده‌سازی داده، تحلیل آماری، داده‌کاوی[۱۴]، یادگیری ماشین[۱۵]، طراحی رابط کاربر و گزارش‌گیری. کنار هم قرارگرفتن این موضوع‌ها باعث می‌شود نتیجه پروژه فقط یک مدل یا یک نمودار نباشد، بلکه زنجیره‌ای کامل از ذخیره‌سازی تا ارائه نتیجه شکل بگیرد. در این زنجیره، کاربر باید بتواند بدون اطلاع از جزئیات فنی، منطق هر بخش را درک کند.

ضرورت دیگر پروژه به حجم داده مربوط است. وجود بیش از دو و نیم میلیون رکورد تراکنشی، امکان مشاهده الگوهای پرتکرار را فراهم می‌کند، اما همین حجم باعث می‌شود روش‌های دستی یا گزارش‌های ثابت کافی نباشند. طراحی صفحه‌های تخصصی و شاخص‌های از پیش تعریف‌شده، زمان دستیابی به اطلاعات را کاهش می‌دهد و از محاسبه چندباره شاخص‌های مشابه جلوگیری می‌کند.

۱-٤ اهداف پروژه

هدف نخست – یکپارچه‌سازی داده: ایجاد ساختاری که اطلاعات تراکنش، محصول، خانوار و تبلیغات را به صورت مرتبط و قابل استفاده در اختیار بخش‌های تحلیلی قرار دهد.

هدف دوم – تحلیل توصیفی: نمایش شاخص‌های کلی، الگوهای سبد خرید، محصولات پرتکرار و روند تغییرات برای شناخت وضعیت موجود.

هدف سوم – تحلیل رفتاری مشتری: گروه‌بندی خانوارها با توجه به تازگی، تکرار و ارزش خرید و بررسی احتمال کاهش فعالیت یا ریزش[۱۶] آن‌ها.

هدف چهارم – پیش‌بینی و پیشنهاد: مقایسه روش‌های مختلف برای پیش‌بینی خرید یا فروش آینده و استفاده از نتیجه برای پیشنهاد محصول یا شناسایی مشتریان مناسب.

هدف پنجم – گزارش‌گیری و ارائه: ارائه نتایج در قالب صفحه‌های تعاملی و داشبوردهای مدیریتی تا کاربر بتواند از نمای کلی به جزئیات مورد نیاز برسد.

---

[۱۴] Data Mining

[۱۵] Machine Learning

[۱۶] Churn

هدف ششم - کنترل و قابلیت پیگیری: محدودکردن دسترسی به کاربران مجاز و مشخص‌کردن تعریف شاخص‌ها و بازه‌های مقایسه، به گونه‌ای که خروجی‌ها قابل تکرار و قابل توضیح باشند.

۱-۵ روش کلی انجام کار

۱-٦ جنبه‌های فنی پروژه

سامانه این پروژه یک برنامه تحت وب است و بنابراین در کنار مسائل تحلیلی، مجموعه‌ای از تصمیم‌های فنی نیز در آن گرفته شده است. در این بخش پشته فناوری[۱۷]، ساختار نرم‌افزاری، شیوه دسترسی به داده و ابزارهای نمایش به اختصار معرفی می‌شوند تا خواننده پیش از ورود به فصل‌های تحلیلی، بستر اجرای کار را بشناسد. مانند بقیه گزارش، جزئیات کدنویسی مطرح نمی‌شود و هدف تنها روشن‌کردن انتخاب‌های فنی و دلیل هر یک است.

۱-٦-۱ معماری کلی و پشته فناوری

سامانه بر پایه چارچوب[۱۸] جنگو نسخه ۲/۵ و زبان پایتون ساخته شده است. انتخاب این چارچوب به دلیل وجود سامانه احراز هویت[۱۹]، لایه نگاشت شیء به رابطه[۲۰]، سامانه قالب و ساختار ماژولار آن انجام شد، یعنی بخش زیادی از کارهای تکراری یک برنامه وب از پیش فراهم است و تمرکز پروژه روی منطق تحلیلی باقی می‌ماند. معماری کلی از الگوی سه‌لایه پیروی می‌کند: لایه داده در پایگاه داده، لایه منطق در ماژول‌های پایتون و لایه نمایش در قالب‌های وب. اجرای فعلی روی یک ماشین محلی و برای یک کاربر انجام می‌شود، بنابراین از سرور اختصاصی یا سرویس ابری استفاده نشده است. جدول ۱-۱ اجزای اصلی پشته فناوری و نقش هر یک را نشان می‌دهد.

---

[۱۷] Technology Stack

[۱۸] Framework

[۱۹] Authentication

[۲۰] Object-Relational Mapping

جدول ۱-۱ - اجزای پشته فناوری سامانه و نقش هر یک

جزء	نسخه	نقش در پروژه
Django	۵/۲	چارچوب وب، مسیریابی، احراز هویت و قالب‌ها
Python	۳	زبان پیاده‌سازی سمت سرور
Microsoft SQL Server	—	پایگاه داده اصلی و اجرای پرس‌وجوهای تجمیعی
mssql-django و pyodbc	۱/۷ و ۵/۳	اتصال چارچوب به پایگاه داده و درایور دسترسی
pandas و numpy	۲/۳	آماده‌سازی و پردازش داده جدولی
scikit-learn	۱/۷	آموزش و ارزیابی مدل‌های یادگیری ماشین
SciPy	۱/۱۶	آزمون‌های آماری بخش تحلیل تفاضلی
XGBoost	۳/۰	مدل درخت تقویت‌شده گرادیانی
Bootstrap	۵	چیدمان و اجزای رابط کاربری
Chart.js	—	رسم نمودارهای تعاملی در مرورگر

۱-۶-۲ پایگاه داده و شیوه دسترسی به آن

داده دان‌هامبی در یک پایگاه داده مایکروسافت اس‌کیوال سرور بارگذاری شده و اتصال برنامه به آن از طریق راه‌انداز ODBC و کتابخانه mssql-django برقرار می‌شود. احراز هویت این اتصال از نوع اتصال مورد اعتماد است، یعنی حساب کاربری سیستم‌عامل مبنای دسترسی قرار می‌گیرد و گذرواژه‌ای در فایل پیکربندی نگهداری نمی‌شود.

نکته مهم‌تر، شیوه خواندن داده است. برای عملیات ساده مانند مشاهده یک رکورد یا ثبت یک قانون از لایه نگاشت شیء به رابطه استفاده می‌شود، اما پرس‌وجوهای تجمیعی سنگین به صورت SQL خام و مستقیم اجرا می‌گردند. دلیل این تفکیک روشن است: تجمیع روی بیش از دو و نیم میلیون ردیف اگر از طریق لایه نگاشت انجام شود هم کندتر است و هم کنترل کمتری بر نحوه اجرای پرس‌وجو[۲۱] باقی می‌گذارد. در مواردی که خروجی پرس‌وجو بزرگ است، رکوردها به صورت دسته‌ای و جریانی خوانده می‌شوند تا حافظه با یک

[۲۱] Query

بارگذاری کامل اشغال نشود. نمونه روشن این روش در استخراج قوانین انجمنی دیده می‌شود که در فصل چهارم توضیح داده شده است.

افزون بر جدول‌های اصلی، مجموعه‌ای از نماهای گزارشی نیز در پایگاه داده تعریف شده است. این نماها ساختاری از نوع طرح ستاره‌ای[۲۲] دارند: یک نمای واقعیت برای فروش و چند نمای بعد برای زمان، محصول و خانوار. جداکردن این لایه باعث می‌شود گزارش‌های هوش تجاری بدون درگیرشدن با ساختار جدول‌های عملیاتی نوشته شوند و تغییر در یکی، دیگری را از کار نیندازد.

۱-٦-۳ ساختار ماژول‌های نرم‌افزاری

برنامه به شش ماژول تقسیم شده و هر ماژول مسئولیت مشخصی دارد. ماژول تحلیل دان‌هامبی هسته پروژه است و صفحه‌های تحلیل سبد خرید، قوانین انجمنی، بخش‌بندی مشتریان، مدیریت داده و داشبورد هوش تجاری در آن قرار دارند. ماژول مشتریان مدل کاربر و صفحه‌های جست‌وجو و مشاهده خانوار را نگهداری می‌کند. ماژول ماندگاری مشتری به آزمایش‌های ریزش اختصاص دارد، ماژول پیشنهاددهنده محصول کار اولویت‌بندی مشتریان برای یک محصول را انجام می‌دهد و دو ماژول کاتالوگ و هسته وظیفه‌های مشترک مانند مدل‌های کالا و تنظیم‌های پایه را بر عهده دارند.

این تقسیم‌بندی فقط یک نظم ظاهری نیست. هر بخش تحلیلی مسیر نشانی، قالب نمایش و توابع خود را در همان ماژول دارد، بنابراین تغییر در یک تحلیل بخش‌های دیگر را تحت تأثیر قرار نمی‌دهد. نقطه اتصال این ماژول‌ها، صفحه اصلی و نوار ناوبری[۲۳] مشترک است که در فصل سوم معرفی می‌شود.

۱-٦-٤ کتابخانه‌های پردازش داده و یادگیری ماشین

کتابخانه‌های pandas و numpy برای آماده‌سازی داده و ساخت ماتریس ویژگی‌ها به کار می‌روند. scikit-learn وظیفه آموزش و ارزیابی مدل‌های دسته‌بندی[۲۴] و رگرسیون[۲۵] را بر عهده دارد و XGBoost به عنوان یک مدل درخت تقویت‌شده در کنار آن قرار گرفته است. آزمون‌های آماری بخش تحلیل تفاضلی نیز از SciPy استفاده می‌کنند.

---

[۲۲] Star Schema

[۲۳] Navigation Bar

[۲۴] Classification

[۲۵] Regression

مدل‌های آموزش‌دیده در یک پوشه محلی ذخیره می‌شوند تا هر بار که کاربر صفحه‌ای را باز می‌کند آموزش دوباره انجام نشود. آموزش مدل عملیاتی زمان‌بر است و اجرای آن باید تصمیم آگاهانه کاربر باشد، نه پیامد جانبی بازکردن یک صفحه. همین منطق در صفحه تحلیل سبد خرید نیز رعایت شده است، جایی که استخراج قوانین تنها با فشردن دکمه اجرا آغاز می‌شود.

۱-۶-۵ رابط کاربری و لایه نمایش

صفحه‌ها با سامانه قالب چارچوب ساخته می‌شوند و ظاهر آن‌ها بر پایه بوت‌استرپ نسخه ۵ است. نمودارها با کتابخانه Chart.js رسم می‌شوند و داده آن‌ها از طریق درخواست‌های نامتقارن[۲۶] از سرور گرفته می‌شود، یعنی صفحه بدون بارگذاری دوباره به‌روز می‌گردد. این روش برای بخش‌هایی مانند اجرای الگوریتم Apriori یا آموزش مدل ضروری است، زیرا عملیات ممکن است چند ده ثانیه طول بکشد و کاربر باید در همین مدت وضعیت پیشرفت را ببیند.

در کنار رابط وب، یک داشبورد مدیریتی نیز ساخته شده است. این داشبورد از همان پایگاه داده تغذیه می‌شود و برای گزارش‌های مدیریتی و مرور کلان کاربرد دارد. تفاوت آن با صفحه‌های سامانه در این است که سامانه امکان اجرای تحلیل و تغییر پارامتر را می‌دهد، در حالی که داشبورد بیشتر برای مشاهده و مقایسه طراحی شده است.

۱-۶-۶ کنترل دسترسی و پیکربندی اجرا

احراز هویت بر پایه سامانه کاربران چارچوب و با یک مدل کاربر سفارشی انجام می‌شود. نشست[۲۷] کاربر یک ساعت اعتبار دارد و با هر درخواست تمدید می‌گردد. کوکی نشست از دسترس کدهای سمت مرورگر خارج است و برای جلوگیری از جعل درخواست بین‌سایتی[۲۸] نیز محدودیت لازم روی آن اعمال شده است. همه صفحه‌های تحلیلی نیازمند ورود هستند و کاربر ناشناس به صفحه ورود هدایت می‌شود.

منطقه زمانی برنامه روی وقت محلی تنظیم شده و زمان‌ها در پایگاه داده به صورت هماهنگ جهانی ذخیره می‌شوند. این تفکیک باعث می‌شود تاریخ ثبت قوانین و سایر رویدادها با ساعت واقعی کاربر هم‌خوان باشد.

---

[۲۶] Asynchronous Requests

[۲۷] Session

[۲۸] Cross-Site Request Forgery

نسخه فعلی برای اجرا در محیط توسعه پیکربندی شده است و پیش از هر استفاده واقعی باید تنظیم‌های امنیتی مانند کلید محرمانه، حالت اشکال‌زدایی و فهرست میزبان‌های مجاز بازبینی شوند.

فرایند انجام پروژه از شناخت داده آغاز شد. ابتدا جدول‌ها، کلیدهای ارتباطی و دامنه مقادیر بررسی شدند. سپس داده‌های لازم برای هر مسئله تحلیلی مشخص گردید و ساختار پایگاه داده برای پاسخ‌گویی به پرسش‌های پرتکرار آماده شد. پس از آن، بخش‌های تحلیلی به صورت مستقل شکل گرفتند و در پایان از طریق یک صفحه اصلی و نوار ناوبری به یکدیگر متصل شدند. در مرحله ارزیابی نیز تلاش شد تعریف شاخص‌ها، جداسازی دوره‌های زمانی و نحوه مقایسه مدل‌ها روشن باشد. این گزارش منطق این مراحل را شرح می‌دهد و وارد جزئیات دستورات یا ساختار کد نمی‌شود.

۱-۷ محدوده این گزارش و ساختار فصل‌های بعد

گزارش نهایی از چند فصل تشکیل می‌شود و نسخه حاضر بخشی از آن را در بر می‌گیرد. فصل اول به کلیات، مسئله، اهداف و جنبه‌های فنی پروژه اختصاص دارد. فصل دوم به ساختار مجموعه‌داده و آماده‌سازی آن می‌پردازد و در نسخه بعدی تکمیل خواهد شد. فصل سوم صفحه اصلی سامانه تحلیل را از نظر نقش، ساختار و شاخص‌ها معرفی می‌کند و فصل چهارم به تحلیل توصیفی سبد خرید و استخراج قوانین انجمنی می‌پردازد. فصل‌های بعدی گزارش به ترتیب به صفحه قوانین انجمنی، بخش‌بندی و ماندگاری مشتری، پیش‌بینی فروش و خرید، پیشنهاددهنده محصول، بخش‌بندی و ماندگاری مشتری، پیش‌بینی فروش و خرید، پیشنهاددهنده محصول، تحلیل‌های آماری، داشبورد هوش تجاری، ارزیابی نتایج و جمع‌بندی اختصاص خواهند یافت. این ترتیب باعث می‌شود خواننده ابتدا با مسئله، بستر فنی و مسیر کلی سامانه آشنا شود و سپس وارد جزئیات هر تحلیل گردد.

فصل دوم: معرفی مجموعه‌داده، آماده‌سازی و ساختار پایگاه داده

هر تحلیل انجام‌شده در سامانه، از محاسبه شاخص‌های کلی بازار تا استخراج قوانین هم‌خریدی و برآورد ریسک ریزش مشتری، به کیفیت و معنای داده‌های پایه وابسته است. ازاین‌رو، پیش از توضیح صفحه‌ها و الگوریتم‌ها لازم است مشخص شود داده از چه منبعی به‌دست آمده، هر جدول چه واحدی از واقعیت را نمایش می‌دهد، چه تغییرهایی پیش از ورود به پایگاه داده روی آن انجام شده و ارتباط میان جدول‌ها چگونه برقرار است. این فصل چنین نقشی دارد و مرجع مشترک فصل‌های تحلیلی بعدی به شمار می‌آید.

منبع اصلی پروژه مجموعه‌داده The Complete Journey شرکت دان‌هامبی است که از پایگاه Kaggle دریافت شده است. در این فصل، آمار بر اساس داده موجود در پایگاه داده مورد استفاده سامانه محاسبه شده است. هدف، معرفی معنای داده‌ها، قواعد آماده‌سازی و روابطی است که تحلیل‌های بعدی بر آن‌ها تکیه دارند. بنابراین همه جدول‌ها و محاسبات این فصل یک دامنه آماری مشترک دارند.

شرح این فصل بر داده‌های خرید، محصول و خانوار متمرکز است. جدول‌های فنی مدیریت کاربران و نگهداری موقت نتایج، جزو داده‌های اصلی تحلیل نیستند و برای شناخت مجموعه‌داده نیازی به توضیح جزئیات آن‌ها وجود ندارد.

۲-۱ منشأ، دامنه و ویژگی‌های مجموعه‌داده

۲-۱-۱ جامعه مورد مطالعه و گستره زمانی

مجموعه The Complete Journey برای مطالعه رفتار خرید خانوارها در یک خرده‌فروش فراهم شده است. داده مورد استفاده در سامانه، خریدهای ۲۴۹۷ خانوار را در گروه‌های متنوع کالا پوشش می‌دهد. ترکیب سابقه خرید با مشخصات محصول و اطلاعات موجود خانوار، امکان تحلیل سبد، شناخت گروه‌های رفتاری مشتری و برآورد احتمال قطع خرید در یک بازه معین را فراهم می‌کند {۱}.

محور زمان در داده به‌صورت شماره روز و شماره هفته ثبت شده است. روزها از ۱ تا ۷۱۱ و هفته‌ها از ۱ تا ۱۰۲ امتداد دارند. این اعداد تاریخ تقویمی واقعی نیستند و نباید بدون فرض صریح به روز و ماه واقعی تبدیل شوند. محاسبات زمانی اصلی سامانه بر همین شماره روز و هفته انجام می‌شود. تاریخ‌های نمایشی رابط کاربری، مبنای محاسبه فاصله خرید و برچسب ریزش نیستند.

۲-۱-۲ واحد مشاهده و دانه داده

یکی از نکات اساسی در خواندن این مجموعه، توجه به دانه داده[۲۹] است، یعنی هر سطر دقیقاً چه واحدی را نمایش می‌دهد. در جدول تراکنش، هر سطر یک قلم محصول در یک سبد خرید است و یک سبد ممکن است چندین سطر داشته باشد. در جدول محصول، هر سطر مشخصات یک شناسه محصول و در جدول خانوار، هر سطر اطلاعات یک شناسه خانوار را نگهداری می‌کند. نادیده‌گرفتن این تفاوت می‌تواند موجب چندبارشماری سبد یا مشتری شود.

به همین دلیل، شمار رکورد با شمار واحد تحلیلی یکسان نیست. جدول اصلی پایگاه داده **۲۵۹۵۲۷۷** ردیف تراکنشی دارد، اما این ردیف‌ها به **۲۷۶۴۵۰** سبد خرید، **۲۴۹۷** خانوار، **۹۲۳۳۵** محصول خریداری‌شده و **۵۸۲** فروشگاه مربوط می‌شوند. انتخاب مخرج هر شاخص در فصل‌های بعد باید بر اساس همین دانه‌بندی انجام شود. برای مثال، میانگین ارزش سبد با تعداد سبدها محاسبه می‌شود، نه تعداد ردیف‌های تراکنش.

۲-۱-۳ تفسیر شناسه‌ها و متغیرهای زمانی

شناسه‌های خانوار، محصول و فروشگاه برای تفکیک و پیوند رکوردها به کار می‌روند و مقدار بزرگ‌تر آن‌ها نشانه ارزش یا اهمیت بیشتر نیست. جدول تراکنش متغیر مستقلی برای سال تقویمی ندارد. شماره روز و شماره هفته ترتیب زمانی خریدها را مشخص می‌کنند و زمان ثبت خرید، ساعت و دقیقه را نشان می‌دهد. همچنین شناسه سبد در سطرهای اقلام همان خرید تکرار می‌شود. ازاین‌رو تعداد دفعات خرید باید با شمارش سبدهای یکتا به دست آید.

۲-۲ شناسنامه فایل‌های منبع و جدول‌های نهایی

سه فایل منبعِ تراکنش، محصول و مشخصات خانوار، داده‌های اصلی مورد نیاز تحلیل‌های پروژه را فراهم می‌کنند. جدول ۲–۱ نقش این فایل‌ها و اندازه جدول متناظر آن‌ها در پایگاه داده مورد استفاده سامانه را نشان می‌دهد. تعدادهای درج‌شده، شمار رکوردهای جدول‌های فعلی‌اند و نباید به‌عنوان تعداد سطرهای فایل منبع تفسیر شوند.

---

[۲۹] Data Grain

جدول ۲-۱ - شناسنامه داده‌های اصلی مورد استفاده در سامانه

فایل منبع	واحد مشاهده	تعداد رکورد جدول	جدول متناظر	کاربرد در پروژه
transaction_data.csv	قلم محصول در سبد خرید	۲۵۹۵۲۷۷	تراکنش‌ها	سابقه خرید و مبلغ فروش
product.csv	یک شناسه محصول	۹۲۳۵۳	محصول	توصیف و گروه‌بندی کالا
hh_demographic.csv	یک شناسه خانوار	۲۴۹۷	خانوار	مرجع مشتری و ویژگی‌های موجود

فایل‌های coupon.csv، campaign_table.csv، campaign_desc.csv، coupon_redempt.csv و causal_data.csv برای تحلیل‌های پیاده‌سازی‌شده پروژه مورد نیاز نبوده‌اند و در ساخت ویژگی‌های مدل‌ها به کار نرفته‌اند. وجود اطلاعات آن‌ها در بخش عمومی مدیریت داده به معنای استفاده تحلیلی نیست. ستون‌های تخفیف کوپن در خودِ جدول تراکنش، مستقل از فایل‌های کوپن، در توصیف رفتار خرید استفاده می‌شوند.

۲-۳ شرح جدول‌های اصلی

۲-۳-۱ جدول تراکنش‌ها

جدول transactions ستون فقرات پایگاه داده است. شناسه خانوار، شناسه سبد، روز، شناسه محصول، تعداد، مبلغ فروش، شناسه فروشگاه، تخفیف خرده‌فروشی، زمان تراکنش، شماره هفته، تخفیف کوپن و تخفیف تطبیقی کوپن در این جدول نگهداری می‌شوند. مقدار sales_value مبلغ خالص ثبت‌شده برای همان قلم خرید است و ستون‌های تخفیف معمولاً با علامت منفی ذخیره شده‌اند. بنابراین برای گزارش مقدار مثبت تخفیف باید قرارداد علامت به‌طور یکسان رعایت شود.

جدول تراکنش ۲۵۹۵۲۷۷ ردیف در بازه روزهای ۱ تا ۷۱۱ دارد. از این تعداد، ۲۵۷۶۴۰۵ ردیف دارای مبلغ فروش مثبت و ۱۸۸۷۲ ردیف دارای مبلغ صفر هستند و مبلغ فروش منفی در جدول دیده نمی‌شود. ردیف‌های صفر در داده پایه حفظ شده‌اند. حضور آن‌ها مبلغ فروش کل را تغییر نمی‌دهد، اما در شمارش

رکوردها و تشکیل سبد خرید اثر دارد. بنابراین تعداد ردیف تراکنش و تعداد اقلام دارای فروش مثبت دو شاخص متفاوت‌اند.

شناسه id کلید اصلی[۳۰] هر ردیف تراکنش است. household_key رابطه تراکنش با خانوار را برقرار می‌کند و product_id مبنای ارتباط آن با محصول است. basket_id در سطح اقلام یک خرید تکرار می‌شود. پس برای رسیدن به سطح سبد، ردیف‌های دارای این شناسه تجمیع می‌شوند. trans_time نیز زمان را به شکل ساعت و دقیقه نگه می‌دارد و تاریخ کامل تقویمی نیست.

۲-۳-۲ جدول محصولات

جدول product برای هر product_id یک ردیف دارد و شامل کد تولیدکننده، دپارتمان، نوع نام تجاری، گروه کالایی، زیرگروه کالایی و اندازه بسته است. در این جدول ۹۲۳۵۳ محصول، ۶۴۷۶ کد تولیدکننده، ۴۳ دپارتمان، ۳۰۷ گروه کالایی و ۲۳۸۲ زیرگروه ثبت شده است. ستون brand دو مقدار متمایز دارد و نوع نام تجاری را توصیف می‌کند. بنابراین نباید آن را نام واقعی برند هر کالا دانست.

رابطه محصول با تراکنش از نوع یک‌به‌چند است: یک محصول می‌تواند در سطرهای خرید متعددی ظاهر شود، اما هر ردیف تراکنش فقط به یک محصول اشاره می‌کند. بررسی شناسه‌ها نشان می‌دهد همه محصولات موجود در تراکنش‌ها در جدول product قابل بازیابی‌اند. از ۹۲۳۵۳ محصول ثبت‌شده، ۹۲۳۳۵ محصول در خریدها دیده می‌شوند. بنابراین شمار محصولات جدول مرجع با شمار محصولات خریداری‌شده یکسان نیست.

۲-۳-۳ جدول خانوار

جدول household هویت تحلیلی مشتری را در سطح خانوار نگهداری می‌کند. کلید household_key برای انتساب خریدها به یک خانوار به کار می‌رود. ویژگی‌های توصیفی شامل گروه سنی، وضعیت تأهل، بازه درآمد، وضعیت مالکیت منزل، ترکیب خانوار، اندازه خانوار و وضعیت فرزند است. این ویژگی‌ها طبقه‌ای‌اند و مقدار دقیق سن یا درآمد را ارائه نمی‌کنند.

جدول خانوار ۲۴۹۷ شناسه را پوشش می‌دهد. برای ۸۰۳ خانوار دست‌کم یک ویژگی جمعیت‌شناختی ثبت شده و ۱۶۹۴ خانوار فاقد همه این ویژگی‌ها هستند. داشتن یک ویژگی به معنای کامل‌بودن اطلاعات نیست. برای نمونه، گروه سنی و بازه درآمد هرکدام برای ۸۰۲ خانوار موجود است. مقادیر نامعلوم با اطلاعات

---

[۳۰] Primary Key

حدسی جایگزین نشده‌اند. ازاین‌رو هر تحلیل جمعیت‌شناختی باید بر تعداد خانوارهای دارای همان ویژگی تکیه کند.

۲-٤ مراحل آماده‌سازی داده

آماده‌سازی داده در چند مرحله انجام شده است تا فایل‌های ناهمگون منبع به ساختاری قابل بارگذاری و تحلیل تبدیل شوند. جدول ۲-۲ این مراحل را به صورت خلاصه نشان می‌دهد و ادامه بخش منطق هر مرحله را توضیح می‌دهد.

جدول ۲-۲ – آماده‌سازی داده‌های اصلی و کنترل‌های اعتبار آن‌ها

مرحله	اقدام و کنترل	هدف و پیامد
شناخت و استانداردسازی	حذف فاصله اضافی نام ستون‌ها و تبدیل به حروف کوچک	هماهنگی نام‌ها با ساختار پایگاه داده
مقادیر نامشخص	تبدیل نشانه‌های ناشناخته در مشخصات خانوار به مقدار تهی	تفکیک نبود داده از طبقه واقعی
کنترل مبلغ	بررسی نبود مبلغ فروش منفی و حفظ ردیف‌های صفر در داده پایه	تفسیر درست تفاوت مبلغ فروش و شمار خرید
اندازه محصول	یکسان‌سازی نوشتار اندازه و واحد بسته	کاهش تفاوت‌های متنی بدون تبدیل واحد فیزیکی
یکتایی شناسه‌ها	کنترل کلیدهای مرجع و شمارش شناسه‌های یکتا در تجمیع	جلوگیری از اشتباه ردیف خرید با سبد و مشتری
قالب ورود	متن **UTF-8** بدون **Byte Order Mark** و شماره هفته با نوع عدد صحیح	کاهش ناسازگاری متن و نوع داده
تعیین دامنه محاسبه و اعتبار پیوندها	بررسی تعداد رکورد، بازه زمانی و پوشش کلیدهای اصلی	اعتبار داده

۲-٤-۱ استانداردسازی نام ستون‌ها و مقادیر تهی

نام ستون‌ها پس از حذف فاصله‌های اضافی و تبدیل به حروف کوچک با ساختار پایگاه داده هماهنگ شدند. مقادیر U، Unknown و None/Unknown در داده خانوار به مقدار تهی تبدیل شدند تا نبود

اطلاعات با یک طبقه جمعیت‌شناختی اشتباه نشود. این تمایز هنگام تحلیل نیز باید حفظ شود. برای نمونه، نبود اطلاعات درآمد نباید درآمد صفر یا عضویت در یک گروه درآمدی تلقی شود.

۲-٤-۲ کنترل تراکنش و قرارداد مبلغ

در داده مورد استفاده، مبلغ فروش منفی وجود ندارد و ردیف‌های دارای مبلغ صفر حفظ شده‌اند. مجموع مبلغ فروش برابر با ۸۰۵۶۰۶۸/۵۲ دلار است. برای محاسبه درآمد، جمع مبلغ فروش به کار می‌رود، اما برای فراوانی خرید مشتری، سبدهای یکتا شمارش می‌شوند. در نتیجه، اعمال یک فیلتر واحد بر همه تحلیل‌ها مناسب نیست و دامنه شمارش باید با تعریف شاخص سازگار باشد.

۲-٤-۳ استانداردسازی اندازه محصول

برای یکسان‌سازی نوشتار اندازه محصول، متن به حروف بزرگ تبدیل شد، واحدهایی مانند OUNCE و OUNCES به OZ، LTR به L، POUND و POUNDS به LB و PK به PACK نگاشت شدند، نشانه‌های غیرضروری حذف و فاصله میان عدد و واحد یکسان شد. همچنین اعداد اعشاری آغازشده با نقطه، مانند .5 OZ، به صورت 0.5 OZ ذخیره شدند. هدف این مرحله تبدیل همه اندازه‌های فیزیکی به یک واحد مشترک نیست، بلکه کاهش تفاوت‌های صرفاً نوشتاری است.

۲-٤-٤ یکتایی شناسه‌ها و تشخیص تکرار

کنترل تکرار باید با واحد مشاهده هر جدول هماهنگ باشد. شناسه محصول و شناسه خانوار در جدول‌های مرجع یکتا هستند، اما تکرار آن‌ها در تراکنش‌ها طبیعی است و خریدهای متعدد را نشان می‌دهد. همچنین وجود چند قلم در یک سبد، رکورد تکراری محسوب نمی‌شود. ازاین‌رو برای شمارش مشتری، محصول خریداری‌شده و سبد، شناسه‌های یکتا شمارش می‌شوند و تعداد سطرهای تراکنش به جای این واحدها قرار نمی‌گیرد.

۲-٤-۵ قالب متن و بارگذاری

فایل‌های آماده ورود با رمزگذاری UTF-8 و بدون نشان ترتیب بایت[۳۱] ذخیره شدند تا نویسه پنهان آغاز فایل در خواندن نام ستون یا مقدار عددی اختلال ایجاد نکند. ستون week_no نیز به عدد صحیح تبدیل شد و ردیف‌های فاقد مقدار معتبر برای آن، در فرایند ورود کنار گذاشته شدند. این اقدامات برای سازگاری قالب

---

[۳۱] Byte Order Mark

متن و نوع داده با SQL Server انجام شدند و به معنای تغییر واحد مشاهده یا تعریف شاخص‌های تحلیلی نیستند.

۲-۵ نمایه کمی داده مورد استفاده

جدول ۲-۳ اندازه و پوشش داده تراکنشی مورد استفاده در سامانه را خلاصه می‌کند. هر شاخص با واحد شمارش خود گزارش شده است تا تعداد سطر خرید، سبد، مشتری و محصول با یکدیگر اشتباه نشوند. این مقادیر از جدول‌های اصلی پایگاه داده محاسبه شده‌اند.

جدول ۲-۳ – شاخص‌های کمی داده تراکنشی مورد استفاده

شاخص	مقدار	واحد شمارش	کاربرد تحلیلی
ردیف‌های تراکنش	۲۵۹۵۲۷۷	قلم خرید ثبت‌شده	بررسی مبلغ فروش و جزئیات خرید
سبدهای خرید	۲۷۶۴۵۰	شناسه سبد یکتا	دفعات خرید و میانگین ارزش سبد
خانوارهای خریدار	۲۴۹۷	شناسه خانوار یکتا	جامعه تحلیل رفتار مشتری
محصولات خریداری‌شده	۹۲۳۳۵	شناسه محصول یکتا در خریدها	دامنه کالاهای حاضر در تحلیل

این خریدها در ۵۸۲ فروشگاه و طی روزهای ۱ تا ۷۱۱ ثبت شده‌اند. مجموع مبلغ فروش ۸۰۵۶۰۶۸/۵۲ دلار است. شمار ۲۴۹۷ خانوار بیانگر خانوارهای دارای سابقه خرید در کل این بازه است و لزوماً به معنای خرید اخیر همه آن‌ها نیست. تشخیص کاهش فعالیت یا خطر قطع خرید، به تحلیل زمانی رفتار هر خانوار نیاز دارد.

کنترل داده نشان داد همه شناسه‌های خانوار و محصول در تراکنش‌ها، رکورد مرجع متناظر دارند. در کنار نبود مبلغ فروش منفی، این کنترل از حذف ناخواسته خریدها هنگام پیوند جدول‌ها جلوگیری می‌کند. البته معتبربودن شناسه‌ها به معنای کامل‌بودن ویژگی‌های جمعیت‌شناختی یا نبود هرگونه خطای ثبت نیست و باید همراه با محدودیت‌های توصیفی داده تفسیر شود.

۲-٦ ساختار پایگاه داده و وابستگی جدول‌ها

۲-٦-۱ کلیدها و منطق ارتباط

وابستگی جدول‌ها بر پایه شناسه‌های مشترک شکل گرفته است. کلید اصلی هر رکورد را در جدول خودش یکتا می‌کند و کلید خارجی[۳۲] ارجاع معتبر به جدول والد را برقرار می‌سازد. نتیجه این کنترل، یکپارچگی ارجاعی[۳۳] است، یعنی رکورد فرزند به شناسه‌ای ناموجود در جدول والد اشاره نمی‌کند. در دو پیوند اصلی تراکنش با خانوار و محصول، هیچ رکورد بدون مرجع متناظر مشاهده نشد.

رابطه تراکنش با خانوار در پایگاه داده دارای قید خارجی است، اما ارتباط تراکنش با محصول در پیاده‌سازی فعلی از طریق شناسه مشترک و پرس‌وجو برقرار می‌شود و قید خارجی فیزیکی ندارد. نبود چنین قیدی به معنای نبود وابستگی نیست. product_id همچنان مبنای پیوند با مشخصات محصول است. کنترل داده نیز پوشش کامل شناسه‌های محصول در تراکنش‌ها را تأیید می‌کند.

جدول ۲-۴ – وابستگی میان جدول‌های اصلی و نقش کلیدهای مشترک

جدول وابسته	جدول مرجع	کلید مشترک	نوع رابطه	نقش تحلیلی
تراکنش‌ها	خانوار	**household_key**	چندبه‌یک، قید خارجی	انتساب خرید به یک مشتری
تراکنش‌ها	محصول	**product_id**	چندبه‌یک، رابطه منطقی	افزودن مشخصات و گروه کالا

۲-٦-۲ مسیرهای اصلی پیوند داده

مسیر نخست، اتصال transactions به product با شناسه محصول است. این مسیر گروه و زیرگروه کالا را به خرید اضافه می‌کند و مبنای تحلیل سبد، قوانین انجمنی و پیشنهاد محصول قرار می‌گیرد. مسیر دوم، اتصال transactions به household با شناسه خانوار است. سابقه خرید مشتری با همین شناسه تجمیع می‌شود و مبنای محاسبه تازگی، فراوانی و مبلغ خرید و تحلیل ریزش است. ویژگی‌های جمعیت‌شناختی، شرط حضور مشتری در تحلیل رفتار خرید نیستند.

---

[۳۲] Foreign Key

[۳۳] Referential Integrity

از آنجا که شناسه‌های محصول و خانوار در جدول مرجع یکتا هستند، اتصال هر ردیف تراکنش به آن‌ها نباید تعداد ردیف‌های خرید را افزایش دهد. بااین‌حال، سبد خرید همچنان چندسطره است و برای محاسبه ارزش هر سبد باید مبلغ اقلام همان سبد جمع شود. میانگین مبلغ یک ردیف تراکنش با میانگین ارزش سبد متفاوت است. اولی بر تعداد سطرها و دومی بر تعداد سبدهای یکتا تکیه دارد.

۲-۶-۳ مرز داده پایه و نتایج تحلیلی

داده پایه، سابقه خرید و مشخصات مرجع آن را نگهداری می‌کند. در مقابل، بخش‌بندی مشتری و نتایج آزمایش ریزش خروجی محاسبه روی همین داده‌اند. ذخیره این نتایج برای نمایش هماهنگ در صفحه‌های سامانه ضروری است، اما آن‌ها منبع مستقلی از خرید واقعی نیستند. جدول‌های فنی مدیریت کاربر و نگهداری نتایج محاسباتی و تاریخچه آزمایش‌ها خارج از دامنه شرح این فصل باقی می‌مانند.

۲-۷ کنترل کیفیت و محدودیت‌های داده

۲-۷-۱ پوشش کلیدها و رکوردهای یتیم

بررسی دو پیوند اصلی نشان داد هیچ تراکنش بدون خانوار یا محصول متناظر در پایگاه داده وجود ندارد. این نتیجه برای اتصال جدول‌ها اهمیت دارد، زیرا مانع حذف خرید به علت نبود شناسه مرجع می‌شود. بااین‌حال، صحت شناسه به معنای کامل‌بودن ویژگی‌های توصیفی نیست و اطلاعات جمعیت‌شناختی همچنان فقط برای بخشی از خانوارها موجود است.

۲-۷-۲ داده‌های تهی و طبقه نامشخص

مقادیر تهی به‌ویژه در جدول household باید به‌عنوان نبود اطلاعات تفسیر شوند، نه مقدار صفر یا یک گروه واقعی. در گزارش‌های مقایسه‌ای، بهتر است گروه نامشخص جداگانه نمایش داده شود و درصد پوشش نمونه نیز کنار نتیجه بیاید. برای مثال، نتیجه مربوط به درآمد خانوار فقط درباره خانوارهایی قابل دفاع است که income_desc آن‌ها موجود است و نباید به تمام ۲۴۹۷ مشتری تعمیم داده شود.

۲-۷-۳ ماهیت ناشناس و غیرتقویمی داده

شناسه‌های خانوار، محصول، تولیدکننده و فروشگاه ناشناس‌اند و نام واقعی اشخاص یا کالاها را نشان نمی‌دهند. این ویژگی از نظر حریم خصوصی مناسب است، اما امکان تفسیر بیرونی برخی یافته‌ها را محدود

می‌کند. همچنین day و week_no شاخص‌های نسبی‌اند. بنابراین نسبت‌دادن جهش فروش به یک تعطیلی یا رویداد واقعی، بدون منبع تقویمی مستقل، نتیجه‌گیری قابل اتکایی نیست.

۲-۷-٤ دامنه تعمیم نتیجه‌ها

نتیجه‌های پروژه رفتار ثبت‌شده در همین مجموعه‌داده را توصیف می‌کنند و به‌تنهایی قابل تعمیم به همه فروشگاه‌ها یا همه مشتریان نیستند. نبود خرید در یک بازه نیز فقط به معنای نبود خرید ثبت‌شده در داده است. درباره علت آن یا خرید مشتری از فروشگاه‌های دیگر اطلاعات مستقیمی وجود ندارد. بنابراین، رابطه مشاهده‌شده میان ویژگی‌های خرید و نتیجه آینده نباید بدون شواهد مستقل به‌عنوان رابطه علت و معلولی بیان شود.

۲-۸ شرح ستون‌های فایل‌های منبع

بخش‌های پیشین این فصل نقش هر جدول، مراحل آماده‌سازی و روابط میان جدول‌ها را توضیح دادند. برای آنکه خواننده بتواند بدون مراجعه به فایل‌های منبع معنای دقیق هر ستون را بیابد، در این بخش شرح ستون‌به‌ستون فایل‌های مجموعه‌داده آورده شده است. نام ستون‌ها همان نام‌های فایل منبع‌اند که در مرحله آماده‌سازی به حروف کوچک تبدیل شده‌اند و ترتیب سطرهای هر جدول از ترتیب ستون‌ها در همان فایل پیروی می‌کند. این بخش نقش مرجع دارد و برای مرور سریع ساختار داده در کنار فصل‌های تحلیلی بعد به کار می‌آید.

۲-۸-۱ ستون‌های فایل تراکنش

فایل تراکنش پرحجم‌ترین بخش مجموعه‌داده است و هر سطر آن یک قلم محصول در یک سبد خرید را نشان می‌دهد. جدول ۲–۵ ستون‌های این فایل را با معنای هر یک معرفی می‌کند. سه ستون تخفیف در انتهای جدول، تنها اطلاعات مربوط به کوپن و تبلیغ‌اند که در تحلیل‌های پروژه به کار رفته‌اند.

جدول ۲-۵ - ستون‌های فایل تراکنش و شرح هر یک

نام ستون	شرح ستون
id	کلید اصلی جدول در پایگاه داده که هر ردیف خرید را یکتا می‌کند. این ستون در فایل منبع وجود ندارد و هنگام بارگذاری افزوده شده است.
household_key	شناسه خانوار خریدار و کلید پیوند تراکنش با جدول خانوار. تجمیع سابقه خرید هر مشتری بر پایه همین ستون انجام می‌شود.
basket_id	شناسه سبد خرید. در همه ردیف‌های اقلام یک خرید تکرار می‌شود، بنابراین شمار دفعات خرید باید از شناسه‌های یکتای این ستون به دست آید.
day	شماره روز خرید در بازه ۱ تا ۷۱۱. ترتیب زمانی خریدها را مشخص می‌کند و تاریخ تقویمی واقعی نیست.
product_id	شناسه کالای خریداری‌شده و کلید پیوند با جدول محصول. گروه و زیرگروه کالا از همین مسیر به هر ردیف خرید افزوده می‌شود.
quantity	تعداد یا مقدار کالای خریداری‌شده در همان ردیف. برای کالاهای وزنی می‌تواند مقدار غیرصحیح داشته باشد.
sales_value	مبلغ خالص پرداختی برای همان قلم خرید بر حسب دلار. مبنای همه شاخص‌های فروش گزارش همین ستون است.
store_id	شناسه فروشگاه محل خرید. امکان مقایسه رفتار خرید میان فروشگاه‌های مختلف را فراهم می‌کند.
retail_disc	تخفیف اعمال‌شده از سوی خرده‌فروش روی همان قلم. این ستون معمولاً با علامت منفی ذخیره شده است.
coupon_disc	مبلغ تخفیف ناشی از کوپن مشتری روی همان قلم، با همان قرارداد علامت منفی.
coupon_match_disc	تخفیف تکمیلی تولیدکننده در مواردی که کوپن با تخفیف خرده‌فروشی هم‌زمان می‌شود.
trans_time	زمان ثبت تراکنش به شکل ساعت و دقیقه. برای بررسی الگوی ساعتی خرید به کار می‌رود و تاریخ کامل را نشان نمی‌دهد.
week_no	شماره هفته خرید در بازه ۱ تا ۱۰۲. مبنای تحلیل‌های هفتگی و بررسی روند فروش است.

۲-۸-۲ ستون‌های فایل محصول

فایل محصول برای هر شناسه کالا یک سطر دارد و ویژگی‌های توصیفی آن را نگهداری می‌کند. جدول ۲-۶ ستون‌های این فایل را معرفی می‌کند. سه ستون دپارتمان، گروه کالایی و زیرگروه کالایی یک سلسله‌مراتب سه‌سطحی می‌سازند که تحلیل‌های سبد خرید در سطوح مختلف آن انجام می‌شود.

جدول ۲-۶ – ستون‌های فایل محصول و شرح هر یک

نام ستون	شرح ستون
product_id	شناسه یکتای کالا و کلید پیوند با جدول تراکنش.
manufacturer	کد ناشناس تولیدکننده کالا. نام واقعی سازنده در داده وجود ندارد و این کد تنها برای تفکیک تولیدکنندگان از یکدیگر به کار می‌رود.
department	دپارتمان یا دسته کلان کالا مانند خواربار و دارویی. درشت‌ترین سطح گروه‌بندی محصول است.
brand	نوع نام تجاری با دو مقدار متمایز که کالای برند ملی را از کالای برند فروشگاهی جدا می‌کند. این ستون نام تجاری هر کالا را نشان نمی‌دهد.
commodity_desc	گروه کالایی و سطح میانی طبقه‌بندی محصول. بیشتر تحلیل‌های سبد خرید این گزارش در همین سطح انجام شده است.
sub_commodity_desc	زیرگروه کالایی و ریزترین سطح طبقه‌بندی، برای تفکیک دقیق‌تر اقلام درون یک گروه کالایی.
curr_size_of_product	اندازه یا حجم بسته‌بندی کالا به‌صورت متنی. نوشتار این ستون در آماده‌سازی یکسان‌سازی شده، اما به واحد عددی تبدیل نشده است.

۲-۸-۳ ستون‌های فایل مشخصات خانوار

فایل مشخصات خانوار ویژگی‌های جمعیت‌شناختی مشتری را در اختیار می‌گذارد. جدول ۲-۷ ستون‌های این فایل را معرفی می‌کند. همه این ویژگی‌ها طبقه‌ای‌اند و مقدار پیوسته ندارند. همان‌طور که پیش‌تر گفته شد، این اطلاعات تنها برای ۸۰۳ خانوار از ۲۴۹۷ خانوار موجود ثبت شده است.

جدول ۲-۷ - ستون‌های فایل مشخصات خانوار و شرح هر یک

نام ستون	شرح ستون
household_key	شناسه یکتای خانوار و کلید پیوند با جدول تراکنش‌ها.
age_desc	گروه سنی سرپرست خانوار به‌صورت بازه، مانند ۲۵ تا ۳۴ سال. مقدار عددی دقیق سن در داده وجود ندارد.
marital_status_code	وضعیت تأهل سرپرست خانوار به‌صورت کد طبقه‌ای.
income_desc	بازه درآمد سالانه خانوار. برای بررسی قدرت خرید به کار می‌رود و عدد دقیق درآمد را ارائه نمی‌کند.
homeowner_desc	وضعیت مالکیت مسکن، مانند مالک یا مستأجر.
hh_comp_desc	ترکیب خانوار، مانند زوج بدون فرزند یا خانوار تک‌نفره.
household_size_desc	تعداد اعضای خانوار به‌صورت طبقه و نه عدد پیوسته.
kid_category_desc	وضعیت و شمار فرزندان خانوار.

۲-۹ نقش داده در فصل‌های بعد

شاخص‌های کلی سامانه از شمار ردیف‌های تراکنش، شناسه‌های یکتای سبد، محصول و خانوار و مجموع مبلغ فروش ساخته می‌شوند. پیوند خرید و محصول، مبنای تحلیل سبد و قوانین انجمنی است و توالی روزها برای تحلیل پیش‌بینانه به کار می‌رود. در فصل هشتم، سابقه خرید هر خانوار به ویژگی‌های رفتاری تبدیل می‌شود. ویژگی‌های جمعیت‌شناختی ورودی مدل ریزش فعلی نیستند. بنابراین نبود آن‌ها باعث حذف مشتری از این مدل نمی‌شود.

اشتراک شناسه‌ها میان بخش‌ها باعث می‌شود یک مشتری در نمای بخش‌بندی، تاریخچه ریزش و فهرست ماندگاری قابل پیگیری باشد. تفاوت خروجی این بخش‌ها ناشی از سؤال تحلیلی و بازه محاسبه است. برای نمونه، نمایه کلی مشتری کل سابقه خرید را خلاصه می‌کند، اما تاریخچه ریزش از برش‌های زمانی معین استفاده می‌کند.

۲-۱۰ جمع‌بندی فصل

تحلیل‌های پروژه بر سه مجموعه اصلیِ خرید، محصول و خانوار استوارند. جدول تراکنش با پوشش ۷۱۱ روز، ۲۷۶۴۵۰ سبد، ۲۴۹۷ خانوار و ۹۲۳۳۵ محصول خریداری‌شده، محور تحلیل است. جدول محصول ویژگی‌های توصیفی کالا را در اختیار تحلیل قرار می‌دهد و جدول خانوار، مرجع شناسه مشتری است، هرچند اطلاعات جمعیت‌شناختی برای همه خانوارها موجود نیست.

آماده‌سازی داده شامل هماهنگ‌سازی نام ستون‌ها، مدیریت مقادیر ناشناخته، یکسان‌سازی نوشتار اندازه محصول و سازگارکردن قالب متن و نوع متغیرهای زمانی با پایگاه داده بوده است. کنترل داده مورد استفاده نیز نبود مبلغ فروش منفی و پوشش کامل شناسه‌های خانوار و محصول در تراکنش‌ها را نشان داد. تعدادهای گزارش‌شده در این فصل همگی به همین داده تعلق دارند.

دو ملاحظه در استفاده از این داده اهمیت بیشتری دارند: نخست، تفکیک ردیف تراکنش از سبد و مشتری در محاسبه شاخص‌ها. دوم، پرهیز از تعمیم اطلاعات ناقص جمعیت‌شناختی به همه خانوارها. رعایت این دو نکته و توجه به زمان نسبی داده، مبنای تفسیر درست تحلیل‌های فصل‌های بعد است.

فصل سوم: معرفی سامانه و صفحه اصلی تحلیل

۳-۱ جایگاه صفحه اصلی در سامانه

صفحه /analysis/ پس از ورود کاربر، نخستین صفحه عملیاتی سامانه است. وظیفه این صفحه انجام یک تحلیل تخصصی واحد نیست، بلکه باید در مدت کوتاهی سه سؤال را پاسخ دهد: وضعیت کلی داده چیست، در دوره اخیر چه تغییری رخ داده است و برای بررسی بیشتر باید به کدام بخش مراجعه کرد. به همین علت ساختار صفحه از نمای کلی به جزئیات حرکت می‌کند. ابتدا عنوان داشبورد و هدف آن دیده می‌شود، سپس شاخص‌های کلیدی قرار می‌گیرند، بعد کارت‌های ورود به ابزارها نمایش داده می‌شوند و در انتها نمودار روند بازار قرار دارد.

این ترتیب از نظر منطقی اهمیت دارد. کاربر پیش از مشاهده قوانین انجمنی یا نتایج مدل پیش‌بینی باید مقیاس داده را بداند. مشاهده تعداد رکوردها، تعداد محصولات و تعداد خانوارها، زمینه لازم برای فهم سایر خروجی‌ها را فراهم می‌کند. همچنین نمایش تغییرات دوره‌ای سبب می‌شود کاربر در همان ابتدا متوجه شود کدام شاخص نسبت به دوره پیش رشد یا افت داشته و در ادامه چه موضوعی نیازمند بررسی بیشتر است.

۳-۲ کنترل دسترسی و ورود به سامانه

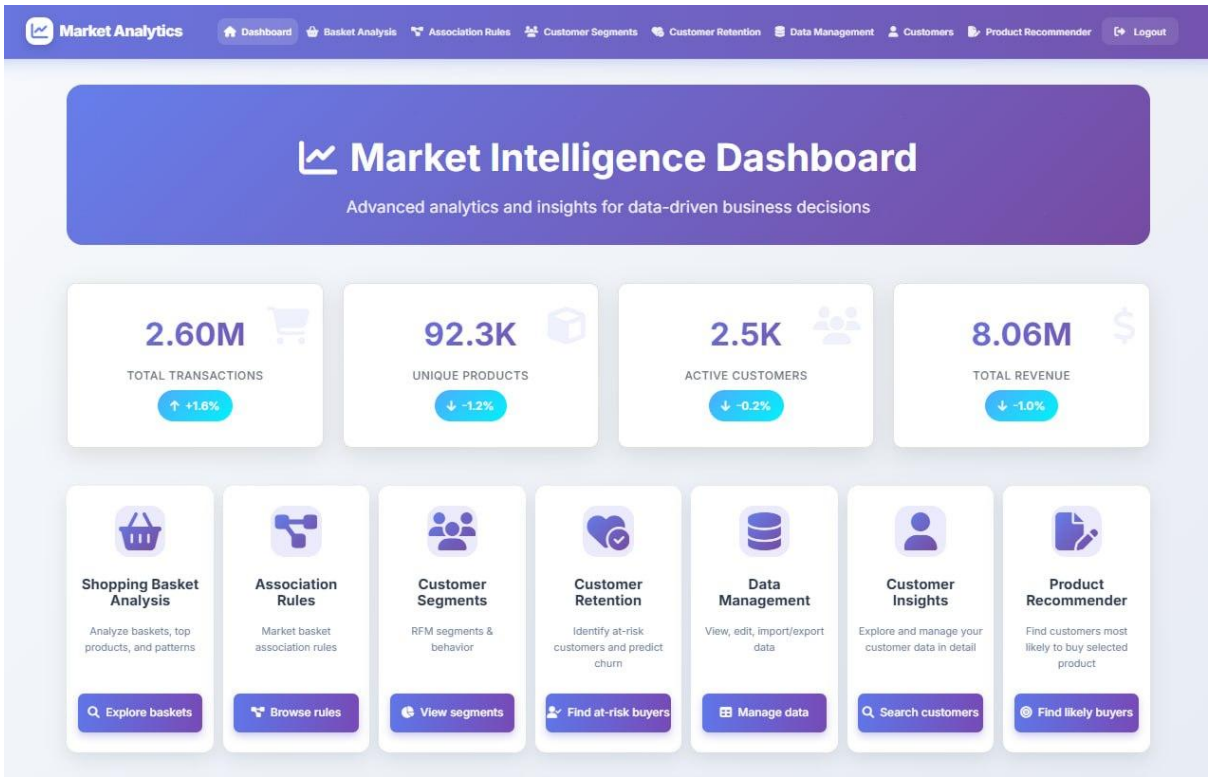
دسترسی به صفحه اصلی برای کاربران عادی باز نیست و ورود با حساب دارای سطح مدیریتی انجام می‌شود. اگر کاربر بدون نشست معتبر نشانی صفحه را باز کند، به صفحه ورود هدایت می‌شود. پس از تأیید نام کاربری و گذرواژه، یک نشست محدود ایجاد می‌شود که در وضعیت فعلی یک ساعت اعتبار دارد. هدف این محدودیت آن است که صفحه‌های مدیریت داده، نتایج مشتریان و ابزارهای تحلیلی در اختیار کاربر ناشناس قرار نگیرند.

کنترل دسترسی در این پروژه فقط یک گزینه ظاهری نیست. بعضی بخش‌ها امکان مشاهده جزئیات خانوار، ویرایش یا خروجی‌گرفتن از داده و اجرای تحلیل را دارند. بنابراین نقطه ورود باید مشخص و قابل کنترل باشد. وجود گزینه خروج در نوار بالای صفحه نیز به کاربر اجازه می‌دهد نشست خود را به شکل روشن پایان دهد. در گزارش بخش‌های بعد، دسترسی هر صفحه متناسب با وظیفه همان صفحه توضیح داده خواهد شد.

۳-۳ ساختار دیداری و اجزای صفحه

در بالاترین قسمت صفحه، نوار ناوبری قرار دارد. نام سامانه در سمت چپ، گزینه خروج و کلید بازکردن فهرست در سمت دیگر دیده می‌شود. زیر این نوار، یک بخش معرفی با زمینه طیفی قرار گرفته که عنوان Market Intelligence Dashboard و توضیح کوتاه مربوط به تحلیل داده‌محور را نمایش می‌دهد. هدف این بخش آن است که کاربر از همان ابتدا بداند با یک پنل مدیریتی و تحلیلی روبه‌رو است.

در ردیف بعد چهار کارت شاخص دیده می‌شود. عدد اصلی هر کارت با اندازه بزرگ نمایش داده شده و زیر آن عنوان شاخص و درصد تغییر دوره‌ای قرار دارد. رنگ و جهت پیکان، مثبت یا منفی‌بودن تغییر را مشخص می‌کند. پس از شاخص‌ها، کارت‌های ابزارهای تحلیلی قرار گرفته‌اند. هر کارت یک نماد، عنوان، شرح یک‌خطی و یک دکمه عملی دارد. این طراحی باعث می‌شود کاربر قبل از ورود به صفحه بعد، هدف آن صفحه را به صورت خلاصه بداند. شکل ۳-۱ نمای بخش بالایی صفحه را نشان می‌دهد.



شکل ۳-۱ – نمای بخش بالایی صفحه اصلی سامانه تحلیل بازار

در پایین صفحه، بخش روند بازار و سپس اطلاعات دانشگاه و سامانه قرار می‌گیرد. پابرگ[۳۴] علاوه بر معرفی دانشگاه کاشان و گروه مهندسی کامپیوتر، ماهیت پروژه که مرتبط با دانشگاه است را نیز مشخص می‌کند. در مجموع، اجزای صفحه به گونه‌ای چیده شده‌اند که ابتدا خلاصه داده، سپس مسیرهای تحلیل و در پایان نمودار روند زمانی ارائه شود.

۳-٤ شاخص‌های کلیدی صفحه اصلی

شاخص‌های صفحه اصلی دو نوع اطلاعات را کنار هم قرار می‌دهند. عدد بزرگ هر کارت وضعیت کل داده موجود را نشان می‌دهد، اما درصد زیر آن فقط به مقایسه دو بازه ۶۰ روزه آخر مربوط است. آخرین بازه از روز ۶۵۲ تا ۷۱۱ مجموعه‌داده و بازه قبل از آن از روز ۵۹۲ تا ۶۵۱ را پوشش و مورد مقایسه قرار می‌دهد. بنابراین درصد تغییر نباید با تغییر کل دوره ۷۱۱ روزه اشتباه گرفته شود.

جدول ۳-۱ – تعریف و مقدار شاخص‌های اصلی صفحه نخست

شاخص	مقدار کل	تغییر ۶۰روزه	مبنای محاسبه
رکوردهای تراکنشی	۲۵۹۵۲۷۷	+۱/۶٪	تعداد همه ردیف‌های ثبت‌شده در جدول تراکنش
محصولات یکتا	۹۲۳۳۵	−۱/۲٪	تعداد شناسه‌های متمایز محصول که در خریدها دیده شده‌اند
خانوارهای فعال	۲۴۹۷	−۰/۲٪	تعداد شناسه‌های متمایز خانوار دارای سابقه خرید
درآمد کل	۸۰۵۶۰۶۸/۵۲	−۱٪	مجموع مبلغ فروش ثبت‌شده در همه ردیف‌ها

نکته: واژه «مشتری» در رابط کاربری به شناسه خانوار اشاره دارد و نماینده یک فرد مشخص نیست.

۳-٤-۱ رکوردهای تراکنشی

این شاخص اندازه جدول تراکنش را نشان می‌دهد و برای بیان مقیاس داده مفید است. در آخرین بازه ۶۰ روزه ۲۵۱۳۸۲ ردیف و در بازه پیشین ۲۴۷۴۰۷ ردیف ثبت شده است. در نتیجه تغییر ۱/۶ درصدی مثبت به دست می‌آید. از آنجا که یک سبد می‌تواند چند قلم داشته باشد، این عدد با تعداد مراجعات خرید یکسان

[۳۴] Footer

نیست. برای شناخت تعداد سبدها باید شناسه‌های مستقل سبد شمارش شوند که در بخش تحلیل سبد خرید انجام می‌شود.

۳-٤-۲ محصولات یکتا

عدد ۹۲۳۳۵ بیانگر محصولاتی است که دست‌کم در یک رکورد تراکنشی مشاهده شده‌اند. این تعریف با تعداد کل اقلام موجود در فهرست محصول تفاوت دارد، زیرا ممکن است برخی محصولات در دوره داده هیچ فروش ثبت‌شده‌ای نداشته باشند. در دو بازه مورد مقایسه، تعداد محصولات مشاهده‌شده از ۳۲۴۰۳ به ۳۲۰۰۹ رسیده و ۱/۲ درصد کاهش یافته است.

۳-٤-۳ خانوارهای فعال

در مجموعه‌داده دان‌هامبی واحد اصلی شناخت مشتری، خانوار است. شاخص خانوار فعال تعداد شناسه‌های متمایزی را می‌شمارد که در داده تراکنشی حضور دارند. مقدار کل آن ۲۴۹۷ است. در بازه اخیر ۲۲۳۷ خانوار و در بازه پیشین ۲۲۴۱ خانوار خرید داشته‌اند. بنابراین تغییر ۰/۲ درصدی منفی بسیار کوچک است و به تنهایی نشانه یک افت جدی محسوب نمی‌شود. برای بررسی ماندگاری باید سابقه هر خانوار، فاصله از آخرین خرید و الگوی تکرار خرید نیز در نظر گرفته شود.

۳-٤-٤ درآمد کل

درآمد کل از جمع مبلغ فروش تمام ردیف‌های تراکنش حاصل می‌شود. مقدار کل برابر ۸۰۵۶۰۶۸/۵۲ واحد پولی ثبت‌شده در داده است. درآمد بازه اخیر ۷۸۷۱۱۶/۹۵ و درآمد بازه پیشین ۷۹۴۹۹۱/۹۲ بوده و یک درصد کاهش نشان می‌دهد. قرارگرفتن این کاهش در کنار افزایش تعداد رکوردها اهمیت دارد، زیرا نشان می‌دهد تعداد ثبت بیشتر الزاماً به معنای ارزش فروش بالاتر نیست و ممکن است ترکیب خرید به سمت اقلام ارزان‌تر یا تعداد بیشتر اقلام کم‌ارزش حرکت کرده باشد.

۳-٤-۵ منطق مقایسه دوره‌ای

استفاده از دو پنجره هم‌اندازه باعث می‌شود تغییر شاخص‌ها تحت تأثیر تفاوت طول دوره قرار نگیرد. آخرین روز داده به عنوان انتهای دوره اخیر در نظر گرفته می‌شود و دو بازه ۶۰ روزه پشت سر هم ساخته

می‌شوند. این روش برای هشدار اولیه مناسب است، اما اثر فصل، تعطیلات و تغییرات کوتاه‌مدت را جدا نمی‌کند. به همین دلیل درصدهای صفحه اصلی نقش نشانه را دارند و نتیجه نهایی تحلیل نیستند.

۳-۵ مسیرهای دسترسی به بخش‌های تحلیلی

کارت‌های میانی صفحه اصلی نقش فهرست عملیاتی سامانه را دارند. عنوان و توضیح هر کارت به کاربر می‌گوید صفحه بعد چه پرسشی را پاسخ می‌دهد. در نسخه فعلی هفت مسیر اصلی وجود دارد که در ادامه هدف هر یک توضیح داده می‌شود و در ادامه این گزارش به تفصیل هریک در فصل‌های مرتبط خود شرح بیشتری داده خواهند شد:

۳-۵-۱ تحلیل سبد خرید

این بخش ساختار هر سبد را از نظر تعداد اقلام، ارزش خرید، محصولات پرتکرار و ترکیب گروه‌های کالایی بررسی می‌کند. هدف آن پاسخ به پرسش‌هایی مانند «سبدهای بزرگ چه ویژگی‌ای دارند؟»، «کدام محصولات بیشتر دیده می‌شوند؟»، «کدام محصولات بیشتر در آینده سود بیشتری برای فروش دارند ؟» و «رفتار خرید در دوره‌های مختلف چه تفاوتی دارد؟» است. این صفحه پایه تحلیل‌های بعدی محسوب می‌شود.

۳-۵-۲ قوانین انجمنی

قوانین انجمنی رابطه هم‌زمانی کالاها را نشان می‌دهند. خروجی این بخش به صورت رابطه «اگر محصول یا گروهی در سبد باشد، چه محصول دیگری بیشتر از حالت عادی همراه آن دیده می‌شود» تفسیر می‌شود. برای جلوگیری از نتیجه‌گیری سطحی، فراوانی، اطمینان[۳۵] و میزان بهبود[۳۶] رابطه هم‌زمان بررسی می‌شوند. کاربرد اصلی آن یافتن محصولات مکمل، بهبود چیدمان و طراحی پیشنهادهای فروش متقابل[۳۷] است.

۳-۵-۳ بخش‌بندی مشتریان

در این صفحه خانوارها بر اساس سه مؤلفه تازگی خرید، دفعات خرید و ارزش پولی خرید خلاصه می‌شوند. نتیجه، گروه‌هایی مانند مشتریان باارزش، فعال، در معرض کاهش فعالیت یا کم‌تکرار را از یکدیگر

---

[۳۵] Confidence

[۳۶] Lift

[۳۷] Cross-selling

جدا می‌کند. هدف بخش‌بندی این نیست که برای هر مشتری یک برچسب دائمی ساخته شود. برچسب با اضافه‌شدن خریدهای جدید می‌تواند تغییر کند و باید به عنوان خلاصه‌ای از وضعیت فعلی در نظر گرفته شود.

۳-۵-٤ ماندگاری مشتری

بخش ماندگاری، سابقه زمانی خرید خانوار را بررسی می‌کند تا مشتریانی را که احتمال کاهش فعالیت یا ریزش دارند شناسایی کند. نتیجه این بخش برای اولویت‌بندی پیگیری مشتریان از نظر شدت خطر ریزش است تا بتوان با توجه به این موضوع پیشنهادهای شخصی‌سازی شده مناسب به این افراد داده شود و آنها را به عنوان مشتری فروشگاه حفظ کرد.

۳-۵-۵ مدیریت داده

این قسمت برای مشاهده ساختار جدول‌ها، مرور رکوردها، ورود یا خروج داده و انجام تغییرات کنترل‌شده در نظر گرفته شده است. هدف اصلی آن جداکردن عملیات داده از صفحات تحلیل است. کاربر پیش از تغییر باید جدول و رکورد هدف را مشخص کند و سامانه نیز محدودیت‌های هر جدول را در نظر می‌گیرد. جدول‌های تحلیلی که از محاسبات به دست می‌آیند با داده‌های اصلی یکسان تلقی نمی‌شوند و برخی از آن‌ها فقط برای مشاهده در دسترس هستند.

۳-۵-٦ اطلاعات و جست‌وجوی مشتری

این مسیر برای رسیدن از نمای کلی به یک خانوار مشخص است. کاربر می‌تواند شناسه خانوار را جست‌وجو کند و سابقه خرید، سبدها، محصولات، وضعیت بخش‌بندی و در صورت نیاز پیشنهادهای مرتبط را مشاهده نماید. در نتیجه، شاخص‌های سطح کلان صفحه اصلی با سابقه جزئی هر خانوار پیوند می‌خورند. این صفحه برای بررسی نمونه‌ها و کنترل منطقی نتایج مدل نیز کاربرد دارد.

۳-۵-۷ پیشنهاددهنده محصول

در پیشنهاددهنده، مسئله از سمت محصول مطرح می‌شود: برای یک محصول انتخاب‌شده، کدام مشتریان احتمال بیشتری برای خرید دارند؟ خروجی می‌تواند در طراحی یک پیشنهاد هدفمند استفاده شود، اما باید همراه با امتیاز اطمینان و سابقه خرید تفسیر گردد. تفاوت این بخش با قوانین انجمنی آن است که قانون انجمنی رابطه میان کالاها را بررسی می‌کند، در حالی که پیشنهاددهنده تلاش می‌کند ارتباط محصول و مشتری را اولویت‌بندی کند.

۳-٦ نمودار روند بازار

پایین صفحه اصلی یک نمودار خطی برای مرور روند بازار قرار دارد. داده نمودار به دوازده دوره ۳۰روزه تقسیم می‌شود و دو مقدار را کنار هم نمایش می‌دهد: حجم فروش و تعداد مشتریان یکتا. استفاده از دو محور عمودی اجازه می‌دهد دو شاخص با مقیاس متفاوت در یک نمودار دیده شوند. هدف نمودار، نشان‌دادن جهت کلی و نقاط تغییر است، نه ارائه جزئیات محصول یا فروشگاه.

اگر کاربر در نمودار یک افزایش یا افت غیرعادی مشاهده کند، ادامه بررسی باید در صفحه تخصصی انجام شود. برای مثال، افت فروش همراه با ثابت‌ماندن تعداد مشتریان می‌تواند از کاهش ارزش متوسط خرید ناشی شود، در حالی که افت هم‌زمان هر دو شاخص ممکن است به کاهش فعالیت خانوارها مربوط باشد. این برداشت‌ها فرضیه اولیه هستند و برای تأیید باید سبدها، گروه‌های کالایی، تخفیف‌ها و دوره‌های زمانی بررسی شوند.

۳-۷ تعامل کاربر و طراحی واکنش‌گرا

اعداد شاخص‌ها هنگام بازشدن صفحه به صورت تدریجی تا مقدار نهایی افزایش می‌یابند و کارت‌ها در زمان قرارگرفتن نشانگر تغییر ظاهری کوتاهی دارند. این حرکت‌ها برای جلب توجه به عناصر قابل انتخاب استفاده شده‌اند و در منطق محاسبه دخالتی ندارند. صفحه در عرض‌های مختلف نیز چیدمان خود را تغییر می‌دهد. کارت‌های چهارتایی و پنج‌تایی در نمایشگر کوچک به دو ستون یا یک ستون تبدیل می‌شوند تا متن و دکمه‌ها فشرده و ناخوانا نشوند.

از نظر تجربه کاربر، مهم‌ترین نکته این است که تعداد زیاد قابلیت‌ها مسیر شروع را مبهم نکند. عنوان روشن ابزارها و نوار ناوبری، دسترسی دوباره به بخش‌ها را ساده می‌کنند.

۳-۸ ملاحظات تفسیری

برای استفاده درست از صفحه اصلی چند نکته باید همواره در نظر گرفته شود. نخست، اعداد بزرگ کارت‌ها مربوط به کل داده هستند، اما درصدها فقط دو دوره اخیر را مقایسه می‌کنند. دوم، «مشتری فعال» در این داده به معنای خانوار دارای رکورد خرید است و نباید با تعداد افراد برابر گرفته شود. سوم، «محصول یکتا» به محصول مشاهده‌شده در تراکنش اشاره دارد، نه همه محصولات ممکن در فهرست کالا. چهارم، افزایش

تعداد رکوردهای تراکنشی می‌تواند از بیشترشدن اقلام هر سبد نیز ناشی شود و لزوماً تعداد مراجعه یا درآمد را افزایش نمی‌دهد.

همچنین درصد تغییر کوچک بدون بررسی اندازه پایه، الگوی فصلی و نوسان طبیعی داده نباید به عنوان هشدار قطعی بیان شود. صفحه اصلی برای نشان دادن برخی هشدارهای اولیه و انتخاب مسیر تحلیل طراحی شده است. نتیجه معتبر زمانی به دست می‌آید که شاخص‌های جزئی و تحلیل تخصصی در صفحات مخصوص به خود در همان موضوع بررسی شود.

۳-۹ جمع‌بندی فصل

صفحه اصلی حلقه اتصال بخش‌های مختلف پروژه است. این صفحه با نمایش مقیاس داده، تغییرات کوتاه‌مدت، مسیرهای تحلیلی و روند زمانی، تصویری فشرده از سامانه فراهم می‌کند. مهم‌ترین ویژگی آن تفکیک میان «مشاهده وضعیت» و «تحلیل علت» است: شاخص‌ها وضعیت را نشان می‌دهند و کارت‌ها کاربر را برای بررسی علت به صفحه مناسب هدایت می‌کنند. در فصل‌های بعد، منطق هر یک از این صفحه‌ها و نحوه تفسیر خروجی آن‌ها به صورت مستقل بررسی خواهد شد.

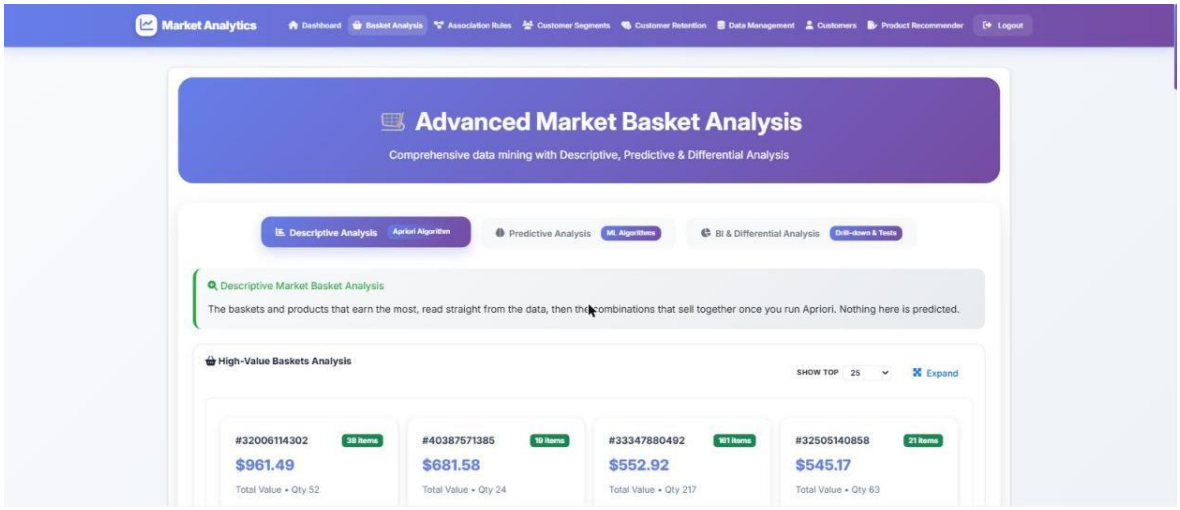
فصل چهارم: تحلیل توصیفی سبد خرید

٤-١ جایگاه صفحه تحلیل سبد خرید در سامانه

صفحه تحلیل سبد خرید در نشانی داخلی /analysis/basket-analysis/ قرار دارد و دومین لایه سامانه پس از صفحه اصلی است. در فصل سوم گفته شد که صفحه اصلی تنها وضعیت کلی داده را نشان می‌دهد و کاربر را به بخش مناسب هدایت می‌کند. صفحه تحلیل سبد خرید نخستین جایی است که کاربر از سطح «چقدر داده داریم» به سطح «ساختار خرید چگونه است» وارد می‌شود. پرسش‌های این صفحه مشخص هستند: یک سبد خرید از چند قلم تشکیل می‌شود، کدام سبدها و کدام محصولات بیشترین ارزش را ایجاد می‌کنند و کدام کالاها بیشتر از حالت تصادفی با یکدیگر در یک سبد دیده می‌شوند. دسترسی به این صفحه نیز مانند سایر صفحه‌های تحلیلی نیازمند ورود با حساب دارای سطح مدیریتی است و کاربر بدون نشست معتبر به صفحه ورود هدایت می‌شود.

این صفحه سه سربرگ دارد. سربرگ نخست با عنوان تحلیل توصیفی به وضعیت موجود داده می‌پردازد و الگوریتم Apriori را برای استخراج قوانین انجمنی اجرا می‌کند. سربرگ دوم با عنوان تحلیل پیش‌بینانه از مدل‌های یادگیری ماشین برای پیش‌بینی خرید دوباره و پیش‌بینی درآمد محصول استفاده می‌کند. سربرگ سوم شامل داشبورد هوش تجاری و تحلیل تفاضلی است و مقایسه گروه‌ها و آزمون‌های آماری را انجام می‌دهد. موضوع این فصل تنها سربرگ نخست است و دو سربرگ دیگر در فصل‌های بعدی گزارش بررسی می‌شوند.

جداسازی این سه سربرگ یک تصمیم طراحی آگاهانه است و نه صرفاً یک تقسیم‌بندی ظاهری. خروجی تحلیل توصیفی مستقیماً از داده ثبت‌شده به دست می‌آید و هیچ مقداری در آن پیش‌بینی نمی‌شود، در حالی که خروجی سربرگ پیش‌بینانه حاصل یک مدل آموزش‌دیده است و خطای مدل را به همراه دارد. اگر این دو نوع خروجی در یک صفحه و با ظاهر یکسان نمایش داده شوند، کاربر ممکن است عدد مشاهده‌شده و عدد پیش‌بینی‌شده را هم‌ارز تلقی کند. به همین دلیل در کارت معرفی سربرگ توصیفی صریحاً نوشته شده است که هیچ‌یک از اعداد این بخش پیش‌بینی نیستند.



شکل ۴-۱ – نمای بالای صفحه تحلیل سبد خرید و سربرگ تحلیل توصیفی

٤-۲ واحدهای تحلیل و تعریف‌های پایه

پیش از توضیح اجزای صفحه لازم است واحدهای تحلیل روشن شوند، زیرا بیشتر خطاهای تفسیری در این بخش از یکسان‌گرفتن این واحدها ناشی می‌شود. کوچک‌ترین واحد داده، ردیف تراکنش است. هر ردیف یک قلم خریداری‌شده را با مقدار، مبلغ فروش، روز خرید و شناسه فروشگاه ثبت می‌کند. مجموعه ردیف‌هایی که شناسه سبد یکسان دارند یک سبد خرید را می‌سازند و هر سبد نماینده یک مراجعه خرید است. هر سبد به یک خانوار تعلق دارد و هر خانوار می‌تواند در طول دوره داده سبدهای متعددی داشته باشد.

در سمت کالا نیز سه سطح وجود دارد. پایین‌ترین سطح، محصول است که با شناسه یکتا مشخص می‌شود. سطح میانی، کالا یا شرح کالایی است که محصولات هم‌ماهیت را در یک عنوان جمع می‌کند. برای نمونه عنوان FLUID MILK PRODUCTS همه انواع شیر مایع را در بر می‌گیرد. بالاترین سطح، گروه کالایی یا بخش فروشگاه است که تعداد آن محدود و در حدود چهل عنوان مانند GROCERY، PRODUCE، MEAT و DRUG GM است. این سه سطح در ادامه فصل نقش مهمی دارند، زیرا استخراج قانون انجمنی تنها در سطح محصول به علت پراکندگی زیاد نتیجه کافی و دقیقی نمی‌دهد و باید در سطح‌های بالاتر هم استخراج قانون انجمنی انجام شود.

تفاوت میان ردیف تراکنش و سبد با عدد نیز روشن می‌شود. در داده فعلی ۲۵۹۵۲۷۷ ردیف تراکنشی ثبت شده است، در حالی که تعداد سبدهای متمایز ۲۷۶۴۵۰ است. بنابراین شاخص «تعداد رکوردهای تراکنشی» که در صفحه اصلی نمایش داده می‌شد، تقریباً نُه برابر تعداد مراجعات خرید است و این دو عدد به هیچ وجه جای یکدیگر را نمی‌گیرند.

٤-۳ ساختار سربرگ تحلیل توصیفی

سربرگ تحلیل توصیفی از هفت جزء تشکیل شده است که به ترتیب از بالا به پایین قرار گرفته‌اند. این ترتیب از یک منطق ساده پیروی می‌کند: نخست آنچه مستقیماً در داده وجود دارد نمایش داده می‌شود، سپس ابزار لازم برای استخراج الگو در اختیار کاربر قرار می‌گیرد و در پایان الگوهای استخراج‌شده ارائه می‌شوند. به بیان دیگر، کاربر ابتدا داده را می‌بیند، بعد پارامتر را تنظیم می‌کند و در آخر نتیجه را می‌خواند. جدول ۴-۱ این اجزا و پرسشی را که هر یک پاسخ می‌دهد نشان می‌دهد.

جدول ۴-۱ - اجزای سربرگ تحلیل توصیفی و هدف هر جزء

جزء صفحه	پرسشی که پاسخ می‌دهد	نوع خروجی
سبدهای پرارزش	کدام مراجعات خرید بیشترین ارزش را داشته‌اند؟	مشاهده مستقیم داده
محصولات پرارزش	کدام محصولات پرتکرارترین یا پرفروش‌ترین هستند؟	مشاهده مستقیم داده
تنظیم پارامترها	تحلیل روی چه دوره‌ای و با چه سخت‌گیری انجام شود؟	ورودی کاربر
اجرای Apriori	الگوها با تنظیم فعلی استخراج شوند.	اجرای الگوریتم
شاخص‌های چهارگانه	مقیاس داده و کیفیت کلی نتیجه چیست؟	خلاصه وضعیت
قوانین سطح گروه کالایی	کدام بخش‌های فروشگاه با هم خرید می‌شوند؟	الگوی استخراج‌شده
قوانین سطح کالا	کدام کالاها با هم خرید می‌شوند؟	الگوی استخراج‌شده

نکته قابل توجه این است که دو جزء نخست بدون هیچ محاسبه‌ای از سوی کاربر و به محض بازشدن صفحه آماده هستند، اما چهار جزء آخر تا زمانی که کاربر دکمه اجرا را نزند خالی می‌مانند. این جداسازی عمدی است، زیرا محاسبه قوانین انجمنی روی دو و نیم میلیون ردیف عملیات سنگینی است و اجرای خودکار آن در هر بار بازکردن صفحه، زمان پاسخ صفحه را به شکل غیرقابل قبولی افزایش می‌دهد.

٤-٤ بخش سبدهای پرارزش

٤-٤-١ منطق محاسبه و مرتب‌سازی

در این بخش، رکوردهای تراکنش بر اساس شناسه سبد و شناسه خانوار گروه‌بندی می‌شوند و برای هر سبد چهار مقدار محاسبه می‌گردد: مجموع مبلغ فروش، مجموع مقدار اقلام، تعداد محصولات متمایز و تعداد ردیف‌های ثبت‌شده. سپس سبدها بر اساس مجموع مبلغ فروش به صورت نزولی مرتب می‌شوند و تعداد مشخصی از بالاترین‌ها به کاربر نمایش داده می‌شود. مرتب‌سازی بر مبنای ارزش انتخاب شده است، نه بر مبنای تعداد اقلام، زیرا هدف این بخش شناخت مراجعاتی است که بیشترین سهم را در درآمد داشته‌اند.

هر سبد در قالب یک کارت نمایش داده می‌شود که شناسه سبد، تعداد محصولات متمایز، مبلغ کل و مقدار کل اقلام را در بر دارد. تفکیک «تعداد محصولات متمایز» از «مقدار کل اقلام» اهمیت دارد. برای نمونه، پرارزش‌ترین سبد داده با شناسه ۳۲۰۰۶۱۱۴۳۰۲ مبلغ ۹۶۱/۴۹ واحد پولی دارد و شامل ۳۸ محصول متمایز و در مجموع ۵۲ قلم است، در حالی که سبد ۳۳۳۴۷۸۸۰۴۹۲ با ۱۶۱ محصول متمایز و ۲۱۷ قلم تنها ۵۵۲/۹۲ واحد ارزش دارد. مقایسه این دو سبد نشان می‌دهد ارزش بالای یک سبد لزوماً از تعداد زیاد اقلام ناشی نمی‌شود و ترکیب کالاها و قیمت واحد آن‌ها نقش تعیین‌کننده‌ای دارد.

٤-٤-٢ اندازه فهرست و صفحه‌بندی

تعداد سبدهای بازیابی‌شده با یک انتخابگر در بالای همین بخش کنترل می‌شود و کاربر می‌تواند یکی از مقادیر ۲۵، ۵۰، ۱۰۰ یا ۲۰۰ را برگزیند. مقدار پیش‌فرض ۲۵ است.

نمایش این فهرست به صورت صفحه‌بندی‌شده انجام می‌شود و تعداد کارت‌های هر صفحه بر اساس عرض نمایشگر میان دو تا هشت کارت تغییر می‌کند. علاوه بر آن، دکمه گسترش، همه اقلام فهرست را در یک پنجره جداگانه و بدون صفحه‌بندی[۳۸] نشان می‌دهد. هدف این دو قابلیت آن است که فهرست طولانی، ادامه صفحه را از دید کاربر پنهان نکند و در عین حال امکان مرور کامل نیز از بین نرود.

٤-٤-٣ ملاحظه تفسیری

سبدهای پرارزش نماینده رفتار عمومی مشتریان نیستند. این فهرست به تعریف خود، دنباله راست توزیع ارزش سبد را نشان می‌دهد و تعداد آن در برابر ۲۷۶۴۵۰ سبد موجود بسیار اندک است. بنابراین نتیجه‌گیری درباره الگوی خرید عمومی از روی این کارت‌ها نادرست است. کاربرد درست این بخش، شناسایی موارد

---

[۳۸] Pagination

استثنایی برای بررسی جداگانه و کنترل صحت داده است. برای نمونه سبدی با تعداد اقلام بسیار زیاد می‌تواند نشانه یک خرید عمده یا یک خطای ثبت باشد.

٤-٥ بخش محصولات پرارزش

٤-٥-١ دو معیار رتبه‌بندی و دلیل نمایش هم‌زمان آن‌ها

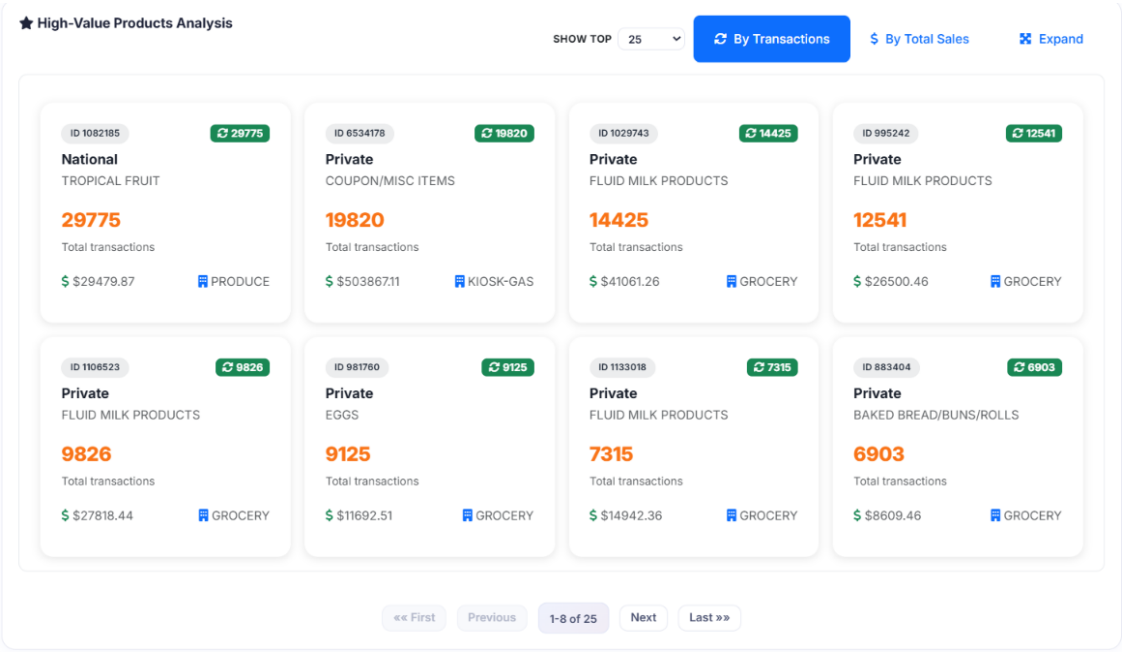
در این بخش، رکوردهای تراکنش بر اساس شناسه محصول گروه‌بندی می‌شوند و برای هر محصول تعداد ردیف‌های ثبت‌شده، مجموع مبلغ فروش و مجموع مقدار فروخته‌شده محاسبه می‌گردد. سپس دو فهرست جداگانه ساخته می‌شود: یکی بر اساس تعداد تراکنش و دیگری بر اساس مجموع فروش. کاربر می‌تواند با یک کلید دوحالته میان این دو نما جابه‌جا شود.

دلیل نمایش هم‌زمان این دو رتبه‌بندی با نگاه به داده روشن می‌شود. محصول ۱۰۸۲۱۸۵ از گروه PRODUCE و با شرح کالایی TROPICAL FRUIT با ۲۹۷۷۵ تراکنش در جایگاه نخست فهرست پرتکرارها قرار دارد، اما مجموع فروش آن تنها ۲۹۴۷۹/۸۷ واحد است. در مقابل محصول ۶۵۳۴۱۷۸ با ۱۹۸۲۰ تراکنش در جایگاه دوم پرتکرارها است، ولی مجموع فروش آن به ۵۰۳۸۶۷/۱۱ واحد می‌رسد و صدر فهرست پرفروش‌ها را در اختیار دارد. اگر تنها یکی از این دو معیار نمایش داده می‌شد، تصویری ناقص از اهمیت محصولات به دست می‌آمد. جدول ۴-۲ چند نمونه از این تفاوت را نشان می‌دهد.

جدول ۴-۲ – نمونه‌هایی از تفاوت رتبه‌بندی محصولات بر اساس تکرار و بر اساس ارزش فروش

شناسه محصول	شرح کالایی و گروه	تعداد تراکنش	مجموع فروش
۱۰۸۲۱۸۵	TROPICAL FRUIT از PRODUCE	۲۹۷۷۵	۲۹۴۷۹/۸۷
۶۵۳۴۱۷۸	COUPON/MISC ITEMS از KIOSK-GAS	۱۹۸۲۰	۵۰۳۸۶۷/۱۱
۱۰۲۹۷۴۳	FLUID MILK PRODUCTS از GROCERY	۱۴۴۲۵	۴۱۰۶۱/۲۶
۶۵۳۳۸۸۹	COUPON/MISC ITEMS از MISC SALES TRAN	۱۴۵۳	۴۶۳۱۱/۳۲

ردیف آخر جدول نمونه گویایی است. محصول ۶۵۳۳۸۸۹ تنها ۱۴۵۳ بار در تراکنش‌ها دیده شده و در فهرست ۲۵ محصول پرتکرارها جایی ندارد، اما به دلیل ارزش بالای هر ثبت، در فهرست ۲۵ محصول پرفروش در رتبه‌های نخست قرار می‌گیرد. در عین حال باید توجه داشت که دو محصول از جدول بالا از گروه‌های KIOSK-GAS و MISC SALES TRAN هستند و ماهیت آن‌ها ثبت مالی یا کوپن است، نه یک کالای مصرفی معمول.



شکل ۴-۲ – بخش محصولات پرارزش با نمای مرتب‌شده بر اساس تعداد تراکنش

۴-۵-۲ غنی‌سازی اطلاعات محصول

خروجی مستقیم پرس‌وجوی تجمیع، تنها شناسه عددی محصول را در اختیار می‌گذارد و این شناسه برای کاربر معنایی ندارد. به همین دلیل پس از تعیین فهرست محصولات برتر، اطلاعات توصیفی آن‌ها شامل برند، گروه کالایی، شرح کالایی، شرح زیرکالایی و شناسه تولیدکننده در یک پرس‌وجوی جداگانه بازیابی و به رکوردها افزوده می‌شود. انجام این کار در یک پرس‌وجو برای همه محصولات فهرست، به جای یک پرس‌وجو به ازای هر محصول، از افت محسوس کارایی جلوگیری می‌کند.

برای محصولاتی که رکورد متناظر در جدول محصول ندارند مقادیر جایگزین در نظر گرفته شده است تا کارت محصول بدون عنوان نماند. این حالت در داده دان‌هامبی رخ می‌دهد، زیرا برخی شناسه‌های موجود در تراکنش در فهرست محصولات ثبت نشده‌اند. نمایش صریح این موارد به جای حذف آن‌ها، به کاربر اجازه می‌دهد از وجود چنین رکوردهایی آگاه شود.

٤-٥-٣ نمای جزئیات محصول

با انتخاب هر کارت محصول، پنجره‌ای باز می‌شود که علاوه بر مشخصات محصول، مجموع فروش، تعداد تراکنش، تعداد خانوارهای خریدار و ارزش هر واحد فروش را نمایش می‌دهد. این نما پیوند میان سطح کلان و سطح جزئی است: کاربر از یک فهرست تجمیعی به سابقه یک محصول مشخص می‌رسد و می‌تواند صحت برداشت خود را کنترل کند.

٤-٦ تنظیم پارامترها و اجرای الگوریتم

بخش تنظیمات در دو گام طراحی شده است. گام نخست انتخاب چهار پارامتر و گام دوم اجرای الگوریتم است. این تفکیک باعث می‌شود کاربر پیش از اجرای یک عملیات زمان‌بر، تنظیم خود را یک‌بار مرور کند. کنار عنوان گام نخست یک راهنمای کوتاه قرار دارد که معنای هر پارامتر و تأثیر آن بر نتیجه را توضیح می‌دهد.

٤-٦-١ دوره تراکنشی

این پارامتر تعیین می‌کند تحلیل روی چه بازه‌ای از داده انجام شود. سامانه در حالت پیش‌فرض همه دوره را در نظر می‌گیرد و در حالت‌های دیگر بازه‌های ۳۰، ۹۰، ۱۸۰ و ۳۶۵ روزه پایانی را پشتیبانی می‌کند. منطق فیلتر ساده است: نخست بزرگ‌ترین شماره روز موجود در جدول تراکنش خوانده می‌شود، سپس با کم‌کردن طول بازه از آن، روز شروع به دست می‌آید و تنها رکوردهای پس از آن روز وارد محاسبه می‌شوند. نکته مهم این است که با تغییر دوره، مخرج محاسبه پشتیبان[۳۹] نیز تغییر می‌کند، زیرا تعداد سبدهای همان دوره مبنا قرار می‌گیرد و نه تعداد کل سبدها.

٤-٦-٢ تعداد قوانین قابل نمایش

این پارامتر با مقادیر ۱۰، ۲۰، ۵۰ و ۱۰۰ و مقدار پیش‌فرض ۲۰ تعیین می‌کند چند قانون در هر فهرست نشان داده شود. اثر آن تنها به نمایش محدود نمی‌ماند و سامانه از همین مقدار برای تعیین سقف اقلام نامزد نیز استفاده می‌کند، به این صورت که تعداد اقلام نامزد چند برابر آن در نظر گرفته می‌شود و در یک بازه مشخص محدود می‌گردد. بنابراین افزایش این مقدار علاوه بر طولانی‌ترشدن فهرست، دامنه جست‌وجو را نیز گسترده‌تر می‌کند و زمان اجرا را افزایش می‌دهد.

---

[۳۹] Support

٤-٦-٣ حداقل پشتیبان

حداقل پشتیبان تعیین می‌کند یک ترکیب دست‌کم در چه نسبتی از سبدها دیده شود تا ارزش بررسی داشته باشد. مقدار پیش‌فرض ۰/۰۰۲ است، یعنی ترکیب باید در دست‌کم دو دهم درصد سبدها حاضر باشد. با توجه به ۲۷۶۴۵۰ سبد موجود، این نسبت به حدود ۵۵۲ سبد ترجمه می‌شود. راهنمای صفحه سه مقدار پیشنهادی معرفی می‌کند: ۰/۰۰۵ برای اجرای سریع و سخت‌گیرانه، ۰/۰۰۲ به عنوان حالت متعادل و ۰/۰۰۱ برای یافتن زوج‌های کم‌تکرارتر با هزینه زمان بیشتر. پایین‌آوردن بیش از حد این مقدار، تعداد اقلام واجد شرایط و در نتیجه تعداد زوج‌های بررسی‌شونده را به سرعت افزایش می‌دهد.

٤-٦-٤ حداقل اطمینان

حداقل اطمینان تعیین می‌کند یک قانون دست‌کم در چند درصد موارد درست از آب درآید تا گزارش شود. مقدار پیش‌فرض ۰/۶ است، یعنی اگر کالای مقدم[۴۰] در سبد باشد، کالای تالی[۴۱] باید دست‌کم در شصت درصد موارد نیز حاضر باشد. بالابردن این آستانه[۴۲] فهرست را کوتاه‌تر و مطمئن‌تر می‌کند و پایین‌آوردن آن قواعد اکتشافی بیشتری را نشان می‌دهد که برای آزمودن مناسب‌اند اما برای تصمیم قطعی کافی نیستند.

جدول ۴-۳ – پارامترهای اجرای تحلیل توصیفی و اثر آن‌ها

پارامتر	دامنه مجاز	مقدار پیش‌فرض	اثر بر نتیجه
دوره تراکنشی	همه، ۳۰، ۹۰، ۱۸۰، ۳۶۵ روز	همه دوره	تغییر بازه داده و مخرج محاسبه پشتیبان
تعداد قوانین نمایشی	۱۰ تا ۱۰۰	۲۰	طول فهرست و پهنای جست‌وجوی نامزدها
حداقل پشتیبان	۰/۰۰۰۰۰۱ تا ۰/۱	۰/۰۰۲	حداقل فراوانی لازم برای بررسی یک ترکیب
حداقل اطمینان	۰/۱ تا ۱	۰/۶	حداقل قابلیت اتکای قانون گزارش‌شده

پس از تنظیم پارامترها، گام دوم تنها یک دکمه دارد. با فشردن آن، دو درخواست مستقل و هم‌زمان برای استخراج قوانین سطح گروه کالایی و سطح کالا ارسال می‌شود. اجرای موازی این دو درخواست باعث می‌شود

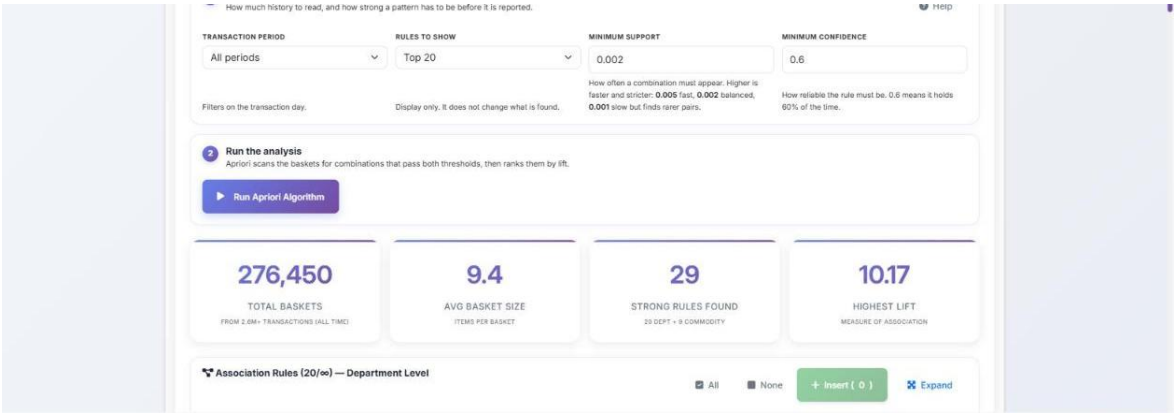
---

[۴۰] Antecedent

[۴۱] Consequent

[۴۲] Threshold

زمان انتظار کاربر به جای مجموع دو محاسبه، تقریباً برابر با طولانی‌ترین آن‌ها باشد. شکل ۴-۳ پنل تنظیمات، دکمه اجرا و شاخص‌های حاصل از یک اجرای واقعی را نشان می‌دهد.



شکل ۴-۳ - پنل تنظیم پارامترها، دکمه اجرای الگوریتم و شاخص‌های چهارگانه پس از اجرا

٤-۷ شاخص‌های چهارگانه سربرگ

پس از بخش اجرا، چهار شاخص در یک ردیف نمایش داده می‌شوند. دو شاخص نخست مستقل از اجرای الگوریتم هستند و وضعیت داده را نشان می‌دهند، در حالی که دو شاخص بعدی تنها پس از اجرا مقدار می‌گیرند و کیفیت نتیجه را خلاصه می‌کنند. جدول ۴-۴ تعریف و مبنای محاسبه هر شاخص را همراه با مقدار به‌دست‌آمده هریک را نشان می‌دهد.

جدول ۴-۴ - تعریف، مبنای محاسبه و مقدار شاخص‌های چهارگانه سربرگ توصیفی

شاخص	مقدار	مبنای محاسبه
تعداد کل سبدها	۲۷۶۴۵۰	شمارش شناسه‌های متمایز سبد در دوره انتخابی
اندازه متوسط سبد	۹/۴	نسبت تعداد ردیف‌های تراکنش به تعداد سبدها
قوانین قوی یافت‌شده	۲۹	تعداد قوانین نمایش‌داده‌شده در هر دو فهرست
بالاترین بهبود	۱۰/۱۷	بیشترین مقدار بهبود در میان قوانین نمایشی

درباره شاخص دوم یک نکته تعریفی وجود دارد که باید صریح بیان شود. برچسب این شاخص در رابط کاربری «تعداد اقلام در هر سبد» است، اما مقدار آن از تقسیم تعداد ردیف‌های تراکنش بر تعداد سبدها به دست می‌آید و نه از تقسیم مجموع مقدار خریداری‌شده. بنابراین عدد ۹/۴ به معنای «به طور متوسط ۹/۴ ردیف در هر سبد» است. چون یک ردیف می‌تواند چند واحد از یک کالا را در بر بگیرد، میانگین واقعی تعداد

واحدهای خریداری‌شده در هر سبد از این عدد بیشتر است. این تفاوت در حجم داده فعلی کوچک به نظر می‌رسد، اما هنگام مقایسه با منابع بیرونی می‌تواند به برداشت نادرست منجر شود.

دو شاخص آخر نیز محدودیت مشخصی دارند. مقدار آن‌ها از روی قوانین نمایش‌داده‌شده محاسبه می‌شود و نه از روی همه قوانینی که الگوریتم یافته است. بنابراین اگر کاربر تعداد قوانین نمایشی را از ۲۰ به ۵۰ افزایش دهد، عدد «قوانین قوی یافت‌شده» نیز افزایش می‌یابد، بدون آنکه الگوی موجود در داده تغییری کرده باشد. این شاخص‌ها باید به عنوان خلاصه‌ای از خروجی نمایش‌داده‌شده خوانده شوند و نه به عنوان اندازه‌ای مطلق از تمامی داده‌های موجود مربوط فروشگاه.

٤-٨ معیارهای سنجش قانون انجمنی

یک قانون انجمنی به شکل «اگر مقدم در سبد باشد آنگاه تالی نیز در همان سبد دیده می‌شود» بیان می‌گردد. برای ارزیابی چنین قانونی سه معیار به کار می‌رود که هیچ‌یک به تنهایی کافی نیست. جدول ۴-۵ این سه معیار را با تعریف و شیوه خواندنشان معرفی می‌کند {۲}.

جدول ۴-۵ – معیارهای ارزیابی قانون انجمنی و شیوه تفسیر آن‌ها

معیار	تعریف	شیوه تفسیر
پشتیبان	نسبت سبدهایی که هر دو طرف قانون در آن‌ها حاضرند به کل سبدها	فراوانی الگو را نشان می‌دهد. پایین‌بودن آن یعنی الگو نادر است.
اطمینان	نسبت سبدهای دارای هر دو طرف به سبدهای دارای مقدم	قابلیت اتکای قانون را نشان می‌دهد اما به تنهایی گمراه‌کننده است.
بهبود	نسبت اطمینان قانون به نسبت حضور تالی در کل سبدها	بزرگ‌تر از یک یعنی این همراهی مقدم و تالی واقعی است و برابر یک یعنی استقلال دارند.

دلیل ضروری‌بودن معیار سوم با یک مثال روشن می‌شود. فرض کنید کالایی مانند شیر در نیمی از سبدها حاضر باشد. در این صورت هر قانونی که تالی آن شیر باشد، تنها به دلیل رواج بالای شیر، اطمینان نسبتاً بالایی به دست می‌آورد، حتی اگر هیچ رابطه واقعی میان دو کالا وجود نداشته باشد. معیار بهبود دقیقاً همین اثر را خنثی می‌کند، زیرا اطمینان قانون را با نسبت حضور مستقل تالی می‌سنجد. به همین دلیل در این پروژه فهرست قوانین بر اساس بهبود مرتب می‌شود و نه بر اساس اطمینان.

در مقابل، تکیه صرف بر بهبود نیز درست نیست. یک قانون می‌تواند بهبود بسیار بالایی داشته باشد اما تنها در چند سبد از کل داده رخ دهد. چنین قانونی از نظر آماری پایدار نیست و برای تصمیم‌گیری تجاری ارزشی ندارد. آستانه حداقل پشتیبان دقیقاً برای کنار گذاشتن این موارد پیش از ساخت قانون اعمال می‌شود.

٤-٩ منطق استخراج قوانین در این پروژه

در این سربرگ بجای استخراج قوانین در سطح تک‌محصول که مفصلاً در سربرگ /analysis/association-rules/ انجام شده است، تصمیم گرفته شد استخراج قوانین در دو سطح بالاتر یعنی گروه کالایی و کالا انجام شود. در این دو سطح، تعداد اقلام به ترتیب در حدود چهل گروه کالایی و چند صد عنوان کالا است و الگوها فراوانی معناداری پیدا می‌کنند. اجرای این محاسبه در سه گام انجام می‌شود.

٤-٩-١ گام نخست: تعیین اقلام واجد شرایط

ابتدا تعداد کل سبدهای دوره انتخابی شمارش می‌شود و از حاصل‌ضرب آن در حداقل پشتیبان، یک حد آستانه به صورت «حداقل تعداد سبد» به دست می‌آید. سپس برای هر گروه کالایی یا هر کالا شمارش می‌شود که در چند سبد متمایز حاضر بوده است و تنها اقلامی که از این آستانه عبور کرده‌اند نگه داشته می‌شوند. اقلام باقی‌مانده نیز بر اساس فراوانی مرتب و به یک سقف مشخص محدود می‌گردند. این گام از منطق هرس[۴۳] الگوریتم Apriori پیروی می‌کند: اگر یک قلم به تنهایی به آستانه پشتیبان نرسد، هیچ ترکیبی که آن را در بر بگیرد نیز نمی‌تواند به آستانه برسد، پس بررسی آن ترکیب‌ها بی‌فایده است.

٤-٩-٢ گام دوم: پویش سبدها و شمارش هم‌زمانی

در گام دوم، رکوردهای مربوط به اقلام واجد شرایط از پایگاه داده خوانده می‌شوند، اما به شکل مرتب‌شده بر اساس شناسه سبد و به صورت دسته‌های چندهزارتایی. به این ترتیب هیچ‌گاه لازم نیست کل داده هم‌زمان در حافظه قرار گیرد. برنامه رکوردها را دنبال می‌کند و تا زمانی که شناسه سبد تغییر نکرده، اقلام آن سبد را در یک مجموعه جمع می‌کند. به محض تغییر شناسه سبد، همه زوج‌های ممکن از اقلام آن سبد ساخته و شمارنده هر زوج یک واحد افزوده می‌شود. این روش پویش جریانی نام دارد و برای داده‌ای در این ابعاد از بارگذاری یکجا بسیار کارآمدتر است.

---

[۴۳] Pruning

٤-۹-۳ گام سوم: ساخت قانون جهت‌دار

پس از پایان پویش، هر زوج که تعداد سبدهای مشترکش از آستانه بگذرد به دو قانون بالقوه تبدیل می‌شود، یکی از قلم نخست به قلم دوم و دیگری در جهت معکوس. علت این دوگانگی آن است که اطمینان یک معیار نامتقارن است. اگر A در ده هزار سبد و B در صد هزار سبد حاضر باشد و هر دو در نه هزار سبد با هم دیده شوند، اطمینان قانون از A به B برابر نود درصد و اطمینان قانون از B به A تنها نُه درصد است. هر جهت که از آستانه اطمینان عبور کند در فهرست باقی می‌ماند و مقدار بهبود آن محاسبه می‌شود. در پایان، همه قوانین بر اساس بهبود به صورت نزولی مرتب و به تعداد درخواستی کاربر محدود می‌گردند.

٤-۹-٤ نسبت این پیاده‌سازی با الگوریتم استاندارد

الگوریتم Apriori در شکل عمومی خود مجموعه‌های پرتکرار[۴۴] با هر اندازه‌ای را می‌سازد و سپس از هر مجموعه، قوانین ممکن را استخراج می‌کند. پیاده‌سازی به‌کاررفته در این صفحه، دو ایده اصلی این الگوریتم یعنی آستانه پشتیبان و هرس اقلام کم‌فراوان را حفظ کرده است، اما به مجموعه‌های دوتایی محدود می‌ماند و مجموعه‌های سه‌تایی و بزرگ‌تر را نمی‌سازد. این محدودسازی یک انتخاب مهندسی برای کنترل زمان پاسخ در یک سامانه تعاملی است. نتیجه آن این است که قوانین گزارش‌شده همیشه یک مقدم و یک تالی دارند و ترکیب‌های سه‌گانه، که در برخی کاربردهای چیدمان فروشگاهی مفیدند، در این نسخه از سامانه پوشش داده نمی‌شوند. این موضوع در فصل مربوط به صفحه قوانین انجمنی و در بخش کارهای آینده دوباره بررسی می‌شود {۲}.

٤-۱۰ دو سطح تحلیل و نمونه نتایج

همان‌طور که اشاره شد، هر بار اجرا دو فهرست جداگانه تولید می‌کند. جدول ۴-۶ تفاوت این دو سطح را از نظر تعداد اقلام، معنای خروجی و کاربرد نشان می‌دهد.

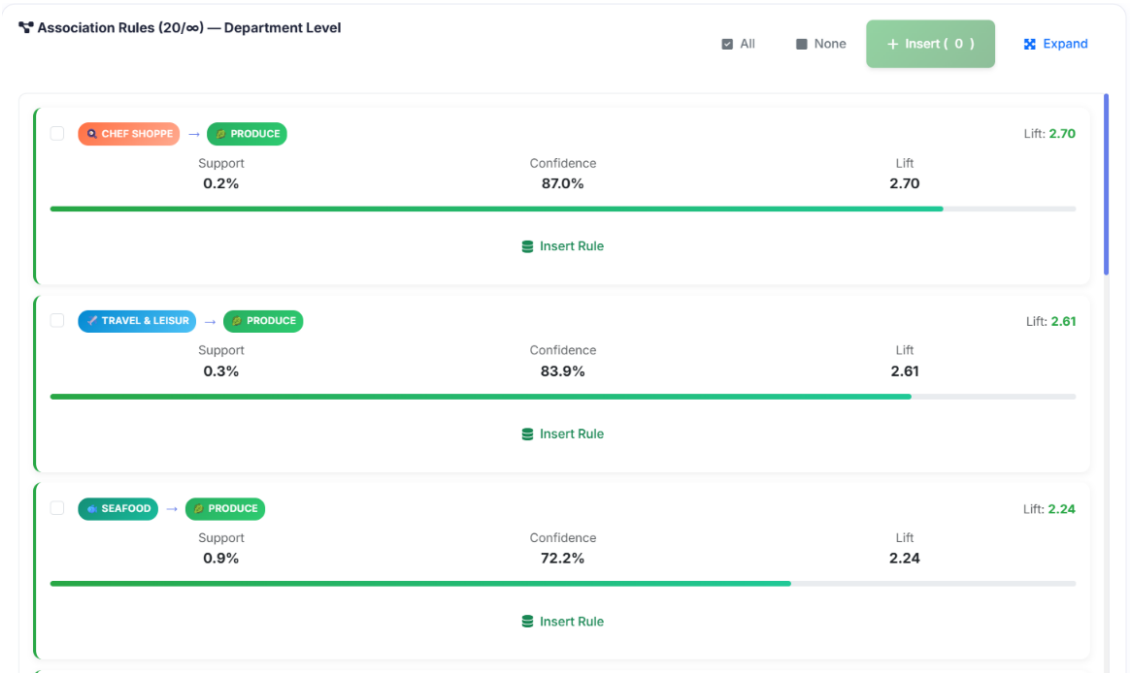
---

[۴۴] Frequent Itemsets

جدول ۴-۶ – مقایسه سطح گروه کالایی و سطح کالا در استخراج قوانین

ویژگی	سطح گروه کالایی	سطح کالا
تعداد اقلام	حدود چهل عنوان	چند صد عنوان
پشتیبان معمول	بالا، بسیاری از سبدها چند گروه دارند	نسبتاً پایین و متنوع
معنای قانون	هم‌زمانی بخش‌های فروشگاه	هم‌زمانی کالاهای مشخص
کاربرد اصلی	شناخت الگوی کلی مراجعه	چیدمان قفسه و پیشنهاد فروش متقابل

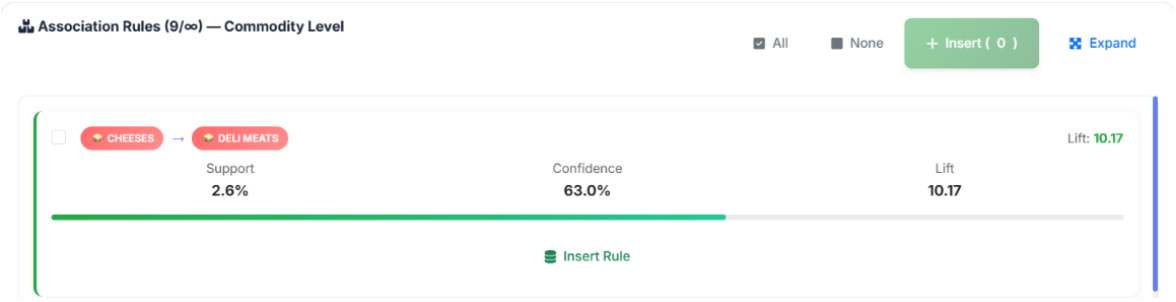
اجرای مرجع این گزارش با تنظیم پیش‌فرض یعنی همه دوره، حداقل پشتیبان ۰/۰۰۲، حداقل اطمینان ۰/۶ و نمایش بیست قانون انجام شد. در سطح گروه کالایی فهرست به سقف نمایش یعنی بیست قانون رسید و در سطح کالا نُه قانون استخراج شد. بالاترین بهبود در کل نتیجه برابر ۱۰/۱۷ بود که به قانون سطح کالا از CHEESES به DELI MEATS تعلق داشت.



شکل ۴-۴ – فهرست قوانین انجمنی سطح گروه کالایی پس از اجرای الگوریتم

قوانین سطح گروه کالایی تصویری کلی از الگوی مراجعه به فروشگاه می‌دهند. برای نمونه قانون از CHEF SHOPPE به PRODUCE با اطمینان ۸۷ درصد و بهبود ۲/ ۷۰ بیان می‌کند که تقریباً هر سبدی که از بخش غذای آماده کالایی داشته باشد، از بخش میوه و سبزی نیز خرید کرده است. پشتیبان این قانون تنها ۰/۲ درصد است، یعنی این ترکیب در سبدهای کمی رخ می‌دهد ولی هرگاه رخ دهد بسیار پایدار است.

در مقابل، قانون از MEAT به PRODUCE با پشتیبان ۱۲/۹درصد، اطمینان ۶۶/۷ درصد و بهبود ۲/۰۷، الگویی است که بخش بزرگی از سبدها را در بر می‌گیرد. مقایسه این دو قانون نشان می‌دهد چرا نمایش هم‌زمان هر سه معیار ضروری است.



شکل ۴-۵ – فهرست قوانین انجمنی سطح کالا و بالاترین بهبود به‌دست‌آمده

قوانین سطح کالا مشخص‌تر و برای تصمیم‌گیری عملی مفیدترند. قانون از CHEESES به DELI MEATS با پشتیبان ۲/۶ درصد، اطمینان ۶۳ درصد و بهبود ۱۰/۱۷ نشان می‌دهد سبدهایی که پنیر دارند بیش از ده برابر حالت مستقل، حاوی گوشت‌های آماده نیز هستند. به همین ترتیب قانون از HOT DOGS به BAKED BREAD/BUNS/ROLLS با بهبود ۳/۲۳ و قانون از COLD CEREAL به FLUID MILK PRODUCTS با بهبود ۲/۶۷ الگوهای مصرفی قابل انتظاری را نشان می‌دهند. هم‌خوانی این نتایج با رفتار شناخته‌شده مصرف‌کننده، شاهدی بر درستی پیاده‌سازی است، هرچند ارزش اصلی چنین تحلیلی در یافتن روابطی است که از پیش آشکار نیستند.

٤-١١ خواندن کارت قانون و نمای جزئیات

هر قانون در قالب یک کارت نمایش داده می‌شود. در بالای کارت، نشان مقدم و نشان تالی با یک پیکان به یکدیگر متصل شده‌اند و مقدار بهبود در سمت دیگر دیده می‌شود. رنگ و نماد هر نشان بر اساس گروه کالایی انتخاب می‌شود و در سطح کالا نیز همان رنگ گروه مادر به کار می‌رود تا دو سطح از نظر دیداری با هم سازگار بمانند. در میانه کارت هر سه معیار به صورت درصد و عدد آورده شده و یک نوار افقی، اطمینان قانون را به شکل نسبی نشان می‌دهد.

با انتخاب کارت، پنجره جزئیات باز می‌شود. این پنجره علاوه بر تکرار سه معیار، یک متن تفسیری تولید می‌کند که بر اساس بازه مقدار بهبود انتخاب می‌شود. برای نمونه بهبود بیش از دو با عبارت «همراهی بسیار قوی» و بهبود میان یک و یک و نیم با عبارت «همراهی متوسط» توصیف می‌شود. هدف این متن آن است که

کاربر غیرمتخصص بتواند اندازه عددی را به یک برداشت کیفی تبدیل کند. باید توجه داشت که این متن یک قاعده ساده مبتنی بر آستانه است و جای تحلیل کارشناسی را نمی‌گیرد و باید هر سه معیار و شرایط کلی نیز در نظر گرفته شود.

٤-١٢ ذخیره قوانین در پایگاه داده

قوانین استخراج‌شده به صورت خودکار ذخیره نمی‌شوند. کاربر می‌تواند هر قانون را به تنهایی با دکمه ثبت همان کارت ذخیره کند یا با کادرهای انتخاب، چند قانون را برگزیند و همه را یک‌جا ثبت نماید. پیش از ثبت تکی، یک پنجره تأیید مقادیر قانون را نشان می‌دهد تا ثبت ناخواسته رخ ندهد. برای هر قانون علاوه بر مقدم، تالی و سه معیار، آستانه‌های به‌کاررفته در اجرا و صفحه‌ای که قانون از آن ثبت شده نیز نگهداری می‌شود.

دلیل نگهداری آستانه‌ها همراه با خود قانون این است که یک قانون بدون تنظیمی که آن را تولید کرده معنای کاملی ندارد. قانونی که با حداقل پشتیبان ۰/۰۰۱ به دست آمده با قانونی که با ۰/۰۰۵ استخراج شده در یک سطح از اعتبار نیست. همچنین اگر قانونی با همان مقدم و تالی و همان سطح از قبل در جدول موجود باشد، رکورد موجود به‌روزرسانی می‌شود و رکورد تکراری ساخته نمی‌شود.

این جدول تنها یک بایگانی نیست. صفحه و بخش پیشنهاددهنده محصول از همین قوانین ذخیره‌شده استفاده می‌کنند. به این ترتیب، خروجی سربرگ تحلیل توصیفی به ورودی بخش دیگر سامانه تبدیل می‌شود و همان یکپارچگی که در فصل نخست به عنوان هدف پروژه بیان شد، در عمل تحقق می‌یابد. در عین حال باید در نظر داشت که قانون ذخیره‌شده تصویری از یک اجرای مشخص در یک زمان مشخص است و با افزوده‌شدن داده جدید ممکن است مقادیر آن تغییر کند.

٤-١٣ رفتار سامانه در زمان اجرا

اجرای الگوریتم روی همه داده می‌تواند چند ده ثانیه طول بکشد. برای اینکه کاربر در این مدت بدون بازخورد نماند، چند تدبیر در نظر گرفته شده است. دکمه اجرا در حین محاسبه غیرفعال می‌شود تا اجرای هم‌زمان چندباره رخ ندهد. در محل هر فهرست، نشانگر انتظار به همراه پیامی از مرحله جاری نمایش داده می‌شود و این پیام هر ده ثانیه تغییر می‌کند تا روشن باشد که پردازش متوقف نشده است. هر فهرست نیز به محض آماده‌شدن نتیجه خود، مستقل از فهرست دیگر پر می‌شود.

برای درخواست‌ها یک مهلت زمانی سی ثانیه‌ای تعیین شده است. اگر پاسخ در این مدت نرسد، درخواست لغو می‌شود و پیامی نمایش داده می‌شود که راه‌حل عملی را پیشنهاد می‌کند: افزایش حداقل پشتیبان یا انتخاب یک دوره کوتاه‌تر. وجود این مهلت لازم است، زیرا با آستانه‌های بسیار کوچک، تعداد زوج‌های نامزد چنان زیاد می‌شود که محاسبه عملاً به نتیجه‌ای در زمان معقول نمی‌رسد. در چنین حالتی رهاکردن درخواست باز، هم منابع سرور را اشغال می‌کند و هم کاربر را بلاتکلیف می‌گذارد.

٤-١٤ ملاحظات تفسیری و محدودیت‌ها

نخست، هم‌زمانی به معنای علیت نیست. اینکه پنیر و گوشت آماده با هم در سبد دیده می‌شوند، ثابت نمی‌کند خرید یکی موجب خرید دیگری شده است. هر دو می‌توانند نتیجه یک عامل سوم مانند تهیه مواد یک وعده غذایی مشخص باشند. قانون انجمنی یک فرضیه اولیه به دست می‌دهد و اعتبار آن باید با آزمون واقعی مانند تغییر چیدمان یا اجرای یک پیشنهاد فروش سنجیده شود.

دوم، نتایج به شدت به آستانه‌ها و دوره انتخابی وابسته‌اند. تغییر حداقل پشتیبان از ۰/۰۰۲ به ۰/۰۰۱ می‌تواند فهرست را چند برابر کند و ترتیب قوانین را نیز تغییر دهد. بنابراین گزارش هر نتیجه باید همراه با تنظیمی که آن را تولید کرده ارائه شود، وگرنه قابل بازتولید نخواهد بود.

سوم، قوانین سطح گروه کالایی بسیار عام هستند. حضور PRODUCE در تالی بسیاری از قوانین، بیش از آنکه یک کشف باشد، نشان‌دهنده رواج بالای این بخش در سبدهاست. اگرچه معیار بهبود بخشی از این اثر را خنثی می‌کند، در سطحی که تنها حدود چهل قلم وجود دارد، تفسیر باید محتاطانه باشد.

چهارم، همان‌طور که گفته شد قوانین این نسخه تنها دوتایی هستند. الگوهایی که تنها در ترکیب سه کالا معنا پیدا می‌کنند در این خروجی دیده نمی‌شوند.

پنجم، وجود گروه‌هایی مانند COUPON/MISC ITEMS و MISC SALES TRAN در داده نشان می‌دهد بخشی از رکوردها ماهیت کالایی ندارند و باید در تحلیل‌های آتی به این نکته توجه داشت. دلیل حذف نکردن این نوع از داده‌ها حفظ یکپارچگی داده‌های فروشگاه بوده است و می‌توان از این داده‌ها در تحلیل های عملی صرف نظر کرد.

٤-١٥ جمع‌بندی فصل

سربرگ تحلیل توصیفی صفحه تحلیل سبد خرید، مسیر کاملی از داده خام تا الگوی قابل استفاده را در یک صفحه جمع می‌کند. نخست ساختار سبد و اهمیت محصولات مستقیماً از داده گزارش می‌شود، سپس کاربر با چهار پارامتر مشخص می‌کند تحلیل بر چه بازه‌ای و با چه سخت‌گیری انجام شود و در پایان الگوهای هم‌زمانی در دو سطح گروه کالایی و کالا با سه معیار پشتیبان، اطمینان و بهبود ارائه می‌گردند.

مهم‌ترین ویژگی این بخش، صراحت در تعریف است. هر عدد نمایش‌داده‌شده مبنای محاسبه مشخصی دارد و مرز میان مشاهده و استنتاج در آن حفظ شده است. اجرای مرجع این گزارش با تنظیم پیش‌فرض، ۲۹ قانون قوی را از میان ۲۷۶۴۵۰ سبد استخراج کرد که بالاترین بهبود آن ۱۰/۱۷ بود. این خروجی به تنهایی یک تصمیم تجاری نیست، بلکه نقطه شروعی برای بررسی دقیق‌تر در بخش مدیریت فروش و چینش کالاهای فروشگاه است و هر قانون استخراج شده یک ورودی برای پیشنهاددهنده محصول به شمار می‌رود. در فصل هفتم، صفحه قوانین انجمنی در سطح محصول بررسی می‌شود. سطحی که نسبت به دو سطح پیشین، جزئی‌تر و پایین‌تر است.

فصل پنجم: تحلیل پیش‌بینانه سبد خرید

۵-۱ جایگاه سربرگ پیش‌بینانه و تفاوت آن با تحلیل توصیفی

سربرگ دوم صفحه تحلیل سبد خرید به تحلیل پیش‌بینانه اختصاص دارد. تفاوت این سربرگ با سربرگ توصیفی که در فصل چهارم بررسی شد، در ماهیت خروجی است و نه در ظاهر صفحه. هر عددی که در سربرگ توصیفی دیده می‌شود از شمارش مستقیم داده ثبت‌شده به دست می‌آید. اگر همان محاسبه دوباره اجرا شود و داده تغییر نکرده باشد، دقیقاً همان عدد تکرار می‌شود. در مقابل، هر عددی که در این سربرگ نمایش داده می‌شود خروجی یک مدل آموزش‌دیده است و خطای مدل را به همراه دارد. بنابراین این دو دسته خروجی را نباید هم‌ارز دانست و در گزارش نیز باید جدا از یکدیگر تفسیر شوند.

دلیل افزودن این بخش به پروژه نیز روشن است. تحلیل توصیفی به پرسش «چه اتفاقی افتاده است» پاسخ می‌دهد، اما تصمیم‌های عملی خرده‌فروشی مانند تعیین موجودی و سفارشات آتی کالاهای فروشگاه، برنامه‌ریزی تبلیغات یا اولویت‌بندی نیازهای مشتری به پاسخ پرسش «چه اتفاقی محتمل است بیفتد» نیاز دارند. این سربرگ همین لایه را به سامانه اضافه می‌کند. در عین حال، افزودن یک مدل پیش‌بینی به یک پروژه دانشجویی تنها زمانی ارزش دارد که ارزیابی آن درست انجام شود، در غیر این صورت عددی گزارش می‌شود که در عمل قابل اتکا نیست. به همین دلیل بخش بزرگی از این فصل به شیوه اعتبارسنجی اختصاص یافته است.

۵-۲ دو مسئله پیش‌بینی مستقل در یک سربرگ

نکته‌ای که پیش از هر توضیح دیگری باید روشن شود این است که در این سربرگ دو مسئله کاملاً متفاوت کنار هم قرار گرفته‌اند. زیربخش نخست با عنوان دسته‌بندی خرید دوباره از گروه‌های کالایی، برای هر خانوار و هر گروه کالایی یک احتمال تولید می‌کند. زیربخش دوم با عنوان پیش‌بینی درآمد محصول، برای هر محصول مقدار درآمد دوره‌های آینده را برآورد می‌کند. این دو مسئله واحد پیش‌بینی، متغیر هدف، شیوه اعتبارسنجی و معیارهای ارزیابی متفاوتی دارند و مقایسه مستقیم اعداد آن‌ها با یکدیگر نادرست است. این هشدار در خود گزارش اعتبارسنجی سامانه نیز به صورت صریح ثبت شده است.

برای مثال، اگر دسته‌بند خرید دوباره صحت[۴۵] ۷۹ درصد را گزارش کند و مدل پیش‌بینی درآمد خطای نسبی ۴۶ درصد نشان دهد، نمی‌توان نتیجه گرفت که مدل نخست بهتر عمل کرده است. اولی درصد

---

[۴۵] Precision

پیش‌بینی‌های درست در یک مسئله دودویی است و دومی نسبت خطای مطلق به مجموع درآمد واقعی در یک مسئله عددی. جدول ۵-۱ تفاوت این دو مسئله را به صورت خلاصه نشان می‌دهد.

جدول ۵-۱ - مقایسه دو مسئله پیش‌بینی موجود در سربرگ تحلیل پیش‌بینانه

ویژگی	دسته‌بندی خرید دوباره	پیش‌بینی درآمد محصول
واحد پیش‌بینی	یک خانوار در یک گروه کالایی	یک محصول در یک دوره ۳۰روزه
متغیر هدف	برچسب دودویی خرید یا نبود خرید	مقدار پیوسته درآمد
شکل خروجی	احتمالی میان صفر و یک	مقدار پولی برای هر دوره آینده
خانواده مدل	چهار الگوریتم دسته‌بندی	شبکه بازگشتی و مدل تقویت گرادیانی
معیار ارزیابی	صحت، بازخوانی، سطح زیر منحنی	خطای مطلق، خطای نسبی و کیفیت رتبه‌بندی
کاربرد اصلی	اولویت‌بندی نیازهای مشتری	برنامه‌ریزی موجودی و تمرکز فروش

کارت معرفی بالای این سربرگ نیز همین نکته را به کاربر یادآوری می‌کند و می‌نویسد که دو وظیفه پیش‌بینی متمایز در این صفحه وجود دارد و هر یک هدف، اعتبارسنجی و معیار مخصوص خود را دارد. جابه‌جایی میان دو زیربخش با دو کلید در بالای صفحه انجام می‌شود و در حالت پیش‌فرض، زیربخش پیش‌بینی درآمد محصول نمایش داده می‌شود.

۵-۳ اصول مشترک: اعتبارسنجی زمانی و پرهیز از نشت داده

با وجود تفاوت دو مسئله، هر دو زیربخش از یک اصل مشترک پیروی می‌کنند و شناخت این اصل برای فهم بقیه فصل ضروری است. این اصل، جداسازی زمانی داده آموزش از داده آزمون است.

۵-۳-۱ چرا تقسیم تصادفی در این مسئله نادرست است

روش رایج در بسیاری از تمرین‌های یادگیری ماشین این است که رکوردها به صورت تصادفی به دو بخش آموزش و آزمون تقسیم شوند. در داده‌ای که بعد زمانی دارد، این کار نتیجه را بی‌اعتبار می‌کند. اگر تقسیم تصادفی باشد، ممکن است رکوردی از ماه پنجم سال در مجموعه آموزش و رکوردی از ماه چهارم سال در مجموعه آزمون قرار گیرد. یعنی مدل هنگام آموزش، آینده را دیده و سپس درباره گذشته آزمون

شده است. این وضعیت را نشت داده[۴۶] می‌نامند و پیامد آن گزارش دقتی است که در استفاده واقعی تکرار نمی‌شود.

در این پروژه هیچ‌جا از تقسیم تصادفی استفاده نشده است. در هر دو زیربخش، مرزی زمانی تعیین می‌شود و همه نمونه‌های آموزش پیش از آن مرز و همه نمونه‌های آزمون پس از آن مرز قرار می‌گیرند. این شیوه در گزارش سامانه با عنوان نگه‌داشت زمانی[۴۷] ثبت شده است.

۵-۳-۲ مفهوم روز مبدأ و پنجره برچسب

برای ساخت یک نمونه آموزشی، ابتدا یک روز مشخص از تقویم داده به عنوان روز مبدأ[۴۸] انتخاب می‌شود. تمام ویژگی‌های ورودی آن نمونه فقط از رکوردهای پیش از آن روز یا خود آن روز محاسبه می‌شوند. سپس یک بازه زمانی پس از روز مبدأ به عنوان پنجره برچسب[۴۹] در نظر گرفته می‌شود و مقدار هدف از رفتار مشاهده‌شده در همان پنجره به دست می‌آید. به این ترتیب، ورودی و خروجی هر نمونه از دو بازه زمانی جدا از هم می‌آیند و ویژگی هیچ‌گاه از داده‌ای که قرار است پیش‌بینی شود ساخته نمی‌شود.

در پرس‌وجوی ساخت نمونه‌ها، پنجره برچسب از روز بعد از مبدأ آغاز می‌شود و نه از خود روز مبدأ. این جزئیات کوچک اهمیت دارد، زیرا اگر روز مبدأ در هر دو طرف حاضر باشد، بخشی از پاسخ در ورودی نیز دیده می‌شود.

۵-۳-۳ فاصله‌گذاری میان مجموعه آموزش و آزمون

جداسازی ورودی و برچسب به تنهایی کافی نیست. اگر پنجره برچسب یک نمونه آموزشی با بازه‌ای که مجموعه آزمون از آن استفاده می‌کند هم‌پوشانی داشته باشد، باز هم بخشی از اطلاعات آزمون به آموزش راه پیدا می‌کند. برای رفع این مشکل، سامانه یک قاعده ساده اعمال می‌کند: نمونه آموزشی تنها زمانی پذیرفته می‌شود که پنجره برچسب آن پیش از روز مبدأ مجموعه آزمون به پایان رسیده باشد. روزهای مبدأیی که این

---

[۴۶] Data Leakage

[۴۷] Chronological Holdout

[۴۸] Origin Day

[۴۹] Label Window

شرط را برآورده نمی‌کنند به طور کامل کنار گذاشته می‌شوند. این کار در ادبیات یادگیری ماشین با عنوان فاصله‌گذاری[۵۰] شناخته می‌شود و هزینه آن، از دست‌رفتن چند نمونه آموزشی است.

۵-۳-٤ معنای «اندازه آموزش» در این پروژه

در تنظیمات هر دو زیربخش پارامتری با عنوان اندازه آموزش وجود دارد که مقدار پیش‌فرض آن هشتاد درصد است. این پارامتر با آنچه معمولاً از آن انتظار می‌رود تفاوت دارد. در اینجا هشتاد درصد به معنای انتخاب تصادفی هشتاد درصد از ردیف‌ها نیست، بلکه به معنای نگه‌داشتن هشتاد درصد از روزهای مبدأ مجاز است، آن هم با اولویت جدیدترین‌ها. دلیل این انتخاب آن است که در داده خرده‌فروشی رفتار مشتری با گذشت زمان تغییر می‌کند و دوره‌های نزدیک‌تر به زمان پیش‌بینی، اطلاعات مرتبط‌تری دارند. مقدار این پارامتر در دسته‌بند میان پنجاه تا نود و پنج درصد محدود شده است.

۵-٤ زیربخش نخست: دسته‌بند خرید دوباره از گروه کالایی

۵-٤-۱ تعریف مسئله و واحد پیش‌بینی

پرسشی که این زیربخش به آن پاسخ می‌دهد چنین است: خانواری که تا امروز از یک گروه کالایی خرید کرده است، با چه احتمالی در بازه پیش رو دوباره از همان گروه خرید خواهد کرد؟ بنابراین واحد پیش‌بینی یک زوج خانوار و گروه کالایی است و نه یک خانوار به تنهایی و نه یک محصول مشخص.

دو محدودیت در این تعریف وجود دارد که باید صریح بیان شوند. نخست اینکه تنها زوج‌هایی وارد محاسبه می‌شوند که خانوار پیش از روز مبدأ دست‌کم یک بار از آن گروه کالایی خرید کرده باشد یعنی سامانه پیش‌بینی نمی‌کند که یک خانوار برای نخستین بار وارد چه گروهی خواهد شد. دوم اینکه خروجی مدل احتمال خرید است و نه مبلغ خرید. این بخش هیچ برآوردی از درآمد ارائه نمی‌دهد. متغیر هدف نیز دودویی است: اگر خانوار در پنجره برچسب دست‌کم یک تراکنش در همان گروه کالایی داشته باشد مقدار یک و در غیر این صورت مقدار صفر می‌گیرد.

---

[۵۰] Purging

۵-٤-۲ ساخت نمونه‌ها روی مجموعه‌ای از روزهای مبدأ

اگر تنها یک روز مبدأ انتخاب شود، تعداد نمونه‌های آموزشی محدود می‌ماند و مدل تنها یک برش زمانی را می‌بیند. برای رفع این محدودیت، سامانه چند روز مبدأ را پشت سر هم می‌سازد و نمونه‌های همه آن‌ها را روی هم می‌چیند. نخستین روز مبدأ ممکن روز نودم است تا هر زوج دست‌کم نود روز سابقه داشته باشد، فاصله میان روزهای مبدأ سی روز است و آخرین روز مبدأ ممکن روزی است که پنجره برچسب آن دقیقاً به آخرین روز داده ختم شود.

برای افق سه‌ماهه که مقدار پیش‌فرض صفحه است، این قاعده روی داده هفتصد و یازده روزه به نوزده روز مبدأ منجر می‌شود. آخرین روز مبدأ، یعنی روز ششصد و بیست و یکم، به عنوان مجموعه آزمون کنار گذاشته می‌شود و پنجره برچسب آن روزهای ششصد و بیست و دوم تا هفتصد و یازدهم را پوشش می‌دهد. از هجده روز مبدأ باقی‌مانده، پانزده روز شرط فاصله‌گذاری را برآورده می‌کنند و با اندازه آموزش هشتاد درصد، دوازده روز جدیدتر برای آموزش انتخاب می‌شوند: روزهای صد و هشتاد تا پانصد و ده با گام سی روز. این ارقام در فایل نتایج اعتبارسنجی سامانه به همراه هر مدل ثبت می‌شوند تا خواننده بداند هر عدد از کدام پیکربندی به دست آمده است.

۵-٤-۳ ویژگی‌های ورودی مدل

برای هر زوج خانوار و گروه کالایی، بیست و دو ویژگی ساخته می‌شود که همگی از رکوردهای پیش از روز مبدأ می‌آیند. این ویژگی‌ها در سه سطح تعریف شده‌اند: سطح زوج، سطح خانوار و سطح گروه کالایی. جدول ۵-۲ آن‌ها را دسته‌بندی می‌کند.

جدول ۵-۲ - ویژگی‌های ورودی دسته‌بند خرید دوباره و سطح تعریف هر دسته

سطح تعریف	تعداد	نمونه ویژگی‌ها
زوج خانوار و گروه کالایی	۱۱	فاصله از آخرین خرید، طول رابطه، تعداد تراکنش، تعداد سبد، تعداد محصول یکتا، مجموع و میانگین فروش، مجموع و میانگین مقدار، تعداد روزهای خرید، شماره روز مبدأ
خانوار	۳	تعداد کل تراکنش‌های خانوار، تعداد گروه‌های کالایی مورد استفاده، مجموع فروش خانوار
گروه کالایی	۳	تعداد خانوارهای فعال گروه، تعداد تراکنش‌های گروه، مجموع فروش گروه
ویژگی‌های اسمی	۵	گروه کالایی، بازه سنی، بازه درآمدی، بُعد خانوار، وضعیت فرزند

سه ویژگی نخست سطح زوج مهم‌ترین نقش را دارند. فاصله از آخرین خرید نشان می‌دهد چند روز از آخرین مراجعه خانوار به آن گروه گذشته است، طول رابطه نشان می‌دهد این خانوار از چه زمانی مشتری آن گروه بوده و تعداد روزهای خرید نشان می‌دهد این رابطه چقدر منظم بوده است. این سه، همان سه مؤلفه‌ای هستند که در بخش‌بندی مشتریان نیز به کار می‌روند و در اینجا در سطح گروه کالایی محاسبه شده‌اند.

ویژگی‌های اسمی مانند بازه سنی و بازه درآمدی از جدول خانوار می‌آیند و برای خانوارهایی که این اطلاعات را ندارند مقدار نامشخص در نظر گرفته می‌شود. حذف چنین خانوارهایی باعث می‌شد بخش قابل توجهی از داده کنار گذاشته شود.

۵-٤-٤ پیش‌پردازش داده پیش از آموزش

پیش از رسیدن داده به مدل، دو تبدیل روی آن اعمال می‌شود. مقادیر گمشده ویژگی‌های عددی با میانه همان ستون و مقادیر گمشده ویژگی‌های اسمی با پرتکرارترین مقدار جایگزین می‌شوند. سپس ویژگی‌های عددی استانداردسازی[۵۱] می‌گردند، یعنی به مقیاسی با میانگین صفر و انحراف معیار یک تبدیل می‌شوند، و ویژگی‌های اسمی به کد عددی نگاشت می‌یابند. استانداردسازی برای دو الگوریتم شبکه عصبی و ماشین بردار

[۵۱] Standardization

پشتیبان[۵۲] ضروری است، زیرا این دو به تفاوت مقیاس ویژگی‌ها حساس‌اند. برای دو الگوریتم درختی اثر چندانی ندارد اما اعمال یکسان آن باعث می‌شود همه مدل‌ها دقیقاً یک ورودی ببینند و مقایسه منصفانه باشد.

نکته مهم این است که پارامترهای این تبدیل‌ها، یعنی میانه و میانگین و انحراف معیار، تنها از داده آموزش محاسبه می‌شوند و سپس بر داده آزمون اعمال می‌گردند. اگر این پارامترها از کل داده به دست می‌آمدند، اطلاعاتی از مجموعه آزمون وارد فرایند آموزش می‌شد.

۵-٤-۵ چهار الگوریتم و تنظیم‌های اصلی آن‌ها

یک تصمیم طراحی مهم در این زیربخش آن است که با هر بار فشردن دکمه آموزش، هر چهار الگوریتم آموزش می‌بینند و نه فقط الگوریتمی که کاربر انتخاب کرده است. انتخابگر موجود در صفحه تنها تعیین می‌کند نتیجه کدام الگوریتم نمایش داده شود. مزیت این کار آن است که کاربر می‌تواند بدون آموزش مجدد میان چهار مدل جابه‌جا شود و آن‌ها را روی دقیقاً یک مجموعه آموزش و یک مجموعه آزمون مقایسه کند. جدول ۵-۳ این چهار الگوریتم را معرفی می‌کند.

جدول ۵-۳ - الگوریتم‌های دسته‌بندی و تنظیم‌های اصلی هر یک

الگوریتم	تنظیم‌های اصلی
شبکه عصبی چندلایه	دو لایه پنهان با ۶۴ و ۳۲ نورون، توقف زودهنگام، حداکثر ۱۸۰ تکرار
جنگل تصادفی	۱۴۰ درخت، حداکثر عمق ۱۵، حداقل ۳ نمونه در برگ، وزن‌دهی متعادل به کلاس‌ها
تقویت گرادیانی	۱۰۰ درخت، نرخ یادگیری ۰/۰۵، حداکثر عمق ۳، حداقل ۱۰ نمونه در برگ
ماشین بردار پشتیبان	هسته شعاعی، تولید احتمال به جای برچسب، وزن‌دهی متعادل به کلاس‌ها

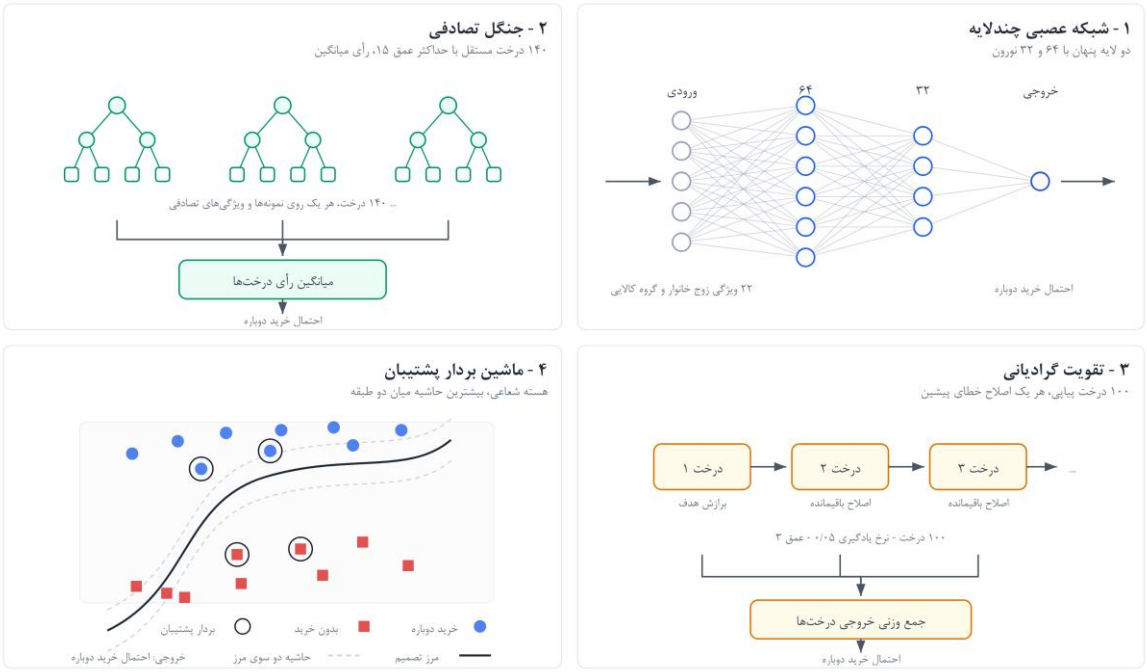
در سه الگوریتم نخست پارامترها به گونه‌ای انتخاب شده‌اند که هزینه محاسبه در حد قابل اجرا روی یک ماشین معمولی باقی بماند. برای نمونه، محدودکردن عمق درخت‌ها در جنگل تصادفی[۵۳] هم زمان آموزش را

---

[۵۲] Support Vector Machine

[۵۳] Random Forest

کاهش می‌دهد و هم از بیش‌برازش[۵۴] جلوگیری می‌کند. وزن‌دهی متعادل به کلاس‌ها نیز در دو الگوریتم اعمال شده تا کلاس کم‌تعدادتر در تابع هدف نادیده گرفته نشود.



شکل ۵-۱ – ساختار چهار الگوریتم دسته‌بندی به‌کاررفته در زیربخش نخست

۵-۴-۶ نمونه‌گیری و کنترل هزینه محاسبات

تعداد زوج‌های خانوار و گروه کالایی در همه روزهای مبدأ به مراتب بیشتر از آن است که بتوان همه آن‌ها را به مدل داد. به همین دلیل سقفی برابر شصت هزار ردیف برای مجموعه آموزش تعیین شده و این سقف به تساوی میان روزهای مبدأ تقسیم می‌شود، با این شرط که سهم هر روز مبدأ کمتر از دویست و پنجاه ردیف نباشد. نکته مهم آن است که این نمونه‌گیری با یک تابع درهم‌ساز روی شناسه خانوار و نام گروه کالایی انجام می‌شود و نه با تولید عدد تصادفی. در نتیجه اجرای دوباره آموزش با همان تنظیمات دقیقاً همان نمونه‌ها را انتخاب می‌کند و نتیجه قابل بازتولید است.

مجموعه آزمون از این محدودیت مستثنی است و همه زوج‌های موجود در روز مبدأ آزمون بدون نمونه‌گیری ارزیابی می‌شوند. در پیکربندی مرجع این گزارش، مجموعه آموزش شصت هزار ردیف و مجموعه

---

[۵۴] Overfitting

آزمون بیست و نه هزار و هفتصد و هفتاد و یک ردیف داشته است. ماشین بردار پشتیبان به دلیل هزینه محاسباتی بالاتر، از زیرمجموعه‌ای حداکثر پنج هزار ردیفی استفاده می‌کند که نسبت دو کلاس در آن حفظ شده است.

۵-٤-۷ معیارهای ارزیابی

خروجی مدل یک احتمال است و برای تبدیل آن به تصمیم دودویی، آستانه احتمالی نیم (احتمال ۰/۵) در نظر گرفته می‌شود. بر این مبنا چند معیار محاسبه می‌گردد. صحت نشان می‌دهد از میان مواردی که مدل مثبت پیش‌بینی کرده چه نسبتی واقعاً مثبت بوده‌اند و بازخوانی[۵۵] نشان می‌دهد از میان موارد واقعاً مثبت چه نسبتی را مدل پیدا کرده است. معیار F۱ میانگین هماهنگ این دو است. صحت متوازن[۵۶]، میانگین نرخ تشخیص درست در دو کلاس است و در داده‌ای که نسبت دو کلاس برابر نیست، تصویر منصفانه‌تری از عملکرد می‌دهد {۳}.

سه معیار دیگر مستقل از آستانه هستند. سطح زیر منحنی مشخصه عملکرد[۵۷] نشان می‌دهد مدل تا چه اندازه در مرتب‌کردن نمونه‌ها بر اساس احتمال موفق بوده است. مقدار نیم به معنای انتخاب تصادفی و مقدار یک به معنای جداسازی کامل است. سطح زیر منحنی دقت و بازخوانی همین کار را انجام می‌دهد اما نسبت به کلاس مثبت حساس‌تر است. امتیاز بریِر[۵۸] میانگین مربع اختلاف احتمال پیش‌بینی‌شده و برچسب واقعی است و کیفیت خودِ احتمال را می‌سنجد نه فقط ترتیب آن.

افزون بر این‌ها، دو عدد برای بررسی کالیبراسیون[۵۹] گزارش می‌شود: نسبت واقعی نمونه‌های مثبت در مجموعه آزمون و میانگین احتمال پیش‌بینی‌شده. اختلاف این دو نشان می‌دهد مدل به طور کلی خوش‌بین بوده یا بدبین. مدلی که میانگین احتمال آن به مراتب کمتر از نرخ واقعی است، حتی اگر ترتیب درستی تولید کند، احتمال‌های قابل استفاده‌ای به دست نمی‌دهد.

---

[۵۵] Recall

[۵۶] Balanced Accuracy

[۵۷] Area Under the ROC Curve

[۵۸] Brier Score

[۵۹] Calibration

۵-٤-۸ نتایج اعتبارسنجی

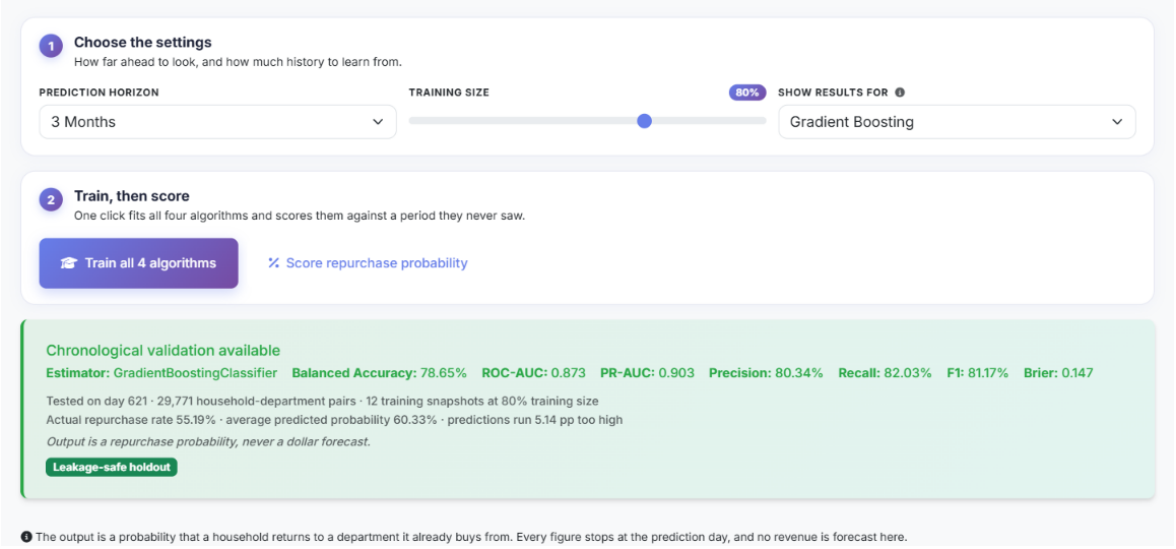
نتایج زیر از اجرای واقعی سامانه با افق سه‌ماهه و اندازه آموزش هشتاد درصد به دست آمده و در فایل نتایج ذخیره شده است. نرخ واقعی نمونه‌های مثبت در مجموعه آزمون برابر ۵۵/۲ درصد بوده است. یعنی یک مدل بی‌فایده که همه را مثبت پیش‌بینی کند هم به همین صحت می‌رسد چون وقتی ۵۵٪ نمونه‌ها مثبت‌اند، «همه را مثبت حساب کردن» بازیابی ۱۰۰٪ می‌دهد و F۱ را بالا نگه می‌دارد اما هر مدلی باید از این مقدار فاصله معناداری بگیرد تا تفاوت اساسی با یک مدل بی فایده داشته باشد. جدول ۵-۴ عملکرد چهار الگوریتم را کنار هم قرار می‌دهد.

جدول ۵-۴ – نتایج اعتبارسنجی چهار الگوریتم روی دوره آزمون، افق سه‌ماهه و اندازه آموزش هشتاد درصد

الگوریتم	صحت	بازخوانی	معیار F۱	سطح زیر منحنی	امتیاز بریِر
شبکه عصبی	۰/۸۰۹	۰/۶۱۰	۰/۶۹۵	۰/۷۷۸	۰/۲۲۰
جنگل تصادفی	۰/۷۷۴	۰/۸۲۲	۰/۷۹۷	۰/۸۵۱	۰/۱۵۸
تقویت گرادیانی	۰/۸۰۳	۰/۸۲۰	۰/۸۱۲	۰/۸۷۳	۰/۱۴۷
بردار پشتیبان	۰/۷۴۵	۰/۸۵۸	۰/۷۹۸	۰/۸۲۴	۰/۱۷۲

تقویت گرادیانی[۶۰] در همه معیارهای کلی بهترین نتیجه را داده است: صحت متوازن ۷۸/۶ درصد، سطح زیر منحنی ۸۷۳ /۰ و کمترین امتیاز بریِر دارد. جنگل تصادفی در رتبه دوم قرار دارد و اختلاف آن با تقویت گرادیانی کم است. ماشین بردار پشتیبان بالاترین بازخوانی را دارد اما صحت آن پایین‌تر است، یعنی موارد مثبت بیشتری را پیدا می‌کند ولی هشدارهای نادرست بیشتری هم تولید می‌کند.

[۶۰] Gradient Boosting



شکل ۵-۲ - پنل تنظیمات دسته‌بند خرید دوباره و نتیجه اعتبارسنجی زمانی آن

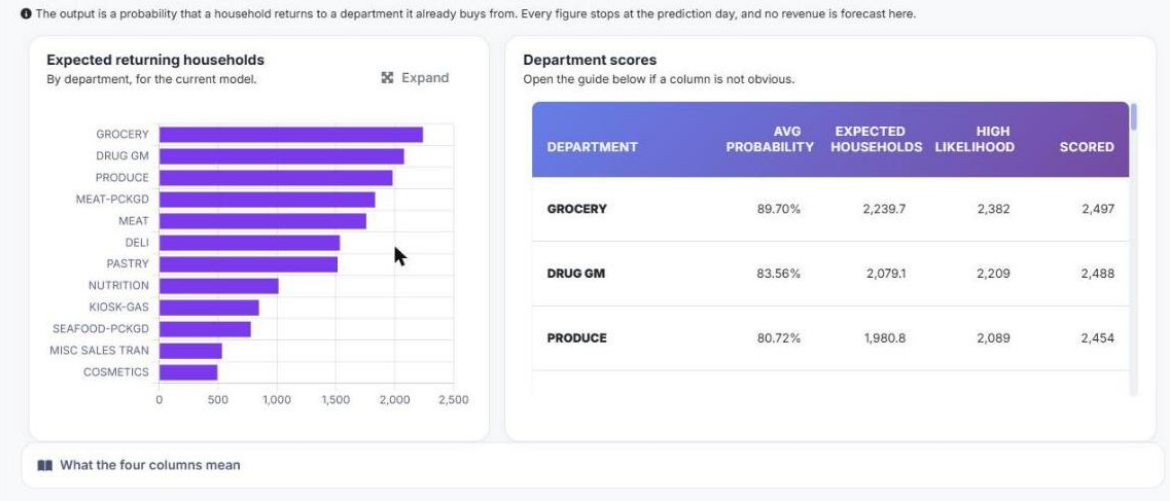
نتیجه شبکه عصبی از این جهت آموزنده است که نشان می‌دهد صحت بالا به تنهایی معیار خوبی نیست. این مدل با صحت ۰/ ۸۰۹ در ظاهر رقیب تقویت گرادیانی است، اما بازخوانی آن تنها ۰/ ۶۱۰ است و میانگین احتمال تولیدشده حدود یازده واحد درصد کمتر از نرخ واقعی است. به بیان ساده، این مدل محتاط عمل کرده و بخش بزرگی از خانوارهایی را که واقعاً بازگشته‌اند از دست داده است. برای کاربردی مانند اولویت‌بندی پیگیری‌ها و نیازهای مشتری، از دست دادن مشتری بازگشتی هزینه‌اش زیادی است که از یک هشدار نادرست حاصل می‌شود و بنابراین این مدل انتخاب مناسبی نیست و در این پروژه صرفا جهت مقایسه قرار داده‌شده است و باید بین این الگوریتم‌ها همیشه بهترین نتیجه را مبنای مناسب‌تری برای تصمیم‌گیری مدیریتی فروشگاه درنظر گرفت.

۵-٤-۹ خروجی عملیاتی و شیوه نمایش آن

پس از آموزش، کاربر می‌تواند دکمه امتیازدهی را بزند. در این مرحله سامانه یک برش جدید از داده در آخرین روز موجود می‌سازد، همه زوج‌های واجد شرایط را امتیاز می‌دهد و سپس نتیجه را در سطح گروه کالایی تجمیع می‌کند. برای هر گروه چهار عدد نمایش داده می‌شود: میانگین احتمال، تعداد خانوارهای امتیازدهی‌شده، تعداد خانوارهایی که احتمال آن‌ها از نیم بیشتر است و مجموع احتمال‌ها که به عنوان تعداد مورد انتظار خانوارهای بازگشتی آن گروه کالایی تفسیر می‌شود.

جدول ۵-۵ – نمونه‌ای از امتیاز گروه‌های کالایی در آخرین روز داده با الگوریتم تقویت گرادیانی

گروه کالایی	میانگین احتمال	تعداد مورد انتظار بازگشت	بالای آستانه نیم	خانوارهای امتیازدهی‌شده
GROCERY	۸۹/۷۰٪	۲۲۳۹/۷	۲۳۸۲	۲۴۹۷
DRUG GM	۸۳/۵۶٪	۲۰۷۹/۱	۲۲۰۹	۲۴۸۸
PRODUCE	۸۰/۷۲٪	۱۹۸۰/۸	۲۰۸۹	۲۴۵۴
MEAT-PCKGD	۷۶/۶۵٪	۱۸۳۲/۶	۱۹۳۶	۲۳۹۱
SEAFOOD PCKGD-	۴۷/۰۰٪	۷۷۶/۹	۶۴۶	۱۶۵۳



شکل ۵-۳ – نمودار تعداد مورد انتظار بازگشت و جدول امتیاز گروه‌های کالایی

تفاوت دو عدد موجود در ستون‌های تعداد مورد انتظار بازگشت و بالای آستانه نیم(۰/۵) نکته‌ای است که در راهنمای همان صفحه هم توضیح داده شده و ارزش تکرار دارد. برای مثال گروهی که همه خانوارهای آن احتمال چهل و پنج درصد دارند، در ستون تعداد بالای آستانه نیم عدد صفر می‌گیرد، در حالی که مجموع احتمال‌ها نشان می‌دهد تعداد قابل توجهی خانوار بازخواهند گشت. بنابراین ستون تعداد مورد انتظار بازگشت

چون از مجموع احتمال‌ها استفاده می‌کند، برآورد بهتری از تعداد واقعی بازگشت است زیرا اطلاعات موجود در احتمال‌های میانی را دور نمی‌ریزد.

۵-٤-۱۰ ملاحظات تفسیری این زیربخش

نخست، احتمال گزارش‌شده مربوط به یک گروه کالایی است و نه یک محصول مشخص. اینکه خانواری با احتمال هفتاد درصد دوباره از گروه لبنیات خرید کند، چیزی درباره اینکه کدام قلم لبنی را انتخاب می‌کند نمی‌گوید. دوم، این احتمال شرطی به این است که خانوار پیش‌تر از آن گروه خرید کرده باشد و برای گروه‌های تازه هیچ پیش‌بینی‌ای وجود ندارد.

سوم، معیارها روی یک دوره آزمون واحد محاسبه شده‌اند. داده هفتصد و یازده روزه امکان ساخت چند دوره آزمون مستقل با افق سه‌ماهه را نمی‌دهد، بنابراین اعداد گزارش‌شده نمونه‌ای از عملکرد در یک بازه مشخص هستند و نه میانگین چند بازه. چهارم، افق‌های بلندتر از نُه ماه از فهرست انتخاب‌ها حذف شده‌اند، زیرا در تقویم هفتصد و یازده روزه نمی‌توان دو پنجره برچسب غیرهم‌پوشان برای آموزش و آزمون ساخت و در نتیجه هیچ ارزیابی معتبری برای آن‌ها ممکن نیست.

۵-۵ زیربخش دوم: پیش‌بینی درآمد محصول با مدل سری زمانی

۵-۵-۱ تعریف مسئله و دانه تحلیل

این زیربخش به پرسش دیگری پاسخ می‌دهد: هر محصول در دوره‌های آینده چه مقدار درآمد ایجاد خواهد کرد؟ واحد تحلیل در اینجا ترکیب یک شناسه محصول و یک دوره سی‌روزه است و متغیر هدف مجموع مبلغ فروش همان محصول در همان دوره است. برخلاف زیربخش قبل که خروجی آن احتمال بود، خروجی این بخش یک مقدار پولی است.

انتخاب سطح محصول و نه سطح گروه کالایی یک تصمیم آگاهانه بوده است. پیش‌بینی در سطح گروه کالایی آسان‌تر است زیرا سری زمانی[۶۱] هموارتری دارد، اما برای تصمیم‌هایی مانند سفارش موجودی، آنچه لازم است پیش‌بینی در سطح قلم کالاست. هزینه این انتخاب، مواجهه با داده بسیار پراکنده است. در این مجموعه‌داده حدود هفتاد و پنج درصد از خانه‌های ماتریس محصول در دوره مدنظر مقدار صفر دارند.

---

[۶۱] Time Series

۵-۵-۲ ساخت دوره‌های سی‌روزه و ماتریس محصول در دوره

داده دان‌هامبی تاریخ تقویمی ندارد و روزها با شماره ثبت شده‌اند. بنابراین به جای ماه تقویمی، دوره‌های سی‌روزه تعریف شده‌اند. نکته ظریف در نحوه شمارش این دوره‌هاست: به جای آنکه شمارش از روز اول آغاز شود، از آخرین روز داده به عقب انجام می‌گیرد. با این کار، بازه ناقص در ابتدای داده قرار می‌گیرد و کنار گذاشته می‌شود، نه در انتها.

اهمیت این جزئیات را می‌توان با عدد نشان داد. داده هفتصد و یازده روز دارد و بر سی بخش‌پذیر نیست. اگر شمارش از روز اول شروع می‌شد، آخرین دوره تنها بیست و یک روز طول داشت و مقایسه آن با دوره‌های سی‌روزه، افتی ساختگی در جدیدترین دوره ایجاد می‌کرد، دقیقاً همان دوره‌ای که بیشترین وزن را در تصمیم‌گیری دارد. با شمارش معکوس، بیست و یک روز نخست داده کنار گذاشته می‌شود و بیست و سه دوره کاملاً هم‌اندازه از روز بیست و دوم تا روز هفتصد و یازدهم باقی می‌ماند. تعداد روزهای کنارگذاشته‌شده نیز در گزارش سامانه ثبت می‌گردد تا پنهان نماند.

پس از تعریف دوره‌ها، یک ماتریس ساخته می‌شود که سطرهای آن محصولات و ستون‌های آن دوره‌ها هستند و هر خانه مجموع درآمد آن محصول در آن دوره را نگه می‌دارد. خانه‌هایی که هیچ فروشی نداشته‌اند مقدار صفر می‌گیرند و نه مقدار نامشخص. این انتخاب درست است، زیرا نبود رکورد فروش در این داده به معنای نبود فروش است و معنی گمشدگی داده نمی‌دهد. ماتریس مشابهی برای تعداد اقلام فروخته‌شده نیز ساخته می‌شود تا بتوان قیمت میانگین هر واحد را برآورد کرد.

۵-۵-۳ پارامترهای پیکربندی

کاربر پیش از آموزش چند پارامتر را تعیین می‌کند که جدول ۵-۶ آن‌ها را معرفی می‌کند. سه پارامتر نخست در بخش اصلی صفحه و بقیه در بخش تنظیمات پیشرفته قرار دارند.

جدول ۵-۶ - پارامترهای پیکربندی پیش‌بینی درآمد محصول

پارامتر	دامنه	پیش‌فرض	نقش در مدل
افق پیش‌بینی	۱ تا ۹	۳	تعداد دوره‌های سی‌روزه‌ای که پیش‌بینی می‌شوند
پنجره گذشته‌نگر	۲ تا ۱۲	۶	تعداد دوره‌های گذشته که مدل به عنوان ورودی می‌خواند
گام پنجره	۱ تا ۳	۱	فاصله میان مبدأهای متوالی هنگام ساخت نمونه
اندازه آموزش	۵۰٪ تا ۹۵٪	۸۰٪	سهم جدیدترین مبدأهای مجاز که برای آموزش نگه داشته می‌شوند
واحدهای پنهان	۸ تا ۶۴	۱۶	تعداد نورون‌های لایه پنهان شبکه بازگشتی
وزن بازخورد	۰/۱تا ۱	۰/۵	سهم خروجی هر گام در ورودی گام بعدی
دوره‌های آموزش	۵ تا ۳۰	۱۰	تعداد مرورهای کامل داده آموزش

در حالت خودکار که پیش‌فرض صفحه است، سه پارامتر آخر مقدار ثابت می‌گیرند و کاربر تنها با سه پارامتر نخست سر و کار دارد. حالت دستی برای بررسی اثر معماری شبکه در نظر گرفته شده است.

۵-۵-٤ محدودیت تقویم و مفهوم عمق نظارت‌شده

مهم‌ترین محدودیت این زیربخش، کوتاهی تقویم داده است. با بیست و سه دوره کامل، هر انتخاب افق و پنجره گذشته‌نگر[۶۲] ممکن نیست. مدل برای آموزش هر گام از افق به نمونه‌ای نیاز دارد که مقدار واقعی آن گام را در اختیار داشته باشد. اگر افق طولانی و پنجره گذشته‌نگر بزرگ باشد، تعداد مبدأهای مجاز چنان کم می‌شود که گام‌های عمیق‌تر هیچ نمونه آموزشی پیدا نمی‌کنند.

به همین دلیل در بالای بخش تنظیمات یک نشانگر وضعیت قرار داده شده است که پیش از آموزش بررسی می‌کند ترکیب انتخابی چند گام از افق را می‌تواند آموزش دهد. اگر همه گام‌ها پوشش داده شوند نشانگر سبز می‌شود و اگر بخشی از افق بدون نمونه آموزشی بماند، نشانگر زرد شده و پیشنهاد مشخصی برای اصلاح ارائه می‌دهد مانند کاهش افق تا بزرگ‌ترین مقدار قابل پشتیبانی، یا افزایش پنجره گذشته‌نگر به

---

[۶۲] Lookback Window

کوچک‌ترین مقداری که افق فعلی را کامل می‌کند. تعداد گام‌های آموزش‌دیده با عنوان عمق نظارت‌شده[۶۳] در گزارش نهایی نیز ثبت می‌شود.

در پیکربندی مرجع این گزارش، افق سه دوره و پنجره گذشته‌نگر شش دوره انتخاب شده است و عمق نظارت‌شده برابر سه است یعنی هر سه گام افق نمونه آموزشی دارند و هیچ گامی برون‌یابی[۶۴] نشده باقی نمی‌ماند. دوره آزمون سه دوره پایانی داده، یعنی روزهای ششصد و بیست و دوم تا هفتصد و یازدهم است و آموزش روی دوازده مبدأ انجام می‌شود.

۵-۵-۵ مدل نخست: شبکه بازگشتی رمزگذار و رمزگشا

مدل نخست یک شبکه عصبی بازگشتی[۶۵] با یک لایه پنهان است که در دو مرحله کار می‌کند. در مرحله رمزگذاری[۶۶]، دوره‌های پنجره گذشته‌نگر یکی پس از دیگری وارد شبکه می‌شوند و شبکه وضعیت درونی خود را به‌روز می‌کند. در پایان این مرحله، وضعیت درونی چکیده‌ای از رفتار اخیر آن محصول است. در مرحله رمزگشایی[۶۷]، شبکه گام به گام مقدار دوره‌های آینده را تولید می‌کند.

صفت بازگشتی به همین مرحله دوم اشاره دارد: خروجی هر گام با وزن مشخصی در ورودی گام بعد شرکت می‌کند. مزیت این روش آن است که مدل رفتار دنباله‌ای را می‌آموزد و می‌تواند روند را در طول افق ادامه دهد. عیب آن نیز روشن است. خطای گام نخست به گام‌های بعد منتقل می‌شود و انباشته می‌گردد.

برای مهار همین مشکل چند تدبیر در پیاده‌سازی انجام شده است. تابع زیان[۶۸] به صورت هم‌زمان روی همه گام‌های افق تعریف شده و گرادیان از عمیق‌ترین گام تا نخستین گام پس‌انتشار[۶۹] می‌یابد بنابراین پارامترهایی که خروجی گام اول را می‌سازند، از خطای گام سوم نیز اصلاح می‌شوند. افزون بر آن، سهم هر گام در تابع زیان یکسان‌سازی می‌شود. دلیل این کار آن است که در ساخت نمونه‌ها، گام‌های نزدیک بسیار

---

[۶۳] Supervised Rollout Depth

[۶۴] Extrapolation

[۶۵] Recurrent Neural Network

[۶۶] Encoding

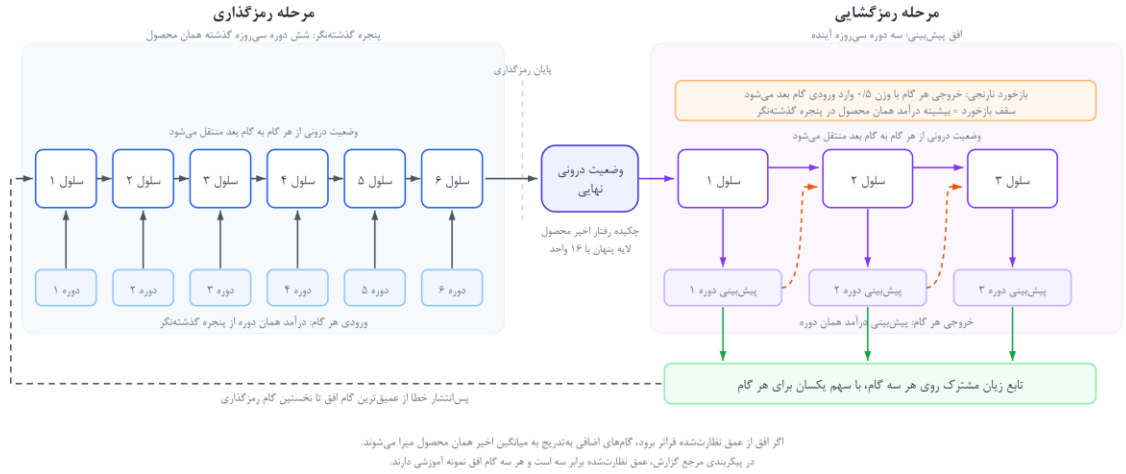
[۶۷] Decoding

[۶۸] Loss Function

[۶۹] Backpropagation

بیشتر از گام‌های دور نمونه دارند و اگر میانگین ساده گرفته شود، مدل عملاً فقط پیش‌بینی یک‌گام‌جلو را می‌آموزد و رفتار آن در گام‌های عمیق کنترل‌نشده می‌ماند.

محافظ سومی نیز وجود دارد. مقدار بازخورد در هر گام از سقفی فراتر نمی‌رود که از بیشترین مقدار مشاهده‌شده همان محصول در پنجره گذشته‌نگر به دست می‌آید. این سقف تنها از داده گذشته ساخته می‌شود و مانع از آن می‌شود که حلقه بازگشتی به سمت مقادیر غیرواقعی واگرا شود. همچنین اگر افق از عمق نظارت‌شده بیشتر باشد، گام‌های اضافی به تدریج به سمت میانگین اخیر همان محصول میرا می‌شوند و این موضوع در گزارش صریحاً اعلام می‌گردد.



شکل ۵-۴ – ساختار شبکه بازگشتی رمزگذار و رمزگشا و مسیر بازخورد و آموزش آن

پیاده‌سازی این شبکه بدون استفاده از کتابخانه‌های یادگیری عمیق و تنها با محاسبات عددی پایه انجام شده است. دلیل این انتخاب، پرهیز از افزودن یک وابستگی سنگین به پروژه بوده است. اندازه شبکه در این مسئله کوچک است و افزودن یک چارچوب یادگیری عمیق کامل توجیه نداشت.

۵-۵-۶ مدل دوم: مدل مستقیم مستقل

مدل دوم رویکرد متفاوتی دارد. به جای یک مدل که گام به گام جلو می‌رود، برای هر گام از افق یک مدل جداگانه آموزش داده می‌شود. مدل گام اول یاد می‌گیرد از پنجره گذشته‌نگر به دوره بعد برسد، مدل گام دوم یاد می‌گیرد از همان پنجره به دو دوره بعد برسد و به همین ترتیب. هنگام پیش‌بینی، هر سه مدل از یک پنجره مشاهده‌شده یکسان تغذیه می‌شوند و هیچ خروجی‌ای به مدل دیگر داده نمی‌شود.

نتیجه این طراحی آن است که خطا در طول افق انباشته نمی‌شود، اما هر گام باید مسئله یادگیری خود را از ابتدا حل کند و نمی‌تواند از الگویی که گام قبل آموخته بهره ببرد. الگوریتم پایه در این بخش درخت تقویت‌شده گرادیانی مبتنی بر بافت‌بندی مقادیر است که برای داده جدولی بزرگ سریع عمل می‌کند. برای هر گام دو مدل آموزش داده می‌شود، یکی با وزن یکسان برای همه محصولات و دیگری با وزن بیشتر برای محصولات پرفروش، و میانگین ساده این دو به عنوان پیش‌بینی نهایی همان گام استفاده می‌گردد. مدل نخست از نادیده‌گرفتن محصولات کوچک جلوگیری می‌کند و مدل دوم دقت را در جایی که بیشترین اثر مالی را دارد بالا می‌برد.

۵-۵-۷ مبنای مقایسه: میانگین اخیر

کنار دو مدل بالا، یک مبنای ساده نیز محاسبه می‌شود: میانگین درآمد چند دوره اخیر هر محصول، که بدون تغییر برای همه دوره‌های افق تکرار می‌شود. این مبنا مدل نیست و هیچ آموزشی نمی‌بیند. نقش آن سنجه‌ای است که نشان می‌دهد آیا مدل‌های پیچیده‌تر واقعاً ارزش افزوده‌ای دارند یا خیر. گنجاندن چنین مبنایی یکی از الزامات ارزیابی درست است، زیرا بدون آن هر عدد خطایی ممکن است خوب یا بد به نظر برسد بدون آنکه مرجعی برای قضاوت وجود داشته باشد.

۵-۵-۸ ویژگی‌های ورودی و چرایی حذف مؤلفه فصلی

برای مدل مستقیم، علاوه بر مقادیر خام پنجره گذشته‌نگر، چند ویژگی خلاصه نیز ساخته می‌شود: مجموع و میانگین درآمد پنجره، میانگین سه دوره اخیر به عنوان سطح جاری، انحراف معیار به عنوان نوسان، اختلاف دوره آخر و اول به عنوان روند، و نسبت دوره‌های غیرصفر به عنوان شاخص پراکندگی. همه این مقادیر پیش از ورود به مدل با تبدیل لگاریتمی فشرده می‌شوند، زیرا توزیع درآمد محصولات بسیار چوله است و چند محصول بزرگ می‌توانند بر کل فرایند یادگیری غالب شوند.

یک نکته مهم آن است که هدف مدل مستقیم، خودِ درآمد نیست بلکه اختلاف لگاریتمی درآمد واقعی و میانگین اخیر است. به بیان دیگر مدل یاد می‌گیرد چه تصحیحی باید روی مبنای ساده اعمال شود. این تغییر قاب مسئله را ساده‌تر می‌کند، زیرا مدل دیگر لازم نیست سطح کلی هر محصول را از نو بیاموزد و تنها انحراف از آن سطح را مدل می‌کند.

نکته قابل توجه دیگر، حذف عمدی مؤلفه فصلی است. در نسخه‌های پیشین، یک جفت ویژگی سینوسی و کسینوسی با دوره دوازده‌تایی به ورودی افزوده شده بود تا الگوی فصلی را نشان دهد. این ویژگی‌ها بعداً حذف شدند و دلیل آن این بود که با بیست و سه دوره موجود، نمونه‌های آموزش تنها چند فاز پیاپی از یک چرخه دوازده‌تایی را پوشش می‌دهند، در حالی که پیش‌بینی به فازهایی می‌رسد که هرگز در آموزش دیده نشده‌اند. در نتیجه ضرایب فصلی قابل تشخیص نیستند و برون‌یابی آن‌ها نتیجه را خراب می‌کند. با حضور مؤلفه فصلی، اریبی[۷۰] کلی مدل بازگشتی به بیش از صد درصد بیش‌برآورد رسیده بود، در حالی که با حذف آن به حدود منفی نوزده درصد کاهش یافت. این ویژگی از هر دو مدل حذف شده تا مقایسه روی اطلاعات یکسان انجام شود.

۵-۵-۹ تصحیح بازگردانی از فضای لگاریتمی

هر دو مدل روی هدف لگاریتمی آموزش می‌بینند و خروجی آن‌ها باید با تابع نمایی به مقیاس اصلی بازگردانده شود. این بازگردانی یک مشکل شناخته‌شده آماری دارد: نمایی‌کردن میانگین لگاریتم‌ها میانگین هندسی[۷۱] می‌دهد و میانگین هندسی برای توزیع چوله[۷۲] همواره کمتر از میانگین حسابی است. نتیجه آن است که مجموع پیش‌بینی‌ها به طور نظام‌مند کمتر از مجموع واقعی می‌شود.

راه‌حل کلاسیک این مشکل ضرب خروجی در یک ضریب تصحیح ثابت است. در این پروژه از این روش استفاده نشده و دلیل آن نیز این است که پراکندگی خطا در این داده به اندازه محصول وابسته است و یک ضریب ثابت، در حالی که اریبی کل را اصلاح می‌کند، مقدار محصولات کوچک را بیش از اندازه بزرگ می‌نمایاند. به جای آن، محصولات بر اساس سطح پیش‌بینی‌شده به ده دسته تقسیم می‌شوند و برای هر دسته ضریب جداگانه‌ای محاسبه می‌گردد. این ضرایب تنها از داده آموزش به دست می‌آیند و برای جلوگیری از تصحیح افراطی در بازه محدودی مقید شده‌اند.

۵-۵-۱۰ هماهنگ‌سازی با پیش‌بینی مجموع کل

در کنار پیش‌بینی محصول به محصول، یک مسیر جداگانه نیز مجموع درآمد کل فروشگاه را برای دوره‌های آینده برآورد می‌کند. این مسیر تنها از مجموع دوره‌های گذشته استفاده می‌کند و از یک سطح پایه

---

[۷۰] Bias

[۷۱] Geometric Mean

[۷۲] Skew

و یک روند میرا ساخته می‌شود که دامنه تغییر آن نیز محدود شده است. سپس پیش‌بینی‌های محصولی به صورت جزئی به سمت این مجموع هدایت می‌شوند. هدف این کار، جلوگیری از انحراف تدریجی مجموع پیش‌بینی‌ها از مقیاس منطقی است، بدون آنکه تفاوت میان دو مدل از میان برود. این تصحیح تنها برای افق‌های دو و سه دوره‌ای فعال است و برای افق یک‌دوره‌ای و افق‌های بلندتر از سه دوره نیز اعمال نمی‌شود چون آن‌قدر جلوتر، خودِ مدل مجموع دیگر قابل‌اتکا نیست. اگر پیش‌بینی‌های محصولی را به معیاری وابسته کنیم که خودش نامطمئن است، خطای آن را هم و دخیل کرده‌ایم. اینجا بهتر بود که مدل‌های با دوره افق بیشتر از سه آزاد بمانند.

۵-۵-۱۱ معیارهای ارزیابی خطا و کیفیت رتبه‌بندی

ارزیابی این زیربخش دو جنبه دارد. جنبه نخست، دقت مقدار پیش‌بینی‌شده است. خطای مطلق میانگین[۷۳] نشان می‌دهد پیش‌بینی هر محصول به طور متوسط چند واحد پولی با واقعیت فاصله دارد. جذر میانگین مربعات خطا[۷۴] همان مفهوم را می‌سنجد اما خطاهای بزرگ را به شدت جریمه می‌کند و بنابراین به چند محصول بزرگ حساس است. خطای درصدی مطلق وزنی، نسبت مجموع خطاها به مجموع درآمد واقعی است و برخلاف دو معیار قبلی به مقیاس داده وابسته نیست. اریبی نیز اختلاف نسبی مجموع پیش‌بینی و مجموع واقعی را نشان می‌دهد و علامت آن مشخص می‌کند مدل کم‌برآورد کرده یا بیش‌برآورد.

جنبه دوم، کیفیت رتبه‌بندی است. در بسیاری از کاربردهای واقعی، آنچه اهمیت دارد این نیست که درآمد یک محصول دقیقاً چقدر پیش‌بینی شده، بلکه این است که آیا مدل توانسته محصولات مهم را در صدر فهرست قرار دهد. برای سنجش این موضوع، فهرست بیست محصول برتر پیش‌بینی‌شده با فهرست بیست محصول برتر واقعی مقایسه می‌شود و معیارهایی مانند تعداد اشتراک، ضریب همبستگی رتبه‌ای[۷۵] و امتیاز تجمعی تنزیل‌یافته نرمال‌شده محاسبه می‌گردد. معیار اخیر علاوه بر حضور در فهرست، جایگاه محصول را نیز در نظر می‌گیرد.

۵-۵-۱۲ نتایج اعتبارسنجی

جمعیت ارزیابی شامل محصولاتی است که یا در پنجره گذشته‌نگر فروش داشته‌اند یا در دوره آزمون فروش داشته‌اند. در پیکربندی مرجع، این جمعیت پنجاه و هشت هزار و سیصد و بیست و هشت محصول را در

---

[۷۳] Mean Absolute Error

[۷۴] Root Mean Squared Error

[۷۵] Rank Correlation

بر می‌گیرد که از میان آن‌ها چهل و هشت هزار و هشتصد و شصت و شش محصول در پنجره گذشته‌نگر فعال بوده‌اند و نُه هزار و چهارصد و شصت و دو محصول شروع سرد[۷۶] محسوب می‌شوند یعنی در پنجره گذشته‌نگر هیچ فروشی نداشته‌اند و مدلی که تنها از درآمد گذشته تغذیه می‌شود ناچار برای آن‌ها صفر پیش‌بینی می‌کند. کنارگذاشتن این محصولات، نتیجه را بهتر نشان می‌داد اما تصویر واقعی را پنهان می‌کرد بنابراین در جمعیت ارزیابی نگه داشته و تعدادشان گزارش شده است. جدول ۵-۷ نتیجه سه روش را کنار هم قرار می‌دهد.

جدول ۵-۷ - مقایسه دو مدل و مبنای ساده روی دوره آزمون سه‌دوره‌ای

روش	خطای مطلق میانگین	جذر میانگین مربعات	خطای نسبی وزنی	ضریب تعیین	اریبی
شبکه بازگشتی	۹/۴۹	۴۸/۸۱	۴۶/۷٪	۰/۹۷۱	−۸٪
مدل مستقیم	۹/۳۵	۴۱/۲۹	۴۶/۰٪	۰/۹۷۹	−۸/۶٪
میانگین اخیر	۹/۸۸	۳۱/۲۴	۴۸/۷٪	۰/۹۸۸	−۴/۷٪

خواندن این جدول نیازمند دقت است و نتیجه آن به اندازه‌ای که انتظار می‌رود ساده نیست. هر دو مدل در دو معیار خطای مطلق میانگین و خطای نسبی وزنی از مبنای ساده بهترند. مدل مستقیم با خطای نسبی ۴۶ درصد در برابر ۴۸/۷ درصد مبنا، بهبود را نشان می‌دهد اما در سه معیار دیگر یعنی جذر میانگین مربعات، ضریب تعیین[۷۷] و اریبی، مبنای ساده بهتر عمل کرده است.

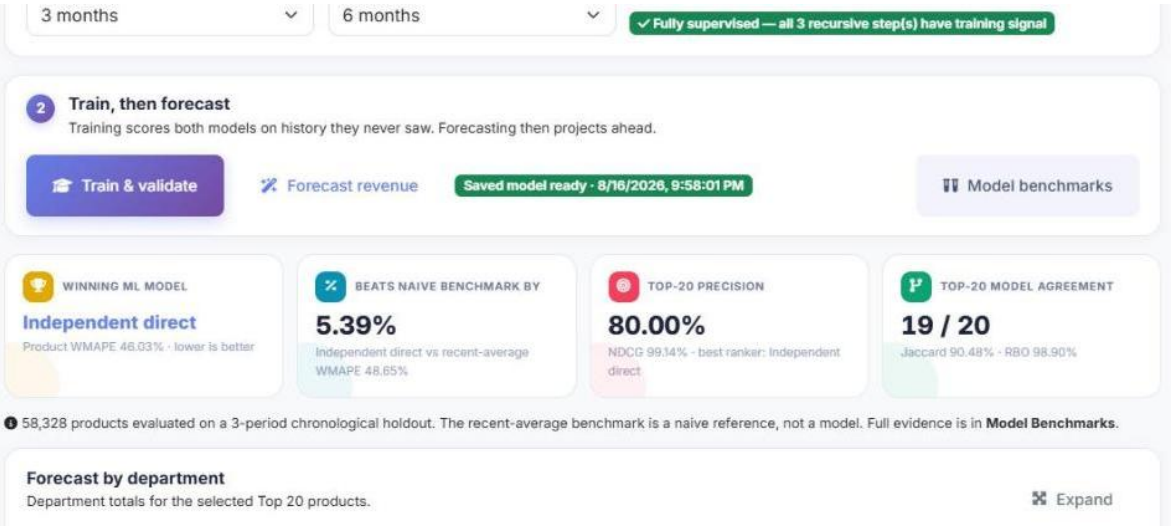
تفسیر این تناقض ظاهری دشوار نیست. جذر میانگین مربعات خطاهای بزرگ را به توان دو جریمه می‌کند و بنابراین تحت تأثیر معدود محصولات بسیار پرفروش قرار می‌گیرد. مبنای ساده برای این محصولات مقدار محافظه‌کارانه‌ای پیش‌بینی می‌کند و از خطای بزرگ در امان می‌ماند. در مقابل، خطای مطلق میانگین همه محصولات را با وزن برابر می‌سنجد و در آنجا مدل‌ها برتری دارند. به بیان دیگر مدل‌ها در اکثریت محصولات با فروش کوچک و متوسط بهتر عمل می‌کنند و مبنای ساده در معدود محصولات بزرگ بهتر عمل می‌کند. این یافته را می‌توان به عنوان برتری مدل‌ها بر مبنای ساده در محصولات کوچک‌تر درنظر گرفت دقیقاً جایی که عملکرد مدل در آن مهم‌تر از پیش‌بینی دقیق مقدار سود حاصل برای محصولات پرفروش و بزرگ می‌شود

---

[۷۶] Cold Start

[۷۷] Coefficient of Determination

پس می‌توان گفت ترتیب و لیست خروجی مدل‌ها برای محصولات پرفروش در آینده قابل اتکاتر از مبلغ سودشان است.



شکل ۵–۵ – پنل اجرای پیش‌بینی درآمد محصول و شاخص‌های کلیدی نتیجه اعتبارسنجی

در سطح مجموع نیز مبنای ساده نتیجه بهتری داده است. جدول ۵–۸ مجموع درآمد واقعی و پیش‌بینی‌شده را در سه دوره آزمون نشان می‌دهد.

جدول ۵–۸ – مجموع درآمد واقعی و پیش‌بینی‌شده در سه دوره آزمون

دوره	مقدار واقعی	شبکه بازگشتی	مدل مستقیم	میانگین اخیر
روز ۶۲۲ تا ۶۵۱	۳۹۷۵۹۰	۳۷۰۵۳۷	۳۶۴۹۰۹	۳۷۶۱۹۳
روز ۶۵۲ تا ۶۸۱	۳۸۵۴۳۵	۳۶۲۱۸۲	۳۵۹۹۶۰	۳۷۶۱۹۳
روز ۶۸۲ تا ۷۱۱	۴۰۱۶۸۲	۳۵۷۲۸۳	۳۵۷۴۶۸	۳۷۶۱۹۳

در هر سه دوره هر سه روش کم‌برآورد کرده‌اند و این کم‌برآوردی در دوره سوم بیشتر است. برای دو مدل، این الگو نشانه میرایی تدریجی در گام‌های عمیق‌تر افق است. مدل هرچه از پنجره مشاهده‌شده دورتر می‌شود محافظه‌کارتر پیش‌بینی می‌کند. مبنای ساده به دلیل ثابت‌بودن میانگین، در هر سه دوره یک مقدار می‌دهد و چون این مقدار به میانگین سه دوره واقعی نزدیک است، در مجموع اریبی کمتری نشان می‌دهد و طبیعی است که در مجموع مبالغ بهتر از مدل‌های آموزش دیده بهتر بنظر بیاید اما این معیار مناسبی برای بررسی دقت پیش‌بینی نیست و باید به ترتیب و محصولات با فروش کمتر و متوسط اهمیت بیشتری داد. باید توجه داشت که کم‌برآوردی نظام‌مند تا حدی نتیجه پراکندگی داده و محصولات شروع سرد است.

در زمینه رتبه‌بندی، نتیجه هر سه روش بسیار نزدیک است. هر سه، هر سه محصول پردرآمد نخست دوره آزمون را در همان سه جایگاه اول قرار داده‌اند و اشتراک فهرست بیست‌تایی برای هر سه برابر شانزده محصول از بیست است. توافق دو مدل با یکدیگر نیز بالاست و از بیست محصول برتر، نوزده محصول مشترک‌اند. بنابراین اگر هدف کاربر تنها شناسایی محصولات مهم باشد، تفاوت روش‌ها اهمیت عملی چندانی ندارد و تفاوت بیشتر در محصولات کم اهمیت‌تر نشان داده می‌شود و این موضوع به روشنی در رتبه‌بندی ۲۰۰ محصول برتر به بالا کم کم نمود پیدا می‌کند و می‌توان عملکرد بهتر مدل‌های یادگیری را از معیار ساده میانگین اخیر تشخیص داد.

۵-۵-۱۳ قاعده انتخاب مدل

سامانه پس از ارزیابی، یکی از دو مدل را به عنوان پیشنهاد معرفی می‌کند. قاعده انتخاب ساده است: مدلی که خطای نسبی وزنی کمتری دارد برای دقت مقدار و مدلی که امتیاز رتبه‌بندی بالاتری دارد برای اولویت‌بندی معرفی می‌شود. در پیکربندی مرجع، مدل مستقیم در هر دو مورد برنده شده و در سه معیار از چهار معیار خطا نیز بهتر بوده است.

یک نکته درباره این قاعده باید صریح گفته شود: مقایسه تنها میان دو مدل انجام می‌شود و مبنای ساده در آن شرکت داده نمی‌شود. بنابراین عنوان مدل برتر به معنای برتری بر مبنای ساده در همه معیارها نیست. همان‌طور که در جدول ۵-۷ دیده شد، این برتری تنها در دو معیار از پنج معیار برقرار است. در کاربرد واقعی و در صورت وجود تقویم طولانی‌تر، این مقایسه باید دوباره انجام شود.

۵-۵-۱۴ بازآموزی تولیدی و تولید پیش‌بینی آینده

مرحله ارزیابی روی داده‌ای انجام می‌شود که سه دوره پایانی از آن کنار گذاشته شده است. اما برای پیش‌بینی آینده، کنارگذاشتن جدیدترین داده منطقی نیست. به همین دلیل پس از پایان ارزیابی، مدل‌ها یک بار دیگر و این بار روی همه دوره‌های موجود آموزش می‌بینند و همین نسخه است که برای تولید پیش‌بینی دوره‌های پس از آخرین روز داده به کار می‌رود.

این تفکیک اهمیت زیادی دارد و در گزارش نیز ثبت شده است. معیارهای گزارش‌شده متعلق به نسخه ارزیابی هستند و نسخه تولیدی نهایی هیچ‌گاه با معیار سنجیده نمی‌شود چون مقایسه کافی در نسخه ارزیابی انجام شده است و دیگر هیچ داده‌ای باقی نمانده که ندیده باشد. همچنین برای پیش‌بینی بهتر مدل نیاز است

داده‌های ارزیابی روزهای انتهایی حتماً باید به داده‌های آموزشی مدل اضافه شوند. تفاوت این دو، نکته مهمی است که باید به آن اشاره می‌شد.

خروجی نهایی به صورت جدولی از محصولات نمایش داده می‌شود که برای هر محصول، پیش‌بینی هر دو مدل و اختلاف آن‌ها را نشان می‌دهد. نمایش هم‌زمان دو ستون عمدی است و به کاربر امکان می‌دهد میزان توافق دو روش را ببیند. محصولی که دو مدل درباره آن اختلاف زیادی دارند، نیازمند بررسی بیشتر است. ستون قیمت میانگین هر واحد نیز از تقسیم درآمد بر تعداد فروخته‌شده در پنجره اخیر به دست می‌آید و برای محصولاتی که واحد شمارش آن‌ها معنادار نیست مانند سوخت و اقلام وزنی، نمایش داده نمی‌شود.

جدول ۵–۹ – نمونه‌ای از خروجی پیش‌بینی درآمد سه دوره آینده برای پرفروش‌ترین محصولات

شناسه محصول	گروه و شرح کالایی	شبکه بازگشتی	مدل مستقیم	اختلاف دو مدل
۶۵۳۴۱۷۸	COUPON/MISC ITEMS از KIOSK-GAS	۶۹۸۳۱/۲۸	۷۰۹۴۶/۵۵	−۱۱۱۵/۲۷
۶۵۳۳۸۸۹	COUPON/MISC ITEMS از MISC SALES TRAN	۷۱۳۴/۴۱	۶۹۸۱/۱۳	+۱۵۳/۲۸
۱۰۲۹۷۴۳	FLUID MILK PRODUCTS از GROCERY	۶۲۰۸/۶۶	۵۸۲۰/۰۱	+۳۸۸/۶۵
۶۵۳۳۷۶۵	FUEL از KIOSK-GAS	۵۰۸۶/۶۸	۵۱۷۷/۴۰	−۹۰/۷۲
۹۹۵۲۴۲	FLUID MILK PRODUCTS از GROCERY	۴۱۳۹/۹۵	۴۵۵۳/۸۰	−۴۱۳/۸۵

جدول ۵–۹ پنج محصول نخست این خروجی را نشان می‌دهد. محصول **۶۵۳۴۱۷۸** که در فصل چهارم نیز به عنوان پرفروش‌ترین قلم داده معرفی شد، در اینجا هم با اختلاف زیاد در صدر قرار دارد و اختلاف دو مدل درباره آن حدود یک و نیم درصد است. در مقابل، برای محصول **۹۹۵۲۴۲** اختلاف دو مدل حدود ده درصد است و چنین موردی نیازمند بررسی بیشتر پیش از تصمیم‌گیری است.

Rank	Product	Department	Commodity	Recursive time series	Independent model	Difference	Historical revenue / quantity	DETAILS
1	6534178 Private	KIOSK-GAS	COUPON/MISC ITEMS	$69,831.28	$70,946.55	-$1,115.27	<$0.01	
2	6533889 Private	MISC SALES TRAN	COUPON/MISC ITEMS	$7,134.41	$6,981.13	+$153.28	<$0.01	
3	1029743 Private	GROCERY	FLUID MILK PRODUCTS	$6,208.66	$5,820.01	+$388.65	$2.52	
4	6533765 Private	KIOSK-GAS	FUEL	$5,086.68	$5,177.40	-$90.72	$16.00	
5	995242 Private	GROCERY	FLUID MILK PRODUCTS	$4,139.95	$4,553.80	-$413.85	$1.27	

شکل ۵-۶ - بخشی از جدول نتایج پیش‌بینی درآمد محصول با نمایش هم‌زمان دو مدل

۵-۶ ذخیره‌سازی مدل‌ها و مدیریت نسخه

آموزش هر دو زیربخش عملیات سنگینی است و اجرای دوباره آن در هر بار بازکردن صفحه پذیرفتنی نیست. بنابراین مدل‌های آموزش‌دیده در یک پوشه محلی ذخیره می‌شوند و نتایج اعتبارسنجی نیز در فایل‌های جداگانه‌ای در کنار آن‌ها نگهداری می‌گردند. نام هر فایل شامل همه پارامترهایی است که مدل با آن‌ها آموزش دیده است. مانند افق، پنجره، گام، اندازه آموزش و در مورد شبکه بازگشتی، معماری آن. در نتیجه هر ترکیب پارامتری فایل مخصوص خود را دارد و ترکیب‌ها روی یکدیگر بازنویسی نمی‌شوند.

در نام هر فایل یک شماره نسخه نیز درج شده است. هر بار که منطق آموزش یا اعتبارسنجی تغییر کرده، این شماره افزایش یافته و سامانه از بارگذاری فایل‌هایی که شماره نسخه آن‌ها قدیمی است خودداری می‌کند. علت این تدبیر آن است که یک مدل ذخیره‌شده با منطق قدیمی ممکن است بدون خطا بارگذاری شود اما عددی تولید کند که با تعریف فعلی سازگار نیست.

برای پیش‌بینی درآمد محصول، محافظ دیگری نیز وجود دارد. مشخصات داده در زمان آموزش، شامل آخرین روز داده و تعداد دوره‌های کامل، درون فایل ذخیره می‌شود و پیش از هر پیش‌بینی با وضعیت فعلی پایگاه داده مقایسه می‌گردد. اگر داده پس از آموزش تغییر کرده باشد، سامانه پیش‌بینی را انجام نمی‌دهد و پیام بازآموزی نشان می‌دهد. بدون این کنترل، ممکن بود پیش‌بینی بر مبنای پنجره‌ای تولید شود که دیگر با داده موجود هم‌خوان نیست.

۵-۷ رفتار سامانه هنگام آموزش

آموزش هر دو زیربخش ممکن است چند دقیقه طول بکشد و بنابراین نمی‌توان آن را در یک درخواست معمولی وب انجام داد. سامانه فرایند آموزش را در پس‌زمینه اجرا می‌کند و صفحه به صورت دوره‌ای وضعیت آن را می‌پرسد و به کاربر نشان می‌دهد. تا زمانی که آموزش به پایان نرسیده، دکمه‌های امتیازدهی و پیش‌بینی غیرفعال می‌مانند تا کاربر از مدلی که هنوز آماده نیست خروجی نگیرد.

اگر مدلی با همان تنظیمات از پیش ذخیره شده باشد، سامانه به جای آموزش دوباره از همان استفاده می‌کند و این موضوع را با پیامی به کاربر اطلاع می‌دهد. گزینه‌ای نیز برای آموزش اجباری در نظر گرفته شده است تا در صورت نیاز بتوان مدل را از نو ساخت. همچنین اگر آموزشی در حال اجرا باشد، درخواست دوم پذیرفته نمی‌شود. اجرای هم‌زمان دو آموزش سنگین روی یک ماشین باعث کندی هر دو می‌شد.

۵-۸ ملاحظات تفسیری و محدودیت‌ها

نخست و مهم‌تر از همه، کوتاهی تقویم داده است. هفتصد و یازده روز برابر با کمی بیش از بیست و سه دوره سی‌روزه است و در چنین تقویمی تنها یک دوره آزمون مستقل می‌توان ساخت. همه معیارهای این فصل از یک دوره آزمون به دست آمده‌اند و بنابراین بازه اطمینانی برای آن‌ها گزارش نشده است. اگر همان مدل روی دوره دیگری آزموده می‌شد، اعداد تفاوت می‌کردند.

دوم، به همین دلیل هیچ الگوی فصلی قابل یادگیری نیست. بیست و سه دوره برای مشاهده حتی دو چرخه سالانه کافی نیست و همان‌طور که توضیح داده شد، تلاش برای افزودن مؤلفه فصلی نتیجه را بدتر کرد. بنابراین پیش‌بینی‌های این فصل روند و سطح را دنبال می‌کنند و به فصل کاری ندارند.

سوم، افزایش تعداد محصولات جایگزین کمبود تاریخچه نمی‌شود. اینکه نمونه‌های آموزشی به میلیون می‌رسند، از تعداد زیاد محصولات می‌آید و نه از طول تقویم. همه این نمونه‌ها از همان بیست و سه دوره ساخته شده‌اند و اطلاعات زمانی مستقلی به مسئله اضافه نمی‌کنند.

چهارم، پراکندگی داده. سه‌چهارم خانه‌های ماتریس محصول در دوره صفر هستند و این موضوع هم مدل‌سازی را دشوار می‌کند و هم معیارهای درصدی را ناپایدار می‌سازد. معیار خطای درصدی متقارن که در جدول‌ها نیامده، در چنین داده‌ای مقادیر بزرگی می‌گیرد و همین نشان می‌دهد چرا انتخاب معیار در داده پراکنده اهمیت دارد.

پنجم، خروجی دسته‌بند خرید دوباره احتمال است و قطعیت نیست. اگر مدل برای خانواری احتمال هفتاد درصد بدهد و آن خانوار بازنگردد، این به تنهایی نشانه خطای مدل نیست. ارزیابی چنین مدلی تنها در سطح جمعیت و با معیارهای آماری معنا دارد.

ششم، در هر دو زیربخش تنها یک پیکربندی به عنوان مرجع گزارش شده است. تغییر افق، پنجره یا اندازه آموزش نتایج را تغییر می‌دهد و هر عددی که نقل می‌شود باید همراه با پیکربندی خود بیان شود. سامانه این اطلاعات را در کنار هر نتیجه ذخیره می‌کند و همین امکان بازتولید را فراهم می‌سازد.

۵-۹ جمع‌بندی فصل

سربرگ تحلیل پیش‌بینانه دو مسئله متفاوت را در یک صفحه گرد آورده است: برآورد احتمال بازگشت خانوار به یک گروه کالایی و برآورد درآمد آینده هر محصول. آنچه این دو را به هم پیوند می‌دهد، روش مشترک اعتبارسنجی است. در هر دو مورد، مرزی زمانی تعیین شده، ویژگی‌ها تنها از گذشته آن مرز ساخته شده‌اند، برچسب‌ها تنها از آینده آن مرز آمده‌اند و میان مجموعه آموزش و آزمون فاصله‌گذاری اعمال شده است.

نتایج نشان می‌دهد که در مسئله نخست، الگوریتم تقویت گرادیانی در هر سه معیار فاصل روشنی از مدل مرجع گرفته است، تقویت گرادیانی با صحت متوازن ۷۸/۶ درصد و سطح زیر منحنی ۰/۸۷۳ به روشنی از نرخ پایهص صحت که ۵۵/۲ درصد است فراتر رفته و مدل نتایج مفیدی به دست آورده است. سایر الگوریتم‌ها نیز تا حدودی در رده‌های بعدی عملکرد قابل قبولی داشته‌اند. در مسئله دوم، هر دو مدل در معیارهای مبتنی بر خطای مطلق از مبنای ساده بهتر عمل کرده‌اند اما در معیارهای حساس به محصولات بزرگ از معیار بسیار ساده میانگین اخیر عقب مانده‌اند. نتیجه‌ای که با تقویم کوتاه و داده‌های پراکنده این مجموعه سازگار است و گزارش آن به همان صورت مستند شده است و از ادعای اغراق‌آمیز درباره کارایی مدل در همه زمینه‌ها به خاطر ماهیت داده‌های موجود این دیتاست جلوگیری می‌کنیم.

از منظر پروژه، ارزش این فصل بیش از آنکه در اعداد به‌دست‌آمده باشد، در چارچوبی است که برای ارزیابی ساخته شده است. همان چارچوب در صورت افزوده‌شدن داده جدید یا تعریف مسئله تازه قابل استفاده است و اجازه می‌دهد نتایج مدل‌های مختلف روی مبنای یکسان مقایسه شوند. در فصل بعد، سربرگ هوش تجاری و تحلیل تفاضلی همین صفحه بررسی می‌شود.

فصل ششم: هوش تجاری و تحلیل تفاضلی سبد خرید

٦-١ جایگاه سربرگ هوش تجاری در صفحه تحلیل سبد خرید

صفحه تحلیل سبد خرید سه سربرگ دارد. سربرگ نخست، یعنی تحلیل توصیفی، در فصل چهارم بررسی شد و سربرگ دوم، یعنی تحلیل پیش‌بینانه، موضوع فصل پنجم بود. سربرگ سوم با عنوان «هوش تجاری و تحلیل تفاضلی» موضوع این فصل است. این سربرگ از دو سربرگ دیگر بزرگ‌تر است و در واقع یک داشبورد کامل با هشت صفحه داخلی، هشت شاخص کلیدی، بیست و چند نمودار و جدول و یک بخش آزمون آماری را در خود جا داده است {۴}.

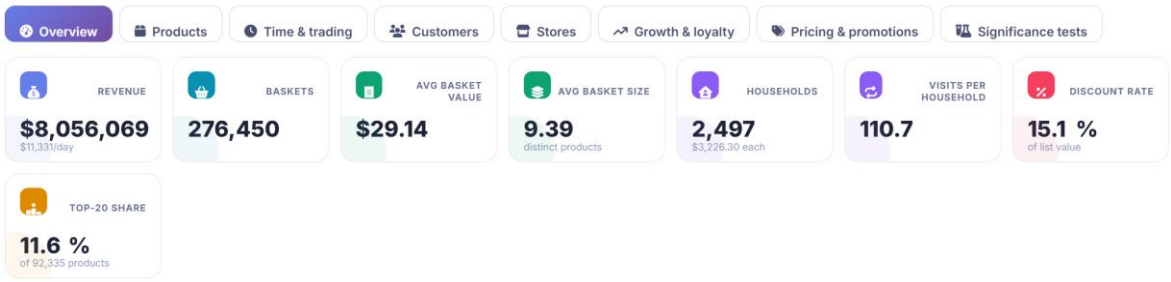
تفاوت این سربرگ با دو سربرگ دیگر در نوع پرسشی است که به آن پاسخ می‌دهد. سربرگ توصیفی می‌گوید چه چیزی فروخته شده و سربرگ پیش‌بینانه می‌گوید چه چیزی محتمل است فروخته شود. این سربرگ اما به پرسش سوم می‌پردازد: تفاوت میان گروه‌ها چقدر است و آیا این تفاوت به اندازه‌ای هست که بر پایه آن تصمیم گرفته شود. به همین دلیل در کنار نمودارها، بخشی برای آزمون معناداری آماری نیز در آن گنجانده شده است.

محتوای این سربرگ در یک قالب جداگانه نگه‌داری می‌شود و همان قالب در نشانی مستقل داشبورد هوش تجاری نیز به کار می‌رود. مزیت این کار آن است که هر اصلاحی در داشبورد، هم‌زمان در هر دو جا اعمال می‌شود. نکته مهم دیگر آنکه محتوای این سربرگ در نخستین باری که کاربر روی آن کلیک می‌کند بارگذاری می‌شود و نه هنگام باز شدن صفحه. برنامه با یک ناظر تغییر، لحظه فعال شدن سربرگ را تشخیص می‌دهد، داده را می‌گیرد و سپس ناظر را برمی‌دارد. اگر این کار انجام نمی‌شد، هر بار باز کردن صفحه تحلیل سبد خرید بیست درخواست اضافی به پایگاه داده می‌فرستاد، حتی برای کاربری که هرگز به این سربرگ سر نمی‌زند.

دسترسی به این سربرگ نیز مانند سایر بخش‌های سنگین سامانه به حساب مدیر محدود شده است. شکل ۶-۱ نمای بالای این سربرگ را شامل نوار برش‌دهنده[۷۸]ها، نوار صفحه‌های داخلی و نوار شاخص‌های کلیدی نشان می‌دهد.

---

[۷۸] Slicer



شکل ۶-۱ – نوار صفحه‌های داخلی و نوار شاخص‌های کلیدی سربرگ هوش تجاری

۶-۲ معماری داده: طرح ستاره‌ای و نماهای پایه

همه نمودارهای این سربرگ روی یک ساختار داده مشترک بنا شده‌اند و همین موضوع رمز سرعت و سازگاری آن‌هاست. به جای اینکه هر نمودار مستقیماً به جدول‌های خام مجموعه‌داده وصل شود، در پایگاه داده چهار نمای پایه ساخته شده است: یک نمای واقعیت فروش و سه نمای بُعد برای تاریخ، محصول و خانوار. این همان الگویی است که در فصل اول با نام طرح ستاره‌ای[۷۹] معرفی شد.

نمای واقعیت فروش، ستون‌های محاسبه‌شده‌ای هم دارد که در داده خام وجود ندارند و بدون آن‌ها بیشتر نمودارهای این سربرگ ساخته نمی‌شد: مجموع تخفیف هر سطر، ارزش پیش از تخفیف، ساعت تراکنش، شماره دوره سی‌روزه و بخش رفتاری خانوار. با آماده بودن این ستون‌ها، هر پرس‌وجو تنها یک تجمیع ساده است.

نکته‌ای که در پیاده‌سازی اهمیت زیادی داشت، شیوه الحاق این نماها به یکدیگر است. الحاق هر سه بُعد به نمای واقعیت در همه پرس‌وجوها، هزینه‌ای است که بسیاری از پنل‌ها به آن نیازی ندارند. روی جدولی با حدود ۲/۶ میلیون سطر، این هزینه در هر درخواست چند ثانیه می‌شود. بنابراین برنامه برای هر پرس‌وجو تشخیص می‌دهد که کدام بُعدها لازم‌اند و تنها همان‌ها را متصل می‌کند. الحاق بُعد خانوار نیز از نوع الحاق چپ[۸۰] است تا سطرهایی که خانوار متناظر ندارند از نتیجه حذف نشوند.

همه پرس‌وجوهای این سربرگ به صورت دستور مستقیم به پایگاه داده نوشته شده‌اند و از لایه نگاشت شیء به رابطه استفاده نمی‌کنند. علت این انتخاب آن است که تجمیع‌های چندسطحی و توابع پنجره‌ای در دستور مستقیم هم خواناتر و هم بسیار سریع‌تر پیاده می‌شوند. در عین حال، همه مقادیری که از کاربر می‌آیند

---

[۷۹] Star Schema

[۸۰] Left Join

به صورت پارامتر مقیدشده به پرس‌وجو داده می‌شوند و نام ستون‌ها همیشه از فهرست‌های ثابت داخلی انتخاب می‌گردد. بنابراین راهی برای تزریق دستور به پایگاه داده باز نمی‌ماند.

٦-٣ منطق پالایش هم‌بسته

ویژگی اصلی که این سربرگ را از یک مجموعه نمودار ساده جدا می‌کند، پالایش هم‌بسته[۸۱] است، یعنی هر انتخابی که کاربر انجام می‌دهد، بی‌درنگ روی هر بیست پنل دیگر اعمال می‌شود. این همان رفتاری است که کاربران از ابزارهای هوش تجاری انتظار دارند و پیاده‌سازی آن در این پروژه تلاش قابل توجهی برد.

٦-٣-١ برش‌دهنده‌های اصلی و فرعی

شش برش‌دهنده اصلی همیشه دیده می‌شوند: سال، فصل، ماه، گروه کالایی، کالا و بخش مشتری. مقدار پیش‌فرض همه آن‌ها «همه» است. هفت برش‌دهنده دیگر پشت دکمه «فیلترهای بیشتر» پنهان شده‌اند: نوع برند، روز هفته، ساعت روز، بازه درآمدی، بازه سنی، اندازه خانوار و فروشگاه. علت پنهان کردن دسته دوم صرفاً نبودن فضا برای آن‌ها در یک سطر نیست. این‌ها فیلترهایی هستند که کاربر تازه‌کار معمولاً به آن‌ها نیازی ندارد و نمایش هم‌زمان سیزده فهرست بازشو، صفحه را شلوغ می‌کند.

فهرست گزینه‌های هر برش‌دهنده از خود پایگاه داده خوانده می‌شود و نه از یک فهرست ثابت. فهرست فروشگاه‌ها به دلیل زیاد بودن تعداد، به شکل کادر متنی با پیشنهاد خودکار درآمده و گزینه‌های آن بر اساس فروش مرتب شده‌اند تا پرفروش‌ترین فروشگاه‌ها بالا بیایند.

٦-٣-٢ انتخاب چندگانه و نشانه‌های پالایش

در حالت عادی، انتخاب یک مقدار جایگزین انتخاب قبلی می‌شود. اما اگر کاربر هنگام کلیک کلید کنترل یا شیفت را نگه دارد، مقدار تازه به انتخاب قبلی افزوده می‌شود. این امکان برای پرسش‌هایی مانند «رفتار خرید در گروه خواروبار و میوه و سبزی با هم چگونه است» ضروری است.

یک جزئیات فنی کوچک اما آموزنده در همین‌جا وجود دارد. مقادیر چندگانه هنگام ارسال به سرور باید با یک جداکننده به هم بچسبند. انتخاب طبیعی برای این کار ویرگول است، اما در این مجموعه‌داده نام برخی

---

[۸۱] Cross-filtering

گروه‌های کالایی و کالاها خودشان ویرگول دارند و استفاده از ویرگول باعث می‌شد یک نام به دو نام شکسته شود. به همین دلیل از علامت خط عمودی به عنوان جداکننده استفاده شده است.

هر فیلتر فعال به شکل یک نشانه در بالای صفحه ظاهر می‌شود و با کلیک روی ضربدر آن حذف می‌گردد. نکته درست دیگری که در پیاده‌سازی رعایت شده این است که حذف یک سطح از سلسله‌مراتب، سطح‌های پایین‌تر آن را هم پاک می‌کند. اگر کاربر گروه کالایی را حذف کند اما کالای انتخاب‌شده باقی بماند، ترکیبی به وجود می‌آید که کاربر آن را نخواسته است.

٦-٣-٣ پالایش با کلیک روی نمودار

در این سربرگ لازم نیست کاربر برای پالایش حتماً سراغ فهرست‌های بازشو برود. کلیک روی هر میله، هر برش دایره، هر نقطه یا هر سطر جدول، همان مقدار را به فیلترها اضافه می‌کند. برای نمودار سلسله‌مراتب محصول این رفتار دو کار را هم‌زمان انجام می‌دهد: هم یک سطح در سلسله‌مراتب پایین می‌رود و هم بقیه پنل‌ها را به همان مقدار محدود می‌کند. در نقشه حرارتی[۸۲] نیز کلیک روی هر خانه، هم‌زمان روز هفته و ساعت را تنظیم می‌کند.

در بالای صفحه یک یادداشت کوتاه نوشته شده که آخرین زمان خواندن از پایگاه داده را نشان می‌دهد و همان‌جا به کاربر یادآوری می‌کند که با نگه داشتن کلید کنترل می‌تواند چند مقدار را با هم انتخاب کند. این نوع راهنمای در جای کار، به مراتب مؤثرتر از نوشتن یک صفحه راهنمای جداگانه است.

٦-٣-٤ ذخیره نما و ابزارهای هر کارت

دکمه «ذخیره نما» ترکیب فعلی فیلترها را با یک نام در حافظه محلی مرورگر نگه می‌دارد تا کاربر بتواند بعداً با یک کلیک به همان وضعیت برگردد. حداکثر دوازده نما نگه‌داری می‌شود و نماهای قدیمی‌تر کنار گذاشته می‌شوند. این نماها روی مرورگر همان کاربر ذخیره می‌شوند و به پایگاه داده نمی‌روند، یعنی با کاربران دیگر به اشتراک گذاشته نمی‌شوند.

روی هر کارت نمودار نیز سه ابزار کوچک قرار داده شده که با نزدیک شدن نشانگر ظاهر می‌شوند. ابزار نخست جدول عددهای پشت نمودار را باز می‌کند، ابزار دوم همان جدول را به صورت پرونده متنی قابل خواندن در نرم‌افزار صفحه‌گسترده دانلود می‌کند و ابزار سوم کارت را تمام‌صفحه می‌کند. ابزار نخست به‌ویژه

---

[۸۲] Heatmap

مهم است، زیرا در گزارش‌های تحلیلی همیشه پرسش «عدد دقیق این میله چند است» پیش می‌آید و بدون آن، کاربر ناچار است مقدار را از روی نمودار حدس بزند.

٦-٤ نوار شاخص‌های کلیدی

در بالای داشبورد هشت شاخص کلیدی نمایش داده می‌شود که با هر تغییر فیلتر دوباره محاسبه می‌گردند. جدول ۶-۱ این هشت شاخص را با شیوه محاسبه و مقدارشان روی کل مجموعه‌داده معرفی می‌کند.

جدول ۶-۱ – شاخص‌های کلیدی سربرگ هوش تجاری، شیوه محاسبه و مقدار روی کل داده

شاخص	شیوه محاسبه	مقدار روی کل داده
درآمد	مجموع ارزش فروش سطرهای واقعیت	۸۰۵۶۰۶۹ واحد، معادل ۱۱۳۳۱ در روز
تعداد سبد	شمارش شناسه‌های سبد متمایز	۲۷۶۴۵۰
ارزش متوسط سبد	درآمد تقسیم بر تعداد سبد	۲۹/۱۴
اندازه متوسط سبد	میانگین تعداد محصول متمایز در هر سبد	۹/۳۹ قلم
تعداد خانوار	شمارش شناسه‌های خانوار متمایز	۲۴۹۷ خانوار، هر یک ۳۰/۳۲۲۶
مراجعه به ازای خانوار	تعداد سبد تقسیم بر تعداد خانوار	۷/۱۱۰
نرخ تخفیف	مجموع تخفیف تقسیم بر ارزش پیش از تخفیف	۱۵/۱ درصد
سهم بیست محصول برتر	درآمد بیست محصول برتر تقسیم بر کل درآمد	۱۱/۶ درصد از ۹۲۳۳۵ محصول

دو نکته درباره این نوار باید صریح گفته شود. نخست آنکه هیچ‌یک از این کارت‌ها مقایسه با دوره قبل ندارند، نه پیکان بالا و پایین دارند و نه درصد تغییر. این تصمیمی آگاهانه در طراحی بوده است، زیرا مبنای مقایسه در حالتی که کاربر می‌تواند سیزده فیلتر را در هر ترکیبی تنظیم کند، معنای یکتایی ندارد. مقایسه دوره‌ای به جای اینجا، در صفحه رشد و وفاداری و روی یک تعریف دقیق از دوره انجام می‌شود.

دوم آنکه فاصله میان دو شاخص «اندازه متوسط سبد» و آنچه در بخش توزیع اندازه سبد دیده می‌شود، به خودی خود یک یافته است. میانگین تعداد قلم در هر سبد ۹/۳۹ است، اما میانه[۸۳] تنها ۵ قلم است و بیش از

[۸۳] Median

شصت هزار سبد، یعنی حدود بیست و دو درصد از کل سبدها، تنها یک قلم دارند. این یعنی توزیع اندازه سبد به شدت راست‌کج[۸۴] است و گزارش کردن میانگین به تنهایی، تصویر نادرستی از رفتار خرید به دست می‌دهد.

٦-٥ صفحه نمای کلی

داشبورد هشت صفحه داخلی دارد و صفحه نمای کلی، صفحه پیش‌فرض آن است. هدف این صفحه پاسخ دادن به چهار پرسش نخست هر تحلیل خرده‌فروشی است: چه چیزی فروخته می‌شود، در چه زمانی، از کدام نوع برند و در چه اندازه سبدی.

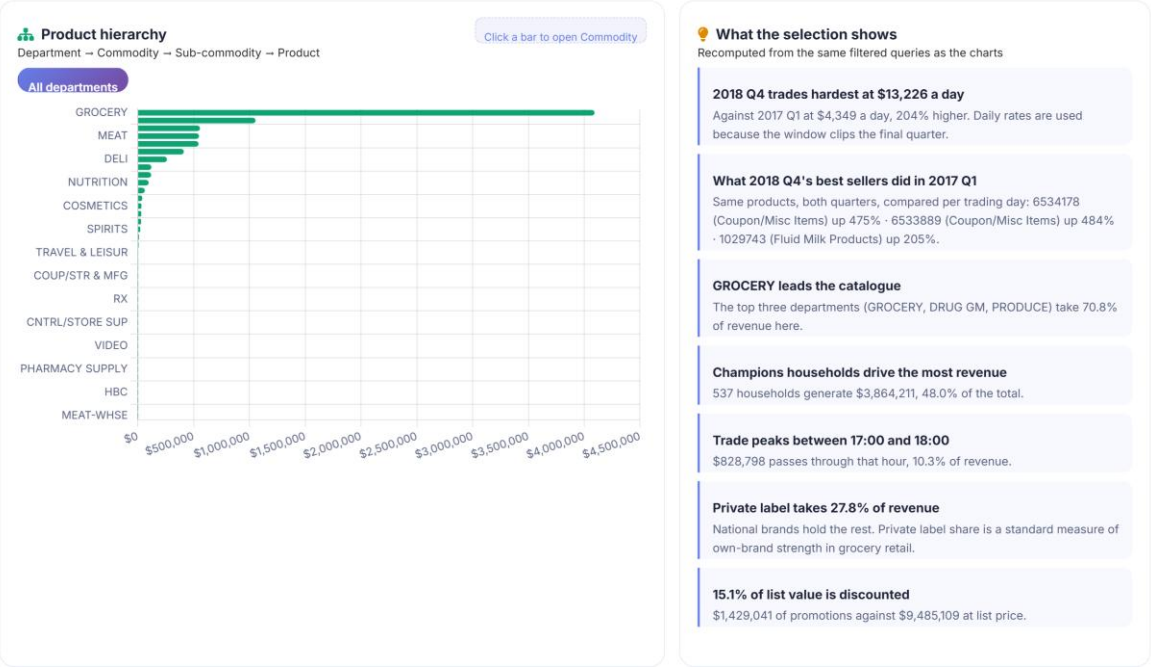
٦-٥-١ نمودار سلسله‌مراتب محصول

این نمودار یک نمودار میله‌ای افقی است که در هر لحظه یک سطح از سلسله‌مراتب محصول را نشان می‌دهد. سطح نمایش خودکار تعیین می‌شود: تا وقتی هیچ گروه کالایی انتخاب نشده، سطح گروه کالایی نمایش داده می‌شود. به محض انتخاب یک گروه، نمودار به سطح کالا می‌رود و به همین ترتیب تا سطح شناسه محصول جلو می‌رود. کلیک روی هر میله هم‌زمان هم پایین می‌رود و هم فیلتر می‌گذارد.

در بالاترین سطح، تصویری که به دست می‌آید بسیار متمرکز است. گروه خواروبار به تنهایی ۴۰۹۲۹۱۹ واحد درآمد دارد که بیش از نیمی از کل ۸۰۵۶۰۶۹ واحد است. پس از آن دارو و کالای عمومی با ۱۰۵۵۱۷۰، میوه و سبزی با ۵۵۷۳۷۵، گوشت با ۵۴۸۷۴۵ و جایگاه سوخت با ۵۴۴۲۲۲ قرار می‌گیرند. سه گروه نخست روی هم ۷۰/۸ درصد از کل درآمد را در بر می‌گیرند. شکل ۶-۲ این نمودار را در کنار کارت‌های برداشت خودکار داشبورد نشان می‌دهد.

---

[۸۴] Skewed Distribution



شکل ۶-۲ – نمودار سلسله‌مراتب محصول و کارت برداشت خودکار در صفحه نمای کلی

حضور گروه «جایگاه سوخت» در رتبه پنجم، نکته‌ای است که در نگاه اول عجیب به نظر می‌رسد اما توضیح روشنی دارد. این گروه در واقع سوخت و اقلام کنار جایگاه است و چند رکورد آن ارزش بسیار بالایی دارند. همان‌طور که در بخش محصولات خواهیم دید، تنها یک شناسه از این گروه بیش از پانصد هزار واحد درآمد ثبت کرده است. این نمونه‌ای از موقعیتی است که یک گروه به دلیل ارزش بالای هر تراکنش و نه فراوانی خرید، در رتبه‌های بالا قرار می‌گیرد.

۶-۵-۲ کارت برداشت خودکار

در کنار نمودار سلسله‌مراتب، کارتی قرار دارد که برداشت‌های متنی را به صورت خودکار تولید می‌کند. این کارت هیچ محاسبه تازه‌ای انجام نمی‌دهد و همان پرس‌وجوهای پالایش‌شده نمودارها را دوباره می‌خواند و نتیجه را به جمله تبدیل می‌کند. هفت نوع برداشت تولید می‌شود: بهترین و بدترین فصل بر پایه درآمد روزانه، رفتار پرفروش‌ترین محصولات بهترین فصل در بدترین فصل، سهم سه گروه کالایی برتر، بخش مشتری برتر، پرترافیک‌ترین ساعت، سهم برند خصوصی[۸۵] و سهم فروش تخفیف‌دار.

روی کل داده، این کارت گزارش می‌کند که فصل چهارم سال دوم با ۱۳۲۲۶ واحد درآمد در هر روز پرکارترین فصل است و در برابر فصل نخست سال اول با ۴۳۴۹ واحد در روز، ۲۰۴ درصد بالاتر ایستاده است.

---

[۸۵] Private Label

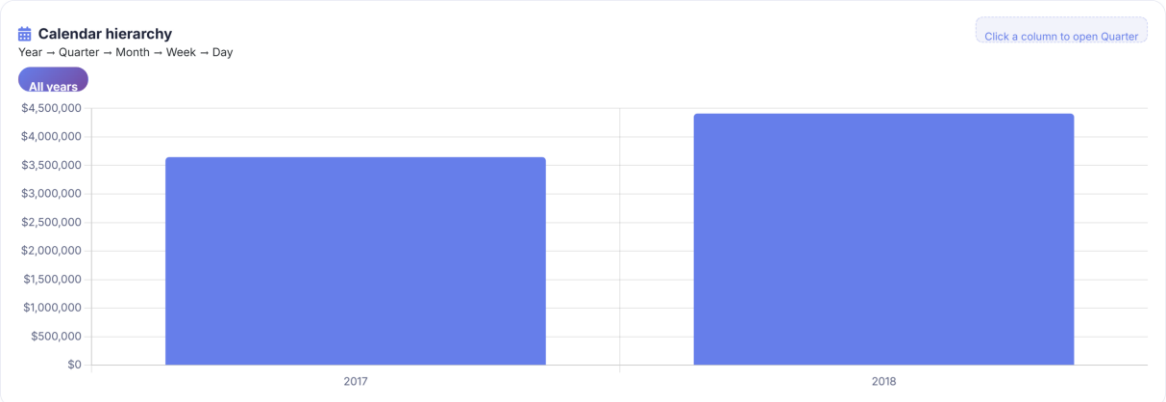
نکته مهم این است که مقایسه بر پایه درآمد روزانه و نه درآمد کل انجام می‌شود. دلیلش هم در خود کارت نوشته شده است: بازه مجموعه‌داده فصل آخر را ناقص می‌برد و مقایسه مجموع درآمد، آن فصل را به ناحق ضعیف نشان می‌دهد. این نوع نرمال‌سازی، تفاوت میان یک گزارش درست و یک گزارش گمراه‌کننده است.

با این حال، خواندن همین عدد ۲۰۴ درصد به عنوان «رشد» نادرست است و در بخش ملاحظات این فصل دوباره به آن بازمی‌گردیم. مجموعه‌داده دان‌هامبی یک پنل ثابت از خانوارهاست که در ابتدای دوره جذب شده‌اند و ثبت خرید آن‌ها به تدریج کامل شده است. بنابراین بخش بزرگی از این ۲۰۴ درصد، نه رشد بازار بلکه کامل شدن پوشش ثبت داده است.

۶-۵-۳ نمودار سلسله‌مراتب تقویمی

نمودار دوم صفحه نمای کلی، همان منطق سلسله‌مراتبی را روی زمان اجرا می‌کند: سال، فصل، ماه، هفته و روز. در بالاترین سطح، دو میله دیده می‌شود، سال اول با ۳۶۴۵۹۰۳ و سال دوم با ۴۴۱۰۱۶۶ واحد درآمد. در سطح‌های پایین‌تر که تعداد نقطه‌ها زیاد می‌شود، نوع نمودار به خودی خود از میله‌ای به خطی تغییر می‌کند تا روند خوانا بماند.

یک جزئیات هوشمندانه در این نمودار وجود دارد که ارزش توضیح دارد. هر دوره‌ای که تعداد روزهای آن کمتر از نود درصد بلندترین دوره باشد، به جای رنگ اصلی با رنگ نارنجی نمایش داده می‌شود. به این ترتیب کاربر بی‌درنگ می‌فهمد که میله کوتاه انتهای نمودار به دلیل افت فروش کوتاه نیست، بلکه به دلیل ناقص بودن آن دوره در مجموعه‌داده است. این یکی از رایج‌ترین خطاهای تفسیر در داشبوردهای واقعی است و اینکه سامانه خودش آن را علامت می‌زند، امتیاز طراحی محسوب می‌شود.



شکل ۶-۳ – نمودار سلسله‌مراتب تقویمی در سطح سال

٦-٦ صفحه محصولات

٦-٦-١ نوع برند و توزیع اندازه سبد

دو نمودار دیگر در صفحه نمای مربوط به محصولات، دو نمای متفاوت از ترکیب فروش نشان می‌دهند. نمودار حلقه‌ای نوع برند نشان می‌دهد که برندهای ملی ۵۸۱۹۱۳۱ واحد یعنی ۷۲/۲ درصد و برند خصوصی فروشگاه ۲۲۳۶۹۳۸ واحد یعنی ۲۷/۸ درصد از درآمد را تشکیل می‌دهند. زیر نمودار، یادداشتی نرخ تخفیف هر دو را هم می‌آورد: ۱۵/۸ درصد برای برند ملی[۸۶] و ۱۳/۲ درصد برای برند خصوصی.

این جفت عدد، یافته‌ای است که ارزش تأمل دارد. سهم بیست و هشت درصدی برند خصوصی برای یک خرده‌فروش آمریکایی رقم بالایی است. مهم‌تر آنکه این سهم با تخفیف کمتری به دست آمده است، یعنی برند خصوصی در این فروشگاه‌ها بر پایه قیمت پایه رقابت می‌کند و نه بر پایه تخفیف مقطعی. نکته دیگر آنکه این سهم بیست و هشت درصدی تنها از ۱۳۸۱۴ محصول به دست آمده، در حالی که ۷۸۵۲۱ محصول ملی سهم بازمانده را دارند، یعنی هر قلم برند خصوصی به طور میانگین چند برابر یک قلم ملی می‌فروشد.

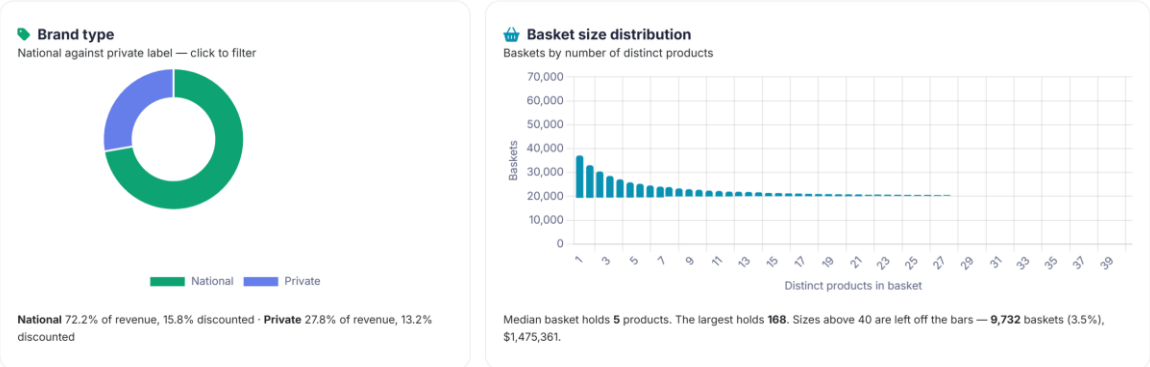
نمودار توزیع اندازه سبد، تعداد سبدها را بر حسب تعداد محصول متمایز درون آن‌ها نشان می‌دهد. تصویر به دست آمده یک توزیع نمایی‌مانند است: ۶۰۰۴۱ سبد تنها یک قلم دارند، ۳۲۸۴۶ سبد دو قلم، ۲۴۶۵۳ سبد سه قلم و از آن پس با شیب ملایمی کم می‌شود. میانه پنج قلم است و بزرگ‌ترین سبد ۱۶۸ قلم دارد. سبدهای بزرگ‌تر از چهل قلم روی نمودار نمایش داده نمی‌شوند و به جای آن در یک جمله گزارش می‌شوند: ۹۷۳۲ سبد یعنی ۳/۵ درصد از کل، با درآمد ۱۴۷۵۳۶۱ واحد. جدول ۶–۲ این دو نمودار را کنار هم خلاصه می‌کند.

---

[۸۶] National Brand

جدول ۶-۲ – ترکیب فروش بر پایه نوع برند و ویژگی‌های توزیع اندازه سبد

شاخص	مقدار
درآمد برند ملی	۵۸۱۹۱۳۱ واحد، ۷۲/۲ درصد
درآمد برند خصوصی	۲۲۳۶۹۳۸ واحد، ۲۷/۸ درصد
تعداد محصول برند ملی	۷۸۵۲۱
تعداد محصول برند خصوصی	۱۳۸۱۴
نرخ تخفیف برند ملی	۱۵/۸ درصد
نرخ تخفیف برند خصوصی	۱۳/۲ درصد
میانه اندازه سبد	۵ قلم
بزرگ‌ترین سبد	۱۶۸ قلم
سبدهای تک‌قلمی	۶۰۰۴۱ سبد، حدود ۲۲ درصد
سبدهای بزرگ‌تر از چهل قلم	۹۷۳۲ سبد، ۳/۵ درصد، درآمد ۱۴۷۵۳۶۱



شکل ۶-۴ – نمودار حلقه‌ای نوع برند و نمودار توزیع اندازه سبد

حجم بالای سبدهای تک‌قلمی یک واقعیت مهم درباره این مجموعه‌داده است که در فصل چهارم هم به شکل دیگری دیده شد. سبد تک‌قلمی برای تحلیل قوانین انجمنی هیچ اطلاعاتی ندارد، زیرا هیچ زوجی در آن شکل نمی‌گیرد. بنابراین وقتی گفته می‌شود پشتیبان قوانین در این مجموعه‌داده کوچک است، بخشی از دلیل آن همین است که یک‌پنجم سبدها اصلاً در شمارش زوج‌ها شرکت نمی‌کنند.

۶-۶-۲ جدول پرفروش‌ترین محصولات

این جدول بیست و پنج محصول برتر دوره انتخابی را با گروه کالایی، کالا، نوع برند، درآمد، سهم و تعداد سبد نشان می‌دهد. پیاده‌سازی آن در دو مرحله انجام می‌شود: نخست بیست و پنج شناسه برتر بر پایه درآمد پیدا می‌شوند و سپس تنها برای همان بیست و پنج شناسه، تعداد سبد متمایز شمرده می‌شود. علت این دو مرحله‌ای بودن، تجربه عملی است. انجام هر دو کار در یک پرس‌وجو به معنای شمردن سبدهای متمایز برای هر **۹۲۳۵۳** محصول بود و بیش از ده ثانیه طول می‌کشید.

خروجی این جدول روی کل داده، یکی از گویاترین بخش‌های کل داشبورد است. جدول ۶-۳ ده ردیف نخست آن را می‌آورد.

جدول ۶-۳ – ده محصول برتر بر پایه درآمد و تعداد سبد حاضر در آن

ردیف	شناسه	گروه و کالا	نوع برند	درآمد	سهم	تعداد سبد
۱	۶۵۳۴۱۷۸	جایگاه سوخت، کوپن و اقلام متفرقه	خصوصی	۵۰۳۸۶۷	۵۰/۶٪	۱۹۸۲۰
۲	۶۵۳۳۸۸۹	تراکنش متفرقه، کوپن	خصوصی	۴۶۳۱۱	۴/۶٪	۱۴۵۳
۳	۱۰۲۹۷۴۳	خواروبار، شیر و لبنیات مایع	خصوصی	۴۱۰۶۱	۴/۱٪	۱۴۴۲۵
۴	۶۵۳۴۱۶۶	تراکنش متفرقه، کوپن	خصوصی	۳۳۵۹۴	۳/۴٪	۱۲۰۶
۵	۱۰۸۲۱۸۵	میوه و سبزی، میوه گرمسیری	ملی	۲۹۴۸۰	۳/۰٪	۲۹۷۷۵
۶	۹۱۶۱۲۲	گوشت، مرغ	ملی	۲۸۹۴۶	۲/۰٪	۴۴۱۳
۷	۶۵۳۳۷۶۵	جایگاه سوخت، سوخت	خصوصی	۲۸۸۳۷	۲/۹٪	۱۷۵۶
۸	۱۱۰۶۵۲۳	خواروبار، شیر و لبنیات مایع	خصوصی	۲۷۸۱۸	۲/۸٪	۹۸۲۶
۹	۹۹۵۲۴۲	خواروبار، شیر و لبنیات مایع	خصوصی	۲۶۵۰۰	۲/۷٪	۱۲۵۴۱
۱۰	۵۵۶۹۲۳۰	خواروبار، نوشابه	ملی	۲۳۶۵۲	۲/۴٪	۴۸۳۴

دو ردیف نخست این جدول باید با احتیاط خوانده شوند. ستون سهم، سهم از مجموع همین بیست و پنج ردیف است و نه از کل درآمد. به همین دلیل عدد ۵۰/۶ درصد برای ردیف نخست به معنای نیمی از فروش فروشگاه نیست. نکته مهم‌تر آنکه ردیف‌های اول، دوم، چهارم و هفتم اصلاً محصول به معنای متعارف نیستند. رکوردهای کوپن، تراکنش متفرقه و سوخت هستند. اگر هدف تحلیل، تصمیم‌گیری درباره چیدمان قفسه یا سبد پیشنهادی باشد، این ردیف‌ها باید پیش از تحلیل کنار گذاشته شوند. همین موضوع در فصل هفتم و درباره

قوانین انجمنی نیز دیده شد و نشان می‌دهد که پالایش اقلام غیرکالایی، یک نیاز مشترک همه بخش‌های تحلیلی این پروژه است که البته ما این کار را به تصمیم مدیر فروشگاه واگذار کردیم.

مقایسه ستون درآمد با ستون تعداد سبد نیز آموزنده است. محصول ۱۰۸۲۱۸۵ از گروه میوه گرمسیری در ۲۹۷۷۵ سبد حاضر بوده اما تنها ۲۹۴۸۰ واحد درآمد دارد، یعنی به طور میانگین کمتر از یک واحد در هر سبد. در برابر آن، محصول ۶۵۳۳۸۸۹ تنها در ۱۴۵۳ سبد بوده و ۴۶۳۱۱ واحد درآمد دارد، یعنی حدود سی و دو واحد در هر سبد. این تفاوت میان «پرتکرار» و «پرارزش» همان موضوعی است که در فصل چهارم نیز بر آن تأکید شد و نشان می‌دهد چرا رتبه‌بندی محصولات باید هم‌زمان با دو معیار انجام شود.

Top products

Highest revenue in the current selection — click a row to filter to that product

#	PRODUCT	DEPARTMENT	COMMODITY	BRAND	REVENUE	SHARE	BASKETS
1	6534178	KIOSK-GAS	COUPON/MISC ITEMS	Private	$503,867	50.6 %	19,820
2	6533889	MISC SALES TRAN	COUPON/MISC ITEMS	Private	$46,311	4.6 %	1,453
3	1029743	GROCERY	FLUID MILK PRODUCTS	Private	$41,061	4.1 %	14,425
4	6534166	MISC SALES TRAN	COUPON/MISC ITEMS	Private	$33,594	3.4 %	1,206
5	1082185	PRODUCE	TROPICAL FRUIT	National	$29,480	3.0 %	29,775
6	916122	MEAT	CHICKEN	National	$28,946	2.9 %	4,413
7	6533765	KIOSK-GAS	FUEL	Private	$28,837	2.9 %	1,756
8	1106523	GROCERY	FLUID MILK PRODUCTS	Private	$27,818	2.8 %	9,826
9	995242	GROCERY	FLUID MILK PRODUCTS	Private	$26,500	2.7 %	12,541
10	5569230	GROCERY	SOFT DRINKS	National	$23,652	2.4 %	4,834
11	844179	MEAT	BEEF	National	$20,155	2.0 %	3,941
12	1044078	MEAT	BEEF	National	$18,896	1.9 %	4,058

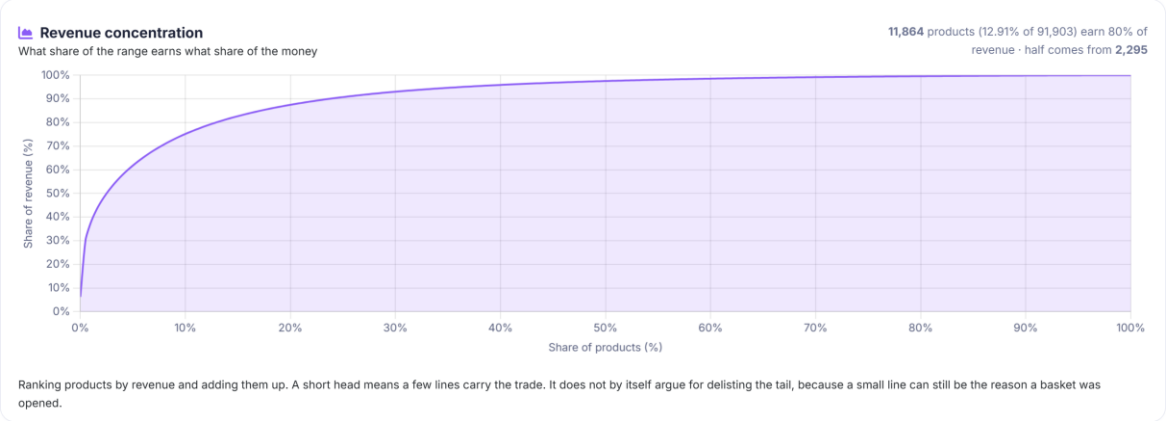
شکل ۶-۵ – جدول پرفروش‌ترین محصولات در صفحه محصولات

۶-۶-۳ منحنی تمرکز درآمد

این نمودار، منحنی تجمعی سهم درآمد بر حسب درصد محصولات مرتب‌شده از پرفروش به کم‌فروش است. هر دو محور بر حسب درصد و از صفر تا صد هستند، بنابراین منحنی به شکلی درمی‌آید که هرچه به گوشه بالا و چپ نزدیک‌تر باشد، تمرکز فروش بیشتر است.

روی کل داده، منحنی سه نقطه عطف را گزارش می‌کند. نیمی از درآمد تنها از ۲۲۹۵ محصول یعنی ۲/۵ درصد اقلام می‌آید. هشتاد درصد درآمد از ۱۱۸۶۴ محصول یعنی ۱۲/۹۱ درصد اقلام و نود درصد آن از ۲۱۷۵۵ محصول یعنی ۲۳/۶۷ درصد اقلام به دست می‌آید. مخرج این نسبت‌ها ۹۱۹۰۳ محصول است.

برداشت عملی این ارقام روشن است و از قاعده متعارف هشتاد بیست هم شدیدتر است. در این مجموعه‌داده هشتاد درصد درآمد از حدود سیزده درصد اقلام می‌آید. به بیان دیگر، بیش از سه‌چهارم فهرست محصولات تنها ده درصد درآمد را می‌سازد. برای یک خرده‌فروش این یعنی فضای قابل توجهی برای کوچک کردن فهرست کالا وجود دارد، هرچند تصمیم نهایی درباره حذف یک قلم را نمی‌توان تنها بر پایه درآمد آن گرفت. برخی اقلام کم‌فروش نقش جذب مشتری یا تکمیل سبد دارند.



شکل ۶-۶ – منحنی تمرکز درآمد بر حسب درصد تجمعی محصولات

۶-۷ صفحه زمان و الگوی خرید

۶-۷-۱ ساعت روز و روز هفته

دو نمودار میله‌ای این صفحه، در نگاه اول شبیه هم به نظر می‌رسند اما یک تفاوت مهم دارند. نمودار ساعت روز، مجموع درآمد هر ساعت را نشان می‌دهد، اما نمودار روز هفته درآمد کل را نشان نمی‌دهد، بلکه درآمد را بر تعداد روزهای متمایز آن روز هفته تقسیم می‌کند.

دلیل این تفاوت یک نکته آماری ساده اما پرکاربرد است. در بازه‌ای که با یک روز دلخواه شروع و به یک روز دلخواه ختم می‌شود، تعداد پنجشنبه‌ها لزوماً با تعداد جمعه‌ها برابر نیست. اگر مجموع درآمد گزارش شود، روزی که یک بار بیشتر تکرار شده به ناحق بالاتر می‌ایستد. تقسیم بر تعداد روز، این اثر را از بین می‌برد. همین یک تصمیم، تفاوت میان یک نمودار درست و یک نمودار سوگیرانه است.

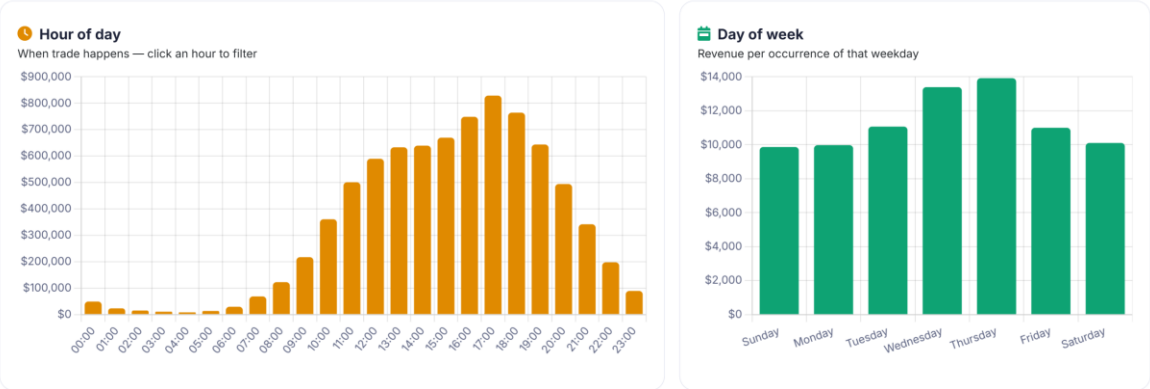
نتیجه روی کل داده در جدول ۶-۴ آمده است. بیشترین درآمد روزانه به پنجشنبه با **۱۳۹۲۱** واحد و پس از آن چهارشنبه با **۱۳۳۹۱** واحد تعلق دارد، در حالی که یکشنبه با **۹۸۶۶** و دوشنبه با **۹۹۷۶** واحد پایین‌ترین‌ها هستند.

جدول ۶-۴ – درآمد روزانه به تفکیک روز هفته

روز هفته	درآمد در هر روز
یکشنبه	۹۸۶۶
دوشنبه	۹۹۷۶
سه‌شنبه	۱۱۰۶۸
چهارشنبه	۱۳۳۹۱
پنجشنبه	۱۳۹۲۱
جمعه	۱۰۹۹۹
شنبه	۱۰۱۰۴

اینجا باید یک هشدار جدی ثبت شود. الگوی به دست آمده، یعنی اوج فروش در میانه هفته و کف آن در آخر هفته، با آنچه از رفتار خرید خواروبار انتظار می‌رود سازگار نیست. در عمل انتظار داریم آخر هفته پرکارترین روزها باشند. توضیح این ناسازگاری در ساختار مجموعه‌داده نهفته است: در داده دان‌هامبی زمان به صورت شماره روز نسبی از یک تا ۷۱۱ ثبت شده و تاریخ تقویمی واقعی وجود ندارد. نام روز هفته در این پروژه با نسبت دادن روز شماره یک به یک تاریخ فرضی ساخته شده است. بنابراین برچسب‌های روز هفته یک قرارداد داخلی‌اند و نه روز واقعی خرید. تفاوت میان بیشترین و کمترین مقدار همچنان یک الگوی دوره‌ای واقعی هفت‌روزه را نشان می‌دهد، اما نام روزها را نباید مبنای تصمیم گرفت.

نمودار ساعت روز چنین مشکلی ندارد، چون ساعت تراکنش در داده اصلی ثبت شده است. الگوی به دست آمده کاملاً منطقی است: از حدود ساعت شش صبح فروش شروع به رشد می‌کند، در ساعت‌های میانه روز به ارقام بالا می‌رسد و اوج آن بین ساعت ۱۷ و ۱۸ با ۸۲۸۷۹۸ واحد یعنی ۱۰/۳ درصد از کل درآمد است. ساعت‌های بامداد کمترین سهم را دارند اما صفر نیستند. ساعت نیمه‌شب ۴۸۸۷۹ واحد ثبت کرده که نشان می‌دهد بخشی از فروشگاه‌ها شبانه‌روزی‌اند.



شکل ۶-۷ - نمودار درآمد بر حسب ساعت روز و درآمد روزانه بر حسب روز هفته

۶-۷-۲ نقشه حرارتی هفته در ساعت

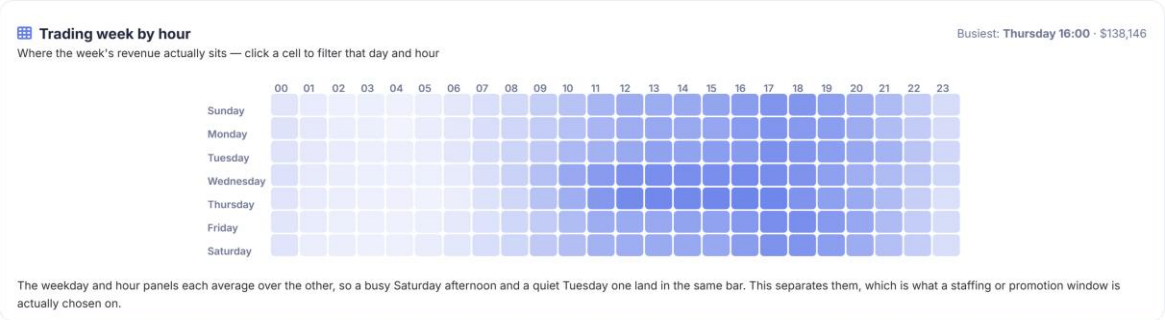
نقشه حرارتی، ترکیب دو نمودار قبلی را در یک شبکه هفت در بیست و چهار نشان می‌دهد. برخلاف بقیه نمودارهای این سربرگ، این یکی با کتابخانه نمودار ساخته نشده و یک جدول ساده است که میزان پررنگی هر خانه با درآمد آن تعیین می‌شود. دلیل این انتخاب آن است که برای یک شبکه ثابت با ۱۶۸ خانه، ساختن جدول ساده هم سبک‌تر است و هم امکان کلیک روی هر خانه را آسان‌تر فراهم می‌کند.

شدت رنگ هر خانه از نسبت درآمد آن به بیشترین درآمد شبکه به دست می‌آید، اما این نسبت پیش از تبدیل به رنگ به توان ششدهم می‌رسد. علت این کار آن است که در مقیاس خطی، تنها چند خانه پررنگ می‌شوند و بقیه شبکه تقریباً سفید می‌ماند. توان کسری، تفاوت خانه‌های میانی را قابل تشخیص می‌کند. این ترفند در تجسم داده رایج است و به آن مقیاس‌بندی توانی[۸۷] گفته می‌شود.

پرترافیک‌ترین خانه شبکه، پنجشنبه ساعت ۱۶ با ۱۳۸۱۴۶ واحد درآمد است. کلیک روی هر خانه، هم‌زمان دو فیلتر روز هفته و ساعت را تنظیم می‌کند و کل داشبورد به همان بازه محدود می‌شود، یعنی کاربر می‌تواند در یک کلیک ببیند که در شلوغ‌ترین ساعت هفته چه چیزی و توسط چه کسانی خریده می‌شود.

---

[۸۷] Power Scaling



شکل ۶–۸ – نقشه حرارتی درآمد بر حسب روز هفته و ساعت

۶–۷–۳ روند شدت تخفیف

این نمودار ترکیبی، درآمد ماهانه را به صورت میله و نرخ تخفیف همان ماه را به صورت خط روی محور دوم نشان می‌دهد. نرخ تخفیف از تقسیم مجموع تخفیف بر مجموع ارزش پیش از تخفیف به دست می‌آید، یعنی همان تعریفی که در شاخص کلیدی هم به کار رفته است.

دو محوره بودن این نمودار ضروری است، چون درآمد در مرتبه صدها هزار و نرخ تخفیف در مرتبه صدم است و روی یک محور مشترک، خط تخفیف کاملاً روی صفر می‌خوابد. با این حال باید یادآوری کرد که نمودارهای دومحوره در تجسم داده جزو ابزارهای پرمخاطره‌اند، زیرا با تغییر مقیاس هر محور می‌توان همبستگی ساختگی به وجود آورد. در اینجا مقیاس هر دو محور از داده تعیین می‌شود و دستکاری نشده است.

نتیجه روی کل داده هم درباره خود داده و هم درباره سیاست قیمت‌گذاری چیزی می‌گوید. درآمد ماه نخست تنها ۵۸۱۸۱ و ماه دوم ۱۱۲۱۸۳ واحد است، در حالی که از ماه پنجم به بعد به بازه ۳۵۰ تا ۳۸۰ هزار می‌رسد و در همان بازه می‌ماند. این شیب صعودی ابتدایی، همان کامل شدن پنل خانوارهاست که در بخش قبل توضیح داده شد و نه رشد فروش. در مقابل، نرخ تخفیف از ۴/۱۶ درصد در ماه نخست شروع می‌شود و در باقی دوره میان حدود ۱۴/۵ تا ۱۶/۵ درصد نوسان می‌کند، یعنی سیاست تخفیف در کل دوره تقریباً ثابت بوده و تغییر درآمد را نمی‌توان به تغییر شدت تخفیف نسبت داد.



شکل ۶–۹ – درآمد ماهانه و نرخ تخفیف بر روی دو محور

۶-۸ صفحه مشتریان

۶-۸-۱ بخش‌های رفتاری مشتریان

این نمودار ترکیبی است: میله‌ها درآمد هر بخش و خط روی آن‌ها تعداد خانوارهای همان بخش را روی محور دوم نشان می‌دهد. بخش‌بندی مورد استفاده همان بخش‌بندی سه‌معیاره تازگی، تکرار و ارزش پولی است که در فصل هشتم به تفصیل بررسی می‌شود. اینجا تنها به عنوان یک بُعد تحلیلی به کار می‌رود.

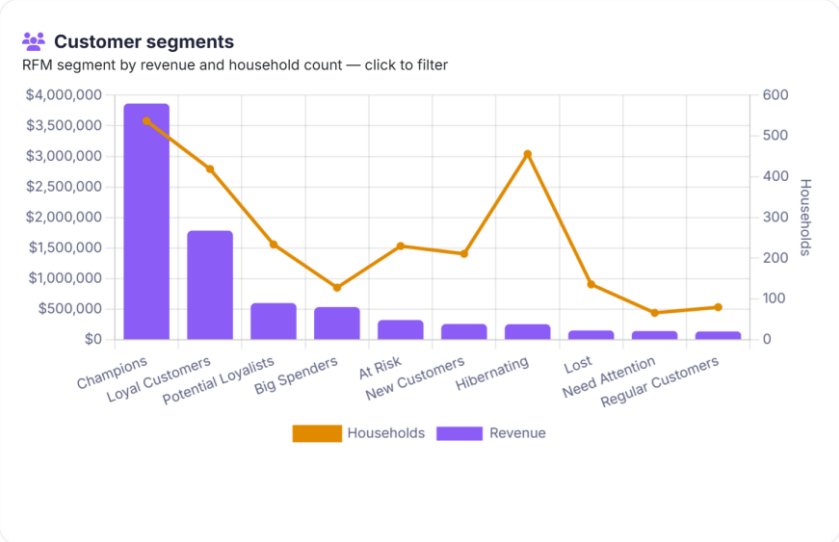
دلیل نمایش هم‌زمان دو معیار همین‌جا روشن می‌شود. جدول ۶-۵ داده این نمودار را به همراه ستون سومی که خودم محاسبه کرده‌ام، یعنی درآمد به ازای هر خانوار، می‌آورد.

جدول ۶-۵ – درآمد، تعداد خانوار و درآمد سرانه هر بخش مشتری

بخش مشتری	درآمد	تعداد خانوار	درآمد هر خانوار
قهرمانان	۳۸۶۴۲۱۱	۵۳۷	۷۱۹۶
مشتریان وفادار	۱۷۸۵۴۶۵	۴۱۹	۴۲۶۱
وفاداران بالقوه	۶۰۰۷۶۰	۲۳۴	۲۵۶۷
خرج‌کنندگان بزرگ	۵۳۵۷۱۵	۱۲۸	۴۱۸۵
در معرض خطر	۳۲۳۷۱۰	۲۳۰	۱۴۰۷
مشتریان تازه	۲۵۸۹۳۴	۲۱۱	۱۲۲۷
خفته	۲۵۵۲۸۹	۴۵۶	۵۶۰
ازدست‌رفته	۱۵۲۲۱۱	۱۳۶	۱۱۱۹
نیازمند توجه	۱۴۳۲۶۱	۶۶	۲۱۷۱
مشتریان معمولی	۱۳۶۵۱۳	۸۰	۱۷۰۶

خواندن این جدول چند نتیجه روشن می‌دهد. بخش قهرمانان با ۵۳۷ خانوار، یعنی حدود بیست و یک درصد از ۲۴۹۷ خانوار، ۴۸ درصد از کل درآمد را می‌سازد. بخش خفته با ۴۵۶ خانوار، یعنی تقریباً به همان تعداد، تنها ۳/۲ درصد درآمد دارد. درآمد سرانه این دو بخش ۷۱۹۶ در برابر ۵۶۰ واحد است، یعنی نسبت نزدیک به سیزده برابر.

نکته ظریف‌تر، مقایسه بخش «خرج‌کنندگان بزرگ» با «مشتریان وفادار» است. بخش نخست تنها ۱۲۸ خانوار دارد اما درآمد سرانه‌اش ۴۱۸۵ واحد است که تقریباً به بخش وفادار با ۴۲۶۱ واحد می‌رسد. یعنی دو مسیر متفاوت به یک نتیجه مالی مشابه می‌رسند: یکی با سبد بزرگ و مراجعه کمتر و دیگری با سبد کوچک‌تر و مراجعه بیشتر. در بخش آزمون، آزمون‌های معناداری خواهیم دید که سامانه دقیقاً همین تفاوت را به صورت آماری تأیید می‌کند.



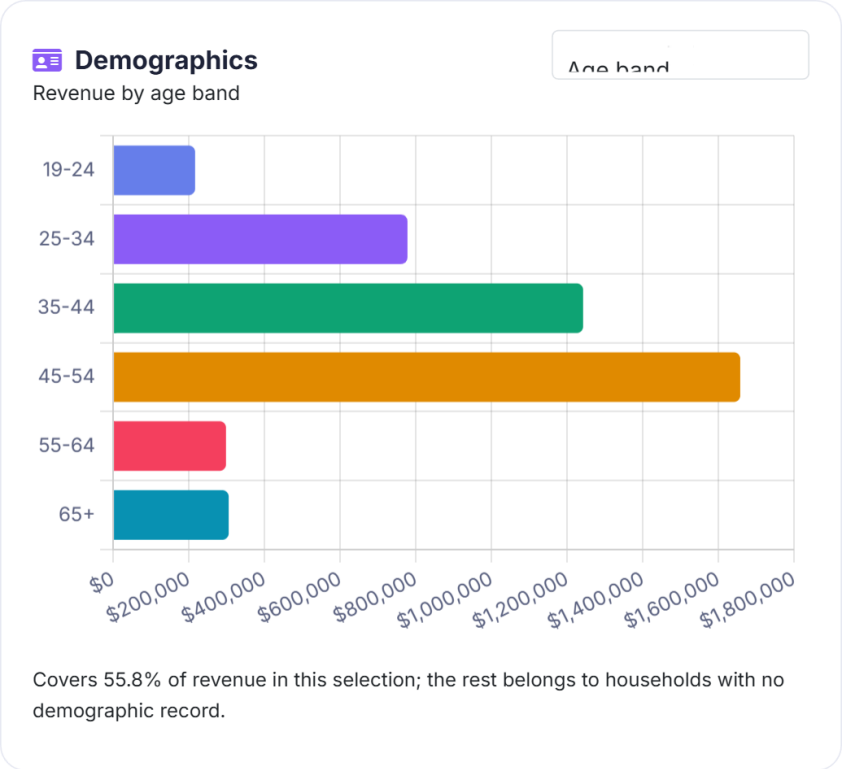
شکل ۶-۱۰ – نمودار ترکیبی درآمد و تعداد خانوار به تفکیک بخش مشتری

۶-۸-۲ جمعیت‌شناسی و مسئله پوشش داده

این پنل یک فهرست بازشو دارد که پنج بُعد جمعیت‌شناختی را در اختیار می‌گذارد: بازه سنی، بازه درآمدی، اندازه خانوار، داشتن فرزند و مالکیت مسکن. مقدار پیش‌فرض بازه سنی است. نمودار یک میله‌ای افقی ساده است اما نکته اصلی این پنل در نموداری که نشان می‌دهد نیست، بلکه در جمله‌ای است که زیر آن می‌نویسد.

در مجموعه‌داده دان‌هامبی، جدول جمعیت‌شناسی تنها ۸۰۲ خانوار از ۲۴۹۷ خانوار را پوشش می‌دهد، یعنی حدود سی و دو درصد. برنامه این محدودیت را پنهان نمی‌کند و در یک پرس‌وجوی جداگانه محاسبه می‌کند که خانوارهای دارای رکورد جمعیت‌شناختی در هر شاخه چه سهمی از درآمد انتخاب فعلی را دارند و همان را گزارش می‌دهد. روی کل داده این سهم برای شاخه بازه سنی برای مثال ۵۵/۸ درصد از درآمد کل است.

اختلاف میان سی و دو درصد خانوار و پنجاه و شش درصد درآمد به خودی خود یک یافته است: خانوارهایی که رکورد جمعیت‌شناختی دارند به طور میانگین بیش از خانوارهای بدون رکورد خرج می‌کنند. این یعنی نمونه دارای جمعیت‌شناسی، نمونه‌ای تصادفی از کل خانوارها نیست و هر نتیجه‌ای که از تحلیل جمعیت‌شناختی گرفته شود، دچار سوگیری انتخاب[۸۸] است. توزیع درآمد بر حسب سن نیز همین را نشان می‌دهد: بازه ۴۵ تا ۵۴ سال با ۱۶۵۷۴۶۷ و بازه ۳۵ تا ۴۴ سال با ۱۲۴۲۱۴۷ واحد، بیشترین سهم را دارند، در حالی که بازه‌های ۵۵ تا ۶۴ و بالای ۶۵ سال هر یک حدود سیصد هزار واحد دارند. اینکه گروه‌های سنی بالاتر کم‌سهم‌اند، به احتمال زیاد بیش از آنکه واقعیت کل بازار باشد، بازتاب ترکیب همین ۸۰۲ خانوار است.



شکل ۶-۱۱ – نمودار درآمد بر حسب بازه سنی و یادداشت پوشش داده جمعیت‌شناختی

۶-۹ صفحه فروشگاه‌ها

این صفحه یک نمودار حبابی[۸۹] دارد که سه معیار را هم‌زمان نشان می‌دهد: محور افقی تعداد سبد، محور عمودی ارزش متوسط سبد و اندازه هر حباب سهم آن فروشگاه از درآمد. سیصد فروشگاه برتر نمایش داده می‌شوند.

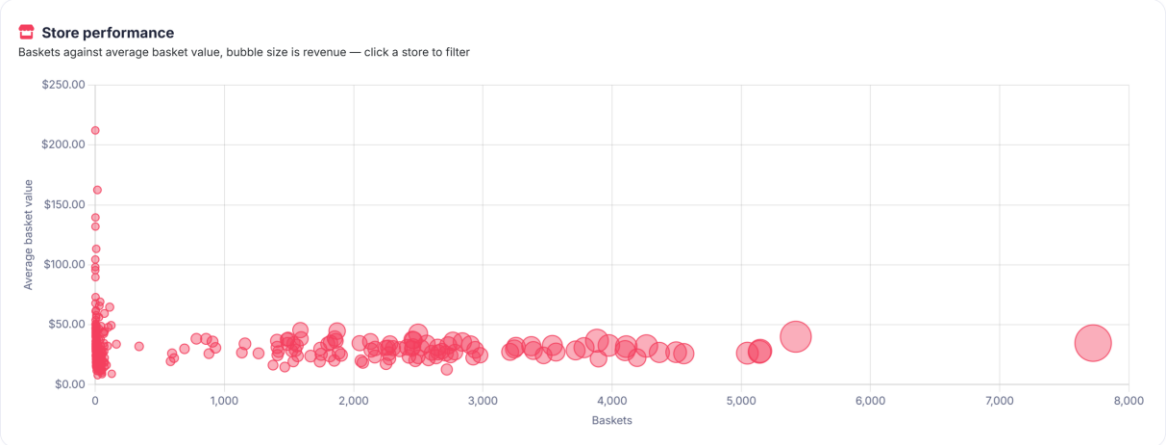
---

[۸۸] Selection Bias

[۸۹] Bubble Chart

انتخاب نمودار حبابی برای این پرسش درست است. اگر تنها درآمد فروشگاه‌ها را روی یک نمودار میله‌ای می‌گذاشتیم، نمی‌شد فهمید که یک فروشگاه پرفروش، درآمدش را از تعداد زیاد مشتری گرفته است یا از سبدهای بزرگ. با این نمودار، این دو حالت در دو ناحیه متفاوت صفحه قرار می‌گیرند.

در داده واقعی، پرفروش‌ترین فروشگاه با شناسه ۳۶۷ درآمد ۲۶۷۶۰۶ واحد از ۷۷۲۳ سبد دارد و ارزش متوسط سبد آن ۳۴/۶۵ است. فروشگاه ۴۰۶ با ۲۱۶۷۸۲ واحد درآمد از تنها ۵۴۲۲ سبد در رتبه دوم است و ارزش متوسط سبدش ۳۹/۹۸ یعنی محسوس‌تر از فروشگاه نخست است. در مقابل، فروشگاه ۳۶۱ با ۵۱۴۶ سبد نزدیک به فروشگاه ۴۰۶ است اما ارزش متوسط سبد آن تنها ۲۸/۱۲ است و درآمدش به ۱۴۴۶۹۹ می‌رسد. مقایسه این سه فروشگاه دقیقاً همان چیزی است که این نمودار برای دیدنش ساخته شده: فروشگاه ۴۰۶ با ترافیک کمتر، درآمدی نزدیک به فروشگاه ۳۶۷ می‌سازد چون سبدهای بزرگ‌تری دارد.



شکل ۶-۱۲ – نمودار حبابی عملکرد فروشگاه‌ها بر پایه تعداد سبد، ارزش متوسط سبد و درآمد

۶-۱۰ صفحه رشد و وفاداری

۶-۱۰-۱ تفاضل دو دوره کامل

نخستین نمودار این صفحه، تنها جایی در کل داشبورد است که یک تفاضل زمانی واقعی محاسبه می‌کند. مقایسه میان دوره بیست و سوم و دوره بیست و دوم انجام می‌شود، همان دوره‌های سی‌روزه‌ای که در فصل پنجم برای پیش‌بینی درآمد ساخته شده بودند. علت انتخاب این دو دوره آن است که هر دو کامل‌اند و دوره‌های ناقص ابتدا و انتهای مجموعه‌داده در مقایسه شرکت نمی‌کنند.

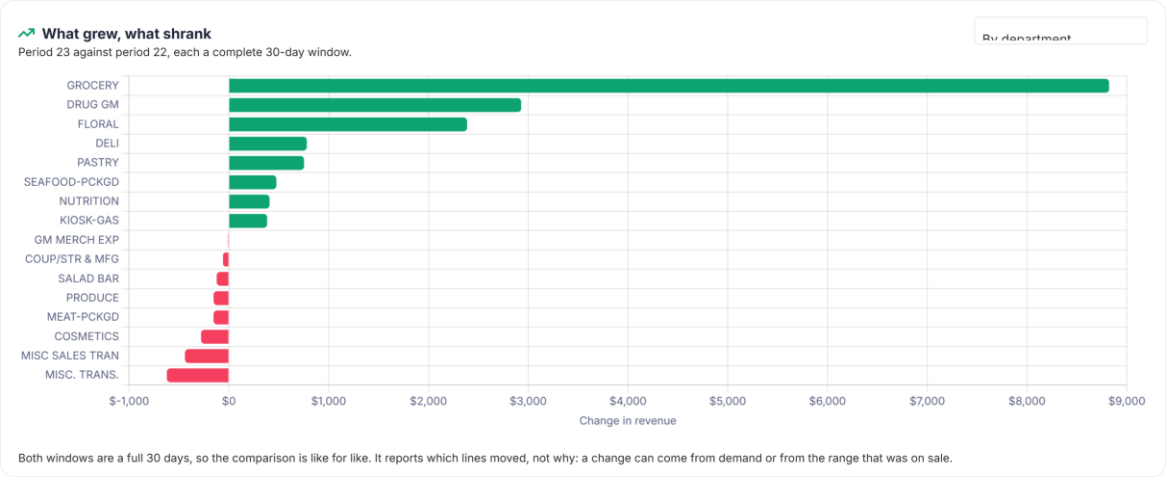
تغییر به دو شکل گزارش می‌شود: تفاضل مطلق درآمد و درصد تغییر نسبت به دوره پیشین. نمودار یک میله‌ای افقی دوسویه است. افزایش‌ها با رنگ سبز به سمت راست و کاهش‌ها با رنگ قرمز به سمت چپ. کاربر می‌تواند بُعد مقایسه را میان گروه کالایی، کالا، فروشگاه و بخش مشتری تغییر دهد.

برخی از نتایج روی کل داده در جدول ۶-۶ آمده است. برای اینکه تصویر کامل باشد، هم تفاضل مطلق و هم درصد تغییر آورده شده‌اند.

جدول ۶-۶ – تفاضل درآمد دوره بیست و سوم نسبت به دوره بیست و دوم به تفکیک گروه کالایی

گروه کالایی	درآمد دوره پیشین	درآمد دوره جاری	تفاضل	درصد تغییر
خواروبار	۱۹۹۸۱۳	۲۰۸۶۳۵	+۸۸۲۲	+۴/۴
دارو و کالای عمومی	۵۰۰۰۷	۵۲۹۳۷	+۲۹۳۰	+۵/۹
گل و گیاه	۹۷۳	۳۳۶۱	+۲۳۸۸	+۲۴۵/۴
اغذیه آماده	۱۱۹۸۱	۱۲۷۶۳	+۷۸۱	+۶/۵

خواندن این جدول یک درس روش‌شناختی مهم دارد. اگر تنها به ستون تفاضل مطلق نگاه کنیم، خواروبار با ۸۸۲۲ واحد افزایش، برنده مطلق است. اما درصد تغییر آن تنها ۴/۴ است. در مقابل، گل و گیاه با ۲۳۸۸ واحد افزایش در جایگاه سوم است اما درصد تغییر آن ۲۴۵ درصد است، یعنی درآمد این گروه نزدیک به سه و نیم برابر شده است. کدام‌یک خبر مهم‌تری است؟ پاسخ به پرسش تحلیلی بستگی دارد. برای برنامه‌ریزی انبار، عدد مطلق اهمیت دارد و برای شناسایی روند نوظهور، درصد.



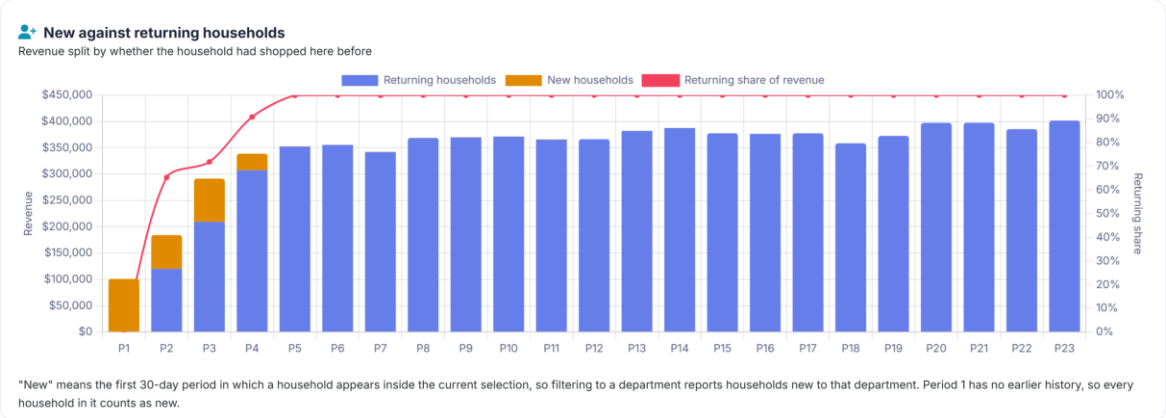
شکل ۶-۱۳ – نمودار دوسویه تفاضل درآمد میان دو دوره کامل متوالی

۶-۱۰-۲ خانوار تازه در برابر خانوار بازگشتی

این نمودار برای هر یک از بیست و سه دوره سی‌روزه، درآمد را به دو بخش تقسیم می‌کند: خانوارهایی که آن دوره نخستین خریدشان بوده و خانوارهایی که پیش‌تر هم خرید کرده بودند. میله‌ها روی هم انباشته می‌شوند و یک خط، سهم درآمد بازگشتی را روی محور دوم نشان می‌دهد.

نتیجه روی این مجموعه‌داده بسیار گویاست و باید با دقت تفسیر شود. در دوره نخست تمام ۱۰۰۹۷۹ واحد درآمد از خانوارهای تازه است، چون همه برای نخستین بار دیده می‌شوند. در دوره دوم سهم بازگشتی به ۶۵/۲ درصد، در دوره سوم به ۷۱/۸ و در دوره چهارم به ۹۰/۸ درصد می‌رسد. از دوره پنجم به بعد این سهم عملاً روی صد درصد می‌ایستد. برای نمونه در دوره پنجم درآمد خانوارهای تازه تنها ۳۷۵ واحد در برابر ۳۵۲۳۹۷ واحد بازگشتی است.

این تصویر را نباید به عنوان «موفقیت خارق‌العاده در حفظ مشتری» خواند. مجموعه‌داده دان‌هامبی یک پنل بسته[۹۰] است. ۲۴۹۷ خانوار در ابتدای مطالعه انتخاب شده‌اند و در ادامه خانوار تازه‌ای به آن اضافه نمی‌شود. بنابراین صفر شدن سهم خانوار تازه، نتیجه طراحی مطالعه است و نه نتیجه رفتار بازار. آنچه این نمودار واقعاً به کار می‌آید، تأیید این است که پنل در چهار دوره نخست کامل شده و از دوره پنجم به بعد داده پایدار است و همین یافته برای انتخاب بازه آموزش مدل‌های فصل پنجم اهمیت دارد.



شکل ۶-۱۴ – درآمد خانوارهای تازه و بازگشتی در بیست و سه دوره سی‌روزه

---

[۹۰] Panel Data

۶-۱۰-۳ دهک‌های ارزش خانوار

این نمودار خانوارها را بر پایه درآمدشان از زیاد به کم مرتب می‌کند، به ده دهک[۹۱] مساوی تقسیم می‌نماید و سهم هر دهک از کل درآمد را به صورت میله و سهم تجمعی را به صورت خط نشان می‌دهد. دهک نخست با رنگ متفاوتی مشخص می‌شود.

ارقام به دست آمده در جدول ۶-۷ آمده‌اند. دهک نخست با ۲۵۰ خانوار، ۳۴/۳ درصد از کل درآمد را می‌سازد و به طور میانگین هر خانوار آن ۱۱۰۵۲ واحد خرید و ۲۹۴ بار مراجعه داشته است. دو دهک نخست روی هم ۵۳/۱ درصد و سه دهک نخست ۶۶/۷ درصد از درآمد را در بر می‌گیرند. در انتهای طیف، دهک دهم تنها ۰/۷ درصد از درآمد را دارد.

جدول ۶-۷ - سهم هر دهک خانوار از درآمد و سهم تجمعی

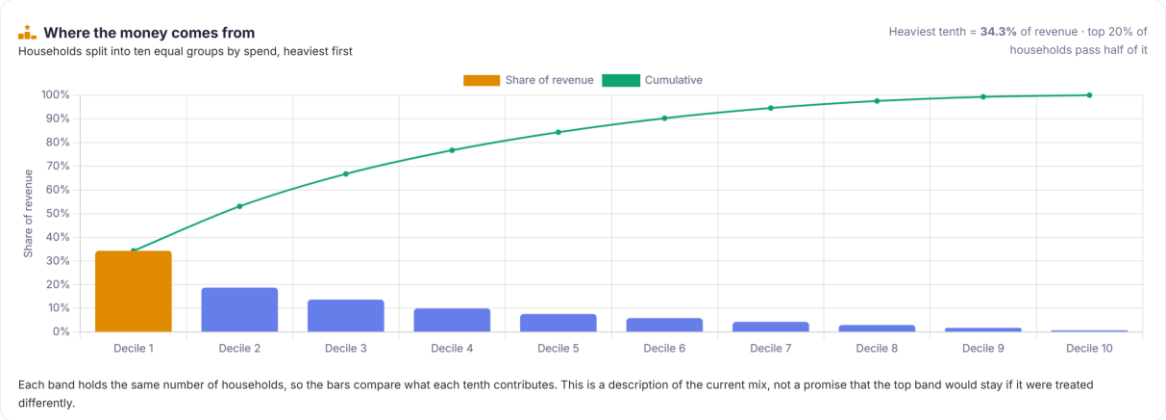
دهک	سهم از درآمد	سهم تجمعی
دهک ۱	۳۴/۳٪	۳۴/۳٪
دهک ۲	۱۸/۸٪	۵۳/۱٪
دهک ۳	۱۳/۷٪	۶۶/۷٪
دهک ۴	۱۰/۰٪	۷۶/۷٪
دهک ۵	۷/۶٪	۸۴/۴٪
دهک ۶	۵/۹٪	۹۰/۲٪
دهک ۷	۴/۳٪	۹۴/۵٪
دهک ۸	۳/۰٪	۹۷/۵٪
دهک ۹	۱/۸٪	۹۹/۳٪
دهک ۱۰	۰/۷٪	۱۰۰٪

مقایسه این جدول با منحنی تمرکز محصولات، نکته‌ای را روشن می‌کند که ارزش گفتن دارد. تمرکز در سمت مشتری بسیار شدیدتر از تمرکز در سمت محصول است. هشتاد درصد درآمد از حدود سیزده درصد محصولات می‌آید، اما همان هشتاد درصد از کمتر از پنجاه درصد خانوارها می‌آید. به بیان دیگر، از دست

---

[۹۱] Decile

دادن یک خانوار دهک اول به مراتب گران‌تر از حذف چند قلم کم‌فروش است. این استدلال، منطق سرمایه‌گذاری روی ماندگاری مشتری را که در فصل هشتم بررسی می‌شود پشتیبانی می‌کند.



شکل ۶–۱۵ – سهم هر دهک خانوار از درآمد و منحنی سهم تجمعی

۶–۱۱ صفحه قیمت‌گذاری و ترویج

۶–۱۱–۱ ترکیب درآمد بر پایه عمق تخفیف

این نمودار درآمد را در پنج طبقه بر پایه عمق تخفیف[۹۲] هر سطر تقسیم می‌کند: بدون تخفیف، کمتر از ده درصد، ده تا بیست و پنج درصد، بیست و پنج تا پنجاه درصد و پنجاه درصد و بیشتر. طبقه‌بندی در خود پرس‌وجو انجام می‌شود و نه در برنامه، چون انتقال میلیون‌ها سطر خام به برنامه برای طبقه‌بندی، بی‌معناست.

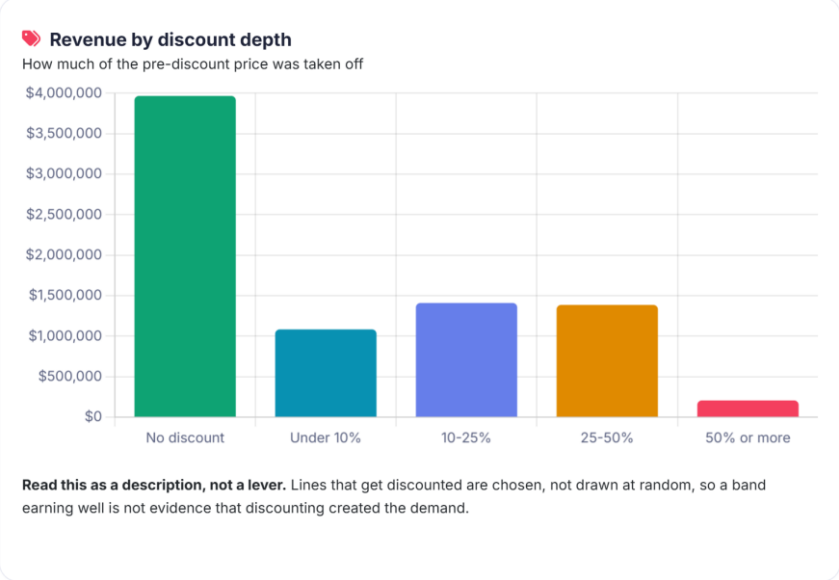
جدول ۶–۸ نتیجه را نشان می‌دهد. تقریباً نیمی از درآمد، یعنی ۳۹۶۶۳۹۰ واحد معادل ۴۹/۲ درصد، بدون هیچ تخفیفی فروخته شده است. در سوی دیگر، ۲۰۷۷۹۵ واحد یعنی تنها ۲/۶ درصد با تخفیف پنجاه درصد و بیشتر فروش رفته‌اند. دو طبقه میانی روی هم ۳۴/۷ درصد درآمد را در بر می‌گیرند.

[۹۲] Discount Depth

جدول ۶–۸ – ترکیب درآمد بر پایه عمق تخفیف

طبقه عمق تخفیف	درآمد	سهم
بدون تخفیف	۳۹۶۶۳۹۰	۴۹/۲٪
کمتر از ۱۰ درصد	۱۰۸۴۵۲۱	۱۳/۵٪
۱۰ تا ۲۵ درصد	۱۴۱۰۷۱۳	۱۷/۵٪
۲۵ تا ۵۰ درصد	۱۳۸۶۶۴۸	۱۷/۲٪
۵۰ درصد و بیشتر	۲۰۷۷۹۵	۲/۲٪

برداشت من از این توزیع این است که سیاست ترویج این خرده‌فروش، سیاست تخفیف‌های عمیق و مقطعی نیست بلکه سیاست تخفیف‌های کم‌عمق و گسترده است. حدود سی و یک درصد درآمد با تخفیف کمتر از بیست و پنج درصد فروخته می‌شود و تنها بخش کوچکی به تخفیف‌های سنگین اختصاص دارد. این نکته با یافته بخش نوع برند سازگار است. آنجا هم دیدیم که برند خصوصی سهم بالایی دارد بی‌آنکه تخفیف بیشتری بگیرد. مجموع این دو یافته، تصویری از یک خرده‌فروش با راهبرد قیمت پایین روزمره[۹۳] می‌سازد و خبری از راهبرد تخفیف‌های ضربتی نیست.



شکل ۶–۱۶ – ترکیب درآمد بر پایه عمق تخفیف

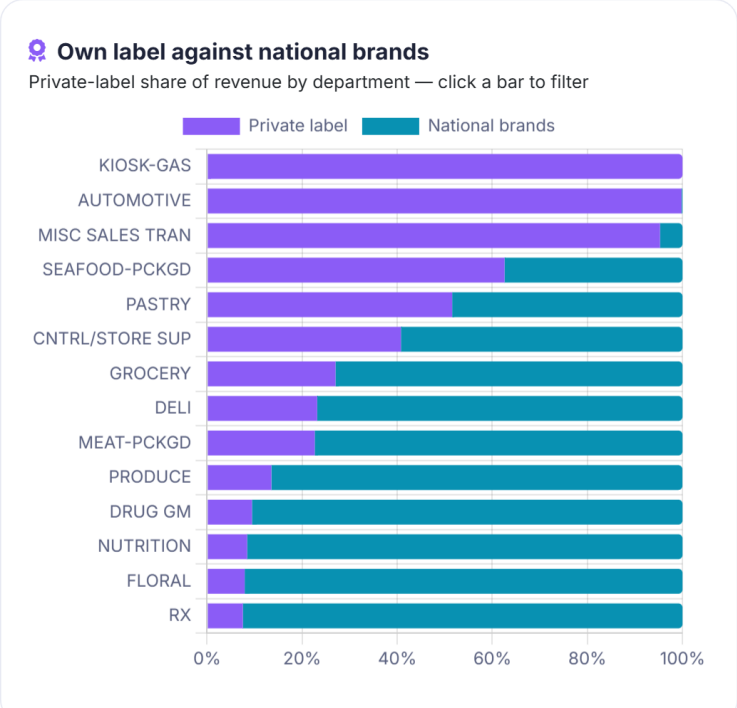
[۹۳] Everyday Low Price

۶-۱۱-۲ سهم برند خصوصی به تفکیک گروه کالایی

نمودار پایانی این صفحه، یک نمودار میله‌ای انباشته صددرصدی افقی است که برای هر گروه کالایی، نسبت سهم برند خصوصی به برند ملی را نشان می‌دهد و بر پایه سهم برند خصوصی مرتب شده است.

نتیجه، طیف بسیار گسترده‌ای است. در بالای فهرست، جایگاه سوخت با صد درصد و خودرویی با ۹۹/۸ درصد و تراکنش متفرقه با ۹۵/۳ درصد قرار دارند که همگی به دلیل ماهیت غیرکالایی‌شان قابل انتظارند. پس از آن گروه‌های واقعی می‌آیند: غذای دریایی بسته‌بندی با ۶۲/۶ درصد، شیرینی با ۵۱/۶ درصد، خواروبار با ۲۷ درصد، اغذیه آماده با ۲۳/۲ درصد و گوشت بسته‌بندی با ۲۲/۶ درصد قرار دارند. در انتهای فهرست، داروی نسخه‌ای با ۷/۵ درصد و گل و گیاه با ۷/۹ درصد و دارو و کالای عمومی با ۹/۴ درصد قرار می‌گیرند.

این ترتیب با شهود بازار سازگار است. در گروه‌هایی که مشتری به برند حساس نیست و کالا تا حد زیادی استاندارد است، مانند غذای دریایی بسته‌بندی یا شیرینی، برند فروشگاه به راحتی جای برند ملی را می‌گیرد. در گروه‌هایی که تعلق به برند یا الزام قانونی وجود دارد، مانند دارو، سهم برند فروشگاه پایین می‌ماند. برای تصمیم توسعه برند خصوصی، گروه‌های میانی این فهرست، یعنی جایی که سهم بین ده تا سی درصد است، بیشترین فضای رشد را دارند.



شکل ۶-۱۷ – سهم برند خصوصی و برند ملی به تفکیک گروه کالایی

٦-۱۲ صفحه آزمون‌های معنادار: هسته تحلیل تفاضلی

تا اینجا هرچه گفته شد گزارش‌گیری بود، یعنی نمایش آنچه در داده هست. این صفحه کار دیگری می‌کند و در واقع دلیل نام‌گذاری این سربرگ است. پرسشی که اینجا پاسخ داده می‌شود این است: وقتی می‌بینیم دو گروه با هم فرق دارند، آیا این تفاوت واقعی است یا می‌تواند حاصل تصادف باشد، و اگر واقعی است آیا آن‌قدر بزرگ هست که ارزش اقدام داشته باشد.

٦-۱۲-۱ چرا مقدار احتمال به تنهایی کافی نیست

در آزمون‌های آماری متعارف، خروجی اصلی مقدار احتمال[۹۴] است، عددی که می‌گوید اگر هیچ تفاوتی وجود نداشت، احتمال دیدن چنین اختلافی چقدر بود. مشکل این معیار در داده‌های بزرگ آشکار می‌شود. وقتی حجم نمونه به صدها هزار سبد می‌رسد، حتی تفاوت‌های بسیار کوچک هم مقدار احتمال بسیار کوچکی می‌گیرند. در این مجموعه‌داده با ۲۷۶۴۵۰ سبد، تقریباً هر مقایسه‌ای «معنادار» از آب درمی‌آید و بنابراین مقدار احتمال به تنهایی هیچ چیزی را جدا نمی‌کند.

راه‌حلی که در این پروژه به کار رفته، تکیه بر اندازه اثر[۹۵] است. اندازه اثر می‌گوید تفاوت چقدر بزرگ است و برخلاف مقدار احتمال، با بزرگ شدن نمونه به طور خودکار بزرگ‌تر نمی‌شود. سامانه برای هر آزمون هم مقدار احتمال و هم اندازه اثر را گزارش می‌کند، اما حکم نهایی خود را تنها بر پایه اندازه اثر می‌دهد.

٦-۱۲-۲ اندازه اثر و آستانه‌های تفسیر

شش آزمون در این بخش اجرا می‌شود و هر یک اندازه اثر متناسب خودش را دارد. جدول ۶–۹ این آزمون‌ها را با پرسشی که به آن پاسخ می‌دهند و معیار اندازه اثرشان معرفی می‌کند.

---

[۹۴] p-value

[۹۵] Effect Size

جدول ۶-۹ - آزمون‌های آماری این صفحه، پرسش هر آزمون و معیار اندازه اثر آن

آزمون	پرسشی که پاسخ می‌دهد	معیار اندازه اثر
Mann-Whitney	آیا ارزش سبد دو گروه به طور کلی متفاوت است	دلتای کلیف
Kolmogorov–Smirnov	آیا شکل توزیع ارزش سبد دو گروه متفاوت است	بیشینه فاصله دو توزیع تجمعی
Chi-Square	آیا دو گروه از گروه‌های کالایی متفاوتی خرید می‌کنند	وی کرامر
t-test welch	آیا میانگین ارزش سبد دو گروه متفاوت است	دی کوهن
تحلیل واریانس	آیا میانگین ارزش سبد در همه گروه‌ها یکسان است	اتا مربع
Kruskal–Wallis	همان پرسش بدون فرض نرمال بودن توزیع	اپسیلون مربع

آستانه‌های تفسیر نیز از مراجع متعارف آمار گرفته شده‌اند. برای دلتای کلیف[۹۶]، مقدار کمتر از ۰/۱۴۷ ناچیز، کمتر از ۰/۳۳ کوچک، کمتر از ۰/۴۷۴ متوسط و بیشتر از آن بزرگ در نظر گرفته می‌شود. برای دی کوهن[۹۷] آستانه‌های ۰/۲ و ۰/۵ و ۰/۸ و برای اتا مربع[۹۸] و اپسیلون مربع[۹۹] آستانه‌های ۰/۰۱ و ۰/۰۱ و ۰/۱۴ به کار می‌روند. هر آزمونی که برچسب ناچیز یا کوچک بگیرد، در خروجی با عبارت «برای اقدام بسیار کوچک است» علامت می‌خورد، حتی اگر مقدار احتمال آن بسیار کوچک باشد.

انتخاب من ویتنی[۱۰۰] و کروسکال والیس[۱۰۱] به جای آزمون‌های مبتنی بر میانگین نیز آگاهانه است. همان‌طور که در بخش توزیع اندازه سبد دیدیم، توزیع ارزش سبد به شدت کج است و فرض نرمال بودن

---

[۹۶] Cliff's Delta

[۹۷] Cohen's d

[۹۸] Eta Squared

[۹۹] Epsilon Squared

[۱۰۰] Mann-Whitney U Test

[۱۰۱] Kruskal-Wallis Test

برقرار نیست. سامانه با این حال تی ولش[۱۰۲] و تحلیل واریانس[۱۰۳] را هم اجرا و گزارش می‌کند، اما در متن راهنمای خودش می‌نویسد که این‌ها در کنار آزمون‌های بدون پارامتر می‌نشینند و مبنای اصلی نیستند.

۶-۱۲-۳ شش آزمون روی یک جفت گروه

کاربر یک بُعد و دو مقدار از آن را انتخاب می‌کند. برای مثال بخش مشتری و دو مقدار قهرمانان و مشتریان وفادار. سامانه هر شش آزمون را اجرا و نتیجه هر یک را در یک کارت با سه بخش نشان می‌دهد: حکم نهایی، برچسب اندازه اثر و یک جمله که نتیجه را به زبان ساده بیان می‌کند. جزئیات عددی شامل مقدار احتمال و مقدار آماری، پشت یک بخش قابل باز شدن پنهان می‌ماند تا کارت شلوغ نشود.

نتیجه پیش‌فرض روی همین دو بخش، یکی از جالب‌ترین یافته‌های کل این فصل است. هر چهار آزمون جفتی برچسب ناچیز می‌گیرند: میانگین ارزش سبد قهرمانان تنها ۳/۲۰ واحد بیشتر از مشتریان وفادار است، اختلاف میانه ۳/۲۶ واحد است، شکل دو توزیع تنها هفت درصد با هم فرق دارد و ترکیب گروه‌های کالایی خریداری‌شده تقریباً یکسان است.

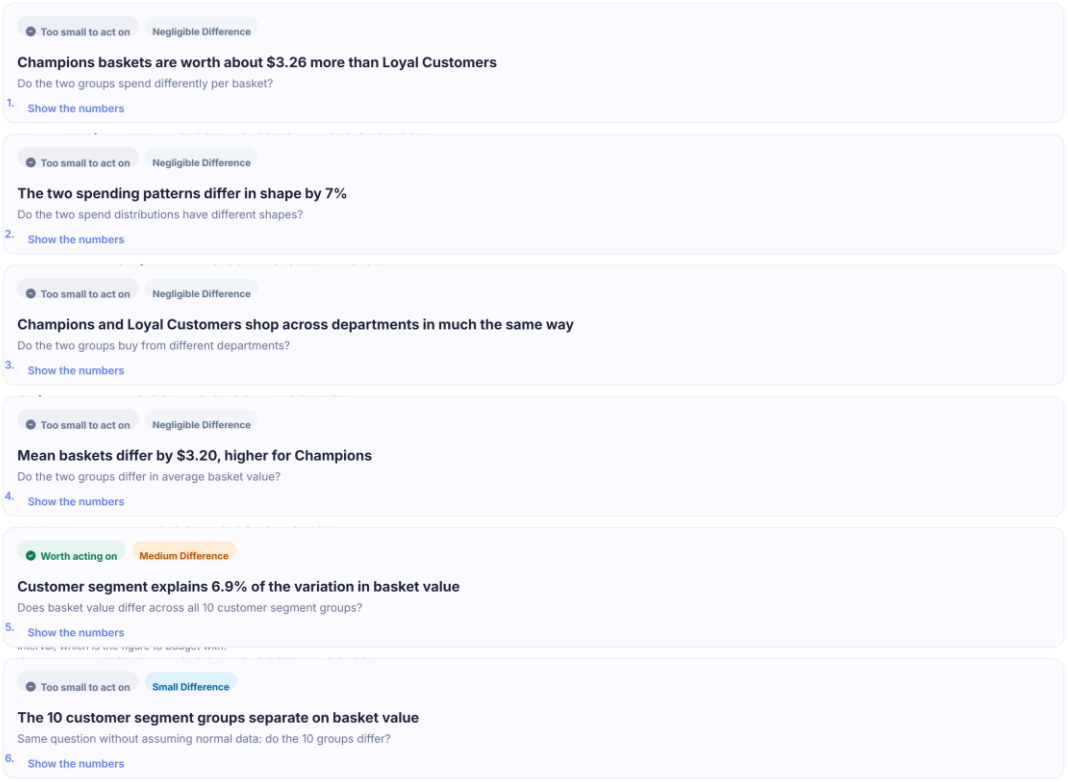
این نتیجه در نگاه اول با جدول ۶–۵ در تضاد است. آنجا دیدیم درآمد سرانه قهرمانان ۷۱۹۶ و مشتریان وفادار ۴۲۶۱ واحد است، یعنی نزدیک به هفتاد درصد اختلاف. اما تضادی در کار نیست و همین‌جاست که ارزش این آزمون‌ها روشن می‌شود: اگر ارزش هر سبد تقریباً یکسان باشد اما درآمد سالانه بسیار متفاوت، پس تفاوت این دو بخش در تعداد مراجعه است و نه در اندازه سبد. برای تیم بازاریابی این یعنی مشتری وفادار را نباید با پیشنهاد افزایش سبد هدف گرفت، بلکه باید با محرک افزایش دفعات مراجعه هدف گرفت. این دقیقاً همان نوع نتیجه‌ای است که از نمودار به تنهایی به دست نمی‌آید.

در مقابل، آزمون‌های چندگروهی روی همان بُعد نتیجه متفاوتی می‌دهند: تحلیل واریانس گزارش می‌کند که بخش مشتری ۶/۹ درصد از پراکندگی ارزش سبد را توضیح می‌دهد و این مقدار برچسب اهمیت متوسط و حکم «ارزش اقدام کردن» می‌گیرد. یعنی وقتی همه ده بخش با هم دیده شوند تفاوت معنادار و قابل استفاده است، هرچند دو بخش بالای فهرست با هم تفاوت عملی ندارند.

---

[۱۰۲] Welch's t-Test

[۱۰۳] Analysis of Variance



شکل ۶-۱۸ - کارت‌های شش آزمون معناداری روی جفت بخش قهرمانان و مشتریان وفادار

٦-۱۲-٤ جست‌وجوی خودکار بزرگ‌ترین تفاوت‌ها

انتخاب دستی جفت گروه‌ها برای ده بُعد و ده‌ها مقدار عملی نیست. به همین دلیل دکمه‌ای با عنوان «پیدایشان کن» وجود دارد که کار را خودکار می‌کند: برای هر یک از ده بُعد، شش گروه پرحجم‌تر انتخاب می‌شوند، هر پانزده جفت ممکن میان آن‌ها ساخته می‌شود و برای هر جفت سه آزمون اجرا می‌گردد. نتیجه به صورت یک جدول مرتب‌شده بر پایه اندازه اثر نمایش داده می‌شود.

برای اینکه این جست‌وجو در زمان معقول تمام شود، چند محدودیت اعمال شده است: هر گروه باید دست‌کم ۳۰۰ سبد داشته باشد، از هر گروه حداکثر ۲۰۰۰ سبد نمونه‌برداری[۱۰۴] می‌شود و در هر بُعد حداکثر شش گروه بررسی می‌گردد. نمونه‌برداری با یک بذر تصادفی[۱۰۵] ثابت انجام می‌شود تا نتیجه در اجراهای مختلف یکسان بماند، و ترتیب نمونه بر پایه یک تابع درهم‌ساز روی شناسه سبد است تا نمونه در کل دوره پخش شود و به یک بازه زمانی خاص محدود نگردد.

---

[۱۰۴] Sampling

[۱۰۵] Random Seed

ده ردیف نخست نتیجه روی کل داده در جدول ۶-۱۰ آمده است.

جدول ۶-۱۰ - ده تفاوت برتر یافت‌شده در جست‌وجوی خودکار

ردیف	بُعد	مقایسه	ارزش سبد دو گروه	اندازه اثر
۱	بخش مشتری	خفته در برابر خرج‌کنندگان بزرگ	۱۲/۳۴ در برابر ۳۷/۶۱	متوسط
۲	گروه کالایی	خواروبار در برابر میوه و سبزی	۱۰/۳۷ در برابر ۴/۱۵	متوسط
۳	بخش مشتری	مشتریان وفادار در برابر خرج‌کنندگان بزرگ	۱۵ در برابر ۳۷/۶۱	متوسط
۴	بخش مشتری	در معرض خطر در برابر خرج‌کنندگان بزرگ	۱۶/۴۱ در برابر ۳۷/۶۱	متوسط
۵	بخش مشتری	وفاداران بالقوه در برابر خرج‌کنندگان بزرگ	۱۵/۸۷ در برابر ۳۷/۶۱	متوسط
۶	گروه کالایی	خواروبار در برابر گوشت بسته‌بندی	۱۰/۳۷ در برابر ۵	متوسط

الگویی که در این جدول دیده می‌شود بسیار روشن است: بخش «خرج‌کنندگان بزرگ» با ارزش سبد ۳۷/۶۱ واحد، در برابر هر بخش دیگری تفاوت متوسط نشان می‌دهد. این تنها بخشی است که واقعاً از نظر اندازه سبد متمایز است. بقیه بخش‌ها ارزش سبدی در بازه ۱۲ تا ۱۶ واحد دارند و تفاوتشان با یکدیگر ناچیز است. ستون «چه می‌خرند» نیز برای همه این جفت‌ها مقدار «همان قفسه‌ها» را نشان می‌دهد، یعنی حتی خرج‌کنندگان بزرگ هم از همان گروه‌های کالایی خرید می‌کنند و تنها مقدار بیشتری برمی‌دارند.

نتیجه عملی این مشاهده برای یک خرده‌فروش این است که راهبرد تفکیک بر پایه «چه می‌خرند» در این داده به آن شدت جواب اثرگذاری نمی‌دهد و باید به «چقدر و چند وقت یک بار می‌خرند» پرسشمان را تغییر دهیم. همین یافته، منطق فصل هشتم را که ماندگاری مشتری را بر پایه تازگی و تکرار خرید اولویت‌بندی می‌کند، پشتیبانی می‌کند.

#	COMPARISON	WHICH IS BIGGER	DIFFERENCE IN BASKET VALUE	TYPICAL BASKETS	WHAT THEY BUY	CHANCE OF A FLUKE
1	**Customer segment** Hibernating vs Big Spenders	**Big Spenders** over Hibernating	MEDIUM	$37.61 vs $12.34	SAME AISLES	under 1 in 10,000
2	**Department** GROCERY vs PRODUCE	**GROCERY** over PRODUCE	MEDIUM	$10.37 vs $4.15	--	under 1 in 10,000
3	**Customer segment** Loyal Customers vs Big Spenders	**Big Spenders** over Loyal Customers	MEDIUM	$37.61 vs $15.00	SAME AISLES	under 1 in 10,000
4	**Customer segment** At Risk vs Big Spenders	**Big Spenders** over At Risk	MEDIUM	$37.61 vs $16.41	SAME AISLES	under 1 in 10,000
5	**Customer segment** Potential Loyalists vs Big Spenders	**Big Spenders** over Potential Loyalists	MEDIUM	$37.61 vs $15.87	SAME AISLES	under 1 in 10,000
6	**Department** GROCERY vs MEAT-PCKGD	**GROCERY** over MEAT-PCKGD	MEDIUM	$10.37 vs $5.00	--	under 1 in 10,000
7	**Department** PRODUCE vs MEAT	**MEAT** over PRODUCE	MEDIUM	$7.08 vs $4.15	--	under 1 in 10,000
8	**Customer segment** Champions vs Big Spenders	**Big Spenders** over Champions	MEDIUM	$37.61 vs $18.26	SAME AISLES	under 1 in 10,000
9	**Department** GROCERY vs DELI	**GROCERY** over DELI	SMALL	$10.37 vs $5.66	--	under 1 in 10,000
10	**Income band** 25-34K vs 75-99K	**75-99K** over 25-34K	SMALL	$25.48 vs $13.15	SAME AISLES	under 1 in 10,000
11	**Department** GROCERY vs DRUG GM	**GROCERY** over DRUG GM	SMALL	$10.37 vs $4.99	--	under 1 in 10,000
12	**Home ownership** Homeowner vs Probable Owner	**Homeowner** over Probable Owner	SMALL	$22.38 vs $8.03	SAME AISLES	under 1 in 10,000
13	**Household size** Unknown vs 5+	**5+** over Unknown	SMALL	$27.29 vs $14.97	SAME AISLES	under 1 in 10,000
14	**Income band**	**75-99K**	SMALL	$25.48 vs $14.97	SAME AISLES	under 1 in 10,000

شکل ۶-۱۹ - جدول نتیجه جست‌وجوی خودکار بزرگ‌ترین تفاوت‌ها

۶-۱۲-۵ رتبه‌بندی شیوه‌های گروه‌بندی

پنل دیگری در همین صفحه، پرسش سطح بالاتری را پاسخ می‌دهد: از میان همه راه‌های ممکن برای گروه‌بندی مشتریان و تراکنش‌ها، کدام‌یک ارزش سبد را بهتر از هم جدا می‌کند؟ برای این کار به جای مقایسه جفتی، یک آزمون روی همه گروه‌های هر بُعد اجرا می‌شود و سهم پراکندگی توضیح‌داده‌شده گزارش می‌گردد.

نتیجه در جدول ۶-۱۱ آمده است و از نظر من مهم‌ترین جدول کل این فصل است.

جدول ۶-۱۱ - رتبه‌بندی بُعدها بر پایه سهم پراکندگی توضیح‌داده‌شده از ارزش سبد

بُعد گروه‌بندی	تعداد گروه	سهم پراکندگی	آماره کروسکال والیس	آماره تحلیل واریانس
گروه کالایی	۶	۷/۷٪	۹۲۳	۲۹۶
بخش مشتری	۶	۷/۲٪	۸۶۹	۲۰۱
بازه درآمدی	۶	۳/۲٪	۴۳۱	۵۰
مالکیت مسکن	۵	۳/۴٪	۳۴۶	۵۲
اندازه خانوار	۶	۲/۷٪	۳۲۷	۵۴
داشتن فرزند	۴	۲/۰٪	۱۶۵	۳۸
بازه سنی	۶	۰/۸٪	۱۰۴	۱۵
روز هفته	۶	۰/۱٪	۲۱	۶
فصل	۴	۰/۱٪	۱۱	۵

این جدول چند نتیجه مهم دارد. نخست آنکه هیچ‌یک از این بُعدها بیش از هشت درصد از پراکندگی ارزش سبد را توضیح نمی‌دهد، یعنی بیش از نود درصد تفاوت میان سبدها با هیچ‌کدام از این گروه‌بندی‌ها قابل توضیح نیست. این واقعیت مهمی است و نشان می‌دهد رفتار خرید در سطح یک سبد، تا حد زیادی تصادفی و وابسته به موقعیت است.

دوم آنکه دو بُعد رفتاری، یعنی گروه کالایی و بخش مشتری، به روشنی از همه بُعدهای جمعیت‌شناختی جلوترند. بازه سنی تنها ۰/۸ درصد و بازه درآمدی ۳/۶ درصد را توضیح می‌دهند، در حالی که بخش مشتری که تنها از رفتار خرید ساخته شده ۷/۲ درصد را پوشش می‌دهد. برای یک تیم بازاریابی این پیام بسیار مشخصی دارد آن این است که سرمایه‌گذاری روی جمع‌آوری داده جمعیت‌شناختی، بازده کمتری از سرمایه‌گذاری روی تحلیل رفتار خرید دارد.

سوم آنکه دو بُعد زمانی، یعنی روز هفته و فصل، عملاً هیچ چیزی توضیح نمی‌دهند. این یعنی زمان بر تعداد سبدها اثر می‌گذارد اما بر اندازه هر سبد اثر ندارد. در روزهای شلوغ، سبدهای بیشتری خریداری می‌شود نه اینکه سبدهای بزرگ‌تر باشند. این تفکیک، برای برنامه‌ریزی نیروی انسانی و ظرفیت صندوق کاربرد مستقیم دارد.

Which way of grouping customers separates spend most

One test across all the groups of a dimension at once, not a pair at a time.

GROUPING	GROUPS	SHARE OF THE SPREAD IT EXPLAINS	KRUSKAL-WALLIS H	ANOVA F
Department	6	7.7%	923	296
Customer segment	6	7.2%	869	201
Income band	6	3.6%	431	50
Home ownership	5	3.4%	346	52
Household size	6	2.7%	327	54
Children	4	2.0%	165	38
Age band	6	0.8%	104	15
Day of week	6	0.1%	21	6
Quarter	4	0.1%	11	5

The percentage is how much of the variation in basket value that grouping accounts for; the rest is everything else. ANOVA answers the same question assuming a normal spread, which basket value does not have, so it sits alongside rather than being relied on

شکل ۶-۲۰ – رتبه‌بندی بُعدهای گروه‌بندی بر پایه سهم پراکندگی توضیح‌داده‌شده

۶-۱۲-۶ تصحیح آزمون چندگانه

در جست‌وجوی خودکار، ده بُعد در پانزده جفت و سه آزمون بررسی می‌شوند، یعنی چند صد آزمون در یک اجرا. اگر برای هر آزمون به تنهایی آستانه پنج درصد به کار رود، به طور میانگین از هر بیست آزمون یکی به شکل تصادفی معنادار می‌شود و در چند صد آزمون، ده‌ها نتیجه کاذب به دست می‌آید.

برای حل این مسئله از روش بنیامینی هوخبرگ[۱۰۶] استفاده شده است. این روش به جای کنترل احتمال خطای هر آزمون، نرخ کشف کاذب[۱۰۷] یعنی نسبت مواردی که به اشتباه معنادار اعلام شده‌اند را کنترل می‌کند. خروجی آن برای هر آزمون یک مقدار تصحیح‌شده است و سامانه تنها نتایجی را «قابل اقدام» می‌نامد که هم مقدار تصحیح‌شده‌شان کمتر از پنج صدم باشد و هم اندازه اثرشان از آستانه ناچیز عبور کند.

۶-۱۳ نمونه‌گیری و کنترل هزینه محاسبات

یک داشبورد تعاملی تنها زمانی مفید است که با هر کلیک، در حد چند ثانیه پاسخ بدهد. رسیدن به این هدف روی جدولی با تقریباً دو و نیم میلیون سطر، مجموعه‌ای از تصمیم‌های مهندسی را لازم داشت که در این بخش جمع شده‌اند.

نخست، الحاق شرطی بُعدها که در بخش ۲-۶ توضیح داده شد. دوم، اعمال سقف‌های نمایش شامل چهل ردیف برای نمودار سلسله‌مراتب، سیصد فروشگاه، بیست‌وپنج محصول برتر و سی گروه کالایی برای نمودار سهم برند. سوم، اجرای پرس‌وجوی محصولات برتر در دو مرحله. چهارم، محاسبه میانه با استفاده از تابع

---

[۱۰۶] Benjamini–Hochberg Procedure

[۱۰۷] False Discovery Rate

رتبه‌بندی به‌جای تابع صدک، که برای این حجم از داده به‌مراتب سریع‌تر است. پنجم، کاهش تعداد نقاط منحنی تمرکز درآمد از ۹۱۹۰۳ نقطه به حدود دویست نقطه پیش از ارسال به مرورگر. این کاهش، از نظر بصری تفاوت محسوسی ایجاد نمی‌کند، اما حجم داده انتقال‌یافته را صدها برابر کاهش می‌دهد.

ششم و مهم‌تر از همه، نمونه‌گیری در بخش آزمون‌ها است. کشیدن همه سبدها به برنامه برای اجرای آزمون‌ها نزدیک به نُه ثانیه طول می‌کشید. در نسخه فعلی، برای هر آزمون جفتی حداکثر بیست هزار سبد و برای جست‌وجوی خودکار حداکثر دو هزار سبد از هر گروه نمونه‌برداری می‌شود. دلتای کلیف نیز روی حداکثر چهار هزار مقدار محاسبه می‌گردد، چون این معیار به مقایسه همه زوج‌های ممکن نیاز دارد و هزینه‌اش با مربع اندازه نمونه رشد می‌کند.

۱۴-۶ جمع‌بندی تحلیلی نتایج این مجموعه‌داده

در بخش‌های پیشین هر نمودار جداگانه تفسیر شد. در این بخش تلاش می‌کنم یافته‌ها را کنار هم بگذارم و تصویری یکپارچه از آنچه این داده می‌گوید ارائه کنم.

نخست، این کسب‌وکار از هر دو منظر، یعنی گروه‌های کالایی و مشتریان، از تمرکز بالایی برخوردار است. سه گروه کالایی ۷۰/۸ درصد درآمد را ایجاد می‌کنند، سیزده درصد محصولات هشتاد درصد درآمد را به خود اختصاص می‌دهند و بیست درصد خانوارها نیز بیش از نیمی از درآمد را تأمین می‌کنند. با این حال، شدت تمرکز در این دو سمت یکسان نیست. تمرکز در سمت مشتریان بیشتر است و در نتیجه، ریسک مرتبط با مشتریان نیز بالاتر است. بنابراین، برای این کسب‌وکار، از دست دادن مشتریان دهک اول تهدیدی جدی‌تر از کاهش فروش یک گروه کالایی محسوب می‌شود.

دوم، آزمون‌های معناداری نشان دادند که بخش‌های مشتری، به استثنای خرج‌کنندگان بزرگ، از نظر اندازه سبد تفاوت عملی با هم ندارند و ترکیب گروه‌های کالایی خریدشان هم تقریباً یکسان است. تفاوت درآمد آن‌ها بنابراین تقریباً به طور کامل از تعداد مراجعه می‌آید. این یافته، جهت‌گیری برنامه‌های بازاریابی فروشگاه را تعیین می‌کند. افزایش دفعات مراجعه به جای افزایش اندازه سبد باید مورد بررسی قرار گیرد.

سوم، بُعدهای جمعیت‌شناختی هم پوشش کمی دارند و هم قدرت تبیین کمی دارند. بازه سنی تنها ۰/۸ درصد از پراکندگی ارزش سبد را توضیح می‌دهد در حالی که بخش‌بندی رفتاری ۷/۲ درصد را پوشش

می‌دهد. اگر قرار باشد میان تکمیل داده جمعیت‌شناختی و بهبود بخش‌بندی رفتاری یکی انتخاب شود، داده این پروژه به روشنی دومی را توصیه می‌کند.

چهارم، نزدیک به نیمی از درآمد بدون اعمال هیچ‌گونه تخفیفی حاصل می‌شود، در حالی که تخفیف‌های عمیق تنها ۲/۶ درصد از درآمد را تشکیل می‌دهند و نرخ کلی تخفیف نیز طی دو سال تقریباً ثابت باقی مانده است. در کنار این موضوع، سهم بیست‌وهشت‌درصدی برند خصوصی که با سطح تخفیف پایین‌تری نیز به دست آمده، تصویری از یک خرده‌فروش با راهبرد پایدار قیمت پایین ارائه می‌دهد، نه خرده‌فروشی که به حراج‌ها و تخفیف‌های دوره‌ای وابسته باشد.

پنجم و مهم‌تر از همه، تفکیک میان یافته‌های واقعی و نتایج حاصل از ساختار مطالعه است. دو الگویی که در نگاه نخست بسیار چشمگیر به نظر می‌رسند، یعنی رشد ۲۰۴ درصدی درآمد از فصل نخست تا فصل آخر و رسیدن سهم مشتریان بازگشتی به صد درصد، هیچ‌یک را نمی‌توان به‌عنوان یافته‌ای واقعی از بازار تلقی کرد. هر دو، بازتابی از طراحی مطالعه و استفاده از پنل ثابتی از خانوارها هستند که در چهار دوره نخست تکمیل شده است. به همین ترتیب، نام روزهای هفته نیز بر مبنای یک تاریخ فرضی ساخته شده و نباید مبنای تصمیم‌گیری قرار گیرد.

۱۵-۶ ملاحظات تفسیری و محدودیت‌ها

در کنار محدودیت‌های داده که در بخش قبل آمد، چند محدودیت پیاده‌سازی نیز باید ثبت شوند.

نخست، همه مقایسه‌های این بخش ساده و مستقیم هستند و در آن‌ها اثر متغیرهای مخدوش‌کننده[۱۰۸] کنترل نمی‌شود. برای مثال، اگر ارزش سبد خانوارهای پردرآمد بیشتر باشد، نمی‌توان با اطمینان گفت که دلیل آن فقط درآمد بالاتر است زیرا ممکن است این خانوارها تعداد اعضای بیشتری داشته باشند. سامانه امکان بررسی هم‌زمان اثر چند متغیر را ندارد، بنابراین این محدودیت باید هنگام تفسیر نتایج در نظر گرفته شود.

دوم، نوار پیشرفت و وضعیت بارگذاری در این سربرگ درست پیاده شده‌اند، اما در صورت کند بودن پاسخ، هیچ مهلت زمانی برای قطع درخواست وجود ندارد. همچنین اگر کاربر پشت سر هم چند فیلتر را تغییر دهد، پاسخ درخواست قدیمی‌تر می‌تواند دیرتر برسد و روی نتیجه تازه‌تر بنشیند و باید به این نکته توجه داشت و در نسخه‌های آتی این پروژه قطعا راه‌حل عملی برای آن پیاده‌سازی خواهد شد.

---

[۱۰۸] Confounding Variable

٦-١٦ جمع‌بندی فصل

در این فصل سربرگ سوم صفحه تحلیل سبد خرید بررسی شد، سربرگی که در واقع یک داشبورد هوش تجاری کامل با هشت صفحه داخلی و بیش از بیست پنل است. نشان داده شد که همه این پنل‌ها روی یک طرح ستاره‌ای مشترک بنا شده‌اند، با الحاق شرطی بُعدها و مجموعه‌ای از سقف‌ها و نمونه‌گیری‌ها به گونه‌ای طراحی شده‌اند که در یک محیط تعاملی قابل استفاده باشند، و همه آن‌ها با یک مجموعه فیلتر مشترک به هم گره خورده‌اند.

بخش متمایز این سربرگ، صفحه آزمون‌های معناداری است. توضیح داده شد که چرا در داده‌ای با این حجم، مقدار احتمال به تنهایی معیار مناسبی نیست و چرا سامانه حکم نهایی خود را بر پایه اندازه اثر می‌دهد. همچنین نشان داده شد که چگونه جست‌وجوی خودکار به همراه تصحیح آزمون چندگانه[۱۰۹]، از میان چند صد مقایسه ممکن، تنها موارد قابل اقدام را بیرون می‌کشد.

از منظر یافته‌ها، مهم‌ترین نتیجه این فصل آن است که تفاوت میان مشتریان این مجموعه‌داده نه در آنچه می‌خرند و نه در اندازه سبدشان، بلکه در تعداد مراجعه‌شان است و اینکه بخش‌بندی رفتاری برای توضیح این تفاوت‌ها بسیار کاراتر از متغیرهای جمعیت‌شناختی است.

در فصل بعد، صفحه مستقل قوانین انجمنی بررسی می‌شود که استخراج قانون را در پایین‌ترین سطح سلسله‌مراتب محصول یعنی سطح شناسه کالا انجام می‌دهد.

---

[۱۰۹] Multiple Testing

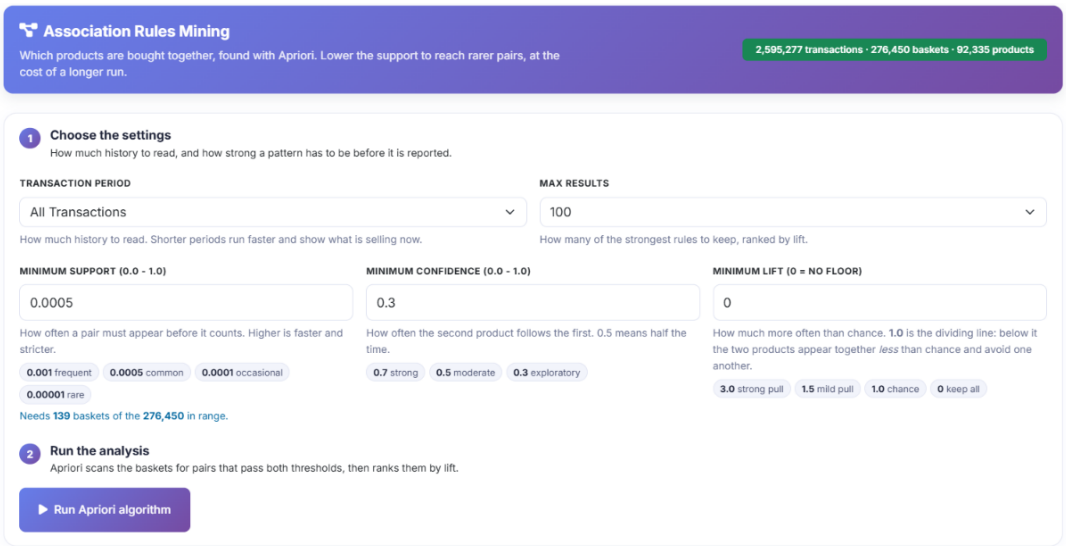
فصل هفتم: استخراج قوانین انجمنی در سطح محصول

۷-۱ جایگاه صفحه قوانین انجمنی در سامانه

صفحه قوانین انجمنی یکی از هفت مسیر تحلیلی است که در نوار راهبری سامانه در دسترس قرار دارد و در فصل سوم به اجمال معرفی شد. این صفحه یک وظیفه مشخص دارد: یافتن محصولاتی که مشتریان آن‌ها را با هم در یک سبد می‌خرند. برخلاف صفحه تحلیل سبد خرید که چند نوع خروجی متفاوت را کنار هم می‌گذارد، این صفحه تنها به همین یک پرسش می‌پردازد و کل فضای آن به سه بخش پشت سر هم اختصاص یافته است: انتخاب تنظیمات، اجرای الگوریتم و مرور نتیجه.

دسترسی به این صفحه محدود است. کاربری که وارد سامانه نشده باشد به صفحه ورود هدایت می‌شود و کاربر عادی نیز اجازه ورود به آن را ندارد. تنها حساب‌های مدیر می‌توانند این صفحه را باز کنند. علت این محدودیت در بخش مربوط به کارایی روشن می‌شود. اجرای این تحلیل یک پرس‌وجوی سنگین روی جدول تراکنش‌ها ایجاد می‌کند و باز گذاشتن آن برای همه کاربران می‌تواند پایگاه داده را درگیر کند.

شکل ۷-۱ نمای بالای این صفحه را نشان می‌دهد. در سربرگ رنگی صفحه و در کنار عنوان، یک نشان سبز قرار دارد که ابعاد مجموعه‌داده را یادآوری می‌کند: در حدود ۲/۶ میلیون رکورد تراکنشی، ۲۷۶۴۵۰ سبد خرید متمایز و ۹۲۳۳۵ محصول یکتا. این سه عدد در سراسر فصل نقش مرجع دارند، زیرا هر یک از معیارهای ارزیابی قانون به یکی از آن‌ها گره خورده است.



شکل ۷-۱ – نمای بالای صفحه قوانین انجمنی، پنل تنظیمات و دکمه اجرای الگوریتم

۷-۲ تفاوت این صفحه با بخش قوانین صفحه تحلیل سبد خرید

در فصل چهارم توضیح داده شد که در سربرگ تحلیل توصیفی نیز بخشی برای استخراج قوانین انجمنی وجود دارد. طبیعی است که این پرسش پیش بیاید که چرا برای همان کار یک صفحه جداگانه ساخته شده است. پاسخ در سطح تحلیل نهفته است.

در صفحه تحلیل سبد خرید، اقلام قانون‌ها یا گروه کالایی هستند یا کالا یعنی سطح‌های بالاتر سلسله‌مراتب محصول[۱۱۰] را شامل می‌شوند. در آن سطح تعداد اقلام به ترتیب در حدود چهل گروه کالایی و چند صد عنوان کالا است و قانونی مانند «هر کس از گروه لبنیات خرید کند، احتمالاً از گروه نان هم خرید می‌کند» به دست می‌آید. چنین قانونی برای تصمیم‌های کلان مانند چیدمان راهروهای فروشگاه مفید است، اما به تیم بازرگانی نمی‌گوید کدام دو کد کالای مشخص را باید کنار هم قرار داد.

صفحه قوانین انجمنی دقیقاً همین شکاف را پر می‌کند. در این صفحه، قلم قانون خودِ شناسه محصول است. خروجی آن به شکل «محصول ۵۵۶۸۹۰۶ و محصول ۵۵۷۰۷۶۴» است و می‌توان آن را مستقیماً به یک بسته پیشنهادی یا یک کوپن تخفیف ترجمه کرد. در مقابل، همین دقت باعث می‌شود مسئله از نظر محاسباتی به‌مراتب سنگین‌تر شود. موضوعی که در بخش بعد بررسی می‌شود. جدول ۷-۱ تفاوت دو مسیر را کنار هم می‌گذارد.

جدول ۷-۱ – مقایسه دو مسیر استخراج قانون انجمنی در سامانه

ویژگی	بخش قوانین صفحه تحلیل سبد خرید	صفحه قوانین انجمنی
قلم قانون	گروه کالایی یا کالا	شناسه تک‌محصول
تعداد اقلام ممکن	در حدود چهل تا چند صد	بیش از نود و دو هزار
شیوه شمارش زوج‌ها	پویش جریانی سبدها در برنامه	خودالحاقی جدول تراکنش‌ها در پایگاه داده
شیوه فراخوانی	درخواست ناهمگام و به‌روزرسانی همان بخش	ارسال فرم و بارگذاری دوباره صفحه
سطح دسترسی	تنها حساب مدیر	تنها حساب مدیر
کاربرد اصلی	تصمیم در سطح دسته و چیدمان	بسته‌سازی و پیشنهاد در سطح کد کالا

[۱۱۰] Product Hierarchy

۷-۳ تعریف مسئله در سطح محصول

پیش از توضیح منطق برنامه، لازم است دو تعریف پایه روشن شود، زیرا همه محاسبات بعدی بر همین دو تعریف بنا شده‌اند.

نخست، منظور از سبد در این صفحه یک شناسه سبد یکتا در جدول تراکنش‌ها است. نه یک سطر تراکنش و نه یک خانوار. اگر مشتری در یک نوبت خرید ده قلم بردارد، ده سطر در جدول ثبت می‌شود اما همه آن‌ها یک سبد به شمار می‌آیند. تمام مخرج‌های محاسبه در این فصل تعداد سبدهای متمایز است. این نکته اهمیت زیادی دارد.

دوم، منظور از قلم در این صفحه شناسه محصول است یعنی پایین‌ترین سطح سلسله‌مراتب محصول در مجموعه‌داده دان‌هامبی. این سلسله‌مراتب از گروه کالایی آغاز می‌شود، به کالا[۱۱۱] و زیرکالا[۱۱۲] می‌رسد و در نهایت به شناسه محصول ختم می‌گردد. صفحه قوانین انجمنی مستقیماً روی آخرین سطح کار می‌کند و دو سطح میانی تنها برای برچسب‌گذاری و نمایش نتیجه به کار می‌روند.

اکنون می‌توان بزرگی مسئله را برآورد کرد. با **۹۲۳۳۵** محصول مشاهده‌شده، تعداد زوج‌های ممکن بیش از چهار میلیارد است. بدیهی است که ساختن جدولی با چهار میلیارد سطر در حافظه ممکن نیست. از سوی دیگر، اکثریت قاطع این زوج‌ها حتی یک بار هم با هم دیده نشده‌اند. بنابراین کل ترفند این است که شمارش تنها روی زوج‌هایی انجام شود که دست‌کم یک بار در یک سبد کنار هم آمده‌اند، و این کار به جای برنامه، در خود پایگاه داده انجام شود.

نکته دیگری که باید از ابتدا پذیرفته شود این است که در این سطح، مقدار پشتیبان ذاتاً کوچک است. حتی پرفروش‌ترین زوج محصول در کل مجموعه‌داده تنها در چند صد سبد از میان **۲۷۶۴۵۰** سبد دیده می‌شود. به همین دلیل آستانه‌های پیش‌فرض این صفحه در مرتبه ده‌هزارم هستند و مقایسه مستقیم آن‌ها با آستانه‌های متعارف که معمولاً در مرتبه صدم بیان می‌شوند، گمراه‌کننده است.

۷-٤ ساختار صفحه و گام‌های کاری

---

[۱۱۱] Commodity

[۱۱۲] Sub-commodity

صفحه به شکل یک مسیر شماره‌گذاری‌شده طراحی شده است تا کاربری که برای نخستین بار آن را باز می‌کند بداند از کجا شروع کند. گام یک با عنوان «انتخاب تنظیمات» چهار کنترل ورودی را در دو ستون کنار هم می‌گذارد. گام دو تنها شامل یک دکمه با برچسب «اجرای الگوریتم Apriori» است و زیر آن یک جمله کوتاه توضیح می‌دهد که این دکمه چه کاری انجام می‌دهد. پایین این دو گام، بخش نتایج قرار دارد که پیش از نخستین اجرا نیز خالی نیست.

این نکته آخر ارزش توضیح دارد. هنگام باز شدن صفحه، برنامه صد قانون با بالاترین بهبود را از جدول قوانین ذخیره‌شده می‌خواند و نمایش می‌دهد. یعنی آنچه کاربر در نگاه اول می‌بیند، نتیجه اجراهای پیشین است که کسی آن‌ها را ذخیره کرده، نه نتیجه یک اجرای تازه. در بالای همین بخش یک جمله راهنما این موضوع را صریح اعلام می‌کند تا کاربر آن را با خروجی جدید اشتباه نگیرد. با فشردن دکمه اجرا، این فهرست با نتیجه اجرای تازه جایگزین می‌شود.

برخلاف صفحه تحلیل سبد خرید که نتایج را با درخواست ناهمگام و بدون بارگذاری دوباره صفحه به‌روز می‌کند، این صفحه از ارسال ساده فرم استفاده می‌کند. یعنی مرورگر تنظیمات را می‌فرستد، سیستم محاسبه را انجام می‌دهد و صفحه به طور کامل دوباره ساخته می‌شود. این انتخاب ساده‌تر است اما یک پیامد دارد، آن هم این است که تا پایان محاسبه، مرورگر روی همان صفحه منتظر می‌ماند و کاربر نمی‌تواند بخش دیگری از آن را ببیند. جدول ۷-۲ اجزای صفحه و نقش هر یک را خلاصه می‌کند.

جدول ۷-۲ - اجزای صفحه قوانین انجمنی و نقش هر جزء

جزء	محل قرارگیری	نقش
نشان ابعاد داده	سربرگ سبز رنگ بالای صفحه	یادآوری تعداد رکورد، سبد و محصول برای تفسیر آستانه‌ها
گام یک: تنظیمات	کارت نخست	دریافت چهار پارامتر ورودی از کاربر
راهنمای زنده آستانه	زیر کادر حداقل پشتیبان و متنی به رنگ آبی	ترجمه آستانه پشتیبان نسبی به حداقل تعداد سبد
گام دو: اجرا	کارت دوم	ارسال فرم و آغاز محاسبه در سرور
بخش نتایج	پایین صفحه	نمایش قوانین به صورت کارت و ابزار انتخاب گروهی
پنجره جزئیات	روی صفحه پس از کلیک روی کارت	نمایش معیارها و برداشت تجاری یک قانون
پنجره تأیید ثبت	روی صفحه پس از فشردن دکمه ثبت	گرفتن تأیید نهایی پیش از نوشتن در پایگاه داده

۷-۵ پارامترهای ورودی و معنای هر یک

چهار پارامتر در گام نخست قابل تنظیم‌اند. هر چهار پارامتر هم در مرورگر و هم دوباره در سرور بررسی می‌شوند. دلیل این بررسی دوگانه آن است که کنترل‌های مرورگر را می‌توان دور زد و سرور نباید به مقداری که از بیرون می‌رسد اعتماد کند.

۷-۵-۱ دوره تراکنشی

این پارامتر تعیین می‌کند محاسبه روی چه بازه‌ای از تاریخچه انجام شود. پنج گزینه وجود دارد: کل تراکنش‌ها، یک ماه، سه ماه، شش ماه و دوازده ماه گذشته. گزینه پیش‌فرض کل تراکنش‌ها است. برنامه برای پیاده‌سازی این محدودیت، ابتدا بزرگ‌ترین شماره روز موجود در جدول تراکنش‌ها را پیدا می‌کند و سپس با کم کردن تعداد روزهای دوره از آن، روز شروع را به دست می‌آورد. یادآوری می‌شود که در مجموعه‌داده دان‌هامبی، زمان به صورت شماره روز نسبی ذخیره شده است. موضوعی که در فصل سوم توضیح داده شد.

محدود کردن دوره دو اثر هم‌زمان دارد. از یک سو محاسبه سریع‌تر می‌شود، چون تعداد سطرهایی که باید پویش شوند کمتر است. از سوی دیگر مخرج محاسبه پشتیبان کوچک‌تر می‌شود، پس یک آستانه ثابت

مانند ۰/۰۰۰۵ در دوره یک‌ماهه به تعداد سبد بسیار کمتری ترجمه می‌شود و نتیجه شامل الگوهای کم‌پشتوانه‌تری خواهد بود. جدول ۷-۳ این ترجمه را برای هر دوره نشان می‌دهد.

جدول ۷-۳ - تعداد سبد هر دوره و حداقل تعداد سبد لازم برای آستانه‌های پیشنهادی

دوره	تعداد سبد در دوره	آستانه ۰/۰۰۱	آستانه ۰/۰۰۰۵	آستانه ۰/۰۰۰۱
کل تراکنش‌ها	۲۷۶۴۵۰	۲۷۷	۱۳۹	۲۸
دوازده ماه	۱۵۵۳۵۲	۱۵۶	۷۸	۱۶
شش ماه	۷۵۲۳۶	۷۶	۳۸	۸
سه ماه	۳۷۱۰۹	۳۸	۱۹	۴
یک ماه	۱۲۱۲۱	۱۳	۷	۲

ستون آخر جدول نشان می‌دهد چرا انتخاب هم‌زمان دوره کوتاه و آستانه پایین توصیه نمی‌شود. در دوره یک‌ماهه با آستانه ۰/۰۰۰۱، هر زوجی که تنها در دو سبد با هم دیده شده باشد وارد نتیجه می‌شود. چنین زوجی می‌تواند صرفاً حاصل تصادف باشد.

نکته‌ای که هنگام کار با این گزینه‌ها باید در نظر داشت این است که کل بازه مجموعه‌داده حدود هفتصد و یازده روز است. بنابراین گزینه «دوازده ماه گذشته» تقریباً نیمی از داده را در بر می‌گیرد و نه بخش کوچکی از انتهای آن. تعداد سبدهای این دوره، یعنی ۱۵۵۳۵۲ همین موضوع را تأیید می‌کند.

۷-۵-۲ تعداد نتایج

این پارامتر سقف تعداد قوانینی است که پس از پایان محاسبه نگه داشته می‌شوند. مقادیر مجاز از پیش تعیین شده‌اند و کاربر تنها می‌تواند یکی از هشت مقدار ۵۰، ۱۰۰، ۲۰۰، ۵۰۰، ۱۰۰۰، ۲۰۰۰، ۳۰۰۰ و ۵۰۰۰ را انتخاب کند. مقدار پیش‌فرض ۱۰۰ است. محدود کردن انتخاب به یک فهرست بسته، به جای گرفتن یک عدد آزاد، یک تصمیم امنیتی است تا کاربر نتواند مقداری وارد کند که صفحه را از کار بیندازد.

مهم است روشن شود که این عدد سقف نمایش است و سقف جست‌وجو نیست. برنامه در مرحله پرس‌وجو تعداد بیشتری نامزد را از پایگاه داده می‌گیرد و سپس فهرست نهایی را به این اندازه کوتاه می‌کند. جزئیات این رفتار در بخش ۷-۶-۴ توضیح داده می‌شود.

۷-۵-۳ حداقل پشتیبان

حداقل پشتیبان تعیین می‌کند یک زوج محصول دست‌کم در چه نسبتی از سبدها باید با هم دیده شود تا اصلاً بررسی شود. این پارامتر یک عدد اعشاری بین صفر و یک است و مقدار پیش‌فرض آن ۰/۰۰۰۵ است. زیر کادر ورودی، چهار برچسب پیشنهادی با عنوان‌های «پرتکرار» برای ۰/۰۰۱، «متداول» برای ۰/۰۰۰۵، «گاه‌به‌گاه» برای ۰/۰۰۰۱ و «نادر» برای ۰/۰۰۰۰۱ قرار دارد که با یک کلیک مقدار را جایگزین می‌کنند.

مفیدترین جزء این بخش، خط راهنمایی است که بلافاصله زیر کادر نمایش داده می‌شود و آستانه نسبی پشتیبان را به زبان قابل فهم ترجمه می‌کند. برای مقدار پیش‌فرض، این خط می‌نویسد که زوج مورد نظر باید در دست‌کم ۱۳۹ سبد از ۲۷۶۴۵۰ سبد دوره انتخابی حاضر باشد. این عدد با تغییر آستانه یا تغییر دوره بی‌درنگ به‌روز می‌شود. تجربه کار با این صفحه نشان داد که بدون چنین راهنمایی، تشخیص اینکه عدد ۰/۰۰۰۵ سخت‌گیرانه است یا سهل‌گیرانه، برای کاربر سخت خواهد بود.

اگر عدد به‌دست‌آمده از این ترجمه کمتر از بیست سبد شود، رنگ خط راهنما به نارنجی تغییر می‌کند. این هشدار پیش از اجرای محاسبه به کاربر می‌گوید که با تنظیم فعلی، قوانین به‌دست‌آمده بر شواهد اندکی استوار خواهند بود.

۷-۵-٤ حداقل اطمینان

حداقل اطمینان تعیین می‌کند یک قانون جهت‌دار دست‌کم در چه نسبتی از سبدهای دارای مقدم باید درست از آب دربیاید تا در فهرست بماند. مقدار پیش‌فرض ۰/۳ است و سه برچسب پیشنهادی «قوی» برای ۰/۷، «متوسط» برای ۰/۵ و «اکتشافی» برای ۰/۳ زیر کادر آمده است.

انتخاب مقدار ۰/۳ به عنوان پیش‌فرض یک تصمیم آگاهانه است. در سطح تک‌محصول، بیشتر قوانین معتبر اطمینان بالایی ندارند، زیرا مشتری‌ای که محصول الف را برداشته ده‌ها جایگزین برای محصول ب دارد. اگر آستانه اطمینان روی ۰/۷تنظیم شود، عملاً تنها زوج‌هایی باقی می‌مانند که یکی از دو طرف آن‌ها بسیار کم‌فروش است و همین باعث می‌شود نتیجه به الگوهای حاشیه‌ای محدود شود.

۷-۵-۵ اعتبارسنجی مقادیر در سرور

سرور پس از دریافت فرم، مقادیر را دوباره بررسی می‌کند و در صورت نامعتبر بودن، آن‌ها را با مقدار امن جایگزین می‌کند. اگر حداقل پشتیبان صفر، منفی یا بزرگ‌تر از یک باشد، مقدار ۰/۰۰۰۰۱جایگزین آن

می‌شود. اگر حداقل اطمینان خارج از بازه مجاز باشد، به ۰/۵ بازنشانی می‌گردد. اگر دوره انتخابی جزو پنج گزینه شناخته‌شده نباشد، کل تراکنش‌ها در نظر گرفته می‌شود و اگر تعداد نتایج برای نمایش جزو هشت مقدار مجاز نباشد، مقدار ۱۰۰ در نظر گرفته می‌شود.

یک قاعده حفاظتی دیگر نیز وجود دارد: اگر حداقل پشتیبان از ۰/۰۰۰۰۰۵کمتر باشد، سرور تعداد نتایج را به حداکثر ۵۰ محدود می‌کند. منطق این قاعده روشن است. آستانه بسیار پایین به معنای عبور تعداد بسیار زیادی زوج از فیلتر است و اگر هم‌زمان سقف نمایش هم بالا باشد، صفحه با هزاران کارت پر می‌شود و مرورگر کند خواهد شد. جدول ۷-۴ چهار پارامتر را با مقدار پیش‌فرض و قاعده اصلاح سرور کنار هم می‌گذارد.

جدول ۷-۴ – پارامترهای صفحه، مقدار پیش‌فرض و قاعده اصلاح در سرور

پارامتر	پیش‌فرض در صفحه	دامنه مجاز	قاعده اصلاح در سرور
دوره تراکنشی	کل تراکنش‌ها	پنج گزینه ثابت	مقدار ناشناخته به کل تراکنش‌ها تبدیل می‌شود
تعداد نتایج	۱۰۰	هشت مقدار از ۵۰ تا ۵۰۰۰	مقدار خارج از فهرست به ۱۰۰ تبدیل می‌شود
حداقل پشتیبان	۰/۰۰۰۵	بزرگ‌تر از صفر تا یک	مقدار نامعتبر به ۰/۰۰۰۰۱تبدیل می‌شود
حداقل اطمینان	۰/۳	بزرگ‌تر از صفر تا یک	مقدار نامعتبر به ۰/۵ تبدیل می‌شود

۷-۶ منطق استخراج قوانین در سطح محصول

محاسبه در شش گام پشت سر هم انجام می‌شود. سه گام نخست تعیین می‌کنند چه چیزی شمارش شود، سه گام بعد نتیجه شمارش را به قانون تبدیل می‌کنند. در ادامه هر گام جداگانه توضیح داده می‌شود.

۷-۶-۱ گام نخست: تعیین بازه زمانی و شمارش سبدها

برنامه ابتدا بزرگ‌ترین شماره روز موجود در جدول تراکنش‌ها را می‌خواند و بر اساس دوره انتخابی، روز شروع را محاسبه می‌کند. سپس تعداد سبدهای متمایز آن بازه را می‌شمارد. اگر این عدد صفر باشد، یعنی در

بازه انتخابی هیچ تراکنشی وجود ندارد، محاسبه بی‌درنگ متوقف می‌شود و فهرست خالی برمی‌گردد. این عدد در ادامه هم به عنوان مخرج پشتیبان و هم به عنوان مبنای محاسبه بهبود به کار می‌رود.

۷-۶-۲ گام دوم: تبدیل آستانه نسبی به حداقل تعداد سبد

آستانه‌ای که کاربر وارد کرده یک نسبت است، اما شمارش در پایگاه داده با عدد صحیح انجام می‌شود. بنابراین حاصل‌ضرب تعداد سبدها در آستانه محاسبه و به بالا گرد می‌شود. گرد کردن به بالا آگاهانه انتخاب شده است تا آستانه‌ای که کاربر روی صفحه می‌بیند دقیقاً همان آستانه‌ای باشد که اعمال می‌شود. اگر به پایین گرد می‌شد، زوجی که نسبت آن اندکی زیر آستانه است نیز از فیلتر عبور می‌کرد. همچنین اگر این حاصل‌ضرب کمتر از یک شود، مقدار یک در نظر گرفته می‌شود تا شرط شمارش بی‌معنا نشود.

۷-۶-۳ گام سوم: شمارش هم‌زمانی با خودالحاقی جدول تراکنش‌ها

قلب این صفحه یک پرس‌وجوی واحد است که جدول تراکنش‌ها را به خودش ملحق می‌کند. عملیاتی که در پایگاه داده به آن خودالحاقی[۱۱۳] گفته می‌شود. ایده ساده است: دو نسخه از جدول در نظر گرفته می‌شود و سطرهایی که شناسه سبد یکسانی دارند به هم وصل می‌شوند. هر جفت سطری که به این ترتیب ساخته شود، یعنی دو محصولی که در یک سبد کنار هم بوده‌اند.

برای اینکه هر زوج تنها یک بار شمرده شود، شرط الحاق به گونه‌ای نوشته شده که شناسه محصول نسخه اول همیشه کوچک‌تر از شناسه محصول نسخه دوم باشد. این یک ترفند رایج است و دو اثر دارد: از شمارش یک زوج در هر دو ترتیب جلوگیری می‌کند و به طور خودکار جفت شدن یک محصول با خودش را نیز حذف می‌نماید.

سپس نتیجه بر اساس زوج محصول گروه‌بندی و تعداد سبدهای متمایز هر زوج شمرده می‌شود. شرط حداقل تعداد سبد که در گام دوم به دست آمد، در همین مرحله و درون پایگاه داده اعمال می‌شود یعنی زوج‌های کم‌فراوان اصلاً به برنامه تحویل داده نمی‌شوند. همین پرس‌وجو با دو زیرپرس‌وجوی دیگر نیز ترکیب می‌شود که تعداد سبدهای هر یک از دو محصول را به تنهایی می‌شمارند. این دو عدد برای محاسبه اطمینان و بهبود لازم‌اند.

---

[۱۱۳] Self Join

مزیت انجام این کار در پایگاه داده آن است که هیچ‌گاه لازم نیست میلیون‌ها سطر تراکنش به برنامه منتقل شوند. تنها خروجی نهایی، یعنی چند صد سطر شامل زوج و سه شمارنده، از پایگاه داده بیرون می‌آید.

۷-٦-٤ گام چهارم: انتخاب نامزدها بر اساس بهبود

در این مرحله یک تصمیم مهندسی مهم گرفته شده است که باید صریح گزارش شود. حتی پس از اعمال آستانه، تعداد زوج‌های واجد شرایط بسیار زیاد است. با آستانه پیش‌فرض، در حدود چهار میلیون زوج از شرط عبور می‌کنند. بازگرداندن همه آن‌ها به برنامه هم کند است و هم بی‌فایده، چون در نهایت تنها چند صد قانون نمایش داده می‌شود.

بنابراین پرس‌وجو تنها تعداد محدودی سطر برمی‌گرداند. این سقف برابر است با چهار برابر تعداد نتایج درخواستی کاربر و دست‌کم چهارصد عدد برگردانده می‌شود. برای مثال اگر کاربر صد قانون خواسته باشد، چهارصد نامزد از پایگاه داده گرفته می‌شود تا پس از ساخت قوانین دوسویه و اعمال آستانه اطمینان، همچنان به اندازه کافی قانون باقی بماند.

پرسش بعدی این است که کدام چهارصد سطر برگردانده می‌شود؟ پاسخ این است که سطرها بر اساس بهبود به صورت نزولی مرتب می‌شوند و بالاترین‌ها انتخاب می‌گردند. علت این انتخاب آن است که اگر مرتب‌سازی بر اساس فراوانی انجام می‌شد، زوج‌هایی انتخاب می‌شدند که هر دو طرفشان پرفروش است و چنین زوج‌هایی تقریباً همیشه بهبود نزدیک به یک دارند، یعنی هیچ همراهی واقعی را نشان نمی‌دهند. با مرتب‌سازی بر اساس بهبود، دقیقاً زوج‌هایی انتخاب می‌شوند که برای تصمیم‌گیری مفیدتر هستند.

در عین حال این انتخاب یک عارضه دارد که در بخش ملاحظات دوباره به آن بازمی‌گردیم. بهبود برای زوج‌های کم‌فروش بیشترین مقدار را می‌گیرد، پس فهرست نامزدها به سمت الگوهای نادر متمایل می‌شود. در صورت تساوی مقدار بهبود، زوجی که در سبدهای بیشتری دیده شده اولویت دارد.

۷-٦-٥ گام پنجم: افزودن اطلاعات توصیفی محصول

خروجی پرس‌وجو تنها شامل شناسه‌های عددی است و برای کاربر معنایی ندارد. بنابراین برنامه در یک مرحله جداگانه، نام گروه کالایی، نام کالا و نوع برند هر محصول را از جدول محصولات می‌خواند. این خواندن به صورت دسته‌ای انجام می‌شود، چون پایگاه داده مورد استفاده در این پروژه سقفی برای تعداد پارامترهای یک پرس‌وجو دارد و قرار دادن چند هزار شناسه در یک فهرست باعث خطا می‌شود. به همین دلیل

شناسه‌ها به دسته‌های نهصدتایی تقسیم و به ترتیب پرسیده می‌شوند. اگر برای محصولی رکورد توصیفی پیدا نشود، مقدارهای جایگزینی مانند «گروه عمومی» یا «بدون شرح» قرار می‌گیرد تا کارت نتیجه ناقص نماند.

۷-۶-۶ گام ششم: ساخت قانون دوسویه و مرتب‌سازی نهایی

هر زوج در این مرحله به دو قانون بالقوه تبدیل می‌شود: یکی از محصول اول به محصول دوم و دیگری در جهت معکوس. همان‌طور که در فصل چهارم توضیح داده شد، این دوگانگی از نامتقارن بودن معیار اطمینان ناشی می‌شود. پشتیبان و بهبود هر دو جهت یکسان است، اما اطمینان آن‌ها متفاوت خواهد بود.

نمونه‌ای از همین رفتار در خروجی واقعی صفحه دیده می‌شود. زوج دو محصول از گروه غذای کودک، یعنی محصولات ۵۵۶۸۹۰۶ و ۵۵۷۰۷۶۴، در ۳۶ سبد با هم دیده شده‌اند. قانون از اولی به دومی اطمینان ۰/۸۷۸۰ دارد و قانون معکوس اطمینان ۰/۸۵۷۱ دارد، در حالی که هر دو پشتیبان ۰/۰۰۰۱۳۰ و بهبود ۵۷۷۹/۴۴ را نشان می‌دهند. در زوج‌هایی که فراوانی دو طرف اختلاف زیادی دارد، این فاصله بسیار بیشتر می‌شود.

هر جهت که از آستانه اطمینان عبور کند در فهرست می‌ماند. در پایان، همه قوانین بر اساس بهبود به صورت نزولی مرتب و به تعداد درخواستی کاربر کوتاه می‌شوند. هیچ آستانه‌ای روی بهبود اعمال نمی‌شود یعنی اگر تعداد قوانین کم باشد، ممکن است قوانینی با بهبود کمتر از یک نیز در انتهای فهرست دیده شوند.

۷-۶-۷ نسبت این پیاده‌سازی با الگوریتم Apriori

عنوان دکمه اجرا و متن راهنمای صفحه از نام Apriori استفاده می‌کنند، اما صداقت علمی حکم می‌کند که تفاوت این پیاده‌سازی با الگوریتم اصلی روشن شود.

الگوریتم Apriori در شکل عمومی خود یک فرایند تکرارشونده است: ابتدا اقلام تک‌عضوی پرتکرار را می‌یابد، از آن‌ها نامزدهای دوعضوی می‌سازد، پس از شمارش، نامزدهای سه‌عضوی را تولید می‌کند و همین‌طور ادامه می‌دهد تا هیچ مجموعه پرتکرار جدیدی ساخته نشود. آنچه در این صفحه اجرا می‌شود یک پویش تک‌مرحله‌ای است که مستقیماً همه زوج‌های هم‌زمان را می‌شمارد و هیچ‌گاه به سراغ مجموعه‌های سه‌عضوی و بزرگ‌تر نمی‌رود. بنابراین مرحله تولید نامزد[۱۱۴] و هرس، که ویژگی شاخص Apriori است، در اینجا بخاطر تک مرحله‌ای بودن وجود ندارد.

---

[۱۱۴] Candidate Generation

دلیل این انتخاب کاملاً عملی است. در سطح تک‌محصول با بیش از نود هزار قلم، ساختن مجموعه‌های سه‌عضوی حتی با هرس نیز در یک سامانه تعاملی که باید در چند ثانیه پاسخ بدهد شدنی نیست. از سوی دیگر، پایگاه داده رابطه‌ای این شمارش دوتایی را با یک پرس‌وجو و بسیار سریع‌تر از هر پیاده‌سازی سطح برنامه انجام می‌دهد. نتیجه آن است که همه قوانین این صفحه یک مقدم و یک تالی دارند.

۷-۷ شیوه محاسبه معیارها در این صفحه

تعریف مفهومی سه معیار پشتیبان، اطمینان و بهبود در فصل چهارم و در جدول ۴-۵ آمده است و در اینجا تکرار نمی‌شود. آنچه در این بخش اهمیت دارد، شیوه دقیق محاسبه آن‌ها در سطح محصول و به‌ویژه مخرج هر کسر است، زیرا اشتباه در مخرج به عددی می‌انجامد که ظاهر درستی دارد اما معنای نادرستی می‌دهد.

در همه فرمول‌های زیر، منظور از «تعداد کل» تعداد سبدهای متمایز دوره انتخابی است. اگر تعداد سبدهای مشترک دو محصول را شمارنده زوج بنامیم و تعداد سبدهای هر محصول را به تنهایی شمارنده آن محصول، آنگاه جدول ۷-۵ سه معیار را نشان می‌دهد.

جدول ۷-۵ – شیوه محاسبه معیارها در سطح محصول و مخرج هر کسر

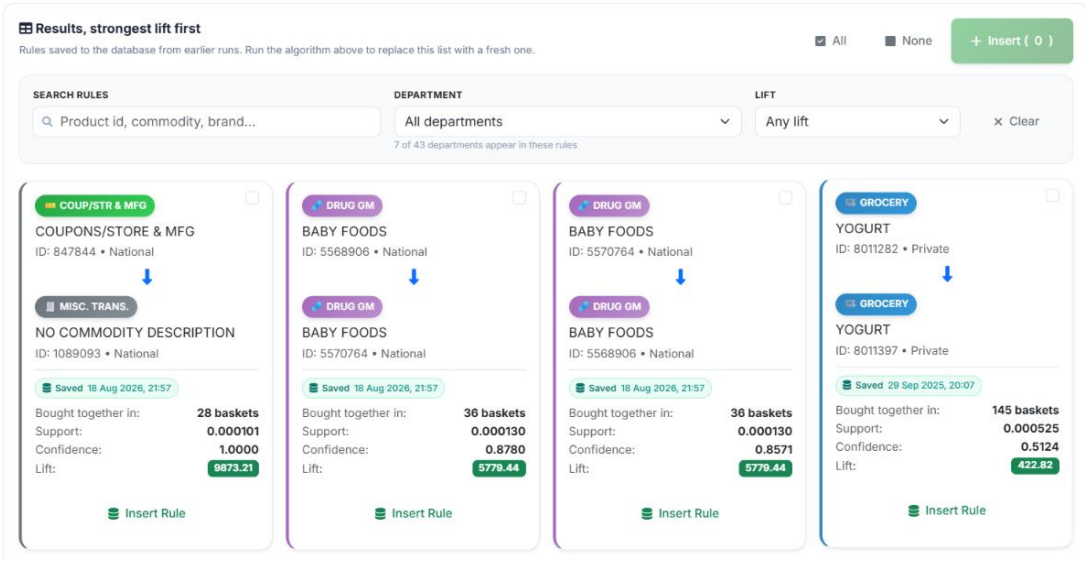
معیار	شیوه محاسبه	نکته
پشتیبان	شمارنده زوج تقسیم بر تعداد کل سبدها	برای هر دو جهت قانون یکسان است
اطمینان قانون از الف به ب	شمارنده زوج تقسیم بر شمارنده محصول الف	در صورت صفر بودن مخرج، مقدار صفر گذاشته می‌شود
اطمینان قانون از ب به الف	شمارنده زوج تقسیم بر شمارنده محصول ب	معمولاً با جهت دیگر برابر نیست
بهبود	اطمینان قانون تقسیم بر نسبت حضور تالی در کل سبدها	برای هر دو جهت عدد یکسانی به دست می‌آید

سطر آخر جدول یک ویژگی ریاضی مفید را نشان می‌دهد. اگر عبارت بهبود را ساده کنیم، به حاصل‌ضرب شمارنده زوج در تعداد کل سبدها تقسیم بر حاصل‌ضرب دو شمارنده تک‌محصولی می‌رسیم. این عبارت نسبت به جای‌گشت دو محصول متقارن است، پس هر دو جهت قانون بهبود یکسانی دارند. همین عبارت است که در پرس‌وجوی گام سوم برای مرتب‌سازی نامزدها به کار می‌رود.

نکته‌ای که باید در گزارش ثبت شود این است که در این صفحه هیچ معیار دیگری مانند اهرم[۱۱۵]، اقناع[۱۱۶] یا شباهت جاکارد[۱۱۷] محاسبه نمی‌شود. سه معیار بالا برای هدف این پروژه کافی دانسته شدند.

۷-۸ نمایش نتایج و خواندن کارت قانون

برخلاف بیشتر صفحه‌های سامانه که نتیجه را در جدول نشان می‌دهند، این صفحه هر قانون را در یک کارت جداگانه نمایش می‌دهد. علت این انتخاب آن است که هر قانون شش تا هشت قلم اطلاعات دارد و جا دادن همه آن‌ها در یک سطر جدول، سطر را چنان شلوغ می‌کند که خواندنش دشوار می‌شود. شکل ۷-۲ ردیف نخست این کارت‌ها را نشان می‌دهد.



شکل ۷-۲ – نمای کارتی نتایج و ابزار انتخاب گروهی در بالای فهرست قوانین

هر کارت از بالا به پایین سه ناحیه دارد. ناحیه بالا محصول مقدم را با نشان رنگی گروه کالایی، نام کالا، شناسه و نوع برند معرفی می‌کند. یک پیکان رو به پایین جهت قانون را نشان می‌دهد و ناحیه میانی همان اطلاعات را برای محصول تالی تکرار می‌کند. ناحیه پایین به معیارها اختصاص دارد.

رنگ نوار کناری هر کارت بر اساس گروه کالایی محصول مقدم تعیین می‌شود. برای نمونه گروه خواروبار آبی، گروه دارو و کالای عمومی بنفش و گروه میوه و سبزی سبز است. این رنگ‌بندی هیچ معنای

---

[۱۱۵] Leverage

[۱۱۶] Conviction

[۱۱۷] Jaccard Similarity

تحلیلی ندارد و تنها به تشخیص سریع کمک می‌کند. کاربر با یک نگاه می‌فهمد که آیا قوانین به‌دست‌آمده همه از یک گروه‌اند یا در گروه‌های مختلف پراکنده‌اند.

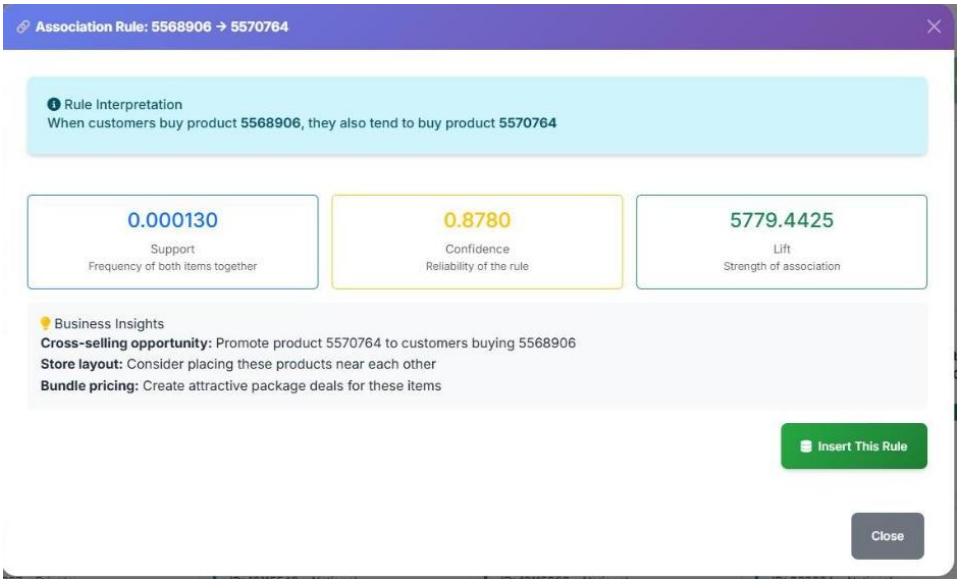
در ناحیه معیارها، به جای نمایش صرف عدد پشتیبان، ابتدا یک عبارت به زبان ساده نوشته می‌شود که این دو محصول در چند سبد با هم دیده شده‌اند. این عدد از حاصل‌ضرب پشتیبان در تعداد کل سبدها به دست می‌آید و برای بیشتر کاربران بسیار گویاتر از یک کسر شش‌رقمی است. اگر این عدد کمتر از بیست باشد، مقدار بهبود به جای پس‌زمینه سبز با پس‌زمینه نارنجی نمایش داده می‌شود و یک جمله هشدار زیر آن اضافه می‌گردد با این مضمون که شواهد برای اتکا به این قانون اندک است. جدول ۷-۶ اجزای کارت را فهرست می‌کند.

جدول ۷-۶ – اجزای کارت قانون و آنچه هر جزء نشان می‌دهد

جزء کارت	محتوا	کاربرد
نوار رنگی کناری	رنگ متناظر گروه کالایی مقدم	تشخیص سریع پراکندگی گروه‌ها
نشان گروه کالایی	نام گروه به همراه یک نماد	قرار دادن محصول در بافت دسته‌بندی
نام کالا و شناسه	شرح کالا، شناسه محصول و نوع برند	شناسایی دقیق قلم برای اقدام عملی
نشان وضعیت ذخیره	ذخیره‌شده یا نیازمند به‌روزرسانی	تشخیص اینکه قانون قبلاً ثبت شده است یا نه
تعداد سبد مشترک	عدد صحیح حاصل از پشتیبان	سنجش پشتوانه واقعی قانون
سه معیار	پشتیبان، اطمینان و بهبود	ارزیابی کمی قانون
هشدار شواهد اندک	تنها زیر بیست سبد	پیشگیری از تصمیم بر پایه نمونه کوچک
دکمه ثبت	در پایین کارت	ذخیره قانون در پایگاه داده

۷-۹ نمای جزئیات قانون

با کلیک روی هر کارت، پنجره‌ای باز می‌شود که همان قانون را با جزئیات بیشتری نشان می‌دهد. شکل ۷-۳ این پنجره را برای یکی از قوانین گروه غذای کودک نشان می‌دهد.



شکل ۷-۳ - پنجره جزئیات قانون شامل معیارها و برداشت‌های تجاری پیشنهادی

بالای پنجره یک جمله قانون را به زبان طبیعی بازنویسی می‌کند: هنگامی که مشتریان محصول نخست را می‌خرند، تمایل دارند محصول دوم را نیز بخرند. این بازنویسی برای کاربری که با اصطلاح مقدم و تالی آشنا نیست راهنما بهتری است.

زیر آن، سه کارت کوچک هر یک از معیارها را با دقت بیشتری نسبت به کارت اصلی و به همراه یک توضیح یک‌خطی نمایش می‌دهند. پشتیبان با عنوان فراوانی حضور هم‌زمان، اطمینان با عنوان قابلیت اتکای قانون و بهبود با عنوان شدت همراهی.

بخش پایانی پنجره سه پیشنهاد عملی ثابت را برای مدیران فروشگاه فهرست می‌کند. اولین پیشنهاد فروش مکمل، یعنی معرفی محصول تالی به خریداران محصول مقدم است. پیشنهاد دوم چیدمان فروشگاه، یعنی نزدیک کردن جای دو محصول است و در نهایت بسته‌بندی مشترک با قیمت تشویقی نیز آخرین پیشنهاد عملی است. باید توجه داشت که این سه جمله ثابت‌اند و برای همه قوانین یکسان نمایش داده می‌شوند یعنی سامانه در این بخش تحلیل تازه‌ای انجام نمی‌دهد و تنها سه کاربرد متعارف قوانین انجمنی را یادآوری می‌کند. تفسیر اینکه کدام‌یک برای این قانون خاص مناسب است بر عهده کاربر باقی می‌ماند.

۷-۱۰ صفحه‌بندی سمت مرورگر

اگر کاربر تعداد نتایج را روی مقدارهای بالا تنظیم کند، ممکن است چند هزار کارت تولید شود. در نسخه نخست این صفحه همه کارت‌ها هم‌زمان نمایش داده می‌شدند و نتیجه صفحه‌ای بسیار بلند بود که پیمایش آن تا انتها بیش از یک ثانیه طول می‌کشید و کار با صفحه را آزاردهنده می‌کرد.

راه‌حل به‌کاررفته یک صفحه‌بندی ساده در سمت مرورگر است. همه کارت‌ها در ساختار صفحه ساخته می‌شوند اما در هر لحظه تنها صد کارت نمایان‌اند و بقیه پنهان می‌مانند. یک نوار پیمایش در بالا و پایین فهرست قرار می‌گیرد که شماره صفحه جاری، بازه کارت‌های نمایش‌داده‌شده و تعداد کل قوانین را نشان می‌دهد و دکمه‌های رفتن به صفحه اول، قبلی، بعدی و آخر را در اختیار می‌گذارد.

انتخاب پنهان کردن به جای حذف کارت‌ها آگاهانه است. به این ترتیب انتخاب‌های کاربر برای ثبت گروهی[۱۱۸] هنگام جابه‌جایی میان صفحه‌ها از بین نمی‌رود.

۷-۱۱ ثبت قوانین در پایگاه داده

یک اصل مهم در طراحی این صفحه آن است که اجرای الگوریتم هیچ چیزی را در پایگاه داده نمی‌نویسد. نتیجه اجرا تنها روی صفحه نمایش داده می‌شود و اگر کاربر صفحه را ببندد، از بین می‌رود. ذخیره‌سازی یک اقدام جداگانه و آگاهانه است. دلیل این تفکیک آن است که بیشتر اجراها اکتشافی‌اند و کاربر آستانه‌ها را بالا و پایین می‌کند تا حس کند داده چه شکلی دارد و ذخیره خودکار همه این اجراها، جدول قوانین را با نتایج بی‌ارزش پر می‌کرد.

۷-۱۱-۱ ساختار جدول قوانین

قوانین ذخیره‌شده در جدولی نگه‌داری می‌شوند که برخلاف جدول‌های اصلی مجموعه‌داده، توسط خود سامانه ساخته و مدیریت می‌شود. جدول ۷–۷ فیلدهای این جدول را معرفی می‌کند.

---

[۱۱۸] Bulk Insert

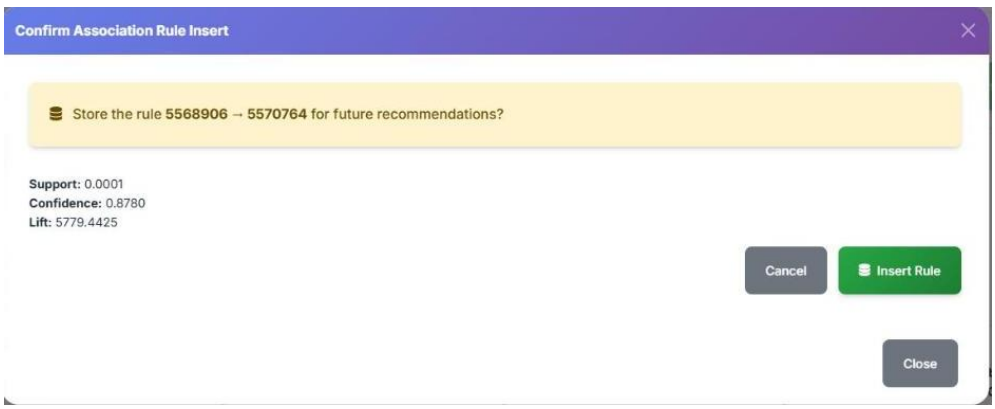
جدول ۷-۷ – فیلدهای جدول قوانین انجمنی و نقش هر فیلد

فیلد	محتوا
مقدم و تالی	فهرست شناسه‌های دو طرف قانون
پشتیبان، اطمینان و بهبود	سه معیار محاسبه‌شده قانون
نوع قانون	سطح تحلیل: محصول، کالا، گروه کالایی یا دسته
آستانه‌های اجرا	مقادیر حداقل پشتیبان، اطمینان و بهبود هنگام تولید قانون
منبع تولید	نام صفحه یا مسیری که قانون از آن به دست آمده است
فراداده	اطلاعات توصیفی مانند نام گروه و کالای دو طرف
زمان ایجاد	برچسب زمانی ثبت نخستین بار

برای سه معیار و نوع قانون، نمایه‌های جداگانه‌ای[۱۱۹] روی جدول تعریف شده است تا مرتب‌سازی بر اساس بهبود، که در هر بار باز شدن صفحه انجام می‌شود، سریع باقی بماند.

۷-۱۱-۲ ثبت تکی و پنجره تأیید

با فشردن دکمه ثبت در پای هر کارت، پیش از هر نوشتنی یک پنجره تأیید باز می‌شود. شکل ۷-۴ این پنجره را نشان می‌دهد. پنجره، قانون را به شکل مقدم و تالی تکرار می‌کند و سه معیار را نمایش می‌دهد تا کاربر مطمئن شود روی کارت درستی کلیک کرده است. تنها با فشردن دکمه تأیید، درخواست به سرور فرستاده می‌شود.



شکل ۷-۴ – پنجره تأیید ثبت قانون پیش از نوشتن در پایگاه داده

[۱۱۹] Index

سرور پس از دریافت درخواست، ابتدا بررسی می‌کند که هر دو طرف قانون خالی نباشند و سه معیار قابل تبدیل به عدد باشند. سپس در جدول به دنبال قانونی با همان مقدم، همان تالی و همان نوع می‌گردد. اگر چنین قانونی پیدا شود، معیارهای آن به‌روز می‌شوند و اگر پیدا نشود، رکورد تازه‌ای ساخته می‌شود. به این ترتیب ثبت دوباره یک قانون باعث تکرار آن در جدول نمی‌شود.

۷-۱۱-۳ ثبت گروهی

در بالای فهرست نتایج، دو دکمه برای انتخاب همه یا هیچ‌کدام و یک دکمه ثبت گروهی قرار دارد که تعداد موارد انتخاب‌شده را نیز نشان می‌دهد. با فشردن آن، برنامه ابتدا موارد تکراری را از فهرست انتخاب‌شده حذف می‌کند و سپس قوانین را یکی‌یکی و به ترتیب به سرور می‌فرستد.

ارسال ترتیبی به جای ارسال هم‌زمان یک انتخاب آگاهانه است. چند ده درخواست هم‌زمان می‌تواند پایگاه داده را درگیر کند. برای هر قانون تا سه بار تلاش انجام می‌شود و فاصله میان تلاش‌ها هر بار افزایش می‌یابد. اگر سه قانون پشت سر هم با خطا مواجه شوند، کل عملیات متوقف می‌گردد. این قاعده مانع از آن می‌شود که در صورت قطع ارتباط با پایگاه داده، برنامه ده‌ها درخواست بی‌نتیجه دیگر بفرستد.

۷-۱۱-٤ نمایش وضعیت ذخیره در اجراهای بعدی

هنگام نمایش نتیجه یک اجرای تازه، برنامه هر قانون را با قوانین ذخیره‌شده مقایسه می‌کند و یکی از سه وضعیت را به آن نسبت می‌دهد: تازه، یعنی هنوز ذخیره نشده است. ذخیره‌شده، یعنی با همان معیارها در جدول موجود است و نیازمند به‌روزرسانی، یعنی قانون در جدول هست اما معیارهای آن با اجرای فعلی تفاوت دارد. مقایسه معیارها با دقت محدود انجام می‌شود تا اختلاف‌های ناشی از گرد کردن، قانونی را بی‌جهت تغییریافته نشان ندهد. نتیجه این مقایسه همان نشانی است که در کارت دیده می‌شود و به کاربر کمک می‌کند بداند کدام قوانین ارزش ثبت دارند.

۷-۱۲ نمونه نتایج و شیوه خواندن آن‌ها

برای اینکه بحث از سطح انتزاعی خارج شود، جدول ۷-۸ چند قانون از خروجی واقعی صفحه را با معیارهای آن‌ها نشان می‌دهد. این قوانین با تنظیمات پیش‌فرض و روی کل تراکنش‌ها به دست آمده‌اند.

جدول ۷-۸ - نمونه‌ای از قوانین به‌دست‌آمده در سطح محصول با تنظیمات پیش‌فرض

مقدم	تالی	کالای دو طرف	سبد مشترک	پشتیبان	اطمینان	بهبود
۸۴۷۸۴۴	۱۰۸۹۰۹۳	کوپن فروشگاهی و تراکنش متفرقه	۲۸	۰/۰۰۰۱۰۱	۱/۰۰۰۰	۹۸۷۳/۲۱
۵۵۶۸۹۰۶	۵۵۷۰۷۶۴	غذای کودک	۳۶	۰/۰۰۰۱۳۰	۰/۸۷۸۰	۵۷۷۹/۴۴
۸۰۱۱۲۸۲	۸۰۱۱۳۹۷	ماست	۱۴۵	۰/۰۰۰۵۲۵	۰/۵۱۲۴	۴۲۲/۸۲
۱۳۱۱۵۵۴۸	۱۳۱۱۵۹۰۳	نوشیدنی ورزشی	۳۱۹	۰/۰۰۱۱۵۵	۰/۷۳۶۸	۴۰۵/۹۷
۹۵۳۱۳۴	۹۸۱۹۴۴	سوپ	۱۴۶	۰/۰۰۰۵۲۸	۰/۵۴۸۹	۳۵۶/۱۹

خواندن این جدول چند درس دارد. نخست اینکه مقادیر بهبود در سطح محصول بسیار بزرگ‌اند، تا حدی که در نگاه اول باورنکردنی به نظر می‌رسند. اما این بزرگی طبیعی است. وقتی هر یک از دو محصول تنها در چند ده سبد از ۲۷۶۴۵۰ سبد حاضر است، حضور هم‌زمان آن‌ها در ۳۶ سبد به معنای انحراف شدید از حالت استقلال است. بهبود پنج هزار به این معنا نیست که این قانون پنج هزار برابر مهم‌تر از قانونی با بهبود چهارصد است و تنها به این معناست که این زوج نسبت به فراوانی کم دو طرفش، به طور غیرمنتظره‌ای زیاد با هم دیده شده‌اند.

دوم اینکه سطر نخست یک نمونه آموزنده از چیزی است که می‌توان آن را قانون درست اما بی‌فایده نامید. هر دو طرف آن، اقلامی هستند که در واقع محصول نیستند. یکی رکورد کوپن فروشگاهی است و دیگری تراکنشی بدون شرح کالا. اطمینان کامل و بهبود بسیار بالای این قانون از یک واقعیت ساده ناشی می‌شود. این دو رکورد فنی همیشه با هم ثبت می‌شوند. الگوریتم هیچ خطایی نکرده است، اما این قانون هیچ تصمیم بازرگانی را پشتیبانی نمی‌کند. چنین مواردی نشان می‌دهند که تصمیم انتخاب هر قانون پیش از ذخیره هر قانون، گامی است که باید بشدت توسط مدیران فروشگاه مورد توجه قرار داده شود.

سوم اینکه قوانین ردیف‌های دوم تا پنجم، که همگی میان دو محصول از یک کالای واحد برقرارند، الگوی رایجی را نشان می‌دهند. مشتری هنگام خرید ماست، سوپ یا نوشیدنی ورزشی معمولاً بیش از یک قلم

از همان کالا و با طعم‌های متفاوت برمی‌دارد. این نوع قانون برای تصمیم چیدمان قفسه و بسته‌سازی[۱۲۰] مستقیماً قابل استفاده است، ولی برای فروش مکمل میان دو دسته متفاوت کمکی نمی‌کند. اگر هدف یافتن پیوند میان دسته‌های مختلف باشد، سطح کالا یا گروه کالایی که در فصل چهارم بررسی شد ابزار مناسب‌تری است.

۷-۱۳ رفتار سامانه در زمان اجرا و ملاحظات کارایی

پس از فشردن دکمه اجرا، دکمه غیرفعال می‌شود، یک نشانگر چرخان کنار آن ظاهر می‌گردد و یک نوار پیشرفت[۱۲۱] راه‌راه نمایش داده می‌شود. البته باید گفت که این نوار پیشرفت ثابت است و تغییری نمی‌کند و دلیل آن این است که محاسبه در یک پرس‌وجوی واحد در پایگاه داده انجام می‌شود و سرور هیچ گزارش میانی از درصد پیشرفت ندارد. نوار تنها به کاربر می‌گوید که کاری در جریان است و باید منتظر بماند.

سنگین‌ترین بخش محاسبه، الحاق جدول تراکنش‌ها با حدود ۲/۶ میلیون سطر به خودش است. سه سازوکار هزینه این کار را مهار می‌کنند: نخست، شرط حداقل تعداد سبد که پیش از خروج داده و درون پایگاه داده اعمال می‌شود. دوم، محدود کردن تعداد سطرهای بازگشتی به سقف نامزدها و سوم، محدود کردن دوره زمانی که مستقیماً حجم داده ورودی را کم می‌کند. تجربه اجرا نشان داد که با تنظیمات پیش‌فرض و روی کل داده، زمان پاسخ در حد چند ده ثانیه است و با انتخاب دوره‌های کوتاه‌تر به طور محسوسی کاهش می‌یابد.

دو محدودیت شناخته‌شده نیز باید ثبت شوند. نخست اینکه هیچ حافظه نهان[۱۲۲]ی برای نتایج وجود ندارد. اگر کاربر دقیقاً همان تنظیمات را دوباره اجرا کند، تمام محاسبه از ابتدا تکرار می‌شود. دوم اینکه در سمت سرور مهلت زمانی[۱۲۳] مشخصی برای این پرس‌وجو تعریف نشده است یعنی اگر ترکیبی از پارامترها به محاسبه‌ای بسیار طولانی بینجامد، سامانه آن را به‌خودی‌خود قطع نمی‌کند.

۷-۱۴ ملاحظات تفسیری و محدودیت‌ها

این بخش محدودیت‌هایی را جمع می‌کند که هنگام استفاده از خروجی این صفحه باید در نظر گرفته شوند. بخشی از آن‌ها ذات روش‌اند و بخشی نتیجه انتخاب‌های پیاده‌سازی هستند.

---

[۱۲۰] Product Bundling

[۱۲۱] Progress Bar

[۱۲۲] Cache

[۱۲۳] Timeout

نخست، قانون انجمنی همبستگی[۱۲۴] را نشان می‌دهد و علیت[۱۲۵] نشان نمی‌دهد. اگر دو محصول اغلب با هم خریده می‌شوند، لزوماً یکی علت خرید دیگری نیست. ممکن است هر دو معلول یک عامل سوم مانند یک کمپین تبلیغاتی هم‌زمان یا قرار گرفتن در یک قفسه باشند. هرگونه تصمیم بر پایه این قوانین باید با یک آزمون واقعی در فروشگاه سنجیده شود.

دوم، همه قوانین این صفحه دقیقاً یک مقدم و یک تالی دارند. الگوهای سه‌تایی، که در برخی کاربردهای چیدمان اهمیت دارند، در این نسخه پوشش داده نمی‌شوند.

سوم، همان‌طور که در بخش ۷-۶-۴ گفته شد، نامزدها بر اساس بهبود انتخاب می‌شوند و این معیار برای زوج‌های کم‌فروش بیشترین مقدار را دارد. نتیجه آنکه بخش زیادی از فهرست خروجی به الگوهای نادر اختصاص می‌یابد. دقیقاً همان الگوهایی که خود صفحه با هشدار شواهد اندک درباره‌شان اخطار می‌دهد. کاربری که به دنبال الگوهای پرحجم و قابل اتکا است باید حداقل پشتیبان را آگاهانه بالا ببرد.

۷-۱۵ جمع‌بندی فصل

در این فصل صفحه قوانین انجمنی سامانه بررسی شد. این صفحه تنها جایی است که استخراج قانون در پایین‌ترین سطح سلسله‌مراتب محصول، یعنی سطح شناسه کالا، انجام می‌شود و همین آن را از بخش مشابهی که در فصل چهارم بررسی شد جدا می‌کند.

نشان داده شد که مسئله در این سطح بیش از چهار میلیارد زوج ممکن دارد و راه‌حل به‌کاررفته، یعنی واگذاری شمارش هم‌زمانی به پایگاه داده از طریق خودالحاقی جدول تراکنش‌ها به همراه اعمال آستانه در همان مرحله، این مسئله را به اندازه‌ای قابل مدیریت می‌رساند که در یک صفحه تعاملی قابل اجرا باشد. همچنین توضیح داده شد که این روش، برخلاف نامی که روی دکمه اجرا آمده، معادل کامل الگوریتم Apriori نیست و تنها به مجموعه‌های دوعضوی محدود می‌ماند.

چهار پارامتر ورودی، شیوه محاسبه سه معیار با مخرج مبتنی بر سبد متمایز، شیوه نمایش کارتی نتایج به همراه هشدار شواهد اندک، و مسیر ذخیره‌سازی آگاهانه قوانین در پایگاه داده، اجزای اصلی این صفحه‌اند. نمونه نتایج نشان داد که مقادیر بهبود در این سطح ذاتاً بزرگ‌اند و بدون توجه به تعداد سبد مشترک نباید

---

[۱۲۴] Correlation

[۱۲۵] Causality

تفسیر شوند، و همچنین روشن کرد که در نظر نگرفتن قوانین حاصل از اقلام غیرکالایی پیش از ثبت قوانین در پایگاه‌داده ضروری است.

فصل هشتم: داشبورد تحلیلی، تحلیل ریزش و اولویت‌بندی ماندگاری مشتری

محور این فصل سه بخش مرتبط با رفتار مشتری است: بخش‌بندی مشتریان، تحلیل ریزش یک مشتری و اولویت‌بندی ماندگاری. بخش‌بندی، تصویر کلی گروه‌های رفتاری و نتایج مدل فعال را نشان می‌دهد، تحلیل فردی، سابقه و ریسک یک شناسه مشخص را بررسی می‌کند و ماندگاری، مشتریان را برای پیگیری اولویت می‌دهد. صفحه اصلی تحلیل بازار نیز به‌عنوان ورودی مدیریتی و زمینه تفسیر این تحلیل‌ها توضیح داده می‌شود.

در این فصل، ابتدا وضعیت کلی مشتریان و مدل ریزش بررسی می‌شود، سپس وضعیت بازار، ریسک یک مشتری و در پایان فهرست مشتریان اولویت‌دار توضیح داده می‌شود. این ترتیب کمک می‌کند ارتباط میان آمار کلی، احتمال پیش‌بینی و اقدام عملی برای کاربر روشن باشد.

هدف از طراحی این مسیر آن است که داده‌های پراکنده تراکنشی به تصمیمی قابل پیگیری تبدیل شوند. در یک فروشگاه، دانستن تعداد فروش یا تعداد مشتریان به تنهایی کافی نیست. مدیر باید بتواند تشخیص دهد کدام تغییرها در بازار رخ داده‌اند، کدام مشتریان نیازمند توجه فوری هستند و آیا شواهد رفتاری موجود، این اولویت را پشتیبانی می‌کنند یا خیر. بنابراین در این فصل، منطق و کاربرد اجزای قابل مشاهده بیان می‌شود و از ورود به جزئیات پیاده‌سازی پرهیز شده است.

۸-۱ جایگاه سه صفحه در فرایند تصمیم‌گیری

صفحه بخش‌بندی مشتریان، جمعیت مشتری را در گروه‌های RFM خلاصه می‌کند و امکان مشاهده آزمایش‌های ریزش و انتخاب مدل فعال را فراهم می‌سازد. صفحه ماندگاری، احتمال‌های همین مدل را به فهرست مشتریان اولویت‌دار تبدیل می‌کند. صفحه تحلیل فردی نیز نمایه کلی مشتری، سابقه زمانی و کنترل پیش‌بینی در هر برش را در کنار هم نشان می‌دهد. این سه بخش از نظر منبع داده و شناسه مشتری به یکدیگر متصل‌اند {۵}.

صفحه اصلی تحلیل بازار زمینه‌ای کلی از حجم خرید و درآمد را در اختیار مدیر می‌گذارد، اما افت یک شاخص کلان به‌تنهایی علت ریزش را مشخص نمی‌کند. برای بررسی مشتری، می‌توان ابتدا توزیع بخش‌ها و ریسک را دید، سپس فهرست ماندگاری را محدود کرد و در نهایت سابقه یک مشتری را بررسی نمود. این مسیر یک روش پیشنهادی برای خواندن نتایج است و ترتیب اجباری استفاده از سامانه نیست.

۸-۱-۱ قاعده خوانش زنجیره تصمیم

در تفسیر نتایج، بهتر است احتمال ریزش، بخش RFM، مبلغ خرید و سابقه زمانی در کنار هم بررسی شوند. فهرست ماندگاری برای انتخاب نامزد پیگیری است، نه صدور حکم قطعی درباره قطع رابطه با مشتری. ثبت زمان تحلیل و تنظیم مدل نیز به بازبینی تصمیم کمک می‌کند. این موارد توصیه‌های استفاده از خروجی‌اند و سامانه فرایند مستقل ثبت و تأیید اقدام نگهداشت را پیاده‌سازی نکرده است.

جدول ۸-۱ – نقش و خروجی سه صفحه اصلی در مسیر تصمیم‌گیری مشتری

صفحه	داده یا ورودی اصلی	خروجی و اقدام کاربر	نقش تحلیلی
بخش‌بندی مشتریان	سابقه خرید و آزمایش‌های ریزش	گروه‌های **RFM**، توزیع ریسک و انتخاب مدل فعال	نمای جمعی رفتار و ارزیابی مدل
ماندگاری مشتری	ریسک مدل فعال، بخش **RFM** و مبلغ خرید	فهرست اولویت‌دار و پیوند پیشنهاد محصول	اولویت‌بندی پیگیری
تحلیل ریزش مشتری	شناسه مشتری و قاعده تاریخچه	نمایه کلی، سابقه و کنترل پیش‌بینی	بررسی تفصیلی مشتری

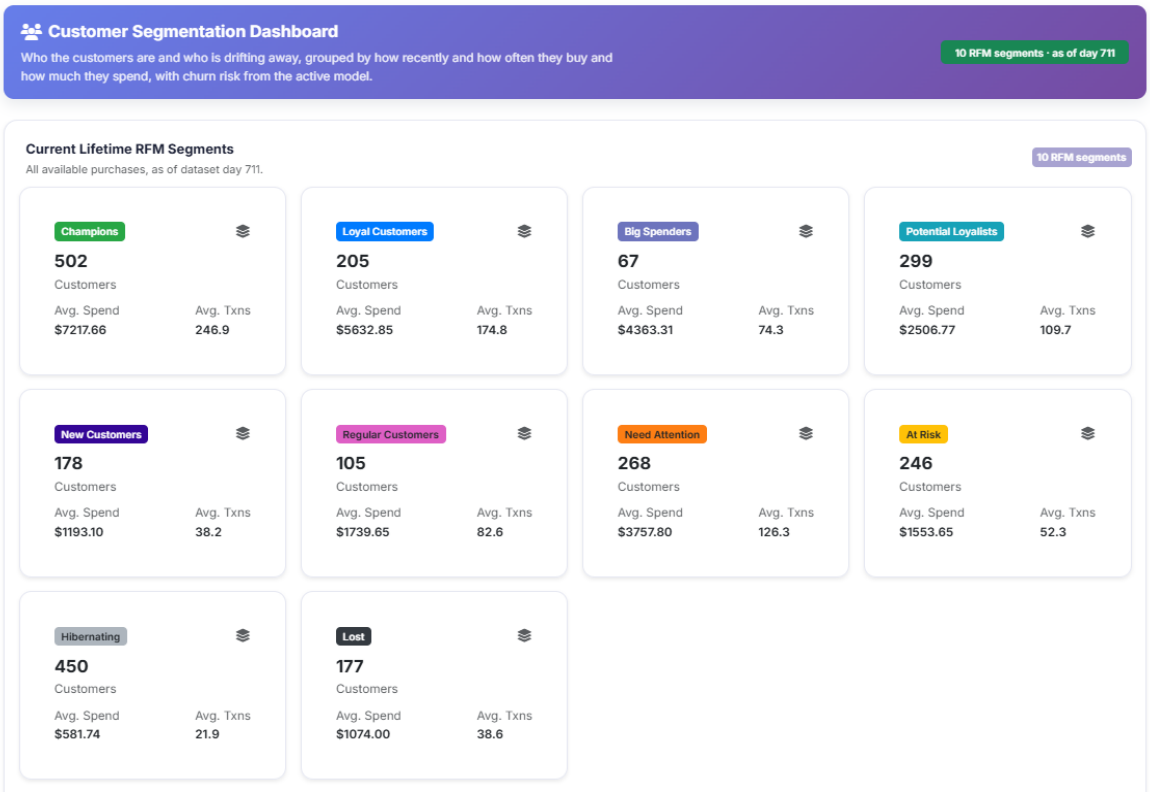
۸-۲ بخش‌بندی مشتریان و پیکربندی مدل ریزش

۸-۲-۱ نمای بخش‌های RFM

صفحه بخش‌بندی مشتریان در مسیر /analysis/customer-segments/، مشتریان را بر اساس تازگی خرید، فراوانی خرید و ارزش پولی[۱۲۶] در ده بخش RFM قرار می‌دهد. تازگی، فاصله آخرین خرید تا آخرین روز داده است. فراوانی با تعداد سبدهای یکتا و ارزش پولی با جمع مبلغ خرید محاسبه می‌شود. برای هر بُعد،

[۱۲۶] Recency, Frequency, Monetary

امتیاز یک تا پنج بر پایه رتبه نسبی تعیین می‌شود و مقادیر برابر امتیاز یکسان می‌گیرند. شکل ۸-۱ تعداد اعضای هر بخش، میانگین مبلغ خرید و میانگین دفعات خرید را نشان می‌دهد {۶}.



شکل ۸-۱ - نمای بخش‌بندی جاری مشتریان بر مبنای RFM

شکل ۸-۱ تفاوت رفتار مشتریان را در یک نمای عملیاتی نشان می‌دهد. تفاوت میان تعداد اعضای هر بخش، میانگین مبلغ خرید و میانگین تعداد تراکنش نشان می‌دهد که ارزش مشتری فقط از روی بزرگی گروه تعیین نمی‌شود. برای نمونه، گروه‌های وفادار و برتر باید از نظر استمرار خرید و حفظ رضایت پایش شوند، در حالی که گروه‌های تازه‌وارد برای تبدیل‌شدن به مشتریان تکرارشونده به ارتباط اولیه و پیشنهاد متناسب نیاز دارند.

گروه هر مشتری با ترکیب سه امتیاز و قواعد مشترک بخش‌بندی تعیین می‌شود. بعضی قواعد در تعیین گروه بر قواعد دیگر اولویت دارند. برای مثال، کاهش تازگی در مشتری دارای فراوانی و مبلغ بالاتر می‌تواند او را در گروه «نیازمند توجه» قرار دهد. نام گروه RFM توصیف رفتار خرید است و با سطح ریسک پیش‌بینی‌شده یکسان نیست. بنابراین مشتری یک بخش می‌تواند در سطح‌های متفاوت ریسک قرار گیرد.

این نما کل سابقه خرید موجود تا روز ۷۱۱ را خلاصه می‌کند. تا زمانی که داده خرید و قواعد RFM ثابت باشند، صرف آموزش یا فعال‌کردن مدل دیگری برای ریزش، تعداد و عضویت این بخش‌ها را تغییر

نمی‌دهد. مقایسه دوره‌ای بخش‌ها فقط در صورت تعریف برش‌های زمانی قابل مقایسه یا ورود داده تازه معنا دارد و نباید تغییر نسخه مدل ریزش را به تغییر رفتار مشتری نسبت داد.

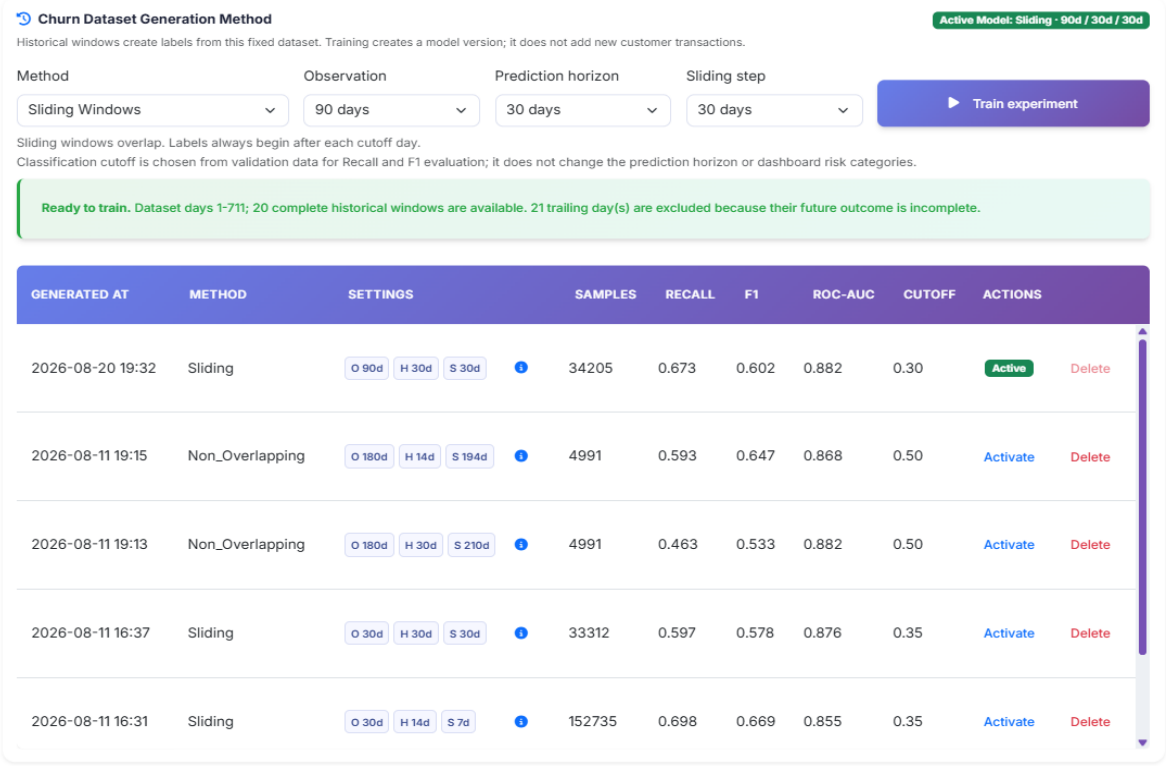
جدول ۸-۲ - توزیع مشتریان در بخش‌های RFM و میانگین هزینه هر بخش

بخش **RFM**	تعداد مشتری	سهم از کل (درصد)	میانگین هزینه (دلار)
مشتریان برتر	۵۰۲	۲۰/۱	۷۲۱۷/۶۶
مشتریان وفادار	۲۰۵	۸/۲	۵۶۳۲/۸۵
پرهزینه‌ها	۶۷	۲/۷	۴۳۶۳/۳۱
وفاداران بالقوه	۲۹۹	۱۲/۰	۲۵۰۶/۷۷
مشتریان جدید	۱۷۸	۷/۱	۱۱۹۳/۱۰
مشتریان عادی	۱۰۵	۴/۲	۱۷۳۹/۶۵
نیازمند توجه	۲۶۸	۱۰/۷	۳۷۵۷/۸۰
در معرض خطر	۲۴۶	۹/۹	۱۵۵۳/۶۵
در حال غیرفعال‌شدن	۴۵۰	۱۸/۰	۵۸۱/۷۴
ازدست‌رفته	۱۷۷	۷/۱	۱۰۷۴/۰۰
جمع	۲۴۹۷	۱۰۰	-

بر پایه محاسبه مستقیم مبلغ خرید اعضای بخش‌ها، دو گروه «مشتریان برتر» و «مشتریان وفادار» در مجموع ۷۰۷ مشتری دارند، یعنی ۲۸/۳ درصد جمعیت و ۵۹/۳ درصد مبلغ خرید کل. در مقابل، گروه‌های «در معرض خطر»، «در حال غیرفعال‌شدن» و «ازدست‌رفته» شامل ۸۷۳ مشتری، معادل ۳۵/۰ درصد جمعیت و ۱۰/۴ درصد مبلغ خرید هستند. درصدهای مبلغ از جمع خرید اعضای هر گروه محاسبه شده‌اند، نه از ضرب میانگین‌های گردشده جدول. این تمرکز ارزش، اهمیت حفظ مشتریان پرارزش را نشان می‌دهد، اما به‌تنهایی اثربخشی یا سودآوری یک اقدام نگهداشت را ثابت نمی‌کند.

۸-۲-۲ تنظیم آزمایش ریزش

برای ساخت داده آموزش، کاربر روش پنجره‌های لغزان[۱۲۷] یا پنجره‌های بدون هم‌پوشانی، طول پنجره مشاهده[۱۲۸] و افق پیش‌بینی[۱۲۹] را انتخاب می‌کند. در روش لغزان، گام حرکت نیز قابل انتخاب است. در روش بدون هم‌پوشانی، گام از مجموع طول مشاهده و افق به دست می‌آید. شکل ۸-۲ آزمایش فعال با مشاهده ۹۰ روزه، افق ۳۰ روزه و گام ۳۰ روزه را نشان می‌دهد. آموزش یک آزمایش، نسخه تازه‌ای از مدل می‌سازد و خرید جدیدی به داده اضافه نمی‌کند.



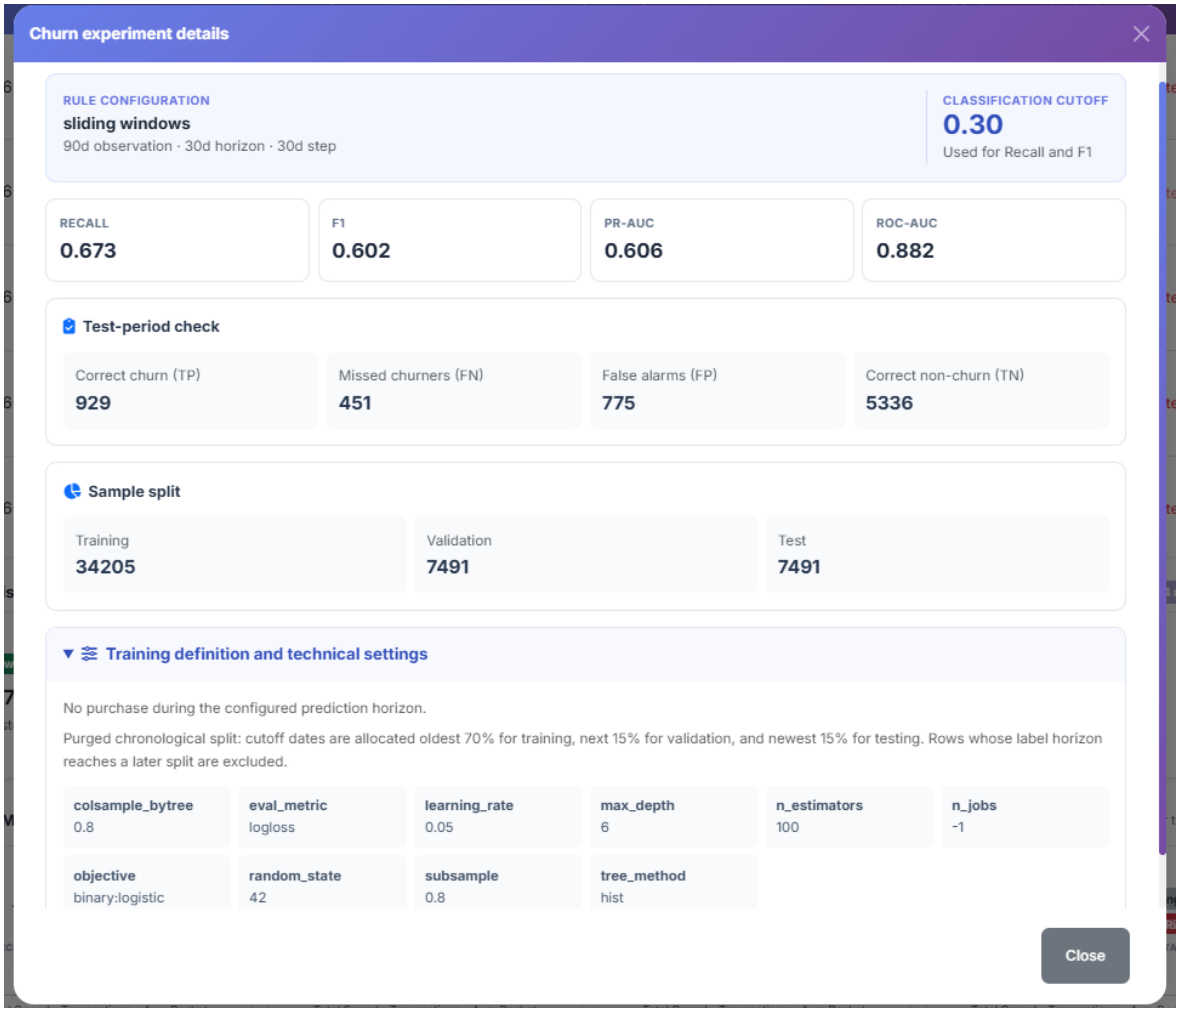
شکل ۸-۲ – تنظیم روش تولید داده و آموزش آزمایش ریزش مشتری

---

[۱۲۷] Sliding Window

[۱۲۸] Observation Window

[۱۲۹] Prediction Horizon



شکل ۸-۳ – جزئیات آزمایش فعال ریزش مشتری و شاخص‌های ارزیابی

برای تنظیم فعال، ۲۰ برش تاریخی با افق کامل ساخته می‌شود. آخرین برش در روز ۶۶۰ پایان می‌یابد و نتیجه خرید تا روز ۶۹۰ قابل مشاهده است. ۲۱ روز انتهایی برای ساخت یک افق کامل دیگر کافی نیستند. هر مشتری که تا نقطه برش سابقه خرید داشته باشد می‌تواند وارد آن برش شود، حتی اگر در پنجره مشاهده خریدی نداشته باشد. مدل علاوه بر RFM از خلاصه‌هایی مانند تنوع کالا، فاصله خریدها، تخفیف و تغییر شدت خرید استفاده می‌کند. اطلاعات پس از نقطه برش فقط برای تعیین نتیجه افق به کار می‌رود.

تنظیمات فنی شکل ۸-۳ باید به‌عنوان پارامترهای کنترل یادگیری خوانده شوند، نه نتیجه ارزیابی. تعداد ۱۰۰ درخت و عمق بیشینه ۶ ظرفیت مدل را محدود می‌کند و نرخ یادگیری[۱۳۰] ۰/۰۵ اندازه اصلاح هر مرحله را تعیین می‌نماید. نسبت نمونه‌برداری[۱۳۱] سطرها و ویژگی‌ها، هر دو ۰/۸، به این معناست که هر درخت با ۸۰٪

---

[۱۳۰] Learning Rate

[۱۳۱] Sampling Ratio

سطرها و ۸۰٪ ویژگی‌ها ساخته می‌شود تا وابستگی بیش از حد به یک بخش از داده کاهش یابد. مقدار ثابت ۴۲ تکرارپذیری آزمایش را حفظ می‌کند. هدف لجستیک دودویی احتمال ریزش را بین صفر و یک می‌سازد، زیان لگاریتمی[۱۳۲] خطای همین احتمال‌ها را هنگام آموزش می‌سنجد و روش هیستوگرامی[۱۳۳] ساخت درخت‌ها را کارآمدتر می‌کند. این اعداد، تنظیم مدل فعال‌اند و به‌خودی‌خود درصد موفقیت مدل محسوب نمی‌شوند {۷}.

داده‌ها با حفظ ترتیب نقاط زمانی به سه بخش آموزش، اعتبارسنجی و آزمون تقسیم می‌شوند: ۷۰ درصد نقاط قدیمی‌تر برای آموزش، ۱۵ درصد بعدی برای اعتبارسنجی و ۱۵ درصد جدیدتر برای آزمون در نظر گرفته می‌شود. نمونه‌هایی که افق برچسب آن‌ها از مرز زمانی مجاز عبور کند حذف می‌شوند. ازاین‌رو این نسبت‌ها لزوماً نسبت تعداد ردیف‌های نهایی نیستند. آستانه طبقه‌بندی با بیشترین F1 در اعتبارسنجی و در حالت برابری با بازخوانی بیشتر انتخاب می‌شود. مقایسه آزمایش‌های دارای افق متفاوت نیز باید با توجه به تفاوت تعریف ریزش انجام گیرد.

فقط آزمایش فعال مبنای احتمال‌های جاری و فهرست ماندگاری است. آستانه طبقه‌بندی آن برای تبدیل احتمال به برچسب در ارزیابی استفاده می‌شود و مرز رنگ‌های چهار سطح ریسک را تغییر نمی‌دهد. برای مقایسه نتایج، علاوه بر معیارها باید طول مشاهده، افق پیش‌بینی و دامنه زمانی ارزیابی معلوم باشد. برتری در یک معیار به‌تنهایی دلیل کافی برای انتخاب مدل نیست.

طول مشاهده تعیین می‌کند چه بخشی از رفتار گذشته خلاصه شود، اما طول افق، معنای نتیجه ریزش را تعیین می‌کند. نداشتن خرید در ۱۴ روز با نداشتن خرید در ۳۰ روز یک رویداد یکسان نیست. گام حرکت نیز تعداد و میزان هم‌پوشانی برش‌ها را تغییر می‌دهد. بنابراین تنظیم این سه مؤلفه باید با فاصله معمول خرید و هدف تحلیل سازگار باشد و صرف افزایش تعداد نمونه، نشانه بهبود مدل محسوب نشود.

در آزمایش فعال، ۳۴۲۰۵ نمونه برای آموزش و برای هر یک از بخش‌های اعتبارسنجی و آزمون ۷۴۹۱ نمونه ثبت شده است. معیارهای جدول ۸–۳ به بخش آزمون تعلق دارند. احتمال‌های جاری مشتریان پس از

---

[۱۳۲] Log Loss

[۱۳۳] Histogram-based Tree Method

برازش نهایی بر تاریخچه‌های کامل تولید می‌شوند. ازاین‌رو نباید آن‌ها را با پیش‌بینی هر سطر تاریخچه یکسان دانست. تغییر مدل یا تنظیم آن می‌تواند احتمال جاری را عوض کند، بدون آنکه خرید تازه‌ای ثبت شده باشد.

جدول ۸-۳ - تنظیمات و شاخص‌های ارزیابی مدل فعال ریزش

مؤلفه	مقدار فعال	تفسیر در گزارش	کاربرد تحلیلی
روش ساخت داده	پنجره‌های لغزان	برش‌های تاریخی هم‌پوشان	بررسی رفتار در نقاط زمانی
دوره مشاهده	۹۰ روز	بازه خلاصه ویژگی‌های خرید	توصیف رفتار گذشته
افق پیش‌بینی	۳۰ روز	بازه بررسی خرید بعد از برش	تعریف نتیجه ریزش
گام حرکت	۳۰ روز	فاصله نقاط برش متوالی	تعیین تعداد برش‌ها
نمونه‌های آموزش	۳۴۲۰۵	پس از تفکیک و کنترل زمانی	برازش مدل در آزمایش
آستانه طبقه‌بندی	۰/۳۰	انتخاب‌شده با اعتبارسنجی	محاسبه برچسب و معیارها
بازخوانی	۰/۶۷۳	سهم ریزش‌های شناسایی‌شده در آزمون	بررسی موارد ازدست‌رفته
امتیاز **F1**	۰/۶۰۲	ترکیب دقت هشدار و بازخوانی	سنجش خطای طبقه‌بندی
مساحت زیر منحنی **ROC**	۰/۸۸۲	تفکیک نسبی دو گروه در آزمون	ارزیابی توان رتبه‌بندی
مساحت زیر منحنی دقت-بازخوانی	۰/۶۰۶	کیفیت هشدار با تمرکز بر گروه ریزشی	ارزیابی مدل در داده نامتوازن

بازخوانی ۰/۶۷۳ نشان می‌دهد مدل حدود ۶۷/۳٪ ریزش‌های واقعی آزمون را شناسایی کرده است. امتیاز F1[۱۳۴] برابر با ۰/۶۰۲، تعادل میان درست‌بودن هشدارها و شناسایی ریزش‌های واقعی را خلاصه می‌کند و در این پروژه نشان می‌دهد افزایش کشف ریزش با مقداری هشدار نادرست همراه است. مساحت زیر منحنی ROC برابر با ۰/۸۸۲، توان مناسب مدل در رتبه‌بندی مشتری ریزشی بالاتر از مشتری غیرریزشی را نشان می‌دهد و نباید به‌صورت «۸۸/۲٪ صحت» خوانده شود. معیار مساحت زیر منحنی دقت-بازخوانی (PR-AUC)[۱۳۵] برابر با ۰/۶۰۶ نیز کیفیت هشدارها را با تمرکز بر گروه ریزشی می‌سنجد. مقایسه آن با نرخ واقعی ریزش آزمون، یعنی ۱۸/۴٪، نشان می‌دهد مدل اطلاعاتی فراتر از نرخ پایه فراهم کرده است.

---

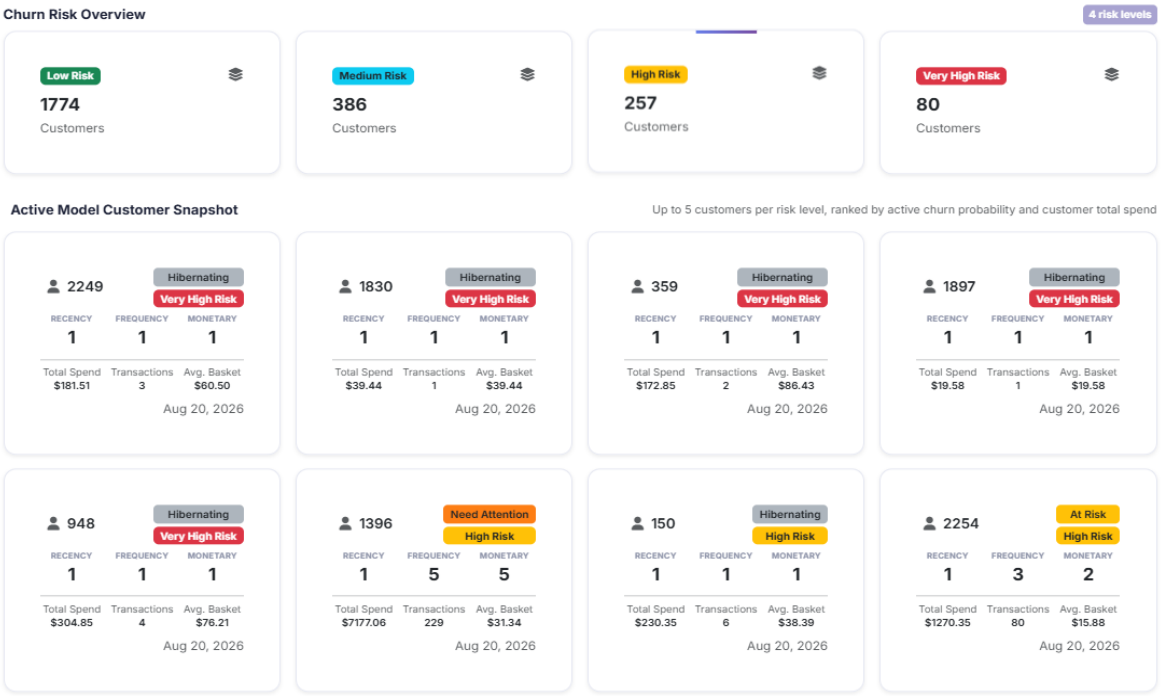
[۱۳۴] F۱ Score

[۱۳۵] Precision-Recall Area Under the Curve

در آزمون، ۹۲۹ مورد ریزش درست شناسایی شده، ۴۵۱ مورد ریزش از دست رفته و ۷۷۵ هشدار نادرست ایجاد شده است. ۵۳۳۶ مورد بدون ریزش نیز درست تشخیص داده شده‌اند. این چهار عدد منشأ معیارهای ارزیابی را روشن می‌کنند و نشان می‌دهند مدل با وجود توان رتبه‌بندی مناسب، هنوز برای بخشی از مشتریان خطای تصمیم دارد. آستانه ۰٫۳۰ برای تبدیل احتمال به برچسب در همین ارزیابی انتخاب شده و با حداقل ریسک پیش‌فرض ۵۰ درصد در فهرست ماندگاری تفاوت دارد.

۸-۲-۳ نمای کلی ریسک ریزش

پس از فعال‌کردن آزمایش، صفحه بخش‌بندی تعداد مشتریان را در چهار سطح ریسک کم، متوسط، بالا و بسیار بالا نشان می‌دهد. در شکل ۸-۴، حداکثر پنج مشتری از هر سطح برای مرور سریع انتخاب می‌شوند. ترتیب انتخاب بر پایه احتمال ریزش و سپس مبلغ خرید است. کارت‌ها علاوه بر ریسک، بخش RFM، مبلغ کل، دفعات خرید و میانگین سبد را نشان می‌دهند. این نمونه‌ها تصادفی نیستند و نماینده آماری همه اعضای هر سطح محسوب نمی‌شوند.



شکل ۸-۴ – توزیع سطح‌های ریسک ریزش و نمونه مشتریان در مدل فعال

کارت‌های نمونه در شکل ۸-۴ نشان می‌دهند که دو مشتری با سطح ریسک مشابه می‌توانند از نظر ارزش خرید و تعداد تراکنش بسیار متفاوت باشند. به همین دلیل، ترتیب نمایش ریسک باید نقطه شروع بررسی باشد

و نه پایان آن. در برنامه نگهداشت، مشتری پرارزش با ریسک بالا معمولاً نیازمند بررسی دقیق‌تر از مشتری کم‌ارزش با همان احتمال ریزش است.

برای جلوگیری از تمرکز نادرست، کاربر باید از نمونه‌های کارت‌ها به توزیع کامل سطح‌های ریسک در همان صفحه بازگردد. کارت‌ها نمونه‌هایی برای مشاهده سریع هستند، در حالی که تصمیم درباره بودجه یا ظرفیت تماس باید با تعداد کل مشتریان هر سطح ریسک و محدودیت اجرایی فروشگاه هماهنگ شود.

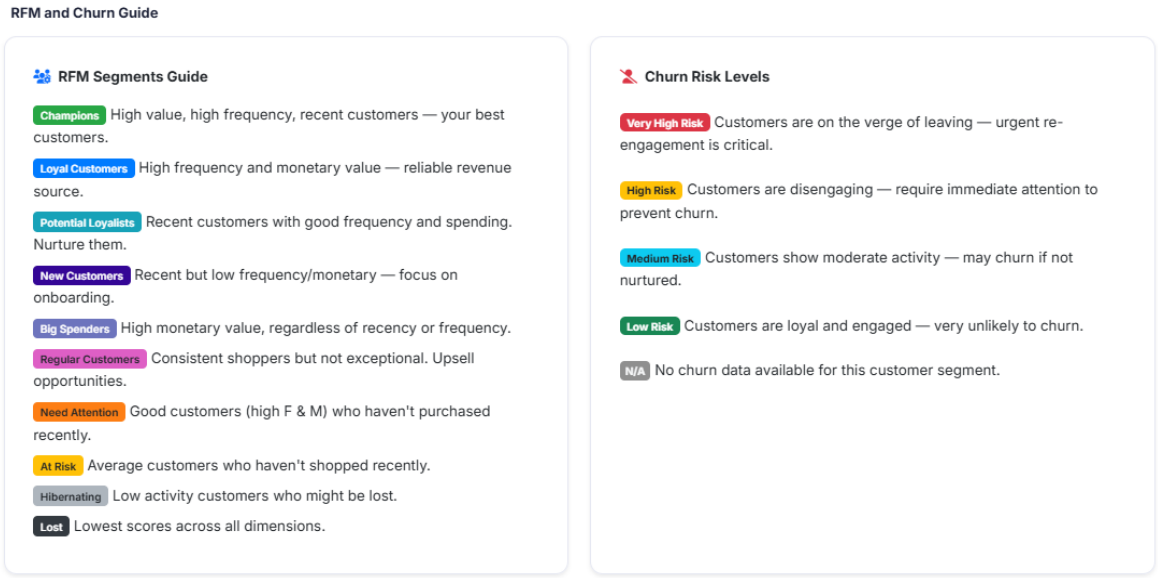
جدول ۸-۴ - توزیع سطح‌های ریسک ریزش و قاعده اقدام

سطح ریسک	تعداد مشتری	سهم از کل (درصد)	قاعده اقدام پیشنهادی
کم	۱۷۷۴	۷۱/۰	پایش عادی و حفظ تجربه خرید
متوسط	۳۸۶	۱۵/۵	پایش هدفمند و بررسی روند **RFM**
بالا	۲۵۷	۱۰/۳	بررسی ارزش مشتری و طراحی اقدام سبک
بسیار بالا	۸۰	۳/۲	بازبینی فوری و اقدام شخصی‌سازی‌شده
بالا و بسیار بالا	۳۳۷	۱۳/۵	فهرست اصلی مداخله نگهداشت

طبق جدول ۸-۴، تنها ۱۳/۵٪ مشتریان در سطح خطر بالا یا بسیار بالا قرار دارند. این نسبت، مزیت اصلی صفحه ماندگاری را روشن می‌کند: به جای اجرای اقدام یکسان برای همه **۲۴۹۷** مشتری، می‌توان ابتدا فهرستی محدودتر از **۳۳۷** مشتری را بررسی کرد. با وجود این، درون همین فهرست نیز ترتیب اقدام باید با مبلغ کل خرید، بخش RFM و امکان بازگشت مشتری تعیین شود، زیرا خطر آماری و ارزش اقتصادی لزوماً هم‌معنا نیستند.

۸-۲-٤ راهنمای تفسیر نتایج

راهنمای درون صفحه، معنی عملی هر بخش RFM و هر سطح ریسک را به زبان کوتاه توضیح می‌دهد. همان‌طور که در شکل ۸-۵ دیده می‌شود، بخش‌هایی مانند مشتریان وفادار، مشتریان بالقوه وفادار، در معرض خطر و غیرفعال از نظر اقدام پیشنهادی یکسان نیستند. این راهنما جای تصمیم نهایی را نمی‌گیرد، اما از تفسیر صرفاً عددی خروجی جلوگیری می‌کند.



شکل ۸–۵ – راهنمای تفسیر بخش‌های RFM و سطح‌های ریسک ریزش

راهنمای شکل ۸–۵ پیوند میان برچسب تحلیلی و اقدام را روشن می‌کند. برای مثال، برچسب «نیازمند توجه» به معنی قطع رابطه نیست، بلکه نشانه کاهش تازگی خرید برای مشتریانی است که سابقه ارزشمندتری دارند. به همین ترتیب، مشتری غیرفعال با مشتری ازدست‌رفته یکسان تلقی نمی‌شود. نخستین گروه ممکن است هنوز با یک مداخله مناسب بازگردد.

قاعده استفاده از راهنما این است که برچسب‌ها برای دسته‌بندی اولیه به کار روند و تصمیم نهایی با داده‌های هزینه، روند زمانی و ظرفیت اقدام تکمیل شود. بدین ترتیب، رنگ‌ها و نام‌های کوتاه داشبورد جای تحلیل را نمی‌گیرند، بلکه آن را سریع‌تر و منظم‌تر می‌کنند.

مزیت این راهنما در یکسان‌سازی زبان تحلیل میان کاربران سامانه است. وقتی همه کاربران معنی عملی یک برچسب را به یک شکل بخوانند، تفسیر نتیجه‌ها و تدوین برنامه پیشنهادی نگهداشت نیز هماهنگ‌تر می‌شود.

۸-۳ تحلیل مدیریتی وضعیت بازار و مسیر تصمیم‌گیری

۸-۳-۱ نقش صفحه اصلی

صفحه اصلی تحلیل بازار در مسیر /analysis/ ، ورودی مدیریتی سامانه است. این صفحه چهار پرسش پایه را پاسخ می‌دهد: چه تعداد ردیف خرید ثبت شده، چند محصول در خریدها دیده شده، چند خانوار در کل سابقه خرید حضور دارند و مجموع مبلغ فروش چقدر است. پاسخ‌ها مقیاس داده را نشان می‌دهند و زمینه ورود به تحلیل‌های تخصصی‌تر را فراهم می‌کنند.

در بالای صفحه یک عنوان و توضیح کوتاه از هدف داشبورد دیده می‌شود. پس از آن، چهار کارت شاخص کلیدی عملکرد قرار دارد. نمایش شاخص‌ها در کارت‌های مستقل باعث می‌شود کاربر بتواند وضعیت کلی را با یک نگاه دریافت کند، اما معنی هر کارت تنها با برچسب و منطق محاسبه آن کامل می‌شود. به همین علت، تغییر درصدی هر شاخص نیز در همان کارت نشان داده می‌شود.

در خواندن این بخش، ابتدا دامنه داده با تعداد ردیف خرید، محصول و خانوار مشخص می‌شود و سپس مبلغ فروش و تغییر دوره‌ای آن بررسی می‌گردد. مراجعه به تحلیل محصول، سبد یا مشتری می‌تواند در پی مشاهده یک تغییر یا بر اساس سؤال مستقل کاربر انجام شود. سامانه استفاده از تحلیل‌های تخصصی را به مشاهده افت در شاخص‌های کلان مشروط نمی‌کند.

۸-۳-۲ شاخص‌های کلیدی و منطق مقایسه

کارت نخست تعداد ردیف‌های تراکنش را نمایش می‌دهد، نه تعداد سبدها. کارت دوم شمار محصولات یکتای حاضر در خریدها و کارت سوم شمار خانوارهای دارای سابقه خرید در کل داده را نشان می‌دهد. عنوان «فعال» در کارت خانوار نباید به معنی خرید اخیر همه این مشتریان تفسیر شود. کارت چهارم نیز مجموع sales_value را به‌عنوان مبلغ فروش ثبت‌شده ارائه می‌کند. این مبلغ، سود یا درآمد پیش‌بینی‌شده نیست.

برای جلوگیری از تفسیر ایستا، هر کارت تغییر همان شاخص را در آخرین ۶۰ روز داده با ۶۰ روز پیش از آن مقایسه می‌کند. بنابراین علامت افزایش یا کاهش، حاصل مقایسه دو دوره هم‌طول و متوالی است، نه مقایسه با یک مقدار دلخواه. اگر مخرج مقایسه مقدار معناداری نداشته باشد، سامانه درصد تغییر را صفر نمایش می‌دهد تا از ایجاد عددهای نامعتبر جلوگیری شود. این شیوه به ویژه زمانی اهمیت دارد که داده برای نخستین بار وارد سامانه شده یا یک بازه خرید بسیار کم‌حجم باشد.

با این حال، افزایش تعداد تراکنش به تنهایی نشانه بهبود عملکرد نیست. ممکن است تعداد ثبت‌های خرید افزایش یابد ولی میانگین ارزش سبد کاهش پیدا کند، یا تعداد خانوارهای فعال افت کند اما خرید مشتریان باقی‌مانده پرارزش‌تر شود. از این رو، چهار شاخص باید در کنار هم خوانده شوند.

۸-۳-۳ مسیرهای دسترسی تحلیلی

پس از کارت‌های شاخص، صفحه اصلی مجموعه‌ای از کارت‌های دسترسی به تحلیل‌های اصلی سامانه را در اختیار کاربر می‌گذارد. این کارت‌ها شامل تحلیل سبد خرید، قوانین انجمنی، بخش‌بندی مشتریان، ماندگاری مشتری، مدیریت داده، اطلاعات مشتری و پیشنهاددهنده محصول هستند. هر کارت علاوه بر عنوان، توضیحی کوتاه و یک عمل مشخص دارد تا نقش مقصد برای کاربر روشن باشد.

این چیدمان از نظر کاربری اهمیت دارد، زیرا تحلیل‌ها همگی برای یک هدف واحد طراحی نشده‌اند. تحلیل سبد خرید و قوانین انجمنی بیشتر برای کشف الگوی هم‌خریدی مناسب‌اند، بخش‌بندی مشتریان برای شناخت گروه‌های رفتاری کاربرد دارد و صفحه ماندگاری برای اولویت‌بندی اقدام نگهداشت. در نتیجه، صفحه اصلی نقش نقشه راه را ایفا می‌کند و کاربر را بر اساس سؤال تحلیلی خود به بخش مناسب هدایت می‌نماید.

۸-۳-٤ قواعد تفسیر شاخص‌های کلان

قاعده اول، مقایسه هم‌زمان چهار شاخص است: افزایش درآمد همراه با افزایش مشتریان و اندازه سبد، نشانه مطلوب‌تری نسبت به رشد صرف تعداد تراکنش دارد. قاعده دوم، بررسی تداوم تغییر در چند دوره است. یک نقطه منفرد در نمودار دلیل کافی برای تصمیم اجرایی نیست. قاعده سوم، ارجاع هر تغییر کلان به یک تحلیل مکمل است تا علت احتمالی در سطح کالا، سبد یا بخش مشتری روشن شود.

۸-۳-۵ نمودار روند بازار

نمودار روند بازار در پیاده‌سازی فعلی، روزهای **۳۵۲** تا **۷۱۱** را در دوازده دوره سی‌روزه خلاصه می‌کند. این بازه در محاسبه نمودار ثابت است و با ورود داده جدید خودبه‌خود جابه‌جا نمی‌شود. حجم ردیف‌های تراکنش، مبلغ فروش و تعداد مشتریان در این دوره‌ها قابل مقایسه‌اند. متغیر دارای عنوان نمایشی «میانگین سبد» در محاسبه فعلی از میانگین مبلغ ردیف تراکنش به دست می‌آید. بنابراین تفسیر دقیق آن «میانگین مبلغ قلم خرید» است، نه میانگین ارزش سبدهای یکتا.

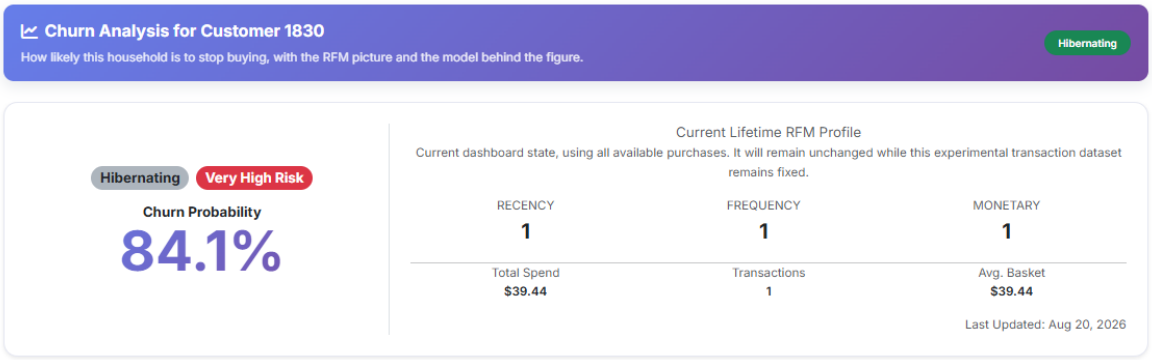
نمودار برای ارائه یک سرنخ مدیریتی طراحی شده است و جای تحلیل علت را نمی‌گیرد. تغییر یک نقطه از روند ممکن است به دلیل مناسبت زمانی، تخفیف، تغییر ترکیب کالاها یا تغییر در ثبت داده باشد. بنابراین کاربر باید پس از مشاهده روند، از مسیرهای دیگر سامانه برای بررسی محصول، سبد یا مشتری استفاده کند.

۸-٤ ارزیابی تفصیلی ریسک ریزش در سطح مشتری

۸-٤-۱ هدف و نقطه ورود

صفحه تحلیل ریزش یک مشتری از مسیر جزئیات مشتری باز می‌شود و شماره مشتری در نشانی صفحه قرار می‌گیرد. بنابراین نمونه‌ای مانند /customers/detail/1830/churn/ به معنای تحلیل شناسه ۱۸۳۰ است و کاربر می‌تواند برای هر مشتری موجود همین مسیر را مشاهده کند. هدف صفحه، پاسخ دادن به این پرسش است که با توجه به رفتار خرید ثبت‌شده، احتمال قطع خرید مشتری در دوره آتی چقدر است و این برآورد در چه زمینه‌ای از رفتار گذشته قرار می‌گیرد.

نمای بالایی صفحه شامل شناسه مشتری، احتمال ریزش و سطح کیفی ریسک است. در این فصل، «احتمال ریزش» برآورد مدل از نبود خرید مشتری در افق ۳۰ روزه آزمایش فعال است. بنابراین نه احتمال ازدست‌رفتن دائمی مشتری است و نه فاصله اطمینان آماری. احتمال کمتر از ۲۵ درصد در سطح کم، از ۲۵ تا کمتر از ۵۰ درصد در سطح متوسط، از ۵۰ تا کمتر از ۷۵ درصد در سطح بالا و از ۷۵ درصد به بالا در سطح بسیار بالا قرار می‌گیرد. بنابراین مقادیر دقیق ۲۵، ۵۰ و ۷۵ درصد به سطح بالاتر تعلق دارند. این مرزهای نمایشی با آستانه طبقه‌بندی هر آزمایش متفاوت‌اند.



شکل ۸-۶ – نمای تحلیل ریزش مشتری ۱۸۳۰ و نمایه فعلی RFM

در شکل ۸-۶، احتمال ریزش مشتری ۱۸۳۰ برابر با ۱/۸۴ درصد و سه امتیاز RFM او برابر با یک است. در کل سابقه، یک سبد به مبلغ ۳۹/۴۴ دلار برای او ثبت شده است. ریسک بسیار بالا در کنار گروه «در حال

غیرفعال‌شدن»، او را به نامزد بررسی تبدیل می‌کند، اما مبلغ خرید کم نشان می‌دهد تصمیم درباره مشوق باید با هزینه اقدام و ارزش قابل بازیابی سنجیده شود.

این نمونه، تفاوت میان «احتمال ریزش» و «اولویت اقتصادی» را روشن می‌سازد. اگر هدف فروشگاه بازگرداندن مشتریان با ارزش بالا باشد، این مشتری ممکن است در رده بررسی قرار گیرد، اما اگر هدف آزمودن یک پیشنهاد کم‌هزینه باشد، می‌تواند در گروه مناسب آزمایش اقدام قرار گیرد.

برای چنین موردی، یک پیشنهاد کم‌هزینه می‌تواند موضوع بررسی مدیر باشد، اما مناسب‌بودن آن از احتمال ریزش به‌تنهایی نتیجه نمی‌شود. سنجش پاسخ واقعی مشتری به پیشنهاد، به اجرای اقدام و ثبت خریدهای بعدی نیاز دارد. این آزمایش عملی در داده ثابت فعلی انجام نشده است.

قاعده ارزیابی موردی این است که ابتدا احتمال ریزش خوانده شود، سپس وضعیت تازگی خرید، تکرار و ارزش مشتری با آن تطبیق داده شود، و در مرحله آخر سابقه زمانی بررسی گردد. برای نمونه، احتمال بسیار بالا همراه با تازگی خرید ضعیف و بخش «در حال غیرفعال‌شدن» شواهد همسو ایجاد می‌کند، اما احتمال بالا برای مشتری تازه‌وارد یا کم‌سابقه نیازمند احتیاط بیشتر است.

۸-٤-۲ ارتباط ریسک با نمایه RFM

نمایه فعلی RFM، کل سابقه موجود مشتری را خلاصه می‌کند و با RFM هر پنجره تاریخی تفاوت دارد. در کنار سه امتیاز، مبلغ کل خرید، تعداد سبدهای یکتا و میانگین ارزش سبد نمایش داده می‌شود. میانگین سبد این بخش از تقسیم مبلغ کل مشتری بر تعداد سبدهای او به دست می‌آید. در نتیجه، این نما زمینه اقتصادی احتمال ریزش را روشن می‌کند و نباید با ویژگی‌های محدود به پنجره مشاهده اشتباه شود.

برای مثال، مشتری با هزینه کل بالا ولی تازگی خرید ضعیف ممکن است ارزش پیگیری بیشتری نسبت به مشتری کم‌ارزشی داشته باشد که خریدش متوقف شده است. برعکس، مشتری تازه‌وارد با تعداد خرید کم ممکن است به علت کوتاه‌بودن سابقه، ریسک ظاهری بالاتری داشته باشد، در حالی که هنوز برای قضاوت قطعی داده کافی ندارد.

۸-٤-۳ سابقه زمانی مشتری و قواعد آزمایش

هر سطر تاریخچه یک نقطه برش زمانی قابل بررسی است. فراوانی و مبلغ خرید از خریدهای داخل پنجره مشاهده محاسبه می‌شوند، اما تازگی بر اساس آخرین خرید مشتری تا همان نقطه برش تعیین می‌شود، حتی اگر

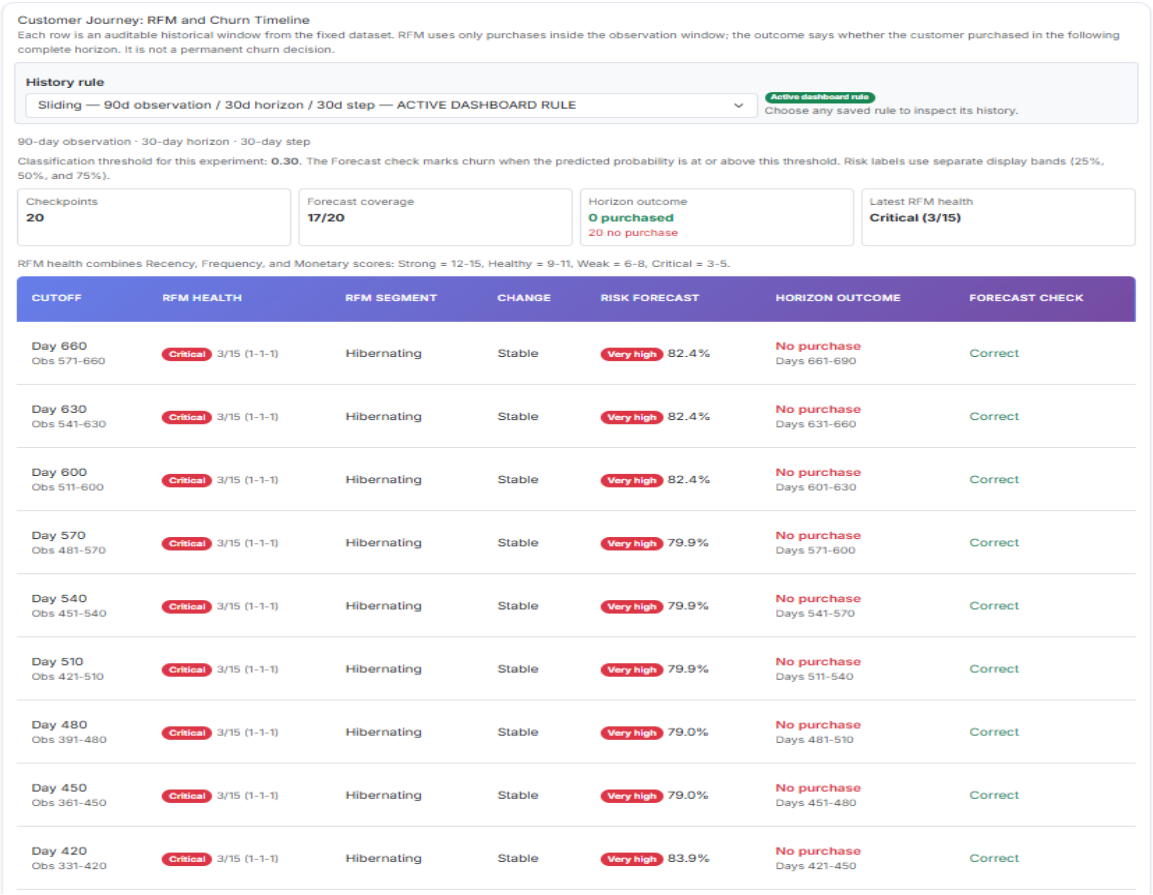
آن خرید پیش از آغاز پنجره بوده باشد. سپس خرید یا نبود خرید در افق پیش‌بینی پس از نقطه برش بررسی می‌گردد. در اینجا ریزش به معنای نداشتن خرید ثبت‌شده در افق کامل است، نه حکم دائمی درباره مشتری.

کاربر می‌تواند تاریخچه یکی از آزمایش‌های ذخیره‌شده را انتخاب کند. روش، طول مشاهده، طول افق و گام، قاعده هر آزمایش را مشخص می‌کنند و از اجرای تکراری یک قاعده، جدیدترین مورد در فهرست دیده می‌شود. انتخاب قاعده تاریخچه فقط نمای همین صفحه را تغییر می‌دهد و آزمایش فعال داشبورد یا فهرست ماندگاری را عوض نمی‌کند. علامت مدل فعال نیز برای تشخیص این تفاوت نمایش داده می‌شود.

سامانه اطلاعات هر آزمایش، پنجره‌های زمانی ساخته‌شده از سابقه خرید، شاخص‌های رفتاری هر مشتری و پیش‌بینی متناظر با آن را نگه می‌دارد. به این ترتیب، کاربر می‌تواند در هر نقطه برش، وضعیت رفتاری و نتیجه پیش‌بینی را در کنار نتیجه واقعی افق بررسی کند.

اطلاعات مدل فعال جدا از تاریخچه پنجره‌ها نگهداری می‌شود تا احتمال‌های داشبورد و فهرست ماندگاری با قواعد همان آزمایش هماهنگ بمانند. ساختارهای قدیمی فقط برای نمایش نتایج آزمایش‌های پیشین باقی مانده‌اند و در محاسبه آزمایش‌های جدید نقشی ندارند. انتخاب یک آزمایش یا تاریخچه ذخیره‌شده، خریدهای پایه را تغییر نمی‌دهد و فقط داده‌های منتخب برای نمایش را عوض می‌کند.

بالای جدول، تعداد نقاط بررسی، تعداد نقاط دارای پیش‌بینی، نتیجه خرید در افق‌ها و آخرین سلامت RFM نشان داده می‌شود. سلامت از جمع سه امتیاز به دست می‌آید: ۱۲ تا ۱۵ قوی، ۹ تا ۱۱ سالم، ۶ تا ۸ ضعیف و ۳ تا ۵ بحرانی. در نمونه مشتری ۱۸۳۰، ۲۰ نقطه بررسی، ۱۷ پیش‌بینی و ۲۰ افق بدون خرید ثبت شده است. نسبت ۱۷ از ۲۰ فقط پوشش زمانی پیش‌بینی را نشان می‌دهد و به معنی صحت ۸۵ درصدی مدل برای این مشتری نیست. عدد ۲۰ افق بدون خرید نیز نتیجه واقعی ثبت‌شده در افق‌های کامل است. نبود پیش‌بینی در سه نقطه نخست ناشی از کافی‌نبودن تاریخچه آموزش قبلی است و نباید ریسک کم تلقی شود.



Customer Journey: RFM and Churn Timeline

Each row is an auditable historical window from the fixed dataset. RFM uses only purchases inside the observation window; the outcome says whether the customer purchased in the following complete horizon. It is not a permanent churn decision.

History rule

Sliding — 90d observation / 30d horizon / 30d step — ACTIVE DASHBOARD RULE

Active dashboard rule

Choose any saved rule to inspect its history.

90-day observation · 30-day horizon · 30-day step

Classification threshold for this experiment: **0.30**. The Forecast check marks churn when the predicted probability is at or above this threshold. Risk labels use separate display bands (25%, 50%, and 75%).

Checkpoints	Forecast coverage	Horizon outcome	Latest RFM health
20	17/20	0 purchased 20 no purchase	Critical (3/15)

RFM health combines Recency, Frequency, and Monetary scores: Strong = 12-15, Healthy = 9-11, Weak = 6-8, Critical = 3-5.

CUTOFF	RFM HEALTH	RFM SEGMENT	CHANGE	RISK FORECAST	HORIZON OUTCOME	FORECAST CHECK
Day 660 Obs 571-660	Critical 3/15 (1-1-1)	Hibernating	Stable	Very high 82.4%	No purchase Days 661-690	Correct
Day 630 Obs 541-630	Critical 3/15 (1-1-1)	Hibernating	Stable	Very high 82.4%	No purchase Days 631-660	Correct
Day 600 Obs 511-600	Critical 3/15 (1-1-1)	Hibernating	Stable	Very high 82.4%	No purchase Days 601-630	Correct
Day 570 Obs 481-570	Critical 3/15 (1-1-1)	Hibernating	Stable	Very high 79.9%	No purchase Days 571-600	Correct
Day 540 Obs 451-540	Critical 3/15 (1-1-1)	Hibernating	Stable	Very high 79.9%	No purchase Days 541-570	Correct
Day 510 Obs 421-510	Critical 3/15 (1-1-1)	Hibernating	Stable	Very high 79.9%	No purchase Days 511-540	Correct
Day 480 Obs 391-480	Critical 3/15 (1-1-1)	Hibernating	Stable	Very high 79.0%	No purchase Days 481-510	Correct
Day 450 Obs 361-450	Critical 3/15 (1-1-1)	Hibernating	Stable	Very high 79.0%	No purchase Days 451-480	Correct
Day 420 Obs 331-420	Critical 3/15 (1-1-1)	Hibernating	Stable	Very high 83.9%	No purchase Days 421-450	Correct

شکل ۸-۷ – مسیر زمانی RFM و ریزش مشتری ۱۸۳۰

شکل ۸-۷ وضعیت مشتری ۱۸۳۰ را در چند نقطه زمانی نشان می‌دهد. پیش‌بینی‌های تاریخچه با آموزش بر برش‌های قبلی و حفظ ترتیب زمانی تولید می‌شوند، نه با استفاده از نتیجه آینده همان سطر. تکرار وضعیت بحرانی و نبود خرید در افق‌ها، توصیف تداوم کاهش فعالیت است. برای قضاوت درباره کیفیت مدل باید نتیجه‌های درست و نادرست همه نمونه‌های آزمون نیز بررسی شوند.

قاعده تحلیل تاریخچه آن است که تنها به آخرین سطر جدول اکتفا نشود. بررسی جهت تغییر سلامت RFM، زمان آخرین خرید و نتیجه واقعی هر افق کمک می‌کند تشخیص داده شود که کاهش رفتار مشتری پایدار بوده است یا صرفاً یک نوسان کوتاه‌مدت در داده محسوب می‌شود.

برش‌های متوالی ممکن است در بخشی از سابقه مشاهده هم‌پوشانی داشته باشند. بنابراین هشدارهای تکراری را نباید چند مشاهده کاملاً مستقل دانست. ارزش تاریخچه در نشان‌دادن تداوم یا تغییر رفتار مشتری است، نه افزایش ظاهری قطعیت مدل بر اثر تکرار هشدارهای مشابه.

۸-٤-٤ تفسیر جدول تاریخچه

هر ردیف جدول شامل نقطه برش زمانی، وضعیت سلامت RFM، بخش RFM، تغییر نسبت به نقطه قبلی، پیش‌بینی ریسک، نتیجه واقعی در افق و کنترل درستی پیش‌بینی است. در ستون تغییر، اگر مجموع سلامت RFM حداقل دو امتیاز نسبت به نقطه قبلی افزایش یا کاهش یابد، وضعیت بهبود یا بدترشدن نمایش داده می‌شود. تغییرهای کوچک‌تر در گروه پایدار قرار می‌گیرند.

ستون نتیجه افق، وجود یا نبود خرید در بازه بعدی را نشان می‌دهد. کنترل پیش‌بینی، احتمال را با آستانه همان آزمایش انتخاب‌شده مقایسه می‌کند. در مدل فعال این آستانه ۰/۳۰ است. در صورت رسیدن احتمال به آستانه یا عبور از آن، برچسب ریزش در نظر گرفته می‌شود و سپس با نتیجه واقعی مقایسه می‌گردد. عبارت «درست» در هر سطر فقط تطابق همین برچسب ریزش یا نبود ریزش با نتیجه آن افق را نشان می‌دهد و معیار کلی کیفیت مدل نیست. این کنترل برای سطر فاقد پیش‌بینی انجام نمی‌شود و جای معیارهای کلی آزمون را نمی‌گیرد.

۸-٤-۵ قواعد کنترل کیفیت تصمیم فردی

پیش از اقدام، بررسی همسویی ریسک با نمایه RFM، مرور تاریخچه و سنجش هزینه اقدام نسبت به ارزش مشتری توصیه می‌شود. اگر شواهد کافی نباشد، تصمیم می‌تواند به بررسی بیشتر موکول شود. این توصیه، قاعده تصمیم‌گیری کاربر است. وضعیت مستقلی با عنوان «نیازمند بررسی» یا گردش کار تأیید اقدام در این صفحه پیاده‌سازی نشده است.

۸-٤-٦ ملاحظات تفسیری صفحه ریزش

احتمال ریزش پیش‌بینی آینده است، نه اثبات اینکه مشتری حتماً خرید را قطع خواهد کرد. به همین دلیل، نباید تنها بر مبنای رنگ یا برچسب ریسک، اقدام پرهزینه‌ای برای همه مشتریان انجام شود. تصمیم مناسب به ارزش مشتری، نوع بخش RFM، هزینه مشوق و ظرفیت عملیاتی فروشگاه نیز وابسته است. این صفحه به کاربر کمک می‌کند نامزدهای پیگیری را با شواهد بیشتری ارزیابی کند، نه اینکه جایگزین قضاوت کسب‌وکار شود.

در صورت ثابت‌بودن داده و قواعد RFM، نمایه کلی مشتری ثابت می‌ماند. بااین‌حال، تغییر آزمایش، روش آموزش یا قاعده زمانی می‌تواند احتمال‌ها و تاریخچه منتخب را تغییر دهد. بنابراین تغییر نتیجه مدل،

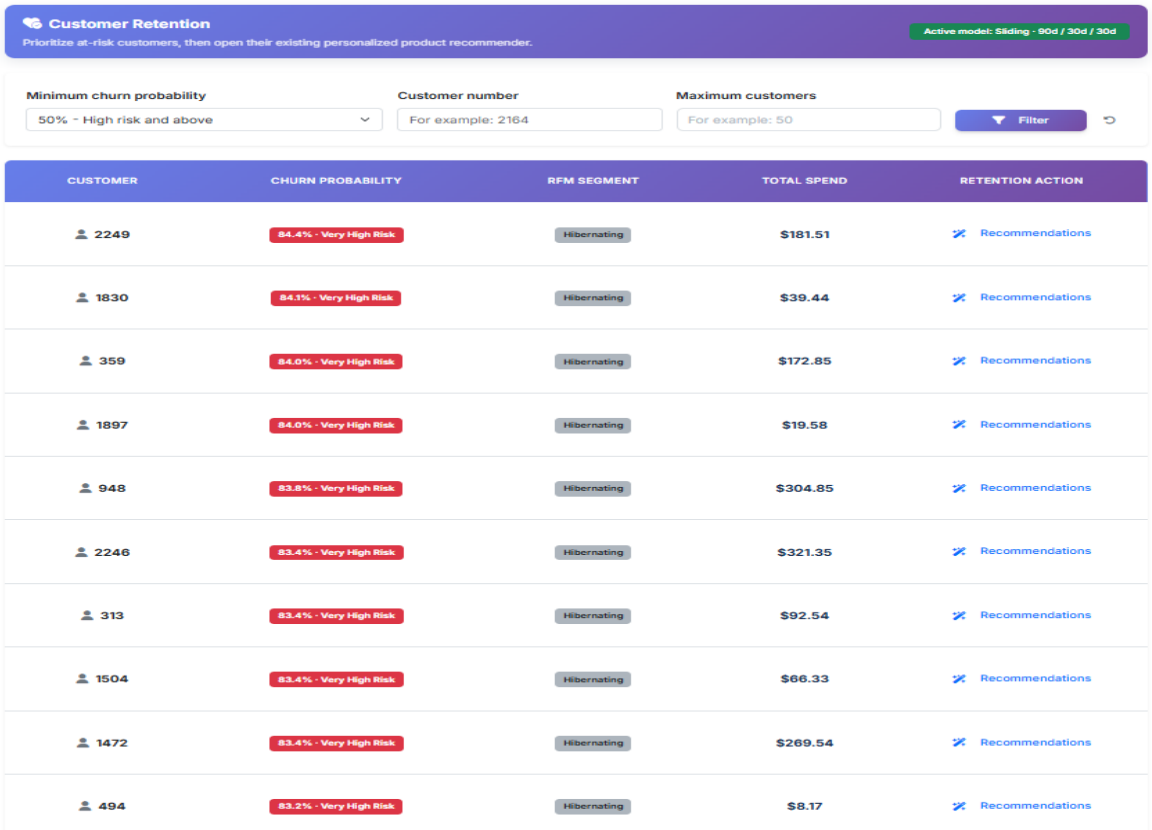
بدون ثبت خرید تازه، دلیل تغییر واقعی رفتار مشتری نیست و مقایسه‌ها باید با توجه به تنظیم آزمایش انجام شوند.

۸-۵ اولویت‌بندی مداخله‌های ماندگاری مشتری

۸-۵-۱ هدف عملیاتی صفحه

صفحه ماندگاری مشتری، خروجی مدل را به فهرستی برای پیگیری مشتریان تبدیل می‌کند. در حالی که صفحه ریزش برای بررسی یک مشتری مناسب است، صفحه ماندگاری مشتریان را بر اساس احتمال ریزش مرتب می‌کند تا کاربر ابتدا مهم‌ترین موارد را ببیند. بنابراین این صفحه برای اولویت‌بندی فعالیت‌های نگهداشت به کار می‌رود.

در نوار بالای صفحه، قاعده فعال مدل نمایش داده می‌شود، یعنی روش ساخت تاریخچه و طول دوره مشاهده، افق پیش‌بینی و گام آن مشخص است. این شفافیت ضروری است، زیرا معنای یک احتمال ریزش بدون دانستن بازه زمانی آن کامل نیست. اگر هنوز هیچ آزمایشی آموزش و فعال نشده باشد، صفحه پیام راهنما نشان می‌دهد و کاربر را به بخش‌بندی مشتریان هدایت می‌کند تا ابتدا مدل مورد نیاز آماده شود.



شکل ۸-۸ – فهرست اولویت‌های ماندگاری مشتری بر اساس ریسک ریزش

شکل ۸-۸ فهرست اقدام را از یک گزارش صرف به یک ابزار انتخاب تبدیل می‌کند. ترکیب احتمال ریزش، بخش RFM و مبلغ کل خرید در یک ردیف، به کاربر اجازه می‌دهد پیش از مراجعه به جزئیات هر مشتری، تصویری اولیه از فوریت و ارزش داشته باشد. پیوند پیشنهادها نیز مرحله بعدی تصمیم را در دسترس قرار می‌دهد تا شناسایی مشتری در معرض خطر به اقدام قابل اجرا متصل شود.

قواعد مرتب‌سازی جدول روشن است: ابتدا مشتریان با احتمال ریزش بالاتر دیده می‌شوند و در احتمال‌های برابر، مشتری با مبلغ کل خرید بیشتر جلوتر قرار می‌گیرد. این ترتیب مرور فهرست را سریع‌تر می‌کند. بااین‌حال، کاربر می‌تواند با فیلترها و مراجعه به تحلیل فردی، اولویت را متناسب با هدف برنامه نگهداشت اصلاح کند.

سه حداقل ریسک موجود در رابط کاربری ۲۵، ۵۰ و ۷۵ درصد هستند. مقدار پیش‌فرض ۵۰ درصد، مشتریان با ریسک بالا و بسیار بالا را نشان می‌دهد. در داده جاری، پیش از اعمال محدودیت تعداد و صفحه‌بندی، ۳۳۷ مشتری معادل ۱۳/۵٪ کل مشتریان در این دامنه قرار می‌گیرند. انتخاب ۷۵ درصد فهرست را محدودتر می‌کند و انتخاب ۲۵ درصد مشتریان با ریسک متوسط را نیز دربر می‌گیرد. تغییر این فیلتر فقط دامنه فهرست قابل بررسی را عوض می‌کند و موجب آموزش دوباره مدل یا تغییر احتمال‌های محاسبه‌شده نمی‌شود. آستانه ۰/۳۰ مدل، گزینه این فیلتر نیست و برای ارزیابی طبقه‌بندی به کار می‌رود.

۸-۵-۲ فیلترها و اولویت‌بندی

پس از تعیین حداقل ریسک، کاربر می‌تواند شماره مشتری را با شناسه دقیق جست‌وجو کند و حداکثر تعداد مشتریان قابل نمایش را مشخص سازد. این محدودیت پس از فیلتر و مرتب‌سازی اعمال می‌شود. بنابراین به بالاترین موارد فهرست مرتب‌شده تعلق دارد، نه به انتخابی تصادفی از مشتریان.

مرتب‌سازی پیش‌فرض ابتدا بر اساس احتمال ریزش از بیشترین به کمترین و سپس، در احتمال برابر، بر اساس مبلغ خرید بیشتر است. این ترتیب، فوریت و سابقه ارزش خرید را در مرور فهرست ترکیب می‌کند. بااین‌حال، مبلغ خرید گذشته برآورد مستقیم سود آینده یا زیان قطعی ناشی از ریزش نیست و تصمیم اقتصادی به اطلاعات بیشتری نیاز دارد.

نتایج در صفحه‌های بیست‌تایی نمایش داده می‌شوند تا فهرست‌های بزرگ خوانا بمانند و کاربر بتواند میان گروه‌های مختلف مشتری حرکت کند.

۸-۵-۳ اجزای جدول ماندگاری

هر ردیف شامل شماره مشتری، احتمال و سطح ریسک، بخش RFM، مبلغ کل خرید و پیوند پیشنهاد محصول است. رنگ و برچسب، تشخیص سطح ریسک را آسان می‌کنند. گروه رفتاری نیز جداگانه نمایش داده می‌شود. برای مثال، مشتری می‌تواند وفادار، نیازمند توجه، در معرض خطر یا در حال غیرفعال‌شدن باشد. گروه RFM و سطح ریسک دو خروجی متفاوت‌اند و یکی جای دیگری را نمی‌گیرد.

ستون مبلغ کل خرید، بعد ارزشی تصمیم را وارد می‌کند. ممکن است دو مشتری احتمال ریزش مشابهی داشته باشند، اما مشتری با ارزش خرید بالاتر در اولویت برنامه نگهداشت قرار گیرد. البته این موضوع یک قانون قطعی نیست. هزینه ارائه مشوق، حاشیه سود کالاها و امکان بازگرداندن مشتری نیز باید در تصمیم نهایی لحاظ شود.

در هر ردیف، شماره مشتری پیوندی به صفحه جزئیات او است و دکمه پیشنهادها، کاربر را به پیشنهاددهنده محصول همان مشتری می‌رساند. این پیوند از نظر مفهومی مهم است: پس از شناسایی مشتری در معرض ریزش، سامانه به جای ارائه یک فهرست بدون اقدام، امکان مشاهده پیشنهادهای شخصی‌سازی‌شده را فراهم می‌کند.

۸-۵-٤ قاعده ثبت و بازبینی اقدام

ثبت شناسه مشتری، زمان تحلیل، تنظیم مدل، اقدام انجام‌شده و نتیجه بعدی برای ارزیابی یک برنامه نگهداشت مفید است. بااین‌حال، سامانه فعلی فقط اولویت‌بندی و دسترسی به پیشنهاد محصول را فراهم می‌کند و تماس با مشتری، ارسال خودکار مشوق یا ثبت نتیجه مداخله در این بخش پیاده‌سازی نشده است. چنین ثبت و ارزیابی‌ای باید خارج از این صفحه انجام شود یا در توسعه بعدی به سامانه افزوده شود.

۸-٦ یکپارچگی جریان تصمیم و قواعد اجرایی

بخش‌بندی، تحلیل فردی و ماندگاری از شناسه مشترک خانوار و سابقه خرید استفاده می‌کنند. بخش‌بندی نمای جمعی را می‌سازد، تاریخچه همان مشتری را در طول زمان بررسی می‌کند و ماندگاری امتیاز جاری مدل فعال را برای اولویت‌بندی به کار می‌برد. اشتراک شناسه‌ها، حرکت میان این نماها را بدون تطبیق دستی مشتری ممکن می‌کند.

یک مسیر پیشنهادی، مشاهده توزیع مشتریان و اعتبار مدل، محدودکردن فهرست ماندگاری، بررسی سابقه فردی و سپس مشاهده پیشنهادهای محصول است. کاربر می‌تواند متناسب با سؤال خود مستقیماً به هر بخش مجاز وارد شود. سامانه ترتیب اجباری برای این گام‌ها تعیین نکرده است.

صفحه اصلی از طریق کارت بخش‌بندی به //analysis/customer-segments و از طریق کارت ماندگاری به //analysis/customer-retention راه می‌دهد. در فهرست مشتریان، پیوند جزئیات امکان بررسی فردی را فراهم می‌کند و پیوند پیشنهادها، پیشنهاددهنده همان مشتری را باز می‌کند. در این ارتباط، نمایش پیشنهاد با اجرای واقعی یک برنامه نگهداشت تفاوت دارد.

صفحه اصلی تحلیل بازار و بخش‌بندی مشتریان به مجوز مدیریتی نیاز دارند. صفحه تحلیل ریزش فردی و فهرست ماندگاری نیز پس از ورود معتبر به سامانه قابل استفاده‌اند. این کنترل دسترسی، نمایش داده رفتاری مشتری را به کاربران مجاز محدود می‌کند.

۸-۷ محدودیت‌ها و نکات کاربردی

نخست، این مرزها فقط برای نمایش سطح ریسک‌اند و مرز قطعی رفتار انسان نیستند. برای مثال، احتمال‌های ۷۴ و ۷۶ درصد با وجود قرارگرفتن در دو گروه، به یکدیگر نزدیک‌اند. در رابط فعلی این مرزها ثابت‌اند و کاربر تنها حداقل ریسک فهرست ماندگاری را انتخاب می‌کند. تغییر مرزهای نمایش با انتخاب آستانه ارزیابی مدل یا فیلتر فهرست یکسان نیست.

دوم، ریزش در این پروژه نبود خرید ثبت‌شده در یک افق معین است و علت آن را مشخص نمی‌کند. تغییر شرایط مشتری، خرید از محل دیگر یا عوامل فروشگاهی در داده به‌طور مستقیم قابل تشخیص نیستند. برای جلوگیری از برچسب‌گذاری نادرست انتهای داده، فقط افق‌های تاریخی کامل وارد ارزیابی می‌شوند. نبود اطلاعات بعد از آخرین روز، خودبه‌خود ریزش محسوب نمی‌شود.

سوم، صفحه اصلی و نمودار روند برای نمایش خلاصه طراحی شده‌اند. فشرده‌سازی داده در سطح دوره‌های زمانی، جزئیات رخدادهای روزانه یا تفاوت فروشگاه‌ها را پنهان می‌کند. در صورت مشاهده تغییر مهم، کاربر باید با استفاده از تحلیل‌های مکمل، علت را در سطح کالا، سبد یا گروه مشتری بررسی کند.

چهارم، معیارهای ارائه‌شده برای مدل فعال، کیفیت آن را در داده‌های آزمایشی توضیح می‌دهند، اما اثربخشی اقتصادی اقدام نگهداشت را ثابت نمی‌کنند. برای سنجش این اثربخشی، لازم است نتیجه اقدام‌های

واقعی – مانند خرید مجدد پس از تماس یا استفاده از پیشنهاد – در دوره‌های بعد ثبت و مقایسه شود. بنابراین، فصل حاضر ابزار انتخاب و اولویت‌بندی ارائه می‌کند، نه تضمین سودآوری هر اقدام.

۸-۸ جمع‌بندی فصل

بخش‌بندی مشتریان، تحلیل فردی ریزش و فهرست ماندگاری، سه نمای مکمل از یک سابقه خرید هستند. نخستین بخش، گروه‌های رفتاری و کیفیت آزمایش را نشان می‌دهد، تحلیل فردی، نمایه کلی و سابقه زمانی مشتری را توضیح می‌دهد و ماندگاری، احتمال‌های مدل فعال را برای اولویت‌بندی به کار می‌برد. صفحه اصلی تحلیل بازار نیز زمینه کلان و مسیر دسترسی به این بخش‌ها را فراهم می‌کند.

کاربر می‌تواند نتیجه مدل را در کنار رفتار و ارزش خرید مشتری بررسی کند، از نمای جمعی به مشتری مشخص برسد و پیشنهادهای محصول را ببیند. بااین‌حال، احتمال ریزش تصمیم قطعی نیست و سامانه اجرای مداخله یا اثربخشی اقتصادی آن را تضمین نمی‌کند.

جمع‌بندی کمی نشان می‌دهد گروه‌های برتر و وفادار با ۲۸/۳ درصد مشتریان، ۵۹/۳ درصد مبلغ خرید را دربر می‌گیرند. از سوی دیگر، ۳۳۷ مشتری، معادل ۱۳/۵ درصد جمعیت، در سطح ریسک بالا یا بسیار بالا قرار دارند. این دو مشاهده، ضرورت بررسی هم‌زمان ارزش خرید و خطر قطع خرید را روشن می‌کند، اما برای تعیین هزینه و نوع اقدام نگهداشت، قضاوت و شواهد اجرایی بیشتری لازم است.

فصل نهم: سامانه‌های پیشنهاددهنده[۱۳۶] و صفحات مرتبط با مشتری

در این فصل بخش‌هایی از سامانه بررسی می‌شوند که از اطلاعات تاریخی خرید برای شناخت بهتر مشتری و ایجاد پیشنهادهای هدفمند استفاده می‌کنند. هدف اصلی، تبدیل داده‌های پراکنده خانوار، سبد خرید و کالا به یک مسیر تصمیم‌گیری روشن است، به‌گونه‌ای که کاربر سامانه بتواند ابتدا مشخصات و سابقه خرید یک مشتری را مشاهده کند و سپس، متناسب با مسئله بازاریابی، از یکی از دو جهت پیشنهاد دریافت نماید: یافتن کالاهای مناسب برای یک مشتری معین، یا یافتن مشتریان مناسب برای یک کالا، گروه کالایی یا دپارتمان معین. این دو جهت مکمل یکدیگرند و به‌ترتیب از دیدگاه مدیریت ارتباط با مشتری و برنامه‌ریزی فروش قابل استفاده هستند.

تأکید این فصل بر منطق مسئله، جریان داده، شیوه تولید و تفسیر خروجی و کاربرد مدیریتی آن است.

۹-۱ جایگاه فصل در معماری سامانه

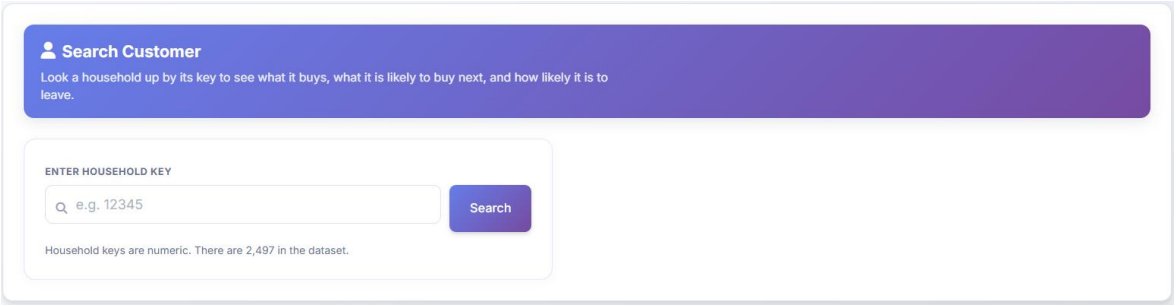
بخش مشتریان نقطه اتصال داده‌های جمعیت‌شناختی و داده‌های تراکنشی است. شناسه خانوار نقش کلید مشترک را دارد و اجازه می‌دهد مشخصات خانوار، سبدهای خرید و خروجی مدل پیشنهاددهنده در یک مسیر واحد نمایش داده شوند. در سوی دیگر، بخش پیشنهاد مشتری برای محصول، نقطه شروع را از مشتری به کالا تغییر می‌دهد. کاربر ابتدا یک هدف تجاری را در سطح محصول، گروه کالایی یا دپارتمان انتخاب می‌کند و سامانه خانوارهایی را که احتمال تناسب بیشتری با آن هدف دارند رتبه‌بندی می‌نماید.

---

[۱۳۶] Recommender Systems

جدول ۹-۱ – صفحات اصلی فصل و نقش هر یک

صفحه	پرسش اصلی	خروجی قابل استفاده
جست‌وجو و پروفایل مشتری	این شناسه متعلق به چه خانواری است؟	مشخصات جمعیت‌شناختی و مسیر دسترسی به تحلیل‌های مشتری
خریدهای مشتری	این خانوار چه چیزهایی، در چه زمان و در چه سبدی خریده است؟	تاریخچه سبدها و اقلام خرید در بازه منتخب
پیشنهاد محصول به مشتری	برای این خانوار چه کالاهایی مناسب‌تر است؟	فهرست رتبه‌بندی‌شده و گروه‌بندی‌شده کالاهای پیشنهادی
پیشنهاد مشتری به محصول	برای این محصول یا دسته، کدام خانوارها مناسب‌ترند؟	فهرست اولویت‌دار مشتریان بالقوه برای اقدام بازاریابی
جزئیات محصول	محصول چه ویژگی، خریدار و الگوی همراهی دارد؟	فراداده محصول، بخش‌های مشتری و قوانین انجمنی مرتبط



شکل ۹-۱ – نمای صفحه جست‌وجوی مشتری بر اساس شناسه خانوار

۹-۲ جست‌وجو و پروفایل مشتری

۹-۲-۱ هدف و شیوه دسترسی

صفحه جست‌وجوی مشتری برای ورود مستقیم از طریق شناسه خانوار طراحی شده است. پس از واردکردن شناسه، سامانه وجود خانوار را بررسی می‌کند و در صورت معتبر بودن، کاربر را به صفحه پروفایل هدایت می‌نماید. در صورت نبود شناسه، پیام روشن نمایش داده می‌شود تا از ادامه مسیر با داده نامعتبر جلوگیری شود. این سازوکار ساده، خطای انتخاب مشتری را کاهش می‌دهد و برای مجموعه‌داده‌ای که نام و اطلاعات هویتی واقعی در آن وجود ندارد مناسب است.

پروفایل مشتری نمای فشرده‌ای از ویژگی‌های جمعیت‌شناختی خانوار است. هدف این صفحه تفسیر قطعی رفتار بر اساس ویژگی‌های فردی نیست، بلکه فراهم‌کردن زمینه‌ای برای درک بهتر سابقه خرید و

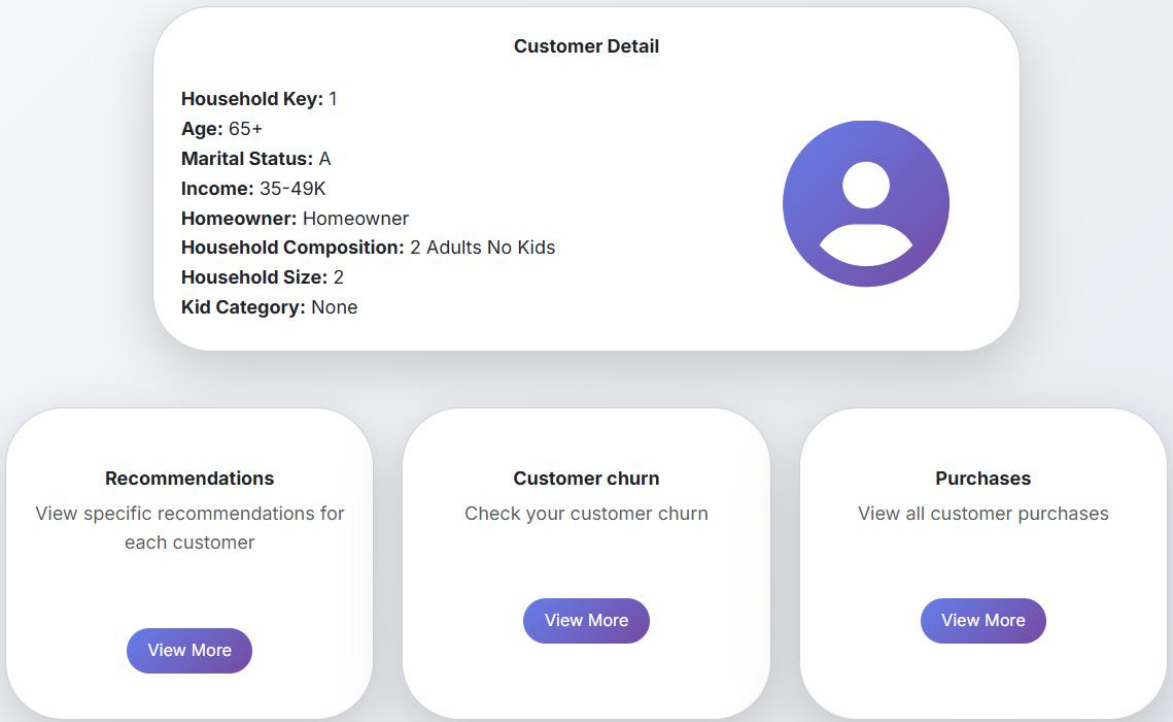
پیشنهادهاست. برای نمونه، اندازه خانوار یا وجود فرزند ممکن است در تفسیر نوع و مقدار خرید مفید باشد، اما نباید به‌تنهایی مبنای تصمیم قرار گیرد. صفحه پروفایل همچنین نقش درگاه دسترسی به خریدها، پیشنهادهای محصول و سایر تحلیل‌های مشتری را ایفا می‌کند.

جدول ۹-۲ - اطلاعات نمایش‌داده‌شده در پروفایل مشتری و کاربرد تفسیری آن‌ها

اطلاعات	معنا	کاربرد در تحلیل
شناسه خانوار	شناسه یکتای مشتری در مجموعه‌داده	اتصال پروفایل، خریدها و پیشنهادها
گروه سنی	بازه سنی ثبت‌شده برای خانوار	ایجاد زمینه برای تفسیر نیاز و الگوی مصرف
وضعیت تأهل	وضعیت خانوادگی ثبت‌شده	تکمیل شناخت ترکیب خانوار
گروه درآمدی	بازه تقریبی درآمد	کمک به تفسیر حساسیت به قیمت و انتخاب کالا
وضعیت مالکیت مسکن	مالک یا مستأجر بودن	ویژگی توصیفی مکمل برای بخش‌بندی
ترکیب و اندازه خانوار	تعداد و ساختار اعضای خانوار	تفسیر حجم سبد و تنوع نیازها
رده فرزند	اطلاعات کلی حضور فرزند	کمک به تفسیر گروه‌های کالایی خانوادگی

۹-۲-۲ ملاحظات تفسیری پروفایل

ویژگی‌های پروفایل باید در کنار رفتار واقعی خرید خوانده شوند. دو خانوار با مشخصات جمعیت‌شناختی مشابه ممکن است سبدهای کاملاً متفاوتی داشته باشند و برعکس، دو خانوار با مشخصات متفاوت ممکن است در یک گروه کالایی رفتار مشابه نشان دهند. به همین دلیل، سامانه از پروفایل به‌عنوان اطلاعات زمینه‌ای استفاده می‌کند و هسته پیشنهادها را بر شواهد تراکنشی بنا می‌گذارد. همچنین مقادیر خالی یا نامشخص نباید به‌صورت یک ویژگی واقعی تفسیر شوند. این موارد تنها نشان‌دهنده نبود اطلاعات کافی‌اند.



شکل ۹-۲ – نمای صفحه پروفایل مشتری و مسیرهای دسترسی به خریدها و پیشنهادها

۹-۳ صفحه خریدهای مشتری

۹-۳-۱ هدف صفحه و سازمان‌دهی اطلاعات

صفحه خریدها تاریخچه تراکنش‌های یک خانوار را از حالت ردیف‌های پراکنده خارج و بر اساس شناسه سبد گروه‌بندی می‌کند. این گروه‌بندی از نظر مفهومی مهم است، زیرا یک مراجعه خرید ممکن است شامل چندین قلم کالا باشد و شمارش هر ردیف به‌عنوان یک خرید مستقل، تصویر نادرستی از رفتار مشتری ایجاد کند. در این صفحه، هر سبد یک واحد مشاهده است و اقلام آن همراه با روز خرید، زمان تراکنش، تعداد، مبلغ فروش و ویژگی‌های محصول نمایش داده می‌شوند.

کاربر می‌تواند بازه زمانی را انتخاب کند و سبدهای جدیدتر را در ابتدای فهرست ببیند. نتایج به‌صورت صفحه‌بندی‌شده ارائه می‌شوند تا حجم زیاد تاریخچه موجب کندی و دشواری مطالعه نشود. شمار سبدهای موجود در بازه نیز به‌عنوان یک خلاصه سریع نمایش داده می‌شود. این عدد با تعداد ردیف‌های تراکنش متفاوت است و باید دقیقاً با عنوان «تعداد سبد» تفسیر شود.

بازه‌های زمانی قابل انتخاب، سه، شش، نه، دوازده، پانزده و هجده ماه گذشته و نیز کل دوره داده را پوشش می‌دهند. ساعت تراکنش در داده اولیه به شکل عددی فشرده ثبت شده است. برای نمونه مقدار ۱۶۳۱

به ساعت ۱۶:۳۱ تبدیل می‌شود تا زمان خرید برای کاربر خوانا باشد. در نمای اصلی هر سبد، اطلاعات خلاصه نمایش داده می‌شود و با انتخاب آن، جزئیات همه اقلام شامل برند، دپارتمان، گروه کالایی، اندازه محصول، تعداد و مبلغ فروش در یک پنجره جداگانه قابل مشاهده است. این تفکیک باعث می‌شود صفحه در حالت عادی فشرده باقی بماند و جزئیات تنها در زمان نیاز در اختیار کاربر قرار گیرد.

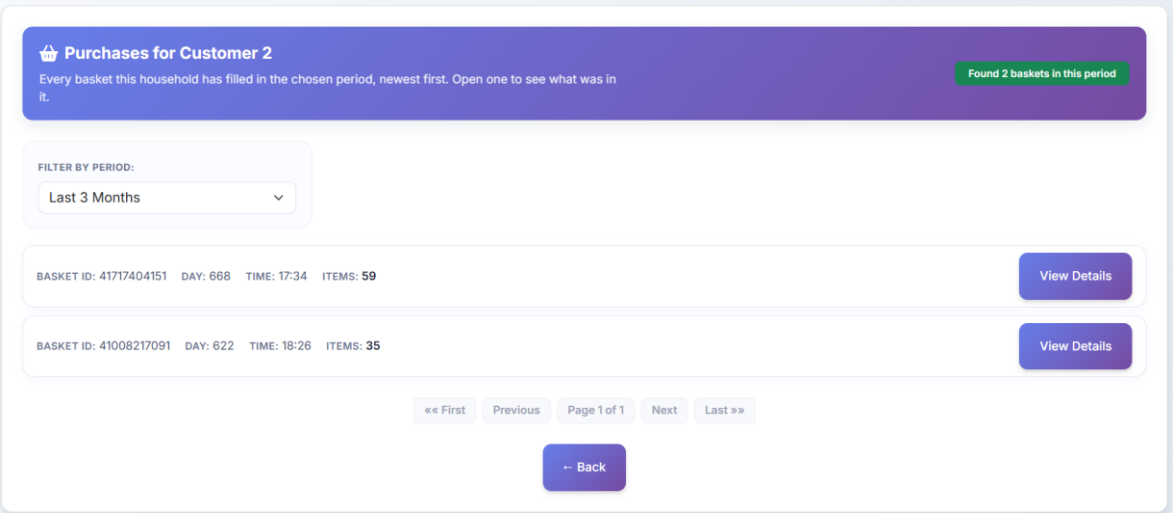
جدول ۹-۳ - اجزای صفحه خریدهای مشتری و هدف هر جزء

جزء	شرح	فایده
فیلتر دوره	محدودکردن مشاهده به بازه زمانی منتخب	مقایسه رفتار اخیر با تاریخچه بلندمدت
شناسه سبد	گروه‌بندی اقلام یک مراجعه	جلوگیری از اشتباه گرفتن ردیف کالا با دفعات خرید
روز و زمان	زمان ثبت تراکنش	بررسی تازگی، توالی و الگوی زمانی خرید
تعداد و مبلغ فروش	حجم و ارزش هر قلم	شناخت اندازه و ارزش اقتصادی سبد
برند، دپارتمان و گروه کالایی	ویژگی‌های توصیفی محصول	تشخیص علاقه‌ها و تنوع سبد
صفحه‌بندی	نمایش ده سبد در هر صفحه	حفظ خوانایی و کنترل هزینه بارگذاری

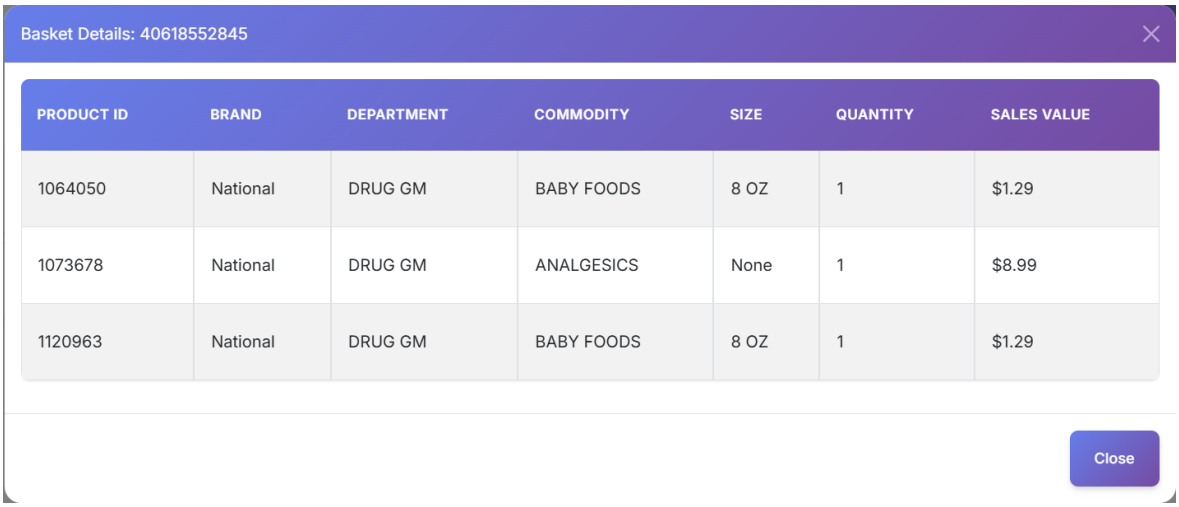
۹-۳-۲ کاربرد تحلیلی تاریخچه خرید

تاریخچه خرید هم برای کاربر و هم برای پیشنهاددهنده اهمیت دارد. کاربر از آن برای کنترل منطقی‌بودن پیشنهادها استفاده می‌کند. برای مثال، اگر بیشتر خریدهای اخیر مشتری متعلق به یک گروه کالایی خاص باشد، حضور چند پیشنهاد مرتبط با همان گروه قابل انتظار است. سامانه نیز از همین تاریخچه برای محاسبه تکرار خرید، آخرین زمان خرید یک گروه، علاقه نسبی به گروه‌های کالایی و تشخیص برند غالب استفاده می‌کند. بنابراین صفحه خریدها تنها یک گزارش آرشیوی نیست، بلکه شواهدی را نشان می‌دهد که نتیجه مدل بر پایه آن شکل گرفته است.

در تفسیر خریدها باید اثر تخفیف، موجودی فروشگاه، فصل و طول دوره مشاهده را در نظر گرفت. مشاهده یک محصول در سبد لزوماً به معنای علاقه پایدار نیست و نبود آن نیز لزوماً بی‌علاقگی را اثبات نمی‌کند. تکرار الگو در چند سبد و چند بازه زمانی، شواهد معتبرتری نسبت به یک خرید منفرد فراهم می‌آورد.



شکل ۹-۳ – نمای صفحه خریدهای مشتری، فیلتر زمانی و گروه‌بندی اقلام بر اساس سبد



شکل ۹-۴ - نمای جزئیات اقلام سبد خرید منتخب

۹-٤ پیشنهاد محصول به مشتری

۹-٤-۱ تعریف مسئله و رویکرد ترکیبی

در این جهت از پیشنهاددهی، ورودی سامانه شناسه یک خانوار و خروجی آن فهرستی از کالاهایی است که احتمال تناسب یا خرید آن‌ها برای همان خانوار بیشتر ارزیابی می‌شود. مسئله صرفاً یافتن پرفروش‌ترین کالاها نیست، زیرا فهرست عمومی محبوبیت برای همه مشتریان تقریباً یکسان خواهد بود. هدف آن است که هم الگوی اختصاصی خانوار و هم الگوهای کلی بازار در نظر گرفته شوند. برای دستیابی به این هدف، سامانه از یک رویکرد ترکیبی شامل قوانین انجمنی[۱۳۷]، پالایش مشارکتی، ویژگی‌های محتوایی و مدل یادگیری ماشین استفاده می‌کند.

معماری پیشنهاددهنده از دو مرحله مستقل تشکیل شده است. در مرحله نخست، منابع مختلف تنها وظیفه دارند مجموعه‌ای محدود اما متنوع از کالاهای محتمل را از میان ده‌ها هزار محصول ایجاد کنند. در مرحله دوم، مدل آموزش‌دیده همین نامزدها را با یک معیار مشترک رتبه‌بندی می‌کند. این جداسازی نسبت به ترکیب دستی امتیاز قوانین انجمنی و پالایش مشارکتی با یک وزن ثابت، انعطاف بیشتری دارد، زیرا مدل می‌تواند اهمیت هر نشانه و اثر متقابل آن با تازگی خرید، محبوبیت و سابقه شخصی مشتری را از داده بیاموزد.

قوانین انجمنی نشان می‌دهند چه کالاها یا دسته‌هایی معمولاً همراه یکدیگر خریداری می‌شوند. پالایش مشارکتی[۱۳۸]، خانوارهایی با الگوی خرید مشابه را پیدا می‌کند و کالاهایی را که همسایگان مشابه خریده‌اند به‌عنوان نامزد در نظر می‌گیرد. ویژگی‌های محتوایی، ارتباط نامزد با گروه کالایی و برندهای موجود در سابقه همان خانوار را منعکس می‌کنند. در نهایت، مدل یادگیری ماشین این شواهد را همراه با محبوبیت و فاصله زمانی خرید ترکیب می‌کند تا احتمال خرید آینده را برآورد نماید.

۹-٤-۲ تولید مجموعه نامزدها

پیشنهاددهنده ابتدا دامنه‌ای از کالاهای ممکن را تولید می‌کند. این مرحله اهمیت زیادی دارد، زیرا مدل رتبه‌بندی[۱۳۹] تنها می‌تواند میان نامزدهایی انتخاب کند که از قبل وارد دامنه شده‌اند. نامزدها در سه سطح محصول، گروه کالایی و دپارتمان گردآوری می‌شوند. استفاده از چند سطح باعث می‌شود سامانه هم روابط

---

[۱۳۷] Association Rules

[۱۳۸] Collaborative Filtering

[۱۳۹] Ranking Model

دقیق میان کالاهای مشخص را ببیند و هم در شرایطی که داده سطح محصول کم است، از روابط کلی‌تر گروه‌ها و دپارتمان‌ها استفاده کند.

جدول ۹-۴ - منابع تولید نامزد در پیشنهاد محصول به مشتری

منبع	منطق	نقش در تنوع پیشنهاد
قوانین انجمنی	انتخاب پیامد قوانینی که مقدمه آن‌ها در سابقه مشتری دیده شده است	کشف کالاهای مکمل و همراه
پالایش مشارکتی	استفاده از خرید خانوارهای دارای الگوی مشابه	کشف ترجیحات مشترک فراتر از اقلام فعلی
سطح گروه کالایی	انتقال الگو از نام گروه به یک محصول نماینده	کاهش مشکل پراکندگی داده در سطح محصول
سطح دپارتمان	استفاده از روابط کلی‌تر میان بخش‌های فروشگاه	گسترش دامنه در نبود شواهد جزئی
کاوش برند جایگزین	پیشنهاد محدود برند دیگر در گروهی با وفاداری بسیار بالا	ایجاد فرصت کنترل‌شده برای کشف انتخاب جدید

کالاهایی که خانوار قبلاً خریداری کرده است از پیشنهادهای جدید کنار گذاشته می‌شوند تا خروجی بیشتر بر کشف اقلام تازه متمرکز باشد. در بخش کاوش برند، اگر خانوار یک گروه کالایی را چند بار خریده و سهم یک برند در آن گروه بسیار غالب باشد، تعداد محدودی کالای هم‌گروه از برند دیگر به دامنه افزوده می‌شود. این تصمیم میان بهره‌برداری از علاقه شناخته‌شده و کاوش گزینه‌های تازه تعادل ایجاد می‌کند. بااین‌حال، سهم آن محدود نگه داشته می‌شود تا ارتباط خروجی با رفتار واقعی مشتری از بین نرود.

ورود نامزد کاوش برند به یک شرط رفتاری مشخص وابسته است: خانوار باید یک گروه کالایی را دست‌کم سه بار خریده باشد و سهم برند غالب از خریدهای آن گروه حداقل ۸۰ درصد باشد. در این وضعیت، تعداد بسیار محدودی محصول از برندی دیگر در همان گروه افزوده می‌شود. این آستانه مانع آن است که یک خرید اتفاقی به‌اشتباه وفاداری به برند تلقی شود و در عین حال امکان آزمودن گزینه‌ای تازه را بدون برهم‌زدن جهت کلی شخصی‌سازی فراهم می‌کند.

۹-٤-۳ پالایش مشارکتی و شباهت خانوارها

برای سنجش شباهت، سابقه خرید به یک ماتریس خانوار–محصول[۱۴۰] تبدیل می‌شود. سطرها خانوارها، ستون‌ها کالاها و مقدار هر خانه نشان‌دهنده دفعات مشاهده خرید است. سپس شباهت کسینوسی میان سطرها

---

[۱۴۰] Household–Product Matrix

محاسبه می‌شود. این معیار جهت الگوی خرید را مقایسه می‌کند و نسبت به تفاوت اندازه مطلق سبدها حساسیت کمتری دارد. برای هر خانوار، همسایگان دارای شباهت مثبت انتخاب می‌شوند و امتیاز یک نامزد از مجموع خرید همسایگان، وزن‌خورده با میزان شباهت، به دست می‌آید {۸}.

ساخت این ماتریس و محاسبه شباهت روی میلیون‌ها رکورد هزینه‌بر است. ازاین‌رو نتیجه یک‌بار از داده تراکنش ساخته و در حافظه میانی ذخیره می‌شود. درخواست‌های بعدی به‌جای تکرار محاسبه کامل، از نسخه ذخیره‌شده استفاده می‌کنند. اگر این نسخه موجود نباشد، سامانه می‌تواند به مسیر محاسبه مستقیم بازگردد، اما برای بهره‌برداری معمول، به‌روزرسانی دوره‌ای حافظه میانی ضروری است.

در اجرای بررسی‌شده پروژه، ماتریس و شباهت‌های ذخیره‌شده از حدود ۲/۶ میلیون رکورد تراکنشی ساخته شده‌اند و فایل حاصل نزدیک به ۱/۸ گیگابایت حجم دارد. این فایل در هر درخواست دوباره خوانده نمی‌شود، بلکه در نخستین استفاده در حافظه قرار می‌گیرد و درخواست‌های بعدی از همان نسخه استفاده می‌کنند. بنابراین دو سطح صرفه‌جویی ایجاد می‌شود: محاسبه شباهت تنها هنگام بازسازی دوره‌ای انجام می‌گیرد و بارگذاری فایل نیز در طول اجرای برنامه تکرار نمی‌شود.

۹-٤-٤ ویژگی‌های رفتاری و مدل رتبه‌بندی

پس از تولید نامزدها، برای هر زوج مشتری–کالا مجموعه‌ای از ویژگی‌ها ساخته می‌شود. این ویژگی‌ها تلاش می‌کنند سه پرسش را پاسخ دهند: آیا شواهدی از ارتباط کالا با خریدهای قبلی وجود دارد؟ آیا کالا یا گروه آن در کل بازار و در میان خانوارهای مشابه معتبر است؟ و آیا از نظر زمان‌بندی، اکنون موقع مناسبی برای پیشنهاد آن به شمار می‌رود؟

در مجموع نه ویژگی برای هر زوج خانوار–کالا ساخته می‌شود. امتیازهای خام قانون انجمنی و پالایش مشارکتی فقط برای ورود کالا به مجموعه نامزدها به کار نمی‌روند، بلکه مستقیماً در اختیار مدل رتبه‌بندی نیز قرار می‌گیرند. در کنار آن‌ها، ارتباط محتوایی، محبوبیت محصول، سابقه خرید محصول و گروه، فاصله از آخرین خرید گروه، چرخه معمول بازخرید و جدیدبودن برند قرار می‌گیرند. به این ترتیب مدل می‌تواند میان «وجود یک نشانه» و «قدرت آن نشانه» تمایز قائل شود.

جدول ۹-۵ - ویژگی‌های مفهومی مدل پیشنهاددهنده

گروه ویژگی	نمونه	برداشت
ارتباط انجمنی	امتیاز حاصل از اطمینان و بهبود قانون	شدت همراهی نامزد با اقلام پیشین
شباهت مشارکتی	امتیاز خرید در میان خانوارهای مشابه	پشتیبانی جمعی از نامزد
ارتباط محتوایی	وجود گروه کالایی در سابقه مشتری	نزدیکی نامزد به علایق آشکار
محبوبیت	فروش کل محصول با تبدیل لگاریتمی	پایداری و پذیرش عمومی کالا
تکرار شخصی	دفعات خرید محصول یا گروه توسط خانوار	شدت علاقه قبلی
تازگی	روزهای گذشته از آخرین خرید گروه	تناسب زمانی پیشنهاد
چرخه خرید مجدد	میانه فاصله خریدهای متوالی گروه	برآورد زمان معمول نیاز دوباره
تنوع برند	جدید بودن برند برای خانوار	سنجش میزان کاوش در پیشنهاد

مدل رتبه‌بندی از نوع تقویت گرادیانیبر پایه هیستوگرام است. داده آموزشی به‌صورت زوج‌های مشتری-کالای نامزد ساخته می‌شود و برچسب مثبت زمانی اختصاص می‌یابد که مشتری در افق آینده تعریف‌شده، آن کالا را خریداری کرده باشد. بخشی از داده برای آموزش و بخشی برای آزمون کنار گذاشته می‌شود تا کیفیت مدل روی نمونه‌هایی سنجیده شود که مستقیماً در یادگیری استفاده نشده‌اند. تقویت گرادیانی می‌تواند روابط غیرخطی و اثر متقابل ویژگی‌ها را مدل کند. برای مثال، محبوبیت بالا زمانی مفیدتر است که با علاقه قبلی و زمان مناسب خرید همراه باشد.[۱۴۱]

۹-٤-۵ قواعد تجاری پس از امتیازدهی

امتیاز آماری به‌تنهایی برای تولید پیشنهاد عملی کافی نیست. سامانه پس از رتبه‌بندی چند قاعده تجاری را اعمال می‌کند. نخست، اگر چرخه خرید یک گروه نسبتاً طولانی باشد و مشتری همان گروه را به‌تازگی خریده باشد، پیشنهاد آن موقتاً سرکوب می‌شود، زیرا احتمال نیاز فوری کمتر است. دوم، علاقه مکرر خانوار به گروه کالایی باعث افزایش محدود امتیاز می‌شود. سوم، نامزدهای کاوش برند حداقل امتیازی وابسته به محبوبیت دریافت می‌کنند تا در صورت مناسب‌بودن امکان حضور در فهرست را داشته باشند.

در نسخه فعلی، گروهی با میانه چرخه بازخرید بیش از ده روز در دسته کالاهای دیرمصرف‌تر قرار می‌گیرد و اگر زمان سپری‌شده از خرید اخیر کمتر از چرخه همان گروه باشد، نامزد آن حذف می‌شود. تقویت علاقه شخصی نیز برای هر بار مشاهده خرید در گروه هدف، دو درصد به ضریب امتیاز می‌افزاید و این افزایش

---

[۱۴۱] Gradient Boosting

حداکثر تا ده مشاهده ادامه دارد. بنابراین بیشترین تقویت از این مسیر ۲۰ درصد است. محدودکردن این افزایش از غلبه کامل سابقه گذشته بر سایر نشانه‌ها جلوگیری می‌کند.

جدول ۹-۶ - قواعد کنترلی خروجی پیشنهاد محصول

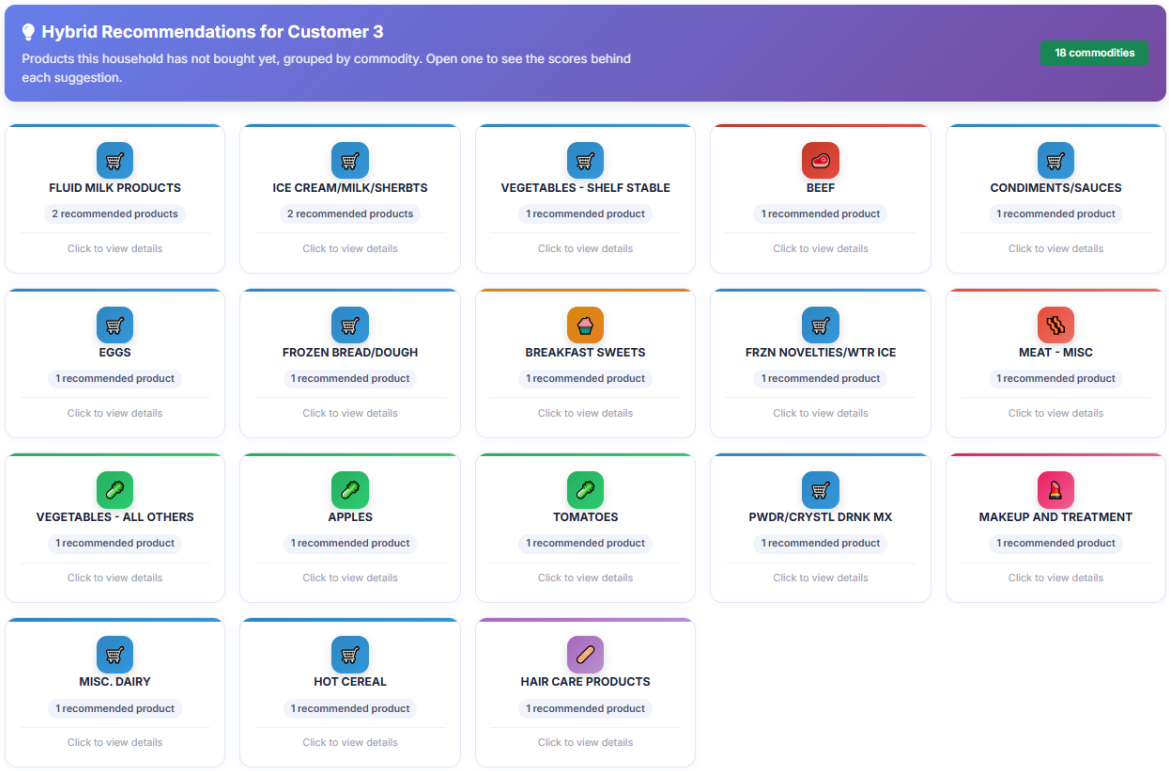
قاعده	هدف	اثر مورد انتظار
حذف خریدهای پیشین از فهرست کالای جدید	تمرکز بر کشف	کاهش پیشنهاد تکراری
سرکوب خرید زودهنگام کالای دیرمصرف	رعایت چرخه مصرف	کاهش پیشنهاد نامتناسب از نظر زمان
تقویت علاقه مکرر به گروه	شخصی‌سازی	ارتقای کالاهای نزدیک به ترجیح پایدار
کاوش محدود برند	افزایش تنوع	جلوگیری از بسته‌شدن کامل دامنه پیشنهاد
محدودکردن فهرست نهایی	خوانایی و قابلیت اقدام	تمرکز کاربر بر بهترین گزینه‌ها

۹-٤-٦ حافظه میانی و نمایش خروجی

نتیجه نهایی هر مشتری همراه با نسخه قوانین انجمنی و زمان آموزش مدل ذخیره می‌شود. اگر کاربر دوباره همان صفحه را باز کند و هیچ‌یک از این دو منبع تغییر نکرده باشد، نتیجه از حافظه میانی بازیابی می‌شود. در صورت آموزش دوباره مدل، تغییر قوانین یا درخواست صریح بازسازی، پیشنهادها مجدداً محاسبه می‌شوند. این راهکار هم زمان پاسخ را کاهش می‌دهد و هم از ارائه خروجی قدیمی پس از تغییر مدل جلوگیری می‌کند.

در صفحه نمایش، کالاها بر اساس گروه کالایی دسته‌بندی می‌شوند و گروه‌های دارای پیشنهاد بیشتر در جایگاه بالاتر قرار می‌گیرند. در کنار مشخصات کالا، اطلاعاتی از منشأ پیشنهاد و امتیازهای مربوط نمایش داده می‌شود تا خروجی تنها یک فهرست مبهم نباشد. بااین‌حال، این امتیازها نسبی‌اند و نباید به‌عنوان احتمال قطعی خرید یا درصد تضمین‌شده تفسیر شوند.

خروجی عملیاتی به بیست پیشنهاد نخست محدود می‌شود. هر کارت، مشخصات اصلی محصول را نشان می‌دهد و نمای جزئیات آن امتیاز مدل، محبوبیت، شواهد انجمنی، امتیاز پالایش مشارکتی و منشأ تولید نامزد را کنار هم قرار می‌دهد. نمایش هم‌زمان این اطلاعات به کاربر امکان می‌دهد تشخیص دهد یک پیشنهاد بیشتر از شباهت مشتریان، همراهی کالاها، علاقه قبلی یا کاوش برند ناشی شده است و در نتیجه کنترل انسانی خروجی آسان‌تر می‌شود.



شکل ۹–۵ – نمای پیشنهادهای محصول برای یک مشتری و گروه‌بندی آن‌ها بر اساس گروه کالایی

BRAND	PRODUCT ID	SIZE	DEPARTMENT	COMMODITY	ML SCORE	POPULARITY	CF SCORE	CONFIDENCE	LIFT	SUPPORT	SOURCE
Private	1029743	1 GA	GROCERY	FLUID MILK PRODUCTS	**0.0278**	9.6897	330.8403849998207	0.619	2.254	0.0381	commodity (rule+cf)
National	1081177	15 LB	PRODUCE	TOMATOES	**0.0223**	8.0965	114.26620272754941	-	-	-	product (cf)
National	31139	N/A	DRUG GM	HAIR CARE PRODUCTS	**0.0222**	0.6931	375.9459095637277	-	-	-	commodity (cf)
National	911388	24 OZ	GROCERY	BAKED BREAD/BUNS/ROLLS	**0.0395**	4.7622	-	0.54	2.345	0.0133	commodity (rule)
National	7168026	56 OZ	GROCERY	ICE CREAM/MILK/SHERBTS	**0.0193**	5.793	-	0.929	1.179	0.1282	department (rule)
Private	459467	1 LB	MEAT	BEEF	**0.0216**	1.0986	-	-	-	-	brand_exploration (brand_exploration)

شکل ۹–۶ – نمونه‌های فهرست پیشنهادی و امتیازهای محصولات منتخب برای مشتری

۹–۵ پیشنهاد مشتری به محصول

۹–۵–۱ تعریف مسئله و سطوح انتخاب

در جهت معکوس، کاربر به‌جای انتخاب مشتری، یک هدف فروش را تعیین می‌کند و سامانه خانوارهای مناسب برای آن هدف را پیشنهاد می‌دهد. هدف می‌تواند یک محصول مشخص، یک گروه کالایی یا یک دپارتمان باشد. سطح محصول برای کمپین‌های دقیق و محدود مناسب است، سطح گروه کالایی دامنه‌ای

همگن‌تر از محصولات مشابه را پوشش می‌دهد و سطح دپارتمان برای برنامه‌ریزی وسیع‌تر به کار می‌رود. صفحه جست‌وجو امکان انتخاب سطح و یافتن مقدار هدف را فراهم می‌کند.

در سطح محصول، به دلیل وجود حدود ۹۲ هزار شناسه کالا، جست‌وجوی متنی راه اصلی انتخاب است. در سطح گروه کالایی و دپارتمان، علاوه بر جست‌وجو، فهرست مقادیر موجود نیز ارائه می‌شود تا کاربر بدون دانستن نام دقیق هدف بتواند آن را انتخاب کند. این تفاوت رابط با اندازه و تنوع فضای جست‌وجو سازگار است و از بارگذاری یک فهرست بسیار بزرگ در سطح محصول جلوگیری می‌کند.

مشتریانی که هدف را قبلاً مستقیماً خریده‌اند، خریدار موجود محسوب می‌شوند و از فهرست مشتریان بالقوه جدید کنار گذاشته می‌شوند. تعداد این خریداران به‌عنوان اطلاعات زمینه‌ای نمایش داده می‌شود. این تفکیک از نظر بازاریابی مهم است، زیرا برنامه جذب مشتری جدید برای یک محصول با برنامه خرید مجدد مشتریان فعلی هدف و پیام متفاوتی دارد.

۹-۵-۲ تولید نامزدهای مشتری

نامزدهای خانوار از چند مسیر ساخته می‌شوند. در سطح محصول، خانوارهایی که محصولات هم‌گروه یا زیرگروه مشابه خریده‌اند، از نظر محتوایی به هدف نزدیک‌اند. در هر سه سطح، قواعد انجمنی خانوارهایی را معرفی می‌کنند که اقلام یا گروه‌های موجود در مقدمه قواعد منتهی به هدف را خریده‌اند. همچنین، خریداران مستقیم هدف به‌عنوان گروه بذر در نظر گرفته می‌شوند و خانوارهای دارای الگوی خرید مشابه با این گروه از طریق ماتریس شباهت مشارکتی استخراج می‌گردند.

جدول ۹-۷ – مسیرهای شناسایی مشتری بالقوه برای محصول

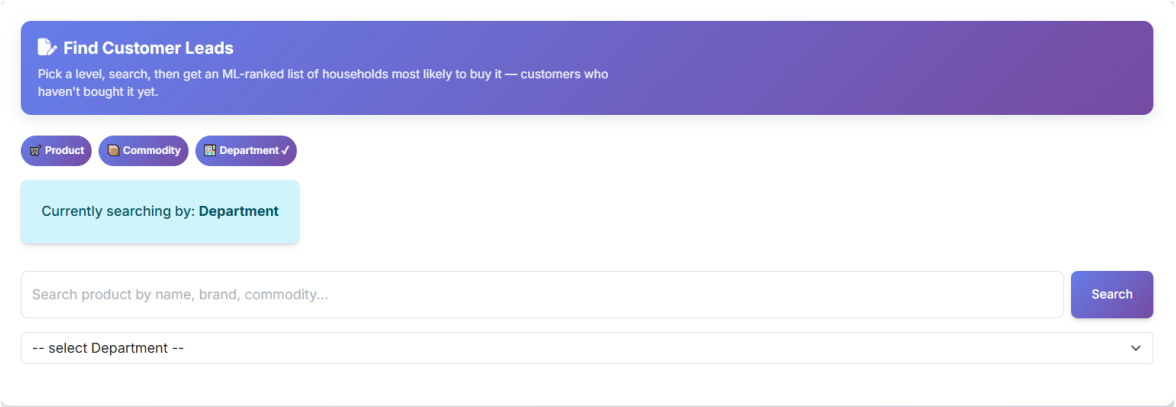
مسیر	مبنای انتخاب	مناسب برای
شباهت محتوایی	خرید محصولات هم‌گروه یا هم‌زیرگروه	هدف در سطح محصول
قانون انجمنی	خرید مقدمه قانونی که پیامد آن هدف است	هر سه سطح انتخاب
شباهت با خریداران موجود	نزدیکی الگوی کل خرید به گروه بذر	گسترش دامنه مشتریان بالقوه
حذف خریداران مستقیم	کنارگذاشتن مشتریان قبلی هدف	تمرکز بر لیدهای جدید

۹-۵-۳ رتبه‌بندی و ارائه فهرست

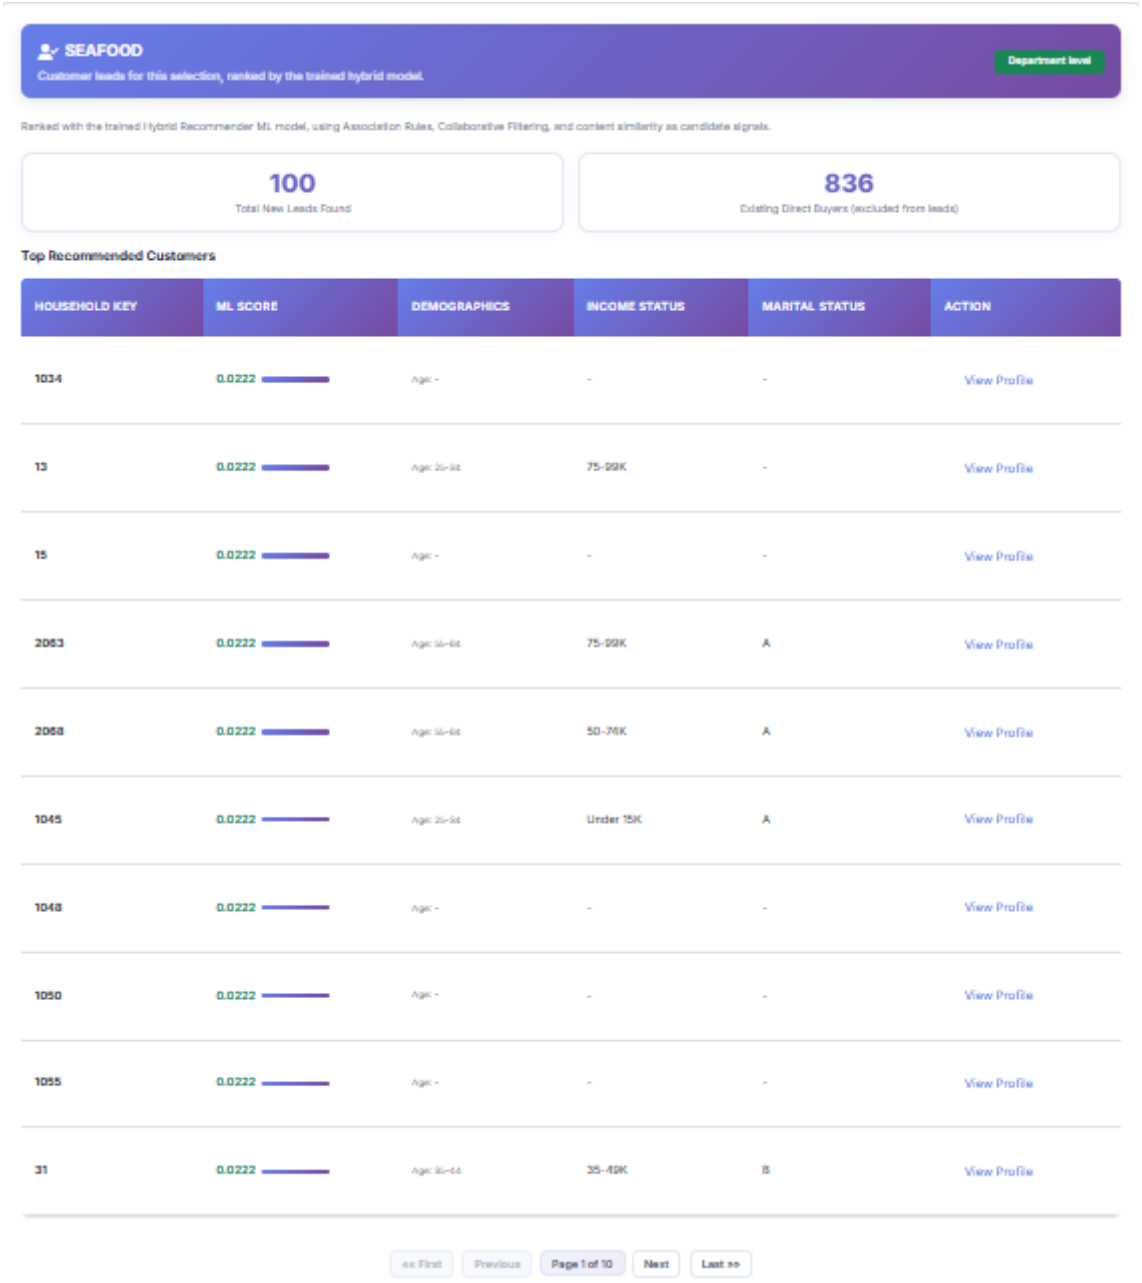
برای هر خانوار نامزد، ویژگی‌هایی با همان ساختار مدل اصلی ساخته می‌شود، با این تفاوت که این بار هدف ثابت و خانوارها متغیرند. امتیاز شباهت مشارکتی، میزان سابقه خانوار در محصول یا گروه هدف، تازگی

آن سابقه، چرخه معمول خرید و محبوبیت هدف در رتبه‌بندی دخالت دارند. استفاده از همان مدل آموزش‌دیده باعث می‌شود منطق دو جهت پیشنهاد تا حد امکان هماهنگ باقی بماند. اگر مدل در دسترس نباشد، امتیاز شباهت مشارکتی مبنای ساده رتبه‌بندی قرار می‌گیرد.

پس از محاسبه، امتیاز خانوارهایی که سابقه بیشتری در گروه هدف دارند اندکی تقویت می‌شود. فهرست از بیشترین امتیاز مرتب، به تعداد محدودی از بهترین گزینه‌ها محدود و در صفحه‌های ده‌تایی نمایش داده می‌شود. علاوه بر امتیاز خام، یک امتیاز درصدی نسبی نسبت به بهترین فرد همان فهرست نشان داده می‌شود. بنابراین درصد نمایش‌داده‌شده مقایسه‌ای است و احتمال مطلق خرید نیست. عدد صد درصد فقط نشان می‌دهد آن خانوار در میان نامزدهای همین اجرا بالاترین امتیاز را داشته است.



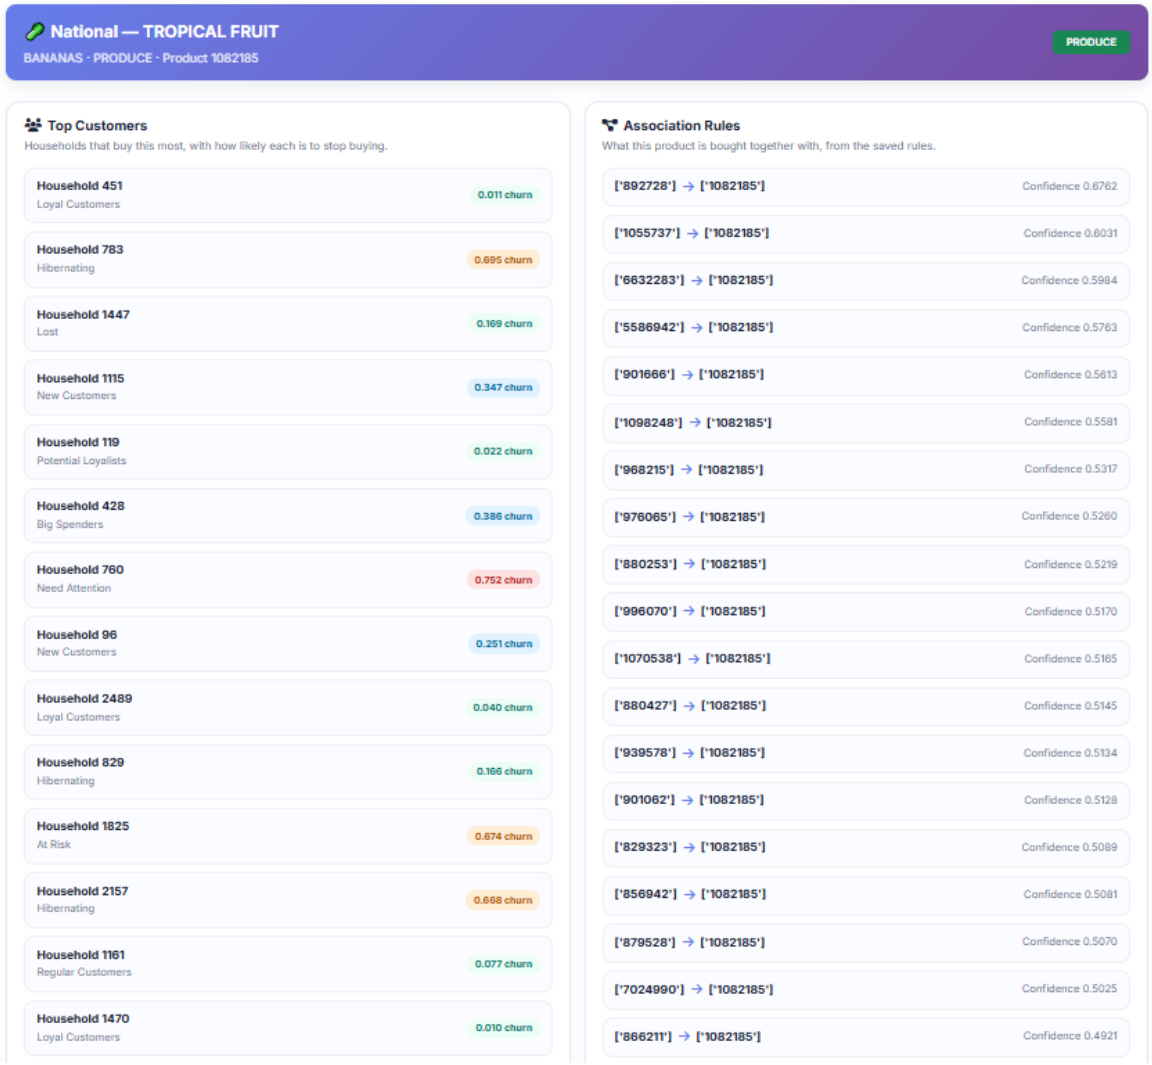
شکل ۹–۷ – صفحه انتخاب محصول، گروه کالایی یا دپارتمان برای پیشنهاد مشتری



شکل ۹-۸ – فهرست رتبه‌بندی‌شده مشتریان پیشنهادی برای هدف منتخب

۹-۵-٤ صفحه جزئیات محصول

صفحه جزئیات محصول زمینه لازم برای تفسیر فهرست مشتریان را فراهم می‌کند. در این صفحه مشخصات محصول، بخش‌های مشتریانی که آن را خریده‌اند و قوانین انجمنی مرتبط نمایش داده می‌شوند. بررسی این اطلاعات کمک می‌کند مشخص شود محصول بیشتر با چه نوع مشتری یا چه اقلام دیگری همراه بوده است. این صفحه برای کنترل کیفی کمپین مناسب است، زیرا کاربر می‌تواند پیش از اقدام، منطق رفتاری پیرامون محصول را ببیند و تنها به یک رتبه عددی اکتفا نکند.



شکل ۹-۹ – نمای جزئیات محصول، مشتریان خریدار و قوانین انجمنی مرتبط

۹-۶ مقایسه دو جهت پیشنهاددهی

جدول ۹-۸ – مقایسه پیشنهاد محصول به مشتری و پیشنهاد مشتری به محصول

معیار	محصول برای مشتری	مشتری برای محصول
نقطه شروع	یک خانوار مشخص	یک محصول، گروه یا دپارتمان
هدف	شخصی‌سازی انتخاب کالا	انتخاب مخاطب مناسب برای فروش
واحد رتبه‌بندی	کالا	خانوار
مهم‌ترین منابع نامزد	قواعد، همسایگان مشابه و کاوش برند	شباهت محتوایی، قواعد و شباهت با خریداران
حذف اصلی	کالاهای قبلاً خریداری‌شده	خریداران مستقیم هدف
کاربرد	پیشنهاد داخل سامانه یا برنامه نگهداشت	کمپین و اولویت‌بندی مخاطبان
خطر تفسیری	یکسان دانستن امتیاز با احتمال قطعی خرید	یکسان دانستن درصد نسبی با احتمال مطلق

این دو جهت را می‌توان در یک چرخه عملیاتی ترکیب کرد. مدیر فروش ابتدا یک گروه کالایی را انتخاب و مشتریان بالقوه را دریافت می‌کند. سپس برای هر مشتری منتخب، پروفایل و خریدهای اخیر را بررسی می‌نماید و در صورت نیاز، فهرست پیشنهادهای شخصی همان مشتری را می‌بیند. این ترتیب باعث می‌شود تصمیم گروهی کمپین با شواهد فردی کنترل شود. مسیر معکوس نیز ممکن است: کاربر از یک مشتری ارزشمند آغاز کند، پیشنهاد مناسب را بیابد و سپس برای همان کالا مشتریان مشابه دیگری را شناسایی نماید.

یکسان‌بودن مدل رتبه‌بندی به معنای یکسان‌بودن نتیجه دو جهت نیست. در مسیر محصول به مشتری، همه خریداران قبلی هدف به‌عنوان یک گروه بذر برای یافتن خانوارهای مشابه به کار می‌روند و دامنه جست‌وجو گسترده است، اما در مسیر مشتری به محصول، نامزدها از تاریخچه همان خانوار و تعداد محدودی همسایه مشابه ساخته می‌شوند و سپس تنها بیست مورد نخست باقی می‌مانند. بنابراین ممکن است یک زوج خانوار–محصول در یکی از مسیرها وارد مجموعه نامزدها شود و در مسیر دیگر اصلاً به مرحله امتیازدهی نرسد. این تفاوت نتیجه خطای مدل نیست، بلکه پیامد نقش متفاوت مرحله تولید نامزد در دو مسئله است.

۹-۷ آموزش و ارزیابی مدل

۹-۷-۱ ساخت داده آموزشی

برای آموزش، یک نقطه برش زمانی تعیین می‌شود. ویژگی‌های رفتاری تنها از تراکنش‌های پیش از این نقطه ساخته می‌شوند و خریدهای پس از آن در یک افق آینده برای تعیین برچسب به کار می‌روند. اگر کالای نامزد در افق آینده خریداری شده باشد، نمونه مثبت و در غیر این صورت نمونه منفی است. این جداسازی زمانی از نشت اطلاعات آینده به گذشته جلوگیری می‌کند و شرایط واقعی استفاده از پیشنهاددهنده را بهتر بازنمایی می‌نماید.

به علت هزینه محاسباتی، آموزش می‌تواند روی نمونه‌ای از خانوارها انجام شود. ماتریس شباهت برای نقطه برش یک‌بار ساخته می‌شود و قواعد انجمنی موجود نیز برای تولید نامزدها به کار می‌روند. سپس داده‌های زوج مشتری–کالا با یک بذر تصادفی ثابت مخلوط و به بخش آموزش و آزمون تقسیم می‌شوند. ثابت‌بودن بذر امکان تکرارپذیری مقایسه‌ها را افزایش می‌دهد، هرچند برای ارزیابی دقیق‌تر، تقسیم زمانی چندمرحله‌ای توصیه می‌شود.

در اجرای نهایی، ۱۵۰۰ خانوار برای ساخت داده آموزشی نمونه‌گیری شدند و افق آینده ۳۰ روز در نظر گرفته شد. پس از تولید و برچسب‌گذاری نامزدها، ۳۹۰۰۰ نمونه برای آموزش و ۹۷۵۱ نمونه برای آزمون استفاده شد. مدل تقویت گرادیانی با ۲۰۰ مرحله یادگیری، نرخ یادگیری ۰/۰۶ و عمق بیشینه شش آموزش یافت. این مقادیر تنظیم‌های اجرایی همین نسخه‌اند و به‌عنوان مقادیر قطعی برای همه مجموعه‌داده‌ها تلقی نمی‌شوند.

۹-۷-۲ معیارهای ارزیابی

جدول ۹-۹ – معیارهای مناسب برای ارزیابی پیشنهاددهنده

معیار	پرسش	نکته تفسیری
ROC-AUC	مدل تا چه حد نمونه مثبت را بالاتر از منفی رتبه‌بندی می‌کند؟	برای مقایسه کلی مفید است، اما در داده نامتوازن کافی نیست
PR-AUC	در میان پیش‌بینی‌های مثبت، تعادل دقت و پوشش چگونه است؟	برای خریدهای آینده کم‌تعداد گویاتر است
Precision@K	از K پیشنهاد اول چند مورد واقعاً خریداری شده‌اند؟	با ظرفیت واقعی نمایش یا کمپین هماهنگ است
Recall@K	از خریدهای واقعی آینده چند مورد در K پیشنهاد اول پوشش یافته‌اند؟	میزان از دست‌رفتن فرصت‌ها را نشان می‌دهد
پوشش	برای چه سهمی از مشتریان یا کالاها پیشنهاد تولید می‌شود؟	از محدودشدن سامانه به اقلام بسیار محبوب جلوگیری می‌کند
تنوع و تازگی	فهرست تا چه حد غیرتکراری و دارای گزینه جدید است؟	باید در کنار ارتباط و نه به‌جای آن سنجیده شود

مدل فعلی هنگام آموزش ROC-AUC و PR-AUC را ثبت می‌کند. Precision@K و Recall@K به‌طور خاص برای رابط کاربری این سامانه معیارهای گویایی هستند، زیرا خروجی نهایی همواره به بیست پیشنهاد نخست محدود می‌شود و آنچه برای کاربر اهمیت دارد کیفیت همین بخش بالای فهرست است، نه کیفیت میانگین کل رتبه‌بندی. به همین دلیل، ROC-AUC و PR-AUC که در جدول ۹-۹ معرفی شدند به‌عنوان معیارهای سطح مدل در نظر گرفته شده‌اند، در حالی‌که Precision@K و Recall@K معیارهای سطح محصول‌نهایی‌اند و مکمل یکدیگرند: نخستین گروه توانایی کلی مدل در تفکیک نمونه مثبت از منفی را می‌سنجد و گروه دوم دقیقاً همان تجربه‌ای را اندازه می‌گیرد که کاربر در صفحه پیشنهادها مشاهده می‌کند. این دوگانگی معیارها، نشان‌دهنده انتخابی آگاهانه در طراحی ارزیابی است تا هم دیدگاه آماری کلی و هم دیدگاه عملیاتی مبتنی بر رابط کاربر، هر دو در نظر گرفته شوند. نتیجه آزمون، مقدار

۰/۶۲۶۸ برای ROC-AUC و مقدار ۰/۰۳۱۹ برای PR-AUC بود. نرخ نمونه مثبت در داده آموزش ۱/۶۹ درصد و در داده آزمون ۱/۸۴ درصد است. ازاین‌رو مسئله به‌شدت نامتوازن محسوب می‌شود. مقدار PR-AUC تقریباً ۱/۷ برابر نرخ پایه آزمون است و نشان می‌دهد مدل در ابتدای رتبه‌بندی اطلاعاتی فراتر از انتخاب تصادفی دارد، اما فاصله آن با یک پیشنهاددهنده دقیق همچنان قابل توجه است. بنابراین این خروجی باید برای اولویت‌بندی نسبی نامزدها استفاده شود و نه به‌عنوان احتمال کالیبره‌شده یا تضمین خرید.

۹-۸ ملاحظات اجرایی، اخلاقی و محدودیت‌ها

داده این پروژه شناسه خانوار و ویژگی‌های جمعیت‌شناختی دارد. بنابراین حتی در نبود نام واقعی، دسترسی باید محدود و هدف استفاده مشخص باشد. ویژگی‌هایی مانند سن، درآمد یا وضعیت خانوادگی نباید به تبعیض یا حذف ناعادلانه گروه‌ها منجر شوند. بهتر است تصمیم نهایی درباره کمپین‌های حساس توسط کاربر انسانی بررسی شود و امکان کنترل دلیل کلی پیشنهاد از طریق سابقه خرید، گروه کالا و منشأ نامزد فراهم باشد.

این بخش، تصمیم‌های طراحی کلیدی سامانه پیشنهاددهنده و توجیه هرکدام را خلاصه می‌کند. نخست، برای مشتری یا کالای تازه که سابقه کافی ندارد، معماری چندمنبعی نامزد (شباهت محتوایی، قوانین انجمنی، پالایش مشارکتی و کاوش برند) طراحی شده تا حتی در نبود یک سیگنال، سیگنال‌های دیگر فهرست معنادار تولید کنند. این چهارگانگی منابع، دقیقاً برای مقاوم‌بودن در برابر کمبود داده منظور شده است. دوم، تعادل میان محبوبیت عمومی و شخصی‌سازی با ترکیب صریح دو ویژگی مجزا در مدل (محبوبیت سراسری و تکرار شخصی) و تقویت امتیاز کاوش برند حاصل می‌شود، به‌گونه‌ای که فهرست نه صرفاً پرفروش‌ترین کالاها را تکرار می‌کند و نه به تجربه گذشته محدود می‌ماند.

سوم، تازگی حافظه میانی از طریق نسخه‌بندی خودکار تضمین می‌شود. نتیجه ذخیره‌شده هر مشتری به‌صورت هم‌زمان به نسخه قوانین انجمنی و زمان آخرین آموزش مدل گره خورده است، بنابراین هرگاه هرکدام از این دو منبع تازه‌سازی شود، خروجی به‌طور خودکار بازمحاسبه می‌شود بدون نیاز به مداخله دستی کاربر. چهارم، امتیاز قوانین انجمنی از الگوهای همراهی کالا استفاده می‌کند که به‌طبیعت نسبتاً پایدارند و در حجم بزرگی از تراکنش‌ها اعتبارسنجی شده‌اند. این ثبات، آن‌ها را برای استفاده به‌عنوان یک منبع نامزد قابل‌اتکا مناسب می‌سازد، در کنار ویژگی‌های رفتاری دیگر که به‌طور کامل زمان‌آگاه محاسبه می‌شوند.

سرانجام، برای اطمینان از قابلیت پیگیری، دو دستور مدیریتی مستقل برای بازسازی حافظه میانی شباهت مشارکتی و بازآموزی مدل در اختیار تیم قرار دارد و هر بار اجرای این دستورها، زمان دقیق تولید مصنوع جدید را در خود ذخیره می‌کند. همین زمان است که مبنای تشخیص نیاز به بازمحاسبه در صفحه پیشنهادها قرار می‌گیرد. این رویه عملیاتی ساده، از یک‌سو سرعت پاسخ را برای کاربر نهایی حفظ می‌کند و از سوی دیگر امکان کنترل و ممیزی نسخه فعال سامانه را برای تیم توسعه فراهم می‌آورد.

۹-۹ سناریوی استفاده پیشنهادی

سناریوی نخست، شخصی‌سازی برای یک مشتری است. کاربر شناسه خانوار را جست‌وجو می‌کند، مشخصات زمینه‌ای و خریدهای اخیر را می‌بیند، سپس پیشنهادهای محصول را باز می‌کند. او پیشنهادهای بالای فهرست را با تازگی خرید و گروه‌های مورد علاقه مقایسه و تنها گزینه‌هایی را برای اقدام انتخاب می‌کند که از نظر زمان، قیمت و هدف برنامه مناسب باشند.

سناریوی دوم، طراحی کمپین برای یک کالا است. کاربر سطح هدف را تعیین و محصول یا گروه را جست‌وجو می‌کند. سامانه خریداران قبلی را از مشتریان بالقوه جدا و فهرست نامزدها را رتبه‌بندی می‌کند. کاربر با مراجعه به پروفایل و تاریخچه خرید چند نامزد نخست، سازگاری پیشنهاد را کنترل می‌کند و نتیجه کمپین را برای ارزیابی بعدی ثبت می‌نماید.

در هر دو سناریو، خروجی سامانه باید پشتیبان تصمیم باشد و نه جایگزین کامل قضاوت کاربر. بهترین کاربرد زمانی حاصل می‌شود که رتبه‌بندی الگوریتمی با محدودیت بودجه، موجودی کالا، سیاست تخفیف و شناخت عملی مدیر فروش ترکیب گردد.

۹-۱۰ جمع‌بندی فصل

در این فصل، بخش‌های مرتبط با مشتری و پیشنهاددهی سامانه بررسی شد. پروفایل مشتری اطلاعات جمعیت‌شناختی را به‌عنوان زمینه تحلیل ارائه می‌کند و صفحه خریدها، تراکنش‌های پراکنده را در قالب سبدهای زمانی قابل مطالعه سازمان می‌دهد. بر پایه این شواهد، پیشنهاددهنده محصول برای مشتری از ترکیب

قوانین انجمنی، پالایش مشارکتی، ویژگی‌های محتوایی[۱۴۲]، چرخه خرید و مدل تقویت گرادیانی استفاده می‌کند و پس از اعمال قواعد تجاری، فهرستی محدود و قابل تفسیر ارائه می‌دهد.

بخش پیشنهاد مشتری برای محصول همان مسئله را از جهت تجاری معکوس حل می‌کند. در این بخش محصول، گروه یا دپارتمان ثابت است و خانوارهای بالقوه با استفاده از شباهت محتوایی، قواعد انجمنی و شباهت با خریداران موجود شناسایی و رتبه‌بندی می‌شوند. وجود هر دو جهت، سامانه را هم برای شخصی‌سازی تجربه مشتری و هم برای انتخاب مخاطب کمپین فروش قابل استفاده می‌سازد.

دستاورد اصلی این بخش، اتصال منظم داده پروفایل، سابقه سبد، الگوهای جمعی و پیش‌بینی آینده در یک جریان واحد است. امتیازهای مدل برای رتبه‌بندی نسبی نامزدها طراحی شده‌اند و در کنار قضاوت کاربر، به‌عنوان ابزار پشتیبان تصمیم عمل می‌کنند. ترکیب رتبه‌بندی الگوریتمی با شناخت عملی مدیر فروش، دقیقاً همان الگویی است که در سناریوهای استفاده این فصل شرح داده شد. با اتکا به این معماری دومرحله‌ای، منابع چندگانه تولید نامزد و راهبرد کش‌سازی نسخه‌بند، پیشنهاددهنده می‌تواند به‌عنوان ابزاری قابل‌اعتماد و کارآمد در یک فروشگاه هوشمند به کار گرفته شود.

---

[۱۴۲] Content-based Features

فصل دهم: نتیجه‌گیری و پیشنهادات

هدف این پروژه، تحلیل و طراحی یک سامانه برای پشتیبانی از تصمیم‌های فروشگاه حضوری با استفاده از مجموعه‌داده دان‌هامبی بود. مسئله اصلی این بود که چگونه می‌توان سابقه پراکنده خرید را به اطلاعاتی قابل استفاده درباره فروش، الگوی سبد، رفتار مشتری و فرصت‌های پیشنهاد محصول تبدیل کرد. حاصل کار، سامانه‌ای است که داده‌های پایه و چند روش تحلیلی را در صفحه‌های مرتبط در اختیار کاربر قرار می‌دهد. ارزیابی فصل‌های قبل نشان داد که این ارتباط از نظر پیاده‌سازی برقرار شده است، اما میزان اتکاپذیری خروجی در همه بخش‌ها یکسان نیست و باید برای هر مسئله جداگانه سنجیده شود.

در این فصل، ابتدا دستاوردهای اصلی پروژه جمع‌بندی می‌شود. سپس نتایج مدل‌ها و روش‌های به‌کاررفته، با توجه به شرایط آزمایش و محدودیت‌های داده، ارزیابی می‌گردد و در پایان، پیشنهادهایی برای ادامه کار ارائه می‌شود.

۱۰-۱ جمع‌بندی کلی نتایج

۱۰-۱-۱ آماده‌سازی داده و شکل‌گیری سامانه

نخستین دستاورد، آماده‌سازی داده و ایجاد ارتباط میان تراکنش، محصول و خانوار بود. پایگاه داده مورد استفاده شامل ۲۵۹۵۲۷۷ ردیف تراکنش، ۲۷۶۴۵۰ سبد یکتا و ۲۴۹۷ خانوار خریدار است. همچنین ۹۲۳۳۵ محصول در خریدها حضور دارند که با تعداد ۹۲۳۵۳ رکورد جدول مرجع محصول تفاوت دارد. تفکیک این واحدها اهمیت داشت، زیرا شمار ردیف‌های خرید، تعداد مراجعات مشتری و تعداد کالاهای متفاوت، پاسخ یک پرسش واحد نیستند. کنترل شناسه‌ها، مقادیر تهی و قرارداد محاسبه مبلغ، مبنای مشترکی برای تحلیل‌های بعدی فراهم کرد.

بر روی این داده‌ها، امکانات جست‌وجوی مشتری، مشاهده سبدهای خرید، تحلیل بازار، استخراج قوانین انجمنی، پیش‌بینی و پیشنهاددهی پیاده‌سازی شد. استفاده از شناسه‌های مشترک، مراجعه از یک گزارش کلی به سابقه یک مشتری یا مشخصات یک محصول را ممکن کرد. بنابراین هدف یکپارچه‌سازی، در محدوده داده‌ها و قابلیت‌های پیاده‌سازی‌شده تحقق یافت.

۱۰-۱-۲ شناخت فروش و الگوهای خرید

تحلیل توصیفی و داشبورد هوش تجاری نشان دادند که یک شاخص کلی، مانند مجموع درآمد، برای شناخت رفتار فروش کافی نیست. بررسی اندازه سبد، ترکیب گروه‌های کالایی، نوع برند و تمرکز درآمد، تفاوت میان مشتریان و محصولات را آشکار می‌کند. برای نمونه، در تحلیل فصل ششم، میانه اندازه سبد پنج قلم بود و حدود ۲۲ درصد سبدها تنها یک قلم داشتند، در حالی که میانگین اندازه سبد بیشتر بود. این اختلاف نشان می‌دهد تعداد محدودی سبد بزرگ بر میانگین اثر می‌گذارند و تصمیم درباره چیدمان یا پیشنهاد فروش باید ترکیب سبدها را نیز در نظر بگیرد.

در همان فصل، دو دهک بالای خانوارها ۵۳/۱ درصد درآمد را ایجاد کردند. این تمرکز، دلیل قابل بررسی برای توجه به ارزش مشتری در کنار احتمال ریزش است، هرچند اثر یک برنامه نگهداشت را ثابت نمی‌کند. قوانین انجمنی نیز با نمایش همراهی کالاها، شناخت سبد را تکمیل کردند. استخراج قانون در سطح محصول و سطوح کلی‌تر کالایی، امکان بررسی الگوهای جزئی و عمومی را فراهم ساخت. خروجی این بخش می‌تواند برای انتخاب نامزدهای فروش مکمل یا بررسی چیدمان استفاده شود، ولی به‌تنهایی ثابت نمی‌کند که کنار هم قرار دادن دو کالا موجب افزایش فروش خواهد شد. تحلیل تفاضلی فصل ششم نیز نشان داد که مقایسه دوره‌ها باید بر پایه طول دوره، تعداد مشاهدات و تعریف ثابت شاخص‌ها انجام شود تا تغییر دامنه داده با تغییر واقعی عملکرد اشتباه گرفته نشود.

۱۰-۱-۳ تحلیل مشتری و پیش‌بینی رفتار

بخش‌بندی RFM، سابقه خرید را از نظر تازگی، تعداد سبدهای یکتا و مبلغ خرید خلاصه کرد. در نمای جاری، این شاخص‌ها کل سابقه موجود تا روز ۷۱۱ را توصیف می‌کنند، اما ویژگی‌های مدل ریزش در برش‌های زمانی تعریف‌شده ساخته می‌شوند. نام بخش RFM با سطح ریسک مدل یکسان نیست. مدل، احتمال نبود خرید ثبت‌شده خانوار در افق بعدی را برآورد می‌کند. تا زمانی که داده و قواعد بخش‌بندی ثابت باشند، تغییر مدل ریزش، بخش‌های RFM را تغییر نمی‌دهد و تغییر احتمال نیز به‌تنهایی نشانه تغییر رفتار مشتری نیست. نمایش هم‌زمان این اطلاعات در نمای فردی و فهرست ماندگاری، امکان بررسی علت اولویت گرفتن یک مشتری را فراهم ساخت.

در پیش‌بینی خرید دوباره نیز چند الگوریتم با یکدیگر مقایسه شدند و برای درآمد محصول، دو مدل یادگیری در کنار مبنای میانگین اخیر ارزیابی گردیدند. نتیجه مهم این مرحله، مشخص‌شدن حدود عملکرد

مدل‌ها بود. برخی مدل‌ها در تفکیک مشتریان یا کاهش خطای متوسط مناسب‌تر بودند، اما این برتری به همه معیارها و همه اهداف مدیریتی تعمیم نداشت.

۱۰-۱-٤ ارتباط تحلیل با پیشنهاد محصول

سامانه پیشنهاددهنده، دو نیاز مرتبط را پوشش داد: انتخاب محصول برای یک مشتری و یافتن مشتری بالقوه برای یک محصول یا دسته کالایی. استفاده از قوانین انجمنی، شباهت خرید خانوارها، ویژگی‌های محتوایی و سابقه زمانی، چند مسیر برای تولید نامزد ایجاد کرد. پس از امتیازدهی و اعمال قواعدی مانند توجه به چرخه خرید و محدودکردن پیشنهادهای تکراری، فهرستی قابل بررسی در اختیار کاربر قرار گرفت.

دستاورد این بخش، پیاده‌سازی مسیر پیشنهاد و اتصال آن به اطلاعات مشتری است. برای مثال، کاربر می‌تواند از فهرست ماندگاری به سابقه مشتری و سپس به پیشنهادهای او مراجعه کند. از دیگر دستاوردهای این بخش، سازوکار «کشف برند جدید» برای پیشنهاد آگاهانه برند جایگزین و استفاده از یک مدل آموزش‌دیده مشترک در هر دو مسیر مشتری‌به‌محصول و محصول‌به‌مشتری است. همچنین، ذخیره‌سازی ازپیش‌محاسبه‌شده ماتریس شباهت، زمان پاسخ را از چند دقیقه به کسری از ثانیه کاهش داد و نسخه‌بندی خودکار حافظه میانی بر پایه زمان آموزش مدل و نسخه قوانین، بازمحاسبه معتبر نتایج را بدون دخالت دستی ممکن ساخت. با وجود این ارتباط، نمایش پیشنهاد هنوز به معنای اجرای کمپین یا اثبات تأثیر آن بر خرید نیست. ارزیابی این اثر به داده‌ای نیاز دارد که پس از انجام اقدام واقعی جمع‌آوری شود.

۱۰-۲ ارزیابی نتایج و روش‌ها

۱۰-۲-۱ اعتبار تحلیل توصیفی و قوانین انجمنی

روش‌های توصیفی از این نظر برای پروژه مناسب بودند که نتیجه آن‌ها به شمارش‌ها و تجمیع‌های قابل پیگیری وابسته است. کاربر می‌تواند مجموع فروش، تعداد سبد یا سهم یک گروه را به داده پایه مرتبط کند. در مقابل، درآمد ثبت‌شده نباید با سود خالص یکسان گرفته شود. اطلاعات هزینه و حاشیه سود برای چنین نتیجه‌ای لازم است. همچنین وجود اقلام متفرقه و مرتبط با کوپن در میان محصولات پردرآمد، لزوم بررسی معنای تجاری هر ردیف را پیش از تصمیم درباره موجودی نشان می‌دهد.

در قوانین انجمنی، تفسیر هم‌زمان پشتیبان، اطمینان و بهبود ضروری است. یک قانون با بهبود زیاد ممکن است فقط در تعداد کمی سبد دیده شده باشد. اطمینان بالا نیز ممکن است از فراوانی زیاد کالای پیامد ناشی

شود. بنابراین کیفیت قانون را نمی‌توان با یک عدد تعیین کرد. به‌کارگیری این روش برای کشف رابطه‌های قابل بررسی مناسب است، اما پایداری زمانی و اثر تجاری قوانین باید در دوره‌ای جداگانه آزموده شود.

۱۰-۲-۲ ارزیابی پیش‌بینی خرید دوباره

در آزمایش فصل پنجم با افق سه‌ماهه، مجموعه آزمون شامل ۲۹۷۷۱ زوج خانوار و گروه کالایی بود. مدل تقویت گرادیانی به سطح زیر منحنی ROC برابر ۰/۸۷۳، امتیاز F1 برابر ۰/۸۱۲، بازخوانی ۰/ ۸۲۰ و امتیاز بریر ۰/۱۴۷ رسید. این نتایج در کنار مقایسه با شبکه عصبی، جنگل تصادفی و ماشین بردار پشتیبان، از انتخاب تقویت گرادیانی در تنظیم بررسی‌شده حمایت می‌کنند. با این حال، ماشین بردار پشتیبان به علت هزینه محاسباتی روی زیرمجموعه کوچک‌تری آموزش دیده است. بنابراین مقایسه، عملکرد پیکربندی‌های اجراشده را نشان می‌دهد و حکم کلی درباره برتری یک خانواده الگوریتم نیست.

مزیت این بخش، ساخت ویژگی از گذشته و سنجش خرید در افق بعدی بود. با این روش، سؤال مدل به یک پیش‌بینی مشخص تبدیل شد. در تفسیر خروجی نیز باید توجه داشت که سطح زیر منحنی، معیار توان تفکیک است و درصد صحت تصمیم‌ها محسوب نمی‌شود. افزون بر آن، نزدیک بودن میانگین احتمال‌ها به نرخ واقعی خرید، به‌تنهایی برای تأیید کالیبراسیون در همه گروه‌های مشتری کافی نیست.

۱۰-۲-۳ ارزیابی پیش‌بینی درآمد محصول

مقایسه پیش‌بینی درآمد، نتیجه‌ای وابسته به معیار نشان داد. در آزمون سه دوره سی‌روزه، خطای نسبی وزنی مدل مستقیم ۴۶ درصد، شبکه بازگشتی ۴۶/۷ درصد و میانگین اخیر ۴۸/۷ درصد بود. در نتیجه، مدل مستقیم نسبت به مبنای ساده، ۲/۷ واحد درصد کاهش در این خطا داشت. با این حال، مبنای میانگین اخیر در جذر میانگین مربعات خطا، ضریب تعیین و قدر مطلق اریبی بهتر عمل کرد. پس برتری مدل مستقیم در خطای نسبی، مجوز کنارگذاشتن مبنای ساده در همه کاربردها نیست.

در رتبه‌بندی نیز هر سه روش، شانزده مورد از بیست محصول برتر واقعی را در فهرست بیست‌تایی خود داشتند. بر اساس این معیار، تفاوت روش‌ها برای شناسایی محصولات اصلی محدود بود. از طرف دیگر، ۹۴۶۲ محصول از جمعیت ۵۸۳۲۸ محصولی ارزیابی، در پنجره گذشته فروش نداشتند. حفظ این موارد در آزمون، محدودیت مدل‌های متکی به سابقه درآمد را نشان داد. از نظر کاربردی، انتخاب مدل باید به هدف وابسته باشد. برای برآورد مقدار فروش، کنترل خطا و اریبی لازم است و برای اولویت‌بندی محصول، کیفیت بالای فهرست اهمیت بیشتری دارد.

۱۰-۲-٤ ارزیابی ریزش و اولویت‌بندی ماندگاری

مدل فعال ریزش با دوره مشاهده ۹۰روزه، افق ۳۰روزه و گام ۳۰روزه بررسی شد. پس از تفکیک زمانی و حذف نمونه‌های دارای افق برچسب نامجاز، ۳۴۲۰۵ نمونه آموزش و برای هر یک از اعتبارسنجی و آزمون ۷۴۹۱ نمونه باقی ماند. آستانه ۰/۳۰ با بیشینه‌کردن F1 در اعتبارسنجی انتخاب شد. در آزمون، ROC-AUC برابر ۰/۸۸۲، PR-AUC برابر ۰/۶۰۶، بازخوانی ۰/۶۷۳ و F1 برابر ۰/۶۰۲ بود. نرخ مثبت آزمون حدود ۱۸/۴ درصد است؛ بنابراین PR-AUC باید در کنار این نرخ پایه تفسیر شود و ROC-AUC نیز به معنی صحت ۸۸/۲ درصدی نیست. این نتایج نشان می‌دهند مدل برای مرتب‌کردن موارد نیازمند بررسی اطلاعات مفیدی فراهم می‌کند، ولی خطای تصمیم آن همچنان قابل توجه است.

در آزمون، ۹۲۹ مورد مثبت درست شناسایی شد، ۴۵۱ مورد از دست رفت، ۷۷۵ هشدار نادرست ایجاد شد و ۵۳۳۶ مورد منفی درست تشخیص داده شد. در نتیجه، حدود ۵۴/۵ درصد هشدارهای آستانه ۰/۳۰ درست بوده‌اند؛ اقدام یکسان و پرهزینه برای همه هشدارها توجیه ندارد. این شمارش‌ها به نمونه‌های خانوار در نقطه برش مربوط‌اند. در مقابل، ۳۳۷ خانوار با ریسک بالا یا بسیار بالا در نمای جاری، معادل ۱۳/۵ درصد جمعیت، خروجی امتیازدهی مدل فعال‌اند و ریزش تأییدشده آینده نیستند. آستانه ارزیابی، مرزهای ثابت نمایش سطح ریسک و فیلتر پیش‌فرض ۵۰ درصدی فهرست ماندگاری سه مفهوم جدا هستند؛ معیارهای آستانه ۰/۳۰ را نمی‌توان مستقیماً به فهرست ۵۰ درصدی نسبت داد.

ریزش در این پروژه فقط نبود خرید ثبت‌شده در یک افق کامل است و درباره ترک دائمی، علت توقف خرید یا خرید از خرده‌فروش دیگر شاهد مستقیمی ارائه نمی‌کند. در هر برش، همه خانوارهای دارای سابقه خرید تا آن زمان واجد بررسی هستند، حتی اگر در پنجره مشاهده خریدی نداشته باشند. بنابراین هدف فعلی، هم عدم خرید بعدی مشتری فعال و هم تداوم بی‌خریدی مشتری از قبل غیرفعال را دربر می‌گیرد؛ معیار کلی، سنجه خالص شناسایی ریزش تازه نیست. از آنجا که برش‌های زمانی یک خانوار می‌توانند سابقه مشترک داشته باشند، تعداد نمونه‌های آزمون نیز نباید به تعداد همان‌قدر مشتری مستقل تعبیر شود. ارزیابی فقط از افق‌های کامل استفاده می‌کند و نبود داده پس از روز ۷۱۱ نباید برچسب ریزش تلقی شود.

۱۰-۲-۵ ارزیابی سامانه پیشنهاددهنده

در اجرای نهایی فصل نهم، با نمونه‌گیری از ۱۵۰۰ خانوار و افق آینده ۳۰روزه، ۳۹۰۰۰ نمونه آموزشی و ۹۷۵۱ نمونه آزمون ساخته شد. سطح زیر منحنی ROC برابر ۰/۶۲۶۸ و سطح زیر منحنی دقت و بازخوانی

برابر ۰/۰۳۱۹ بود. نرخ نمونه مثبت آزمون نیز ۸۴/۱ درصد گزارش شد. این نتیجه، وجود مقداری توان تفکیک را نشان می‌دهد، اما برای توصیف پیشنهاددهنده به‌عنوان یک مدل با دقت بالا کافی نیست. همچنین از این معیارها نمی‌توان احتمال خرید هر کالای پیشنهادی را به دست آورد.

محدودیت دیگر به شیوه ارزیابی مربوط است. با وجود جداسازی گذشته و آینده برای ساخت ویژگی و برچسب، زوج‌های حاصل از یک نقطه برش میان آموزش و آزمون تقسیم شده‌اند. این روش با آزمودن سامانه در چند دوره کاملاً جدید یکسان نیست. علاوه بر آن، استفاده از قواعد انجمنی موجود ایجاب می‌کند که در ارزیابی بعدی، خود قواعد نیز فقط از داده مجاز پیش از هر برش بازسازی شوند.

کیفیت بیست پیشنهاد نهایی نیز باید پس از تولید نامزد، رتبه‌بندی و اعمال قواعد تجاری سنجیده شود. در گزارش حاضر، مقدار تجربی دقت و بازخوانی در بیست پیشنهاد نخست ارائه نشده است. بنابراین وجود معماری ترکیبی و امکانات رابط کاربری را باید دستاورد پیاده‌سازی دانست و میزان موفقیت پیشنهادهای نهایی را موضوع ادامه ارزیابی قرار داد.

۱۰-۲-۶ جمع‌بندی مقایسه و دامنه اعتبار

جدول ۱۰-۱ نتایج کمی اصلی را خلاصه می‌کند. اعداد از جدول‌های ۵-۴ و ۵-۷، بخش رتبه‌بندی فصل پنجم، جدول ۸-۳ و نتایج آزمون فصل نهم گرفته شده‌اند. این مقادیر به مسئله‌ها و مجموعه‌های آزمون متفاوت تعلق دارند. ازاین‌رو مقایسه مستقیم مقدار یک معیار بین ریزش، خرید دوباره و پیشنهاد محصول، رتبه‌بندی معتبر بخش‌های سامانه نیست.

جدول ۱۰-۱ – خلاصه نتایج کمی ارزیابی مدل‌ها

بخش و روش	شاخص‌های اصلی	برداشت از نتیجه
خرید دوباره تقویت گرادیانی	**ROC-AUC** برابر ۰/۸۷۳ **F1** برابر ۰/۸۱۲ بریر برابر ۰/۱۴۷	نتیجه مناسب‌تر در پیکربندی بررسی‌شده، وابسته به افق و نمونه آموزش
درآمد محصول مدل مستقیم و دو مبنا	خطای نسبی وزنی مستقیم ۴۶ درصد بازگشتی ۴۶/۷ درصد میانگین اخیر ۴۸/۷ درصد	کاهش خطای نسبی مدل مستقیم، برتری مبنای ساده در برخی معیارهای دیگر
رتبه‌بندی درآمد هر سه روش	اشتراک بیست محصول برتر ۱۶ مورد از ۲۰ مورد	تفاوت محدود روش‌ها در این معیار رتبه‌بندی
ریزش مشتری مدل فعال	**ROC-AUC** برابر ۰/۸۸۲ **PR-AUC** برابر ۰/۶۰۶ بازخوانی ۰/۶۷۳	کاربرد برای اولویت‌بندی، همراه با ریزش‌های ازدست‌رفته و هشدار نادرست
پیشنهاد محصول مدل ترکیبی	**ROC-AUC** برابر ۰/۶۲۶۸ **PR-AUC** برابر ۰/۰۳۱۹ نرخ مثبت آزمون ۱/۸۴درصد	توان تفکیک محدود، کیفیت بیست پیشنهاد نهایی هنوز اندازه‌گیری نشده است

مقایسه با مبنای ساده و الگوریتم‌های جایگزین در همین داده، برای داوری این پروژه مفیدتر از کنار هم گذاشتن اعداد پژوهش‌هایی با تعریف هدف یا جامعه متفاوت است. نتایج حاضر نشان می‌دهند استفاده از مدل پیچیده‌تر همیشه نتیجه بهتر نمی‌دهد و مزیت هر روش باید با معیار متناسب با کاربرد اثبات شود. سهم اصلی پروژه نیز طراحی الگوریتمی تازه نیست بلکه پیاده‌سازی و بررسی چند روش شناخته‌شده در یک سامانه مرتبط برای تحلیل فروشگاه است.

دامنه نتیجه‌گیری به همین مجموعه‌داده محدود است. واحد مشتری، خانوار است و زمان با شماره روز و هفته بیان می‌شود؛ نسبت‌دادن نتایج به افراد، همه خرده‌فروشان یا مناسبت‌های تقویمی به شواهد دیگری نیاز دارد. اطلاعات جمعیت‌شناختی کامل نیست، اما ورودی مدل ریزش فعلی نیز نیست و نبود آن موجب حذف خانوار از این مدل نمی‌شود. مبلغ خرید گذشته فقط یک شاخص ارزش تاریخی است و با سود یا ارزش طول عمر مشتری برابر نیست. داده فعلی علت عدم خرید، پاسخ به اقدام نگهداشت و منفعت افزوده آن را مشخص نمی‌کند. در این پروژه افزایش واقعی فروش یا بهبود ماندگاری پس از مداخله اندازه‌گیری نشده است.

۱۰-۳ پیشنهادات برای ادامه کار

۱۰-۳-۱ تکمیل و یکسان‌سازی ارزیابی

اولویت نخست، تکرار ارزیابی در چند دوره آینده با افق کامل و قرارداد مشخص است. جداسازی زمانی آموزش، اعتبارسنجی و آزمون و کنترل عبور افق برچسب در مدل ریزش فعلی وجود دارد؛ توسعه پیشنهادی، بررسی پایداری آن در دوره‌های بیشتر است. در هر ارزیابی، همه ویژگی‌ها، قواعد و شباهت‌های مورد استفاده باید فقط از گذشته مجاز ساخته شوند. تنظیم و انتخاب آستانه باید در اعتبارسنجی انجام شود و آزمون نهایی برای گزارش نتیجه کنار بماند. ثبت نسخه داده، تنظیم‌ها و تعداد خانوارهای یکتا ضروری است. برای برآورد عدم‌قطعیت باید وابستگی نمونه‌های یک خانوار و ترتیب زمان لحاظ شود. بررسی جداگانه عملکرد روی خانوارهای دیده‌نشده می‌تواند دامنه تعمیم را روشن‌تر کند.

برای پیشنهاددهنده، محاسبه دقت و بازخوانی بیست پیشنهاد نخست، پوشش مشتری و محصول، تنوع و تازگی فهرست ضروری است. این ارزیابی باید برای هر دو جهت پیشنهاد انجام شود، زیرا مجموعه نامزدهای آن‌ها متفاوت است. مقایسه با پیشنهاد پرفروش‌ترین کالاهای خریداری‌نشده و نسخه‌های ساده‌تر مبتنی بر قوانین انجمنی یا شباهت خانوارها، با شرایط یکسان برای انتخاب نامزدها، مشخص می‌کند هر جزء چه سهمی در نتیجه دارد. برای خرید دوباره و ریزش، بررسی کالیبراسیون احتمال و انتخاب آستانه بر پایه هزینه هشدار نادرست و فرصت ازدست‌رفته، خروجی را به نیاز عملی نزدیک‌تر می‌کند.

۱۰-۳-۲ بهبود مدل‌ها بر اساس نوع خطا

در پیش‌بینی درآمد، پیشنهاد می‌شود خطا به تفکیک محصولات پرفروش، کم‌فروش و فاقد سابقه بررسی شود. سپس روش مناسب هر گروه با میانگین اخیر و سایر مبناهای ساده مقایسه گردد. برای محصولات بدون فروش در پنجره گذشته، استفاده از گروه کالایی و ویژگی‌های محصول می‌تواند یک مسیر توسعه باشد و میزان فایده آن باید در آزمون مشخص شود. طولانی‌تر شدن سابقه داده نیز به بررسی الگوهای تکرارشونده کمک می‌کند. برای نسبت‌دادن این الگوها به فصل‌ها یا مناسبت‌های واقعی، نگاشت معتبر زمان به تقویم لازم است.

در پیشنهاددهی، ابتدا باید مشخص شود محدودیت اصلی از تولید نامزد ناشی می‌شود یا از رتبه‌بندی. اگر کالای خریداری‌شده آینده اصلاً وارد نامزدها نشود، تغییر مدل امتیازدهی به‌تنهایی مسئله را حل نمی‌کند.

بررسی جداگانه پوشش نامزدها، سپس حذف آزمایشی هر منبع و سنجش اثر آن، مبنای روشن‌تری برای بهبود فراهم می‌سازد. افزودن مدل پیچیده‌تر بهتر است پس از این بررسی و همراه با سنجش هزینه محاسبه انجام شود.

در توسعه ریزش، پیشنهاد می‌شود دو مسئله جدا تعریف شوند: پیشگیری از قطع خرید خانوارهای فعال و بازفعال‌سازی خانوارهای غیرفعال. قاعده فعال‌بودن باید فقط با سابقه پیش از نقطه برش تعیین شود و حساسیت نتیجه به افق و فاصله معمول خرید بررسی گردد. برای خانوارهای کم‌سابقه نیز باید تعداد مشاهدات کافی یا یک قاعده جایگزین مشخص باشد. این تفکیک، توسعه‌ای بر هدف فعلی است و صرف افزودن آن به رابط کاربری، بدون ساخت و ارزیابی جداگانه نمونه‌ها، کافی نیست.

۱۰-۳-۳ سنجش اثر اقدام در فروشگاه

برای ارزیابی کاربرد واقعی، لازم است ثبت اقدام به سامانه افزوده شود: چه پیشنهادی، در چه زمان و با چه هزینه‌ای به کدام مشتری ارائه شده و پس از آن چه خریدی رخ داده است. سپس می‌توان در یک اجرای محدود، مشتریان واجد شرایط را به‌صورت تصادفی به گروه دریافت‌کننده اقدام و گروه کنترل تقسیم کرد. مقایسه خرید مجدد، مبلغ خرید و سود پس از کسر هزینه مشوق، شواهدی درباره اثر اقدام فراهم می‌کند که از امتیاز مدل به‌تنهایی به دست نمی‌آید.

در برنامه ماندگاری، اولویت پیگیری بهتر است علاوه بر ریسک، ظرفیت اجرایی، هزینه اقدام و ارزش قابل بازیابی را در نظر بگیرد. مشتری پرریسک الزاماً بیشترین منفعت را از دریافت پیشنهاد ایجاد نمی‌کند. پس از ثبت کافی و معتبر اقدام‌ها، تخصیص تصادفی گروه دریافت‌کننده و کنترل، هزینه مشوق و خریدهای بعدی، می‌توان مدل اثر افزایشی مداخله را بررسی کرد: چه خانواری در اثر دریافت پیشنهاد، بیش از حالت عدم دریافت آن خرید می‌کند؟ این قابلیت در پروژه فعلی اجرا نشده است و از تراکنش‌ها یا مبلغ تخفیف به‌تنهایی قابل استنتاج نیست. برای سنجش سود افزایشی، اطلاعات هزینه کالا و حاشیه سود نیز لازم است.

۱۰-۳-٤ آماده‌سازی داده و سامانه برای استفاده عملی

در توسعه بعدی، یکسان‌سازی تعریف شاخص‌ها و قواعد بخش‌بندی در همه صفحه‌ها باید ادامه یابد. نمایش زمان آخرین به‌روزرسانی و نسخه تحلیل نیز کمک می‌کند تفاوت ناشی از تنظیم یا دامنه داده با تغییر رفتار مشتری اشتباه گرفته نشود. افزودن اطلاعات معتبر موجودی، هزینه کالا و برنامه‌های ترفیعی، امکان بررسی دقیق‌تر تصمیم‌های فروش را فراهم می‌کند. در عین حال، مقادیر نامشخص باید از طبقه‌های واقعی داده جدا بمانند.

پیش از استقرار، بازبینی تنظیم‌های محیط اجرا، پشتیبان‌گیری، کنترل دسترسی و آزمون زمان پاسخ در بار کاری واقعی لازم است. نگهداری تاریخچه مدل‌ها و امکان بازگشت به نسخه قبلی نیز برای پیگیری خطا مفید خواهد بود. اطلاعات خانوار باید فقط در حدود نیاز تحلیل در دسترس قرار گیرد و عملکرد مدل برای گروه‌های مختلف بررسی شود تا کمبود داده در یک گروه، به حذف مداوم آن از پیشنهادها منجر نشود.

در پایان، ارزیابی ما این است که پروژه در محدوده یک کار کارشناسی، مسیر استفاده از داده تراکنشی تا ارائه تحلیل و پیشنهاد را به‌صورت عملی پیاده‌سازی کرده است. ارزش آموزشی و فنی آن در ارتباط میان طراحی پایگاه داده، تحلیل، ارزیابی مدل و رابط کاربر قرار دارد. نتایج آزمایش‌ها از کاربرد سامانه برای بررسی و اولویت‌بندی پشتیبانی می‌کنند، اما برای ادعای افزایش فروش یا جایگزینی تصمیم مدیر هنوز کافی نیستند. ادامه منطقی پروژه، دقیق‌تر کردن ارزیابی و سنجش نتیجه اقدام در محیط واقعی است تا مشخص شود این قابلیت‌ها در چه شرایطی به تصمیم بهتر و منفعت قابل اندازه‌گیری منجر می‌شوند.

واژه‌ها و اختصارهای پرکاربرد

ANOVA: تحلیل واریانس، آزمون یکسان بودن میانگین یک کمیت در چند گروه

Antecedent: مقدم، طرف شرطی یک قانون انجمنی

Apriori: الگوریتم استخراج مجموعه‌های پرتکرار و قوانین انجمنی از سبدهای خرید

Area Under the ROC Curve: سطح زیر منحنی مشخصه عملکرد، معیار توان تفکیک یک دسته‌بند

Association Rules: قوانین انجمنی، قاعده‌های «اگر این، آنگاه آن» میان اقلام یک سبد

Asynchronous Requests: درخواست ناهمگام، گرفتن داده از سرور بدون بارگذاری دوباره صفحه

Authentication: احراز هویت، سازوکار شناسایی و ورود کاربر به سامانه

Background Queue: صف پس‌زمینه، اجرای کارهای سنگین بیرون از چرخه پاسخ به کاربر

Backpropagation: پس‌انتشار خطا، روش به‌روزرسانی وزن‌های شبکه عصبی

Balanced Accuracy: صحت متوازن، میانگین نرخ تشخیص درست دو طبقه در داده نامتوازن

Benjamini-Hochberg: روش تصحیح آزمون چندگانه با کنترل نرخ کشف کاذب

BI: هوش تجاری و گزارش‌گیری مدیریتی

Bias: اریبی، انحراف نظام‌مند پیش‌بینی از مقدار واقعی

Bridge Table: جدول واسط، جدولی که رابطه چندبه‌چند میان دو جدول را نگه می‌دارد

Brier Score: امتیاز بریر، میانگین مربع خطای احتمال پیش‌بینی‌شده

Bubble Chart: نمودار حبابی، نمایش هم‌زمان سه کمیت با دو مختصات و اندازه نقطه

Bulk Insert: ثبت گروهی، ذخیره چند رکورد در یک عملیات

Byte Order Mark: نشانه ترتیب بایت، کاراکتر ابتدای فایل متنی که می‌تواند خواندن ستون نخست را مختل کند

Cache: حافظه نهان، نگه‌داری موقت نتیجه محاسبه برای پرهیز از تکرار آن

Calibration: کالیبراسیون، میزان انطباق احتمال گزارش‌شده با نرخ واقعی رخداد

Campaign: کمپین، برنامه تبلیغاتی یا ترویجی ارائه‌شده به گروهی از مشتریان

Candidate Generation: تولید نامزد، مرحله ساخت ترکیب‌های بالقوه پیش از شمارش آن‌ها

Causality: علیت، رابطه علت و معلولی، در برابر همبستگی صرف

Chi-Square Test: آزمون خی‌دو، آزمون استقلال دو متغیر رسته‌ای

Chronological Holdout: کنارگذاری زمانی، جداسازی داده آموزش و آزمون بر پایه ترتیب زمان

Churn: ریزش، قطع رابطه خرید مشتری با فروشگاه

Classification: دسته‌بندی، پیش‌بینی برچسب گسسته برای هر نمونه

Cliff's Delta: دلتای کلیف، اندازه اثر ناپارامتری برای مقایسه دو گروه

Coefficient of Determination: ضریب تعیین، سهم پراکندگی توضیح‌داده‌شده توسط مدل

Cohen's d: دی کوهن، اندازه اثر مبتنی بر فاصله میانگین‌ها نسبت به انحراف معیار

Cold Start: شروع سرد، نبود سابقه کافی برای پیش‌بینی یک قلم یا مشتری تازه

Collaborative Filtering: پالایش مشارکتی، پیشنهاد بر پایه شباهت رفتار خرید مشتریان

Commodity: کالا، سطح میانی سلسله‌مراتب محصول که اقلام هم‌ماهیت را جمع می‌کند

Composite Key: کلید ترکیبی، کلیدی که از بیش از یک ستون ساخته می‌شود

Confidence: اطمینان، احتمال حضور تالی به شرط حضور مقدم در سبد

Confounding Variable: متغیر مخدوش‌کننده، متغیر سومی که رابطه دو متغیر دیگر را گمراه‌کننده می‌کند

Consequent: تالی، طرف نتیجه یک قانون انجمنی

Content-based Features: ویژگی‌های محتوایی، ویژگی‌های خود کالا مانند گروه، برند و اندازه

Conviction: اقناع، معیاری برای سنجش قدرت یک قانون انجمنی

Correlation: همبستگی، هم‌تغییری دو کمیت، بدون دلالت بر علیت

Coupon: کوپن، ابزار تخفیف قابل استفاده در خرید

Cramér's V: وی کرامر، اندازه اثر وابستگی میان دو متغیر رسته‌ای

Cross-filtering: پالایش هم‌بسته، اعمال یک انتخاب روی همه پنل‌های داشبورد

Cross-selling: فروش مکمل، پیشنهاد کالای مرتبط به خریدار یک کالا

Cross-Site Request Forgery: جعل درخواست میان‌سایتی، حمله‌ای که با نشانه امنیتی فرم مهار می‌شود

Customer Retention: ماندگاری مشتری، حفظ رابطه خرید مشتری در طول زمان

Customer Segmentation: بخش‌بندی مشتریان، تقسیم مشتریان به گروه‌های هم‌رفتار

Dashboard: داشبورد، صفحه‌ای که چند شاخص و نمودار را یکجا نشان می‌دهد

Data Cleaning: پالایش داده، حذف یا اصلاح رکوردهای نامعتبر پیش از تحلیل

Data Grain: دانه داده، سطحی که هر سطر جدول آن را نمایندگی می‌کند

Data Leakage: نشت داده، ورود ناخواسته اطلاعات آینده به مرحله آموزش مدل

Data Mining: داده‌کاوی، کشف الگوهای پنهان در حجم بزرگ داده

Dataset: مجموعه‌داده، داده ساختاریافته‌ای که تحلیل روی آن انجام می‌شود

Decile: دهک، تقسیم یک جامعه مرتب‌شده به ده بخش مساوی

Decoding: رمزگشایی، بخش تولید خروجی در شبکه رمزگذار و رمزگش

Department: گروه کالایی، بالاترین سطح سلسله‌مراتب محصول

Dimension Table: جدول بُعد، جدول توصیفی مانند محصول، تاریخ یا خانوار در طرح ستاره‌ای

Discount Depth: عمق تخفیف، نسبت تخفیف به قیمت پیش از تخفیف

Drill-down: ریزنمایی، حرکت از یک سطح تجمیع به سطح جزئی‌تر آن

Effect Size: اندازه اثر، معیار بزرگی تفاوت، مستقل از حجم نمونه

Encoding: رمزگذاری، فشرده کردن دنباله ورودی به یک بردار حالت

Endpoint: نقطه پایانی، نشانی مشخصی از سرور که داده را برمی‌گرداند

Epsilon Squared: اپسیلون مربع، اندازه اثر متناظر با آزمون کروسکال والیس

Eta Squared: اتا مربع، سهم پراکندگی توضیح‌داده‌شده در تحلیل واریانس

Everyday Low Price: قیمت پایین روزمره، راهبرد قیمت‌گذاری بدون اتکا به حراج‌های مقطعی

Extrapolation: برون‌یابی، پیش‌بینی بیرون از بازه داده مشاهده‌شده

Fact Table: جدول واقعیت، جدول اصلی رویدادهای فروش در طرح ستاره‌ای

False Discovery Rate: نرخ کشف کاذب، نسبت نتایجی که به اشتباه معنادار اعلام شده‌اند

Footer: پابرگ، نوار پایین صفحه

Foreign Key: کلید خارجی، ستونی که به کلید اصلی جدول دیگری اشاره می‌کند

Framework: چارچوب نرم‌افزاری، بستر آماده توسعه برنامه

Frequent Itemsets: مجموعه‌های پرتکرار، ترکیب‌هایی از اقلام که از آستانه پشتیبان می‌گذرند

Geometric Mean: میانگین هندسی، میانگین مناسب برای کمیت‌های نسبتی

Gradient Boosting: تقویت گرادیانی، ساخت دنباله‌ای از درخت‌ها که خطای یکدیگر را جبران می‌کنند

Heatmap: نقشه حرارتی، نمایش شدت یک کمیت با پررنگی خانه‌های یک شبکه

Household: خانوار، واحد مشتری در مجموعه‌داده دان‌هامبی

Household–Product Matrix: ماتریس خانوار در محصول، ماتریس خرید هر خانوار از هر محصول

Index: نمایه، ساختار کمکی پایگاه داده برای تسریع جست‌وجو و مرتب‌سازی

Jaccard Similarity: شباهت جاکارد، معیار شباهت دو مجموعه بر پایه اشتراک و اجتماع آن‌ها

Kolmogorov-Smirnov Test: آزمون کولموگروف اسمیرنوف، آزمون یکسان بودن شکل دو توزیع

KPI: شاخص کلیدی عملکرد

Kruskal-Wallis Test: آزمون کروسکال والیس، نسخه ناپارامتری تحلیل واریانس

Label Window: پنجره برچسب، بازه زمانی که برچسب هدف در آن تعیین می‌شود

Left Join: الحالق چپ، الحالقی که سطرهای بدون تطابق را حذف نمی‌کند

Leverage: اهرم، معیاری برای سنجش انحراف یک قانون از حالت استقلال

Lift: بهبود، نسبت اطمینان قانون به نسبت حضور مستقل تالی

Lookback Window: پنجره نگاه به گذشته، تعداد دوره‌های تاریخی ورودی مدل

Loss Function: تابع زیان، معیاری که مدل در آموزش آن را کمینه می‌کند

Machine Learning: یادگیری ماشین، ساخت مدل از روی داده به جای قاعده دستی

Mann-Whitney U Test: آزمون من ویتنی، آزمون ناپارامتری تفاوت دو گروه مستقل

Many-to-Many Relationship: رابطه چندبه‌چند، رابطه‌ای که هر سطر هر طرف می‌تواند به چند سطر طرف دیگر وصل شود

Market Basket: سبد خرید، مجموعه اقلام یک نوبت خرید

Mean Absolute Error: میانگین قدر مطلق خطا، معیار خطای پیش‌بینی عددی

Median: میانه، مقدار میانی داده مرتب‌شده، مقاوم در برابر مقادیر پرت

Multiple Testing: آزمون چندگانه، مسئله افزایش خطای کاذب هنگام اجرای آزمون‌های پرشمار

National Brand: برند ملی، کالای تولیدشده توسط سازنده بیرونی

Navigation Bar: نوار راهبری، نوار پیمایش میان بخش‌های سامانه

Object-Relational Mapping: نگاشت شیء به رابطه، لایه‌ای که جدول‌های پایگاه داده را به کلاس تبدیل می‌کند

Observation Window: پنجره مشاهده، بازه‌ای که ویژگی‌های ورودی از آن ساخته می‌شود

Origin Day: روز مبدأ، روزی که پیش‌بینی از آن به بعد انجام می‌شود

Overfitting: بیش‌برازش، حفظ کردن داده آموزش به جای یادگیری الگوی کلی

p-value: مقدار احتمال، احتمال مشاهده چنین تفاوتی در صورت نبود تفاوت واقعی

Pagination: صفحه‌بندی، تقسیم فهرست بلند به صفحه‌های کوچک‌تر

Panel Data: داده پنلی، داده‌ای که مجموعه ثابتی از افراد را در طول زمان دنبال می‌کند

Pareto Chart: نمودار پارتو، نمایش سهم تجمعی از پرفروش به کم‌فروش

Precision: صحت، نسبت پیش‌بینی‌های مثبت درست به کل پیش‌بینی‌های مثبت

Prediction Horizon: افق پیش‌بینی، فاصله زمانی میان مبدأ و لحظه‌ای که پیش‌بینی می‌شود

Primary Key: کلید اصلی، ستون یا ترکیبی که هر سطر جدول را یکتا می‌کند

Private Label: برند خصوصی، کالای عرضه‌شده با نام خود فروشگاه

Product Bundling: بسته‌سازی، عرضه چند کالا به صورت بسته با قیمت تشویقی

Product Hierarchy: سلسله‌مراتب محصول، زنجیره گروه کالایی، کالا، زیرکالا و محصول

Product Recommender: پیشنهاددهنده محصول، سامانه پیشنهاد کالا بر پایه رفتار مشتری

Progress Bar: نوار پیشرفت، نشانگر وضعیت اجرای یک عملیات

Pruning: هرس، کنار گذاشتن ترکیب‌هایی که نمی‌توانند از آستانه بگذرند

Purging: فاصله‌گذاری، حذف نمونه‌های نزدیک به مرز آموزش و آزمون برای پرهیز از نشت

Query: پرس‌وجو، دستور بازیابی داده از پایگاه داده

Random Forest: جنگل تصادفی، ترکیب رأی شمار زیادی درخت تصمیم

Rank Correlation: همبستگی رتبه‌ای، سنجش هم‌ترتیبی دو فهرست

Ranking Model: مدل رتبه‌بندی، مدلی که به جای پیش‌بینی مقدار، ترتیب گزینه‌ها را تعیین می‌کند

Recall: بازخوانی، نسبت موارد مثبت واقعی که مدل آن‌ها را پیدا کرده است

Recommender Systems: سامانه‌های پیشنهاددهنده، سامانه‌هایی که کالای مناسب هر مشتری را پیشنهاد می‌کنند

Recurrent Neural Network: شبکه عصبی بازگشتی، شبکه‌ای که دنباله زمانی را گام‌به‌گام پردازش می‌کند

Referential Integrity: یکپارچگی ارجاعی، تضمین اینکه هر ارجاع به یک سطر موجود اشاره کند

Regression: رگرسیون، پیش‌بینی مقدار پیوسته

RFM: تازگی خرید، دفعات خرید و ارزش پولی خرید مشتری

Root Mean Squared Error: ریشه میانگین مربع خطا، معیار خطایی که به خطاهای بزرگ حساس‌تر است

Sampling: نمونه‌گیری، انتخاب زیرمجموعه‌ای از داده برای کاهش هزینه محاسبه

Selection Bias: سوگیری انتخاب، خطای ناشی از غیرتصادفی بودن نمونه در دسترس

Self Join: خودالحاقی، الحاق یک جدول به خودش برای ساخت زوج‌های هم‌سبد

Session: نشست، وضعیت ماندگار کاربر میان درخواست‌های پیاپی

Skewed Distribution: توزیع کج، توزیعی که میانگین و میانه آن به روشنی از هم فاصله دارند

Slicer: برش‌دهنده، کنترل انتخاب مقدار یک بُعد برای پالایش داشبورد

Sliding Window: پنجره لغزان، ساخت نمونه‌های پیاپی با جابه‌جایی یک بازه ثابت

Standardization: استانداردسازی، هم‌مقیاس کردن ویژگی‌های عددی

Star Schema: طرح ستاره‌ای، ساختار یک جدول واقعیت در میان چند جدول بُعد

Sub-commodity: زیرکالا، سطح جزئی‌تر از کالا در سلسله‌مراتب محصول

Supervised Rollout Depth: عمق نظارت‌شده، بیشترین گامی که مدل با هدف واقعی آموزش دیده است

Support: پشتیبان، نسبت سبدهایی که یک ترکیب در آن‌ها دیده می‌شود

Support Vector Machine: ماشین بردار پشتیبان، دسته‌بندی با یافتن مرز با بیشترین حاشیه

Technology Stack: پشته فناوری، مجموعه ابزارها و کتابخانه‌های به‌کاررفته در پروژه

Threshold: آستانه، حد تصمیم برای پذیرش یا رد یک مورد

Time Series: سری زمانی، دنباله مقادیر یک کمیت در گام‌های زمانی پیاپی

Timeout: مهلت زمانی، حد زمانی که پس از آن عملیات قطع می‌شود

Transaction: تراکنش، رکورد خرید یک قلم در یک نوبت

View: نما، پرس‌وجوی ذخیره‌شده در پایگاه داده که مانند جدول خوانده می‌شود

Welch's t-Test: آزمون تی ولش، مقایسه میانگین دو گروه بدون فرض برابری واریانس‌ها

منابع

{۱} دان‌هامبی، «Dunnhumby – The Complete Journey»، مجموعه‌داده وب‌گاه کاگل، تاریخ دسترسی: شهریور ۱۴۰۵، در دسترس در: https://www.kaggle.com/datasets/frtgnn/dunnhumby-the-complete-journey

{۲} نوبل، ج.، «What is the Apriori algorithm?»، بخش آموزشی IBM Think، شرکت آی‌بی‌ام، ۲۰۲۴، تاریخ دسترسی: شهریور ۱۴۰۵، در دسترس در: https://www.ibm.com/think/topics/apriori-algorithm

{۳} گروه توسعه scikit-learn، «Metrics and scoring: quantifying the quality of predictions»، راهنمای کاربری کتابخانه scikit-learn، تاریخ دسترسی: شهریور ۱۴۰۵، در دسترس در: https://scikit-learn.org/stable/modules/model_evaluation.html

{۴} شرکت آی‌بی‌ام، «What Is Business Intelligence (BI)?»، بخش آموزشی IBM Think، ۲۰۲۴، تاریخ دسترسی: شهریور ۱۴۰۵، در دسترس در: https://www.ibm.com/think/topics/business-intelligence

{۵} ابراین، ک.، داونی، آ.، «What is customer churn?»، بخش آموزشی IBM Think، شرکت آی‌بی‌ام، ۲۰۲۴، تاریخ دسترسی: شهریور ۱۴۰۵، در دسترس در: https://www.ibm.com/think/topics/customer-churn

{۶} شرکت اوراکل، «Recency, Frequency and Monetary models»، راهنمای کاربری Oracle Unity، تاریخ دسترسی: شهریور ۱۴۰۵، در دسترس در: https://docs.oracle.com/en/cloud/saas/cx-unity/cx-unity-user/Help/Data_Science/Engagement_analysis/DataScience_Model_RFM.htm

{۷} گروه توسعه XGBoost، «Introduction to Boosted Trees»، مستندات کتابخانه XGBoost، تاریخ دسترسی: شهریور ۱۴۰۵، در دسترس در: https://xgboost.readthedocs.io/en/stable/tutorials/model.html

{۸} شرکت گوگل، «Collaborative filtering»، دوره آموزشی Recommendation Systems، تاریخ دسترسی: شهریور ۱۴۰۵، در دسترس در: https://developers.google.com/machine-learning/recommendation/collaborative/basics